دانشگاه صنعتی شریف
دانشکده مهندسی کامپیوتر

پروژه کارشناسی
مهندسی کامپیوتر

مدل زبانی بزرگ گفتاربه‌گفتار برای زبان فارسی

نسخه خلاصه گزارش پروژه

نگارش

مهران بختیاری

استاد راهنما

دکتر حسین صامتی

مهر ۱۴۰۵

چکیده

هدف این پروژه، طراحی، پیاده‌سازی و ارزیابی یک نمونه اولیه سامانه گفتاربه‌گفتار فارسی تمام‌دوطرفه است؛ یعنی میکروفون کاربر در هنگام پخش پاسخ فعال می‌ماند و سامانه به وقفه کاربر واکنش نشان می‌دهد. دو مسیر بررسی شد: تطبیق مدل سرتاسری Moshika با داده فارسی، و یک سامانه آبشاری جریانی شامل بازشناسی گفتار NeMo، پاسخ‌گوی Qwen3-4B-Instruct-2507 و گفتارساز Piper. از آرشیو گفتاری فارسی یک مجموعه داده مکالمه با 6,754 جفت و 108.584 ساعت صوت با تفکیک گروهی بر پایه نشست ساخته شد.

سامانه آبشاری نهایی پایان گفتار را خودکار و پیش‌دستانه تشخیص می‌دهد، پاسخ را جریانی و بندبه‌بند می‌سازد، و وقفه را در دو مرحله مدیریت می‌کند: کم‌کردن صدا پس از یک قاب گفتار بلندتر از پژواک مورد انتظار دستیار، و تأیید واژگانی با بازشناس پس از کنارگذاشتن واژه‌های شنونده و پژواک خود دستیار. در آزمون حلقه‌ای با مرورگر واقعی، میانگین تأخیر پایان گفتار تا نخستین صدای پاسخ 372 و صدک نود آن 431 میلی‌ثانیه بود، همه نوبت‌ها زیر 500 میلی‌ثانیه، و بخش گرافیکی سامانه GiB 11.1 حافظه گرفت. تشخیص وقفه در شبیه‌سازی استقرار از ضبط‌های واقعی به دقت 0.933 و F1 0.880 با میانه 120 میلی‌ثانیه تا کم‌کردن صدا، و در مرورگر به دقت 0.825 و F1 0.817 رسید؛ طبقه‌بند صوتی انرژی/زیروبمی/MFCC به‌تنهایی روی رخدادهای واقعی 0.574 گرفت. پاسخ‌گو در آزمون معنایی نهایی 40 ردیفی از هر هفت شرط خودکار گذشت (مرتبط‌بودن 3.150 در برابر 1.425). اجزا روی پنل‌های تازه دوباره برگزیده شدند، از جمله بازشناس روی رونوشت انسانی و گفتارساز با دو شنونده خودکار.

مسیر مستقیم به مدل قابل استقرار نرسید؛ نشان داده شد که توکن‌ساز انگلیسی Moshi برای هر واژه فارسی 6.6 نشانه می‌خواهد و از بودجه یک نشانه در قاب فراتر می‌رود. لاتین‌نویسی واجی بهترین نتیجه را دو برابر کرد اما گفتار هنوز فهم‌پذیر نبود، و مدل ورودی گفتاری Gemma 4 نیز از سامانه آبشاری ضعیف‌تر بود. شواهد تأخیر و وقفه خودکار و روی H100 است (حافظه یک کارت 12 گیگابایتی رعایت شد، سرعت آن نه) و برچسب‌ها خودکارند؛ نتایج مطالعه شنیداری انسانی هنوز در دست نیست.

کلیدواژه‌ها: گفتاربه‌گفتار، تمام‌دوطرفه، تشخیص وقفه، زبان فارسی، مدل زبانی بزرگ، سامانه آبشاری جریانی، توکن‌ساز، تطبیق کم‌پارامتر

فهرست مطالب

۱ مقدمه ۲

۱-۱ تعریف مسئله ۲

۱-۲ اهمیت موضوع ۳

۱-۳ نیازمندی‌های تعریف‌شده ۳

۱-۴ راهبرد دومسیره و چالش‌ها ۴

۱-۵ دستاوردها ۴

۱-۶ ساختار این نوشتار ۵

۲ پیشینه و مفاهیم لازم ۶

۲-۱ دو خانواده معماری ۶

۲-۲ مدل زبانی، تطبیق کم‌پارامتر، و اریبی مواجهه ۶

۲-۳ بازشناسی، گفتارسازی، و ویژگی‌های وقفه ۷

۲-۴ جایگاه در کارهای پیشین ۷

۲-۵ سنجه‌ها و داوری مدل ۷

۳ روش پیشنهادی و پیاده‌سازی ۹

۳-۱ تلاش اولیه و بازنگری ۹

۳-۲ ساخت مجموعه داده ۹

۳-۳ معماری سامانه آبشاری جریانی ۱۰

۳-۴ تشخیص وقفه و بستر تمام‌دوطرفه ۱۱

۳-۵ طراحی آزمایش‌های مسیر مستقیم ۱۱

۳-۶ روش کاری شواهدمحور ۱۳

۴ آزمایش‌ها و نتایج ۱۴

۴-۱ پوشش شروط پذیرش و وضعیت شواهد ۱۴
۴-۲ مجموعه داده ۱۵
۴-۳ سامانه آبشاری: پنل مکانیکی و فهم‌پذیری ۱۵
۴-۴ آزمون معنایی خودکار ۱۶
۴-۵ بازگزینش اجزا ۱۷
۴-۶ تشخیص وقفه ۱۹
۴-۷ مسیر مستقیم ۱۹
۴-۸ تأخیر، حافظه و آزمون حلقه‌ای مرورگر ۲۰
۴-۹ وضعیت نهایی نیازمندی‌ها ۲۱

۵ بحث، نتیجه‌گیری و کارهای آینده **۲۲**
۵-۱ فاصله زیان و تولید ۲۲
۵-۲ علت شکست مسیر مستقیم ۲۲
۵-۳ محدودیت‌ها و ملاحظات ۲۳
۵-۴ پاسخ به پرسش‌های پژوهش ۲۳
۵-۵ کارهای آینده ۲۳

مراجع **۲۴**

فصل ۱

مقدمه

این نوشتار **نسخه خلاصه** گزارش پروژه کارشناسی است. گزارش کامل، با هفت فصل، واژه‌نامه و پیوست بازتولید، در پرونده جداگانه‌ای آمده است. اعداد، نیازمندی‌ها و مرز ادعاها در هر دو نسخه یکی است؛ آنچه کوتاه شده، شرح و تکرار است نه نتیجه.

گفت‌وگوی گفتاری طبیعی‌ترین شکل تعامل انسان با ماشین است، اما تا همین اواخر تقریباً همیشه از زنجیره‌ای از مؤلفه‌های مستقل ساخته می‌شد. مدل‌هایی مانند Moshi [۱] و Freeze-Omni [۲] نشان دادند که می‌توان گفت‌وگو را به‌صورت یک مسئله «گفتاربه‌گفتار» و در قالب مدلی که هم‌زمان می‌شنود و سخن می‌گوید مدل کرد. این تحول برای زبان‌های پرمنبع رخ داده است. برای فارسی، هیچ‌یک از مدل‌های متن‌باز موجود پشتیبانی رسمی ارائه نمی‌کنند و پیکره مکالمه‌ای با برچسب وقفه نیز به‌صورت عمومی در دسترس نیست.

پرسش عملی پروژه این است: با بودجه یک پروژه کارشناسی، تا چه اندازه می‌توان یک سامانه گفتاربه‌گفتار فارسی تمام‌دوطرفه ساخت، و چه چیزی را می‌توان با شواهد قابل ممیزی «اثبات» کرد؟

۱-۱ تعریف مسئله

هدف تعریف‌شده، طراحی، پیاده‌سازی و ارزیابی یک نمونه اولیه مدل زبانی بزرگ گفتاربه‌گفتار برای زبان فارسی است. سامانه باید تمام‌دوطرفه باشد: میکروفون کاربر در طول پخش پاسخ فعال بماند و سامانه بتواند به «وقفه» کاربر واکنش نشان دهد. سه ویژگی این مسئله را از پرسش‌وپاسخ گفتاری متعارف جدا می‌کند: هم‌زمانی شنیدن و گفتن؛ تصمیم توقف پخش در مقیاس چنده میلی‌ثانیه؛ و تداوم گفتاری که در لحظه وقفه ادا می‌شود، تا کاربر ناچار به تکرار جمله نشود.

۱-۲ اهمیت موضوع

رابط گفتاری برای کاربرانی که با صفحه‌کلید فارسی راحت نیستند، برای کم‌بینایان و به‌طور خاص برای سالمندان می‌تواند تنها راه مؤثر استفاده از خدمات دیجیتال باشد. برای فارسی، منابع بازشناسی و تبدیل متن به گفتار وجود دارد؛ نمونه شاخص ManaTTS [۳] با بیش از 86 ساعت گفتار تک‌گوینده است. اما این منابع خوانشی‌اند و هم‌پوشانی، وقفه و بازخورد کلامی را پوشش نمی‌دهند. از سوی دیگر، مدل‌های روز مانند Qwen2.5-Omni [۴] برای نسخه هفت‌میلیاردپارامتری خود به حافظه‌ای به‌مراتب بیش از بازه 12 تا 24 گیگابایت نیاز دارند. نشان‌دادن آنچه در این بازه قابل دستیابی است و آنچه نیست، خودش یک نتیجه مهندسی است.

۱-۳ نیازمندی‌های تعریف‌شده

تعریف پروژه هفت نیازمندی مشخص را تعیین کرده است (جدول ۱-۱). خروجی مورد انتظار نیز چهار قلم است: نمونه اولیه کارا، کد منبع مستند، مجموعه داده مکالمه فارسی، و یافته‌های مربوط به تعامل سالمندان. برای قلم چهارم، پروتکل و زیرساخت سنجش آماده شده است؛ یافته تجربی آن تنها پس از تکمیل مطالعه انسانی قابل ادعا خواهد بود و ازاین‌رو در این نوشتار ادعایی درباره تجربه سالمندان مطرح نمی‌شود.

جدول ۱-۱: نیازمندی‌های هفت‌گانه تعریف پروژه

شماره	نیازمندی	سنجه تعیین‌شده
ن۱	نمونه اولیه گفتاربه‌گفتار فارسی	تولید پاسخ گفتاری فارسی از ورودی گفتاری فارسی
ن۲	کارکرد تمام‌دوطرفه	شنیدن در هنگام پخش و واکنش به وقفه
ن۳	تأخیر سرتاسری	حداکثر 500 میلی‌ثانیه از دریافت گفتار تا تولید پاسخ گفتاری
ن۴	مجموعه داده مکالمه فارسی	100 تا 200 ساعت گفتار همراه با نویز، هم‌پوشانی و قطع‌ووصل کلام
ن۵	ماژول تشخیص وقفه	دقت بالای 80 درصد با ویژگی‌های انرژی، زیروبمی و MFCC
ن۶	ارزیابی روی سخت‌افزار هدف	پردازنده گرافیکی با 12 تا 24 گیگابایت حافظه
ن۷	ارزیابی انسانی	5 تا 10 گویشور فارسی، دست‌کم دو نفر بالای 60 سال

۱–۴ راهبرد دومسیره و چالش‌ها

چهار چالش شکل نهایی کار را تعیین کرد: نبود مسیر آموزشی رسمی برای فارسی در مدل‌هایی مانند Mini-Omni2 [۵] و LLaMA-Omni2 [۶]؛ نبود پیکره مکالمه‌ای برچسب‌دار فارسی؛ فاصله میان کاهش زیان آفلاین و تولید خودرگرسیو معتبر؛ و مرز میان شواهد مهندسی و ادعای علمی.

برای کاهش ریسک، دو مسیر به‌طور موازی پیش رفت. مسیر مستقیم، تطبیق کم‌پارامتر Moshika با آموزش‌دهنده رسمی خانواده Moshi [۷] است. مسیر آبشاری، زنجیره بازشناسی گفتار فارسی، مدل زبانی متنی و تبدیل متن به گفتار است که کنترل تمام‌دوطرفه و منطق وقفه به‌صورت جداگانه روی آن سوار می‌شود. هر دو مسیر از یک مجموعه داده مشترک استفاده کردند. نتیجه نامتقارن بود: مسیر آبشاری به سامانه جریانی تمام‌دوطرفه‌ای رسید که معیارهای عددی تأخیر و وقفه را در آزمون‌های خودکار برآورده می‌کند، و مسیر مستقیم با علت سنجیده‌شده‌اش به‌عنوان نتیجه منفی گزارش شد.

۱–۵ دستاوردها

۱. **دستیار گفتاری فارسی تمام‌دوطرفه جریانی.** میکروفون باز، تشخیص پیش‌دستانه پایان گفتار و پخش بندبه‌بند؛ در آزمون حلقه‌ای مرورگر میانگین تأخیر 372 و صدک نود 431 میلی‌ثانیه با 11.1 GiB حافظه گرافیکی.

۲. **تشخیص وقفه دومرحله‌ای.** کم‌کردن صدا پس از یک قاب و تأیید واژگانی با حذف پژواک؛ دقت 0.880 F1/0.933 در شبیه‌سازی و 0.825 در مرورگر، در برابر 0.574 برای طبقه‌بند صوتی تنها.

۳. **مجموعه داده ممیزی‌شده.** 6,754 جفت با 108.584 ساعت صوت، تفکیک بر پایه نشست و نشت گروهی صفر.

۴. **گزینش اجزا با شواهد.** آزمون معنایی نهایی (3.150 در برابر 1.425) و بازگزینش بازشناس، پاسخ‌گو و گفتارساز روی پنل‌های تازه.

۵. **علت سنجیده‌شده شکست مسیر مستقیم.** هفت نسل Moshika و یک مدل ورودی گفتاری؛ گلوگاه توکن‌ساز واقعی است اما تنها مانع نیست.

۶. **روش کاری شواهدمحور.** پروتکل‌ها پیش از اجرا ثبت شدند، بخش‌های آزمون یک‌بار گشوده شدند و مصنوعات یک‌بارنوشت‌اند.

شواهد تأخیر و وقفه خودکار و روی H100 است و نتایج مطالعه شنیداری هنوز در دست نیست.

۱-۶ ساختار این نوشتار

فصل ۲ مفاهیم لازم و جایگاه کار را فشرده می‌کند. فصل ۳ روش ساخت داده، معماری آبشاری، آشکارساز وقفه، آزمایش‌های مسیر مستقیم و کلاس‌های شواهد را شرح می‌دهد. فصل ۴ نتایج اندازه‌گیری‌شده را با مرز ادعای هر یک گزارش می‌کند. فصل ۵ تفسیر، محدودیت‌ها و کارهای آینده را جمع می‌بندد.

فصل ۲

پیشینه و مفاهیم لازم

این فصل تنها مفاهیمی را می‌آورد که برای خواندن روش و نتایج ضروری است، و جایگاه پروژه را در برابر کارهای پیشین مشخص می‌کند.

۲-۱ دو خانواده معماری

سامانه‌های گفت‌وگوی گفتاری در دو خانواده قرار می‌گیرند. در خانواده **آبشاری**، بازشناسی گفتار، موتور گفت‌وگوی متنی و تبدیل متن به گفتار جداگانه اجرا می‌شوند. این معماری قابل ممیزی و قابل جایگزینی است، اما تأخیر مؤلفه‌ها جمع می‌شود و خطای هر مرحله به مرحله بعد منتقل می‌گردد. در خانواده **سرتاسری**، مدل مستقیماً از گفتار به گفتار می‌رود. مدل‌های تمام‌دوطرفه ذاتی، مانند Moshi، دو جریان صوتی را به‌صورت موازی مدل می‌کنند و برای نوبت‌گیری به بخش‌بندی صریح گفتار نیاز ندارند.

تعریف این پروژه روح سرتاسری دارد، اما بودجه کارشناسی و نبود آموزش‌دهنده رسمی فارسی، مسیر آبشاری را به‌عنوان سامانه تحویل‌شده اجتناب‌ناپذیر کرد.

۲-۲ مدل زبانی، تطبیق کم‌پارامتر، و اریبی مواجهه

پاسخ‌گوی متنی این پروژه یک مدل دستورپیرو است. تنظیم دقیق کامل یک مدل چندمیلیاردپارامتری روی سخت‌افزار محدود عملی نبود؛ بنابراین مسیر مستقیم از LoRA [۸] استفاده کرد: به‌روزرسانی وزن به‌صورت حاصل دو ماتریس رتبه پایین روی وزن منجمد اضافه می‌شود.

نکته تعیین‌کننده برای تفسیر نتایج مسیر مستقیم، تفاوت آموزش و استنتاج است. در آموزش، مدل در هر گام نشانه مرجع پیشین را می‌بیند؛ این شیوه **تحمیل معلم** است و زیان گزارش‌شده تحت همین شرط محاسبه می‌شود. در استنتاج، مدل باید بر نشانه‌های تولیدی خودش شرط بگذارد. اگر این دو توزیع فاصله بگیرند، خطا تجمعی می‌شود. این ناسازگاری **اریبی مواجهه** نام دارد [۹] و راهکار متعارف آن نمونه‌گیری

زمان‌بندی‌شده است [۱۰]. پیامد عملی صریح است: کاهش زیان تحت تحمیل معلم، تولید خودرگرسیو معتبر را تضمین نمی‌کند.

۲-۳ بازشناسی، گفتارسازی، و ویژگی‌های وقفه

بازشناسی گفتار سامانه، یک مدل ترکیبی RNNT-CTC از خانواده Conformer است که به‌صورت محلی با پشته NeMo [۱۱] اجرا می‌شود. تبدیل متن به گفتار با موتور Piper [۱۲] و مدل صوتی فارسی انجام می‌گیرد.

آشکارساز وقفه ویژگی‌های کلاسیک را به‌صورت غلتان محاسبه می‌کند: انرژی، نرخ گذر از صفر، ضرایب MFCC [۱۳] و بسامد پایه با روش YIN [۱۴]. طبقه‌بند، تقویت گرادیانی است [۱۵]. فاصله‌های اطمینان دقت با روش ویلسون [۱۶] و در سطح نشست به‌صورت بلوکی گزارش می‌شوند. در گفت‌وگوی انسانی، شکاف‌های نوبت‌گیری اغلب در حدود 200 میلی‌ثانیه است [۱۷]؛ بنابراین تصمیم وقفه باید بسیار سریع‌تر از تولید کامل پاسخ گرفته شود.

۲-۴ جایگاه در کارهای پیشین

Mini-Omni2 و LLaMA-Omni2 مخزن استنتاج دارند اما آموزش‌دهنده کامل و رسمی گفتاربه‌گفتار ارائه نمی‌دهند. Freeze-Omni تمام‌دوطرفه است اما آموزش‌دهنده آن برای زبان جدید کامل نیست. Qwen2.5-Omni فارسی را در فهرست ورودی و خروجی گفتاری ندارد و نسخه هفت‌میلیاردپارامتری آن از بازه حافظه هدف خارج است. PersonaPlex [۱۸] بر پایه Moshi نقش و صدا را شرطی می‌کند، اما در زمان تصمیم این پروژه آموزش‌دهنده رسمی و در دسترس برای زبان جدید فراهم نبود. در میان مدل‌های بررسی‌شده، تنها خانواده Moshi هر سه شرط مسیر مستقیم را داشت: تمام‌دوطرفه ذاتی، وزن متن‌باز، و آموزش‌دهنده رسمی تطبیق کم‌پارامتر.

برای فارسی، منابع خوانشی تک‌گوینده جایگزین پیکره مکالمه‌ای تعاملی نیستند. جدول ۲-۱ این مقایسه را خلاصه می‌کند.

۲-۵ سنجه‌ها و داوری مدل

کیفیت مکانیکی زنجیره با عبور ردیف از شروط رونویسی فارسی، پاسخ فارسی و صوت غیرساکت سنجیده می‌شود. حفظ محتوای گفتار تولیدشده با بازبازشناسی و نرخ خطای نویسه و واژه تقریب زده می‌شود؛ این سنجه فهم‌پذیری انسانی نیست. کیفیت معنایی پاسخ با داوری مدل زبانی روی ارتباط و انسجام، به‌صورت دوسوکور و با دو تکرار، اندازه گرفته شد. چون داور و نامزد از یک خانواده‌اند، نتیجه در کلاس «تقریب

جدول ۲-۱: مقایسه این پروژه با کارهای پیشین از نظر قابلیت‌های تعریف پروژه

کار	تمام دوطرفه	وزن متن‌باز	آموزش‌دهنده رسمی	پشتیبانی فارسی	بازه حافظه
Mini-Omni2	فرمان‌محور	دارد	ندارد	ندارد	مناسب
LLaMA-Omni2	ندارد	دارد	ندارد	ندارد	مناسب
Freeze-Omni	دارد	دارد	جزئی	ندارد	مناسب
Qwen2.5-Omni	دارد	دارد	ندارد	ندارد	نامناسب
Moshi	ذاتی	دارد	دارد	ندارد	نامناسب
PersonaPlex	ذاتی	دارد	جزئی	ندارد	نامناسب
این پروژه، مسیر آبشاری	کنترل بیرونی	دارد	بی‌نیاز	دارد	مناسب
این پروژه، مسیر مستقیم	ذاتی	دارد	دارد	ناموفق	نامناسب

ستون «بازه حافظه» تناسب با 12 تا 24 گیگابایت تعریف پروژه است، نه کیفیت علمی مدل. «ناموفق» در مسیر مستقیم به معنای شکست شرط اجرای خودرگرسیو است، نه کاهش‌نیافتن زیان.

خودکار هم‌خانواده» می‌ماند و جانشین ارزیابی انسانی یا معیار ITU-T P.800 [۱۹] نیست. تفکیک آموزش، اعتبارسنجی و آزمون همیشه بر پایه شناسه نشست منبع است تا نشت گروهی رخ ندهد.

فصل ۳

روش پیشنهادی و پیاده‌سازی

این فصل ساختار سامانه تحویل‌شده، زنجیره داده، آشکارساز وقفه، طراحی آزمایش‌های مسیر مستقیم، و روش کاری شواهدمحور را شرح می‌دهد.

۳-۱ تلاش اولیه و بازنگری

نخستین پیاده‌سازی بر پایه LLaMA-Omni2 بود: کدگذار منجمد Whisper، لایه تصویرگر، مدل زبانی Qwen2.5-0.5B [۲۰] با آداپتر LoRA، و سرهای جداگانه بازشناسی و تولید. زیان کاهش یافت، اما ممیزی درونی سه اشکال بنیادی را نشان داد: مدل زبانی در تابع پیش‌رو مشارکت نداشت؛ هدف بازشناسی از درهم‌سازی‌های تصادفی در هر فرایند استفاده می‌کرد؛ و هدف تولید، بازسازی همان اظهار ورودی بود نه پاسخ گفت‌وگویی. آن مصنوع یک مدل گفتاربه‌گفتار نبود. دو تصمیم از این ممیزی آمد: سرویس‌دهی به زنجیره آبشاری با مؤلفه‌های واقعی منتقل شد، و برای مسیر مستقیم تنها مدلی پذیرفته شد که آموزش‌دهنده رسمی داشته باشد.

۳-۲ ساخت مجموعه داده

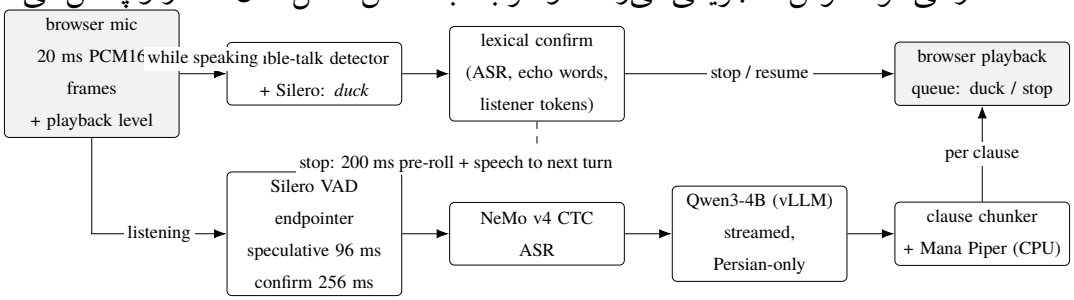
پیکره عمومی فارسی با برچسب وقفه در دسترس نبود. مجموعه داده از آرشیو داخلی محتوای گفتاری چهار کانال مشتق شد. استفاده پژوهشی داخلی با تأیید استاد راهنما ثبت شده است؛ این تأیید مجوز بازنشر صوت یا زیرنویس خام نیست و هیچ داده محدودشده‌ای در مخزن کد نیست.

در طرح نخست، برچسب متنی با اجرای مجدد سرویس بازشناسی ساخته می‌شد. همان سرویس پیش‌تر روی زیرنویس همین کانال‌ها تنظیم شده بود و یک حلقه دوری می‌ساخت. پس از شناسایی این مشکل، برچسب متنی به زیرنویس اصلی منبع تغییر یافت و بازشناسی تنها در نقش مؤلفه زمان اجرا و ابزار سنجش باقی ماند.

زنجیره چنین است: موجودی 775.887 ساعتی زیرنویس، انتخاب وزن‌دار برنامه، بازسازی پنجره‌های پانزده‌دقیقه‌ای، تفکیک گوینده، برچسب شرایط نویز، استخراج جفت «گفتار کاربر / پاسخ» بدون بازاستفاده، و ساخت استریوی ممیزی‌شده با کانال صفر برای دستیار بازسازی‌شده و کانال یک برای کاربر. تفکیک آموزش / اعتبارسنجی / آزمون بر شناسه نشست منبع است. برچسب‌های تعاملی نامزد خودکارند و شمار ردیف تأییدشده انسانی صفر است.

۳-۳ معماری سامانه آبشاری جریانی

سامانه تحویل‌شده یک زنجیره آبشاری جریانی با کنترل تمام‌دوطرفه است (شکل ۳-۱). نسخه نخست با دکمه «فشار برای صحبت» کار می‌کرد و کل پاسخ را پیش از پخش می‌ساخت (حدود 2.2 ثانیه تا نخستین صدا). در نسخه نهایی مراحل هم‌پوشانی دارند: پایان گفتار خودکار تشخیص داده می‌شود، تولید پیش‌دستانه آغاز می‌شود، توکن‌ها جریانی می‌رسند و هر بند به‌محض کامل‌شدن گفتار و پخش می‌شود.



شکل ۳-۱: معماری جریانی سامانه. ردیف پایین تولید پاسخ در حالت شنیدن و ردیف بالا کنترل وقفه در حالت سخن‌گفتن دستیار است.

کارخواه مرورگر میکروفون را پیوسته می‌گیرد و هر 20 میلی‌ثانیه یک قاب (شماره ترتیب، تراز صدای در حال پخش دستیار و 320 نمونه PCM16) می‌فرستد؛ بندهای پاسخ را روی صف پخش زمان‌بندی می‌کند و زمان‌ها را با ساعت خود گزارش می‌دهد. آشکارساز Silero پس از 96 میلی‌ثانیه سکوت نوبت پیش‌دستانه را آغاز می‌کند و صوت آن را تا قطعی‌شدن پایان گفتار در 256 میلی‌ثانیه نگه می‌دارد؛ اگر کاربر ادامه دهد، این نوبت لغو و گفتار به همان نوبت افزوده می‌شود. بازشناسی با NeMo نسخه 4 (CTC) انجام می‌شود که مقایسه نامزدها آن را دقیق‌ترین نامزد درون بودجه تأخیر یافت. پاسخ با Qwen3-4B-Instruct-2507 [۲۱] و پرامپت قفل‌شده v2، به صورت جریانی روی vLLM با دو نوبت تاریخچه تولید می‌شود و قید «فقط خط فارسی» هنگام رمزگشایی با خروجی ساخت‌یافته اعمال می‌شود. متن در مرز بندها (نخستین تکه 2 تا 4 واژه، سپس حداکثر 14 واژه) بریده و هر تکه با Piper و صدای Mana روی پردازنده به گفتار تبدیل می‌شود.

پنل مکانیکی نه‌ردیفی و سنجه بازبازشناسی پیشین روی زنجیره پیش از ارتقا (Qwen2.5-0.5B-Instruct) اجرا شده‌اند؛ آزمون معنایی 40 ردیفی روی Qwen3-4B و با داور Qwen3.8-27B-FP8 است.

۳-۴ تشخیص وقفه و بستر تمام‌دوطرفه

هنگام سخن‌گفتن دستیار، کنترل‌گری دومرحله‌ای قاب‌ها را بررسی می‌کند. مرحله نخست: قاب باید گفتار باشد و از پژواک مورد انتظار صدای دستیار (تراز پخش گزارش‌شده کارخواه به‌اضافه ضریب جفت‌شدگی برآوردشده) با حاشیه‌ای بلندتر باشد (ضریب در آغاز هر پاسخ محافظه‌کارانه فرض و سپس تطبیق داده می‌شود)؛ یک قاب، صدای دستیار را کم می‌کند — واکنش «تشخیص و تطبیق» با هدف 150 میلی‌ثانیه. مرحله دوم: گفتار ضبط‌شده از آغاز وقفه با همان بازشناس رونویسی می‌شود؛ واژه‌های شنونده («آره»، «بله»، «اوهوم»...)، واژه‌های پاسخی که در حال پخش است (پژواک باقی‌مانده) و واژه‌های دستوری کنار گذاشته می‌شوند. اگر واژه‌ای بماند، پخش قطع، تولید لغو و گفتار کاربر همراه با 200 میلی‌ثانیه پیش‌بافر نوبت بعدی می‌شود؛ وگرنه صدا برمی‌گردد و پاسخ ادامه می‌یابد. اجراهای توسعه شبیه‌سازی نشان دادند که تأیید بر پایه مدت گفتار یا طبقه‌بند صوتی، بازخورد کلامی بلند، نویز بلند و پژواک را از وقفه جدا نمی‌کند.

ارزیابی در سه سطح است: آزمون طبقه‌بند روی رخدادهای پادکست با برچسب خودکار مستقل دومرحله‌ای Gemini، شبیه‌سازی موقعیت استقرار از ضبط‌های واقعی، و آزمون حلقه‌ای با مرورگر واقعی. بازخوردهای کلامی آزمون با مدل بازشناسی دیگری (SeamlessM4T v2) برگزیده شده‌اند تا تأیید واژگانی دوری نباشد.

۳-۵ طراحی آزمایش‌های مسیر مستقیم

مسیر مستقیم، تطبیق کم‌پارامتر Moshika با آموزش‌دهنده رسمی است. ورودی، همان استریوی بخش ۳-۲ است. زیان، ترکیب وزن‌دار زیان متنی و زیان نشانه‌های صوتی است.

شرط پذیرش زمان اجرا پیش از آموزش قفل شد: آداپتر در سرور جویباری رسمی بار می‌شود و برای هر یک از ۹ ردیف ازپیش‌تعیین‌شده باید متن، گفتار غیرساکت و قید خط فارسی برقرار باشد. چک‌پوینت تنها با 9/9 واجد شرایط است. این شرط عمداً سخت‌گیرانه است، چون کمترین زیان اعتبارسنجی در نسخه نخست تقریباً صوت ساکت و بدون متن می‌داد.

آزمایش‌ها زنجیره فرضیه‌های قابل ابطال‌اند و در هر نسل عمدتاً یک عامل تغییر کرد (جدول ۳-۱). نسخه v6.2 آزمون ظرفیت است نه تعمیم: آموزش و ارزیابی روی همان 32 نمونه، پنجره 12 ثانیه، و حذف تصادفی زمان‌بندی‌شده ورودی متنی از 0.25 تا 0.75. اگر زیان حتی روی داده آموزشی کاهش نیابد مشکل ظرفیت است؛ اگر کاهش یابد اما اجرا شکست بخورد، مشکل اریبی مواجهه است.

ممیزی پایانی علت ساختاری‌ای را نشان داد که شش نسل نخست نیازموده بودند: توکن‌ساز انگلیسی Moshi برای هر واژه فارسی 6.6 نشانه لازم دارد (55 درصد بازگشت به بایت)، در حالی که مدل در هر قاب 12.5 هرتزی حداکثر یک نشانه متنی می‌سازد؛ 98.5 درصد نوبت‌ها از این بودجه فراتر می‌رفتند. نسخه v7a متن تک‌گویی درونی را لاتین‌نویسی واج‌های گفته‌شده Piper (2.7 نشانه در واژه) و زمان‌بندی را واژه‌به‌واژه کرد و بقیه شرایط آزمون ظرفیت را ثابت نگه داشت. مسیر مستقیم دوم Gemma 4 E4B است که صوت را

جدول ۳-۱: طراحی هفت نسل آزمایشی مسیر مستقیم

نسخه	عامل تغییریافته	فرضیه آزمون‌شده	رتبه
v1	پیکربندی پایه، پنجره 20 ثانیه	مدل با داده کافی گفتار فارسی می‌آموزد	64
v2	پنجره متن 100 ثانیه	پنجره کوتاه آغاز پاسخ را در بافت نمی‌گنجاند	64
v3	انجماد درج‌گرها، رتبه بالاتر	آموزش درج‌گرها بازنمایی پایه را تخریب می‌کند	128
v4	تنها دو درج‌گر متنی	تنها فضای متنی فارسی نیاز به تطبیق دارد	128
v5	ضریب زیان کتاب رمز نخست از 100 به 10	وزن زیاد کتاب رمز معنایی یادگیری آوایی را خفه می‌کند	128
v6.2	آزمون ظرفیت درون‌نمونه، پنجره 12 ثانیه	مدل ظرفیت یادگیری دارد و مشکل اریبی مواجهه است	64
v7a	متن لاتین‌شده واجی، زمان‌بندی واژه‌ای	توکن‌ساز بودجه یک نشانه در قاب را می‌شکند	64

مستقیم می‌شنود؛ بی‌آموزش و با آداپتر LoRA خودتقطیری به سبک DiVA (3,817 نوبت، 11.2 ساعت) در برابر سامانه آبشاری سنجیده شد.

۳-۶ روش کاری شواهدمحور

پنج قاعده عملیاتی اعمال شد. یک: پروتکل، شاخص ردیف‌ها و آستانه‌ها پیش از اجرا ثبت می‌شوند. دو: ارزیابی معنایی دومرحله‌ای است؛ تنها پس از عبور کامل صلاحیت هفت‌ردیفی، آزمون نهایی یک‌بار باز می‌شود. داور Qwen3.8-27B-FP8 با دمای صفر، ترتیب دوسوکور و دو تکرار است. سه: مصنوعات نتیجه یک‌بارنوشت‌اند. چهار: هر اندازه‌گیری یک کلاس شواهد دارد (جدول ۳-۲) و تنها کلاس رسمی می‌تواند نیازمندی تعریف پروژه را اثبات کند. پنج: تجمیع‌کننده شکست‌بسته است؛ نبود مصنوع یا کلاس پایین‌تر از حد لازم، شرط را ناموفق می‌کند نه نامعلوم.

جدول ۳-۲: کلاس‌های شواهد و توان ادعای هر کلاس

کلاس شواهد	شرایط لازم	اثبات نیازمندی
رسمی سرتاسری	نشست زنده با رضایت، تأیید پخش کارخواه، میکروفون واقعی و سخت‌افزار واجد شرایط	مجاز
زنده غیررسمی	همان پروتکل، بدون سخت‌افزار یا شرایط مطالعه واجد شرایط	غیرمجاز
مؤلفه سمت سرور	زمان‌سنجی تولید یا آشکارساز، بدون اثبات رفتار شنیدنی کارخواه	غیرمجاز
تقریب مصنوعی	صوت تولیدشده یا رخداد شبیه‌سازی‌شده	تنها آزمون بازگشتی
تقریب خودکار هم‌خانواده	داوری با مدل زبانی از خانواده نامزد	غیرمجاز

پیامد این روش آن است که وضعیت شواهد هر شرط مستقل از آمادگی گزارش برای ارائه و داوری بیان شود. نتیجه نهایی، تفکیک روشن آنچه ساخته شده از آنچه با شواهد رسمی اثبات شده است.

فصل ۴

آزمایش‌ها و نتایج

برای هر نتیجه، مقدار، مخرج و مرز ادعای مجاز مشخص شده است. همه اعداد از مصنوعات ثبت‌شده خوانده شده‌اند.

۴-۱ پوشش شروط پذیرش و وضعیت شواهد

جدول ۴-۱ شروط پذیرش رسمی (برچسب انسانی، سخت‌افزار هدف، مطالعه کامل) را کنار شواهد خودکار مرحله پایانی می‌گذارد؛ شواهد خودکار جای شروط رسمی را نمی‌گیرد.

جدول ۴-۱: شروط پذیرش رسمی و شواهد خودکار پایانی

شرط پذیرش	رسمی	شواهد خودکار پایانی
نمونه اولیه کارکردی گفتاربه‌گفتار فارسی	کافی	سامانه جریانی و آزمون حلقه‌ای
آزمون نهایی معنایی خودکار	کافی	—
خروجی ممیزی‌شده 100 تا 200 ساعت	کافی	—
سیاست داده تحت انصراف مستند	کافی	—
مجوز کد منبع	کافی	—
مدل مستقیم واجد شرایط استقرار	منفی	v7a: 6/9، نافهم
آشکارساز بالای 80 درصد	انسانی نیست	شبیه‌سازی 0.880/0.933؛ مرورگر 0.817/0.825
تأخیر و حافظه سخت‌افزار هدف	سخت‌افزار هدف نیست	GiB 11.1؛ میانگین 372، صدک نود 431
مطالعه انسانی	در انتظار	ابزار ثبت‌شده

۴-۲ مجموعه داده

جدول ۴-۲ مشخصات نهایی را نشان می‌دهد. مقدار 108.584 ساعت درون بازه ن۴ است و ممیزی خودکار یکپارچگی، شامل ترتیب کانال‌ها، درهم‌سازی و تفکیک گروهی، بدون شکست گذشته است.

جدول ۴-۲: مشخصات مجموعه داده مکالمه فارسی مشتق‌شده

شاخص	مقدار
موجودی زیرنویس کانال‌ها	775.887 ساعت
جفت‌های پاسخ بدون بازاستفاده	6,754
ساعت صوت منبع جفت‌ها	123.796 ساعت
گویندگان / نشست‌ها	407/162
ساعت استریوی خروجی	108.584 ساعت
تفکیک آموزش / اعتبارسنجی / آزمون	6,419/131/204
نشت گروهی / شکست ممیزی خودکار	0/0
نامزدهای خودکار رخداد تعاملی	770
ردیف‌های تأییدشده توسط انسان	0

یک شنونده خودکار مستقل (Gemini، دو پرسش، فقط برچسب‌های هم‌رأی) روی 300 جفت در دسترس، در 93.8 درصد مرزهای نوبت آغاز سخن گوینده‌ای دیگر را شنید و 75.7 درصد هم‌پوشانی‌های علامت‌خورده را تأیید کرد؛ زیرنویس‌ها با رونوشت آن 15.9 درصد خطای نویسه دارند.

برچسب‌های تعاملی نامزد خودکارند و راستی‌آزمایی هم خودکار است. این مجموعه را نمی‌توان برچسب‌گذاری‌شده توسط انسان نامید و داده منبع قابل بازنشر نیست.

۴-۳ سامانه آبشاری: پنل مکانیکی و فهم‌پذیری

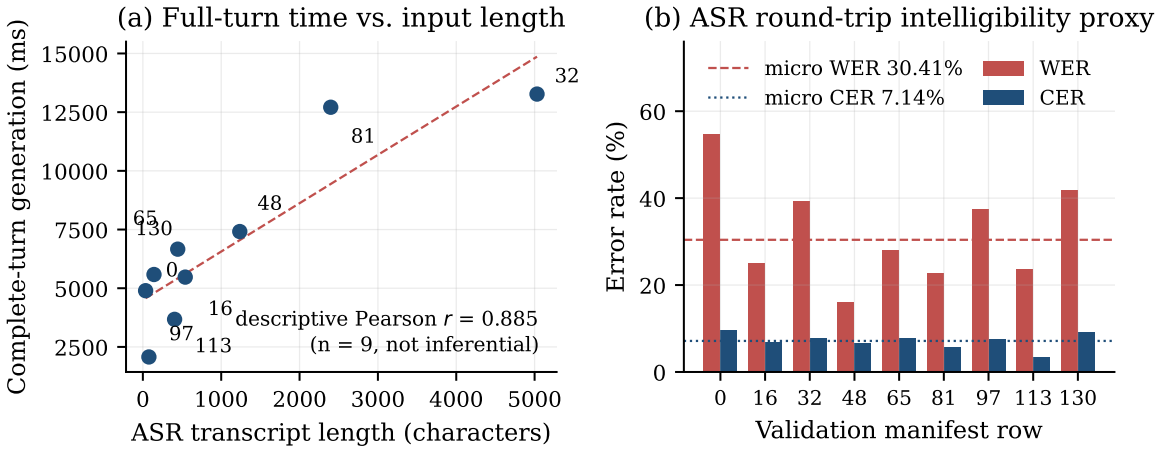
پنل اعتبارسنجی، ۹ ردیف با فاصله ثابت از فهرست‌نامه 131 ردیفی است. شاخص ردیف‌ها پیش از اجرا قفل بود. زنجیره، سرویس واقعی بازشناسی، پاسخ‌گوی Qwen2.5-0.5B-Instruct و موتور گفتاری واقعی است و ورودی کانال یک ممیزی‌شده کاربر است. این پنل مکانیک زنجیره را می‌سنجد، نه کیفیت معنایی Qwen3-4B. نتیجه در جدول ۴-۳ آمده است.

میانه، صدک نودوپنجم و بیشینه طول رونویسی 445، 3977.8 و 5031 نویسه بود. همبستگی پیرسون توصیفی میان طول رونویسی و زمان تولید کامل 0.885 است؛ بلندترین رونویسی و کندترین نوبت هر دو ردیف 32 بودند. ستون زمان، مدت تولید کامل پاسخ است نه تأخیر نخستین صوت.

بازبازشناسی همان ۹ خروجی، با متن پاسخ به‌عنوان مرجع، نرخ خطای نویسه تجمیع خرد 7.14 درصد (47/658) و نرخ خطای واژه 30.41 درصد (52/171) را نشان داد. هیچ ردیفی تطابق کامل واژه‌ای یا نویسه‌ای نداشت. شکل ۴-۱ هر دو محور را نشان می‌دهد.

جدول ۴-۳: نتیجه پنل ثابت اعتبارسنجی سامانه آبشاری

شاخص	مقدار
پاسخ‌گوی متنی پنل	Qwen2.5-0.5B
ردیف‌های عبورکرده از همه شروط	9/9
ردیف‌های با پاسخ جایگزین قاعده‌محور	0/9
کمینه سهم نویسه فارسی در رونویسی و پاسخ	1.000
پاسخ‌های صوتی غیرساکت	9/9
کمینه ریشه میانگین مربعات صوت پاسخ	0.133529
میانه / بیشینه زمان تولید کامل (ms)	5584.7/13270.2
ردیف‌های آزمون نهایی استفاده‌شده	0



شکل ۴-۱: (الف) زمان تولید کامل در برابر طول رونویسی برای ۹ ردیف پنل. (ب) نرخ خطای واژه و نویسه بازبازشناسی همان ۹ خروجی.

نتیجه مکانیکی برون‌نمونه با پاسخ‌گوی Qwen2.5-0.5B است و به Qwen3-4B تعمیم داده نمی‌شود. نُه ردیف برای تعمیم جمعیتی کافی نیست. زمان تولید کامل سنجه T_{first_audio} نیست و شرط 500 میلی‌ثانیه را برآورده نمی‌کند. بازبازشناسی فهم‌پذیری انسانی یا طبیعی‌بودن را اثبات نمی‌کند.

۴-۴ آزمون معنایی خودکار

مرحله صلاحیت روی هفت ردیف اعتبارسنجی استفاده‌نشده همه شروط را گذراند: 42/42 فراخوانی معتبر، ارتباط 3.857 در برابر 1.000، انسجام 3.571، برد زوجی 6/7 و ارتباط حداقل دو 100 درصد. تنها پس از این عبور، آزمون نهایی یک‌بار باز شد.

آزمون نهایی روی 40 ردیف از فهرست‌نامه 204 ردیفی و در پنج نشست کنارگذاشته اجرا شد. سه بازوی دوسوکور: خط پایه قفل‌شده Qwen2.5-0.5B، نامزد Qwen3-4B با پرامپت v2، و مرجع هم‌ترازشده

خودکار نوبت بعدی. داور Qwen3.8-27B-FP8 با دمای صفر و دو تکرار در هر ردیف بود. جدول ۴-۴ نتیجه را نشان می‌دهد و جدول ۴-۵ عبور هر هفت شرط ازپیش‌تعریف‌شده را.

جدول ۴-۴: نتیجه آزمون نهایی معنایی خودکار روی 40 ردیف گروه‌ناهمپوشان

شاخص	مقدار
فراخوانی معتبر داور / مورد انتظار	240/240
نرخ توافق تکرار داور	1.00
میانگین ارتباط نامزد / خط پایه / مرجع	3.150/1.425/0.950
میانگین انسجام نامزد / خط پایه	3.325/1.525
بهبود ارتباط / انسجام نسبت به خط پایه	+1.725/+1.800
برد زوجی ارتباط	27/40 (67.5%)
ارتباط حداقل دو	35/40 (87.5%)
تلاش دوباره تولید / صوت نامعتبر نامزد	0/0

جدول ۴-۵: شروط خودکار ازپیش‌تعریف‌شده آزمون نهایی

شرط	آستانه	مشاهده	وضعیت
میانگین ارتباط نامزد	$\geqslant$ 2.00	3.150	برآورده
میانگین انسجام نامزد	$\geqslant$ 2.50	3.325	برآورده
بهبود ارتباط	$\geqslant$ 0.50	1.725	برآورده
بهبود انسجام	$\geqslant$ 0	1.800	برآورده
نرخ برد زوجی ارتباط	$\geqslant$ 0.60	0.675	برآورده
نرخ ارتباط حداقل دو	$\geqslant$ 0.70	0.875	برآورده
اعتبار کامل مکانیکی	240/240	240/240	برآورده

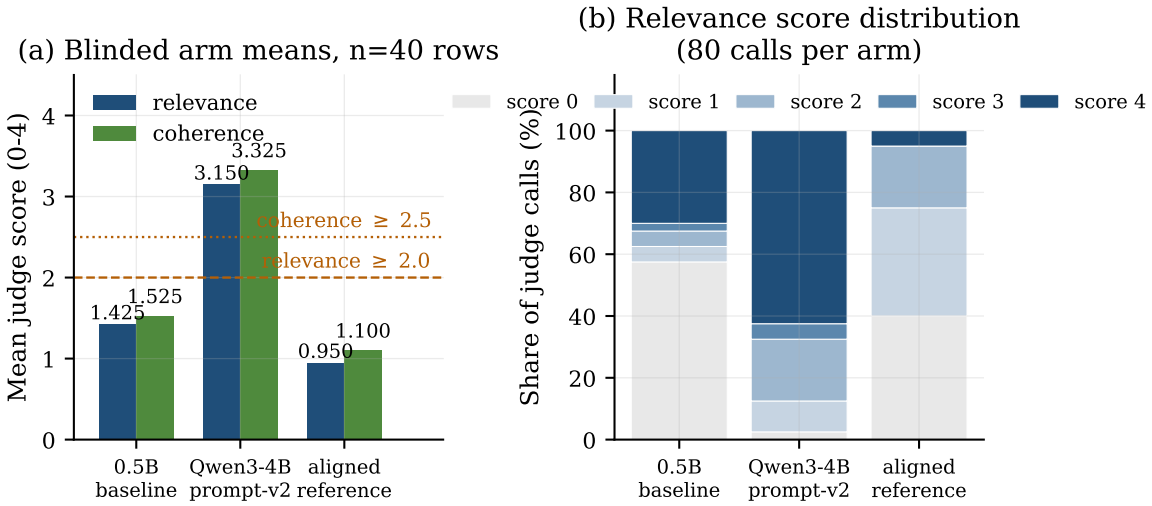
شکل ۴-۲ میانگین و توزیع امتیازها را نشان می‌دهد. امتیاز پایین مرجع هم‌ترازشده نشان می‌دهد که «گفتن نوبت بعدی پیکره» لزوماً پاسخ مناسب به اظهار کاربر نیست.

یک آزمایش جانبی LoRA روی پاسخ‌گو زیان توسعه را 31.18 درصد کاهش داد اما در ارزیابی معنایی از خط پایه پیشی نگرفت و در سامانه نهایی به کار نرفت.

عبور از هفت شرط خودکار به معنای کیفیت ادراکی یا معیار مستقل نیست. داور و نامزد هم‌خانواده‌اند.

۴-۵ بازگزینش اجزا

هر سه جزء با پروتکل تازه دوباره مقایسه شدند. **بازشناسی:** روی 344 قطعه PSRB با رونوشت انسانی، Seamless دقیق‌ترین بود (خطای نویسه 6.92 درصد) اما با میانه 671 میلی‌ثانیه از بودجه 150 میلی‌ثانیه فراتر رفت؛ NeMo نسخه 4 با 9.44 درصد و 58 میلی‌ثانیه بهترین نامزد درون بودجه بود و باقی ماند (Whisper large-v3، Qwen3-ASR و Gemma 4 بالای 20 درصد). دور دوم هشت مدل فارسی دیگر را افزود: Shenava



شکل ۴-۲: (الف) میانگین ارتباط و انسجام سه بازوی دوسوکور. (ب) توزیع امتیاز ارتباط در 80 فراخوانی داور برای هر بازو.

Koochik 0.50 واحد بهتر بود، اما نه به‌طور معنادار، و Rade-ASR-CTC-3B به 16.1 درصد رسید که بیشتر از گفتار حذف‌شده است. **پاسخ‌گو:** با پنل 60 درخواست سالمندان و 60 نوبت طبیعی، هیچ نامزدی زیر هر دو داور به آستانه جایگزینی (0.25+ مرتبط‌بودن) نرسید. داورها اختلاف دارند: زیر Gemini، Qwen3.5-4B و Gemma 4 با پرامپت سالمندان حدود یک امتیاز بهتر از سامانه مستقرند (3.36 و 3.54 در برابر 2.38)، اما زیر داور Qwen نه (3.31 و 3.00 در برابر 3.29). پیکربندی Qwen3.5-4B آزمون استقرار پیش‌ثبت‌شده را گذراند (حافظه 11.1 GiB، میانگین و صدک نود تأخیر 345 و 398 میلی‌ثانیه، انسجام پس از وقفه نزد هر دو داور)؛ جایگزینی آن به ترجیح شرکت‌کنندگان مطالعه شنیداری وابسته است. سپس یک مقایسه اندازه پیش‌ثبت‌شده پنج مدل بزرگ‌تر با 9 تا 36 میلیارد پارامتر را، بیشترشان چهاربیتی، با مرز 22 گیگابایت اجرا کرد. Gemma 4 31B جا نشد و هیچ‌یک از چهار مدل دیگر زیر هر دو داور از Qwen3.5-4B بهتر نبود. زیر داور Qwen هیچ‌کدام بیش از 0.01 در مرتبط‌بودن افزایش نداشت. زیر Gemini، Gemma 4 12B 0.26 افزایش داشت اما تنها در 26 درصد ردیف‌ها برنده بود. روی این پنل اندازه کیفیت پاسخ را بالا نبرد. **صدا:** از شش صدای فارسی Piper، Mana با میانگین خطای نویسه 5.82 درصد نزد دو شنونده خودکار فهم‌پذیرترین ماند؛ ganji_adabi هم‌تراز و با بهترین DNSMOS بود و هر دو به مطالعه شنیداری رفتند. ParsVoice-XTTS با صدای ManaTTS روی قطعه معمولی هم‌تراز بود، اما حدود یک قطعه از ده را خراب کرد (خطای میانگین 13.55 درصد، به‌طور معنادار بدتر) و نخستین قطعه جریانی آن 307 میلی‌ثانیه طول کشید؛ به مطالعه راه نیافت. مدل VITS آزمایشگاه نیز، حتی پس از بهینه‌سازی استنتاج بدون آموزش مجدد (خطا از 9.89 به 9.19 درصد، بالاترین DNSMOS)، به‌طور معنادار از Mana بدتر ماند و به مطالعه راه نیافت.

۴-۶ تشخیص وقفه

کنترل‌گر مستقر در شبیه‌سازی موقعیت استقرار سنجیده شد: میکروفون در هنگام پخش، پژواک باقی‌مانده پاسخ، نویز زمینه، پاسخ اتاق و یک رخداد واقعی (وقفه، بازخورد کلامی، نویز یا هیچ). شش اجرای توسعه فقط روی بخش آموزشی انجام شد: تأیید بر پایه مدت و طبقه‌بند صوتی 0.687، تأیید واژگانی 0.840، و با اصلاح مقداردهی آشکارساز هم‌سخنی و تطبیق پژواک 0.920. گونه برگزیده یک‌بار روی 600 سناریوی آزمون به دقت **0.933** و F1 **0.880** رسید (بازیابی 0.98؛ توقف نادرست بازخورد 8.7، نویز 9.3 و بی‌رخداد 6.7 درصد) با میانه 120 میلی‌ثانیه از آغاز آوایی تا کم‌کردن صدا. طبقه‌بند انرژی/زیروبمی/MFCC روی 94 رخداد آزمون پادکست با برچسب Gemini تنها دقت 0.574 و F1 0.672 گرفت.

آمیزه شبیه‌سازی‌شده از ضبط‌های واقعی، با برچسب خودکار؛ نه کاربر زنده.

۴-۷ مسیر مستقیم

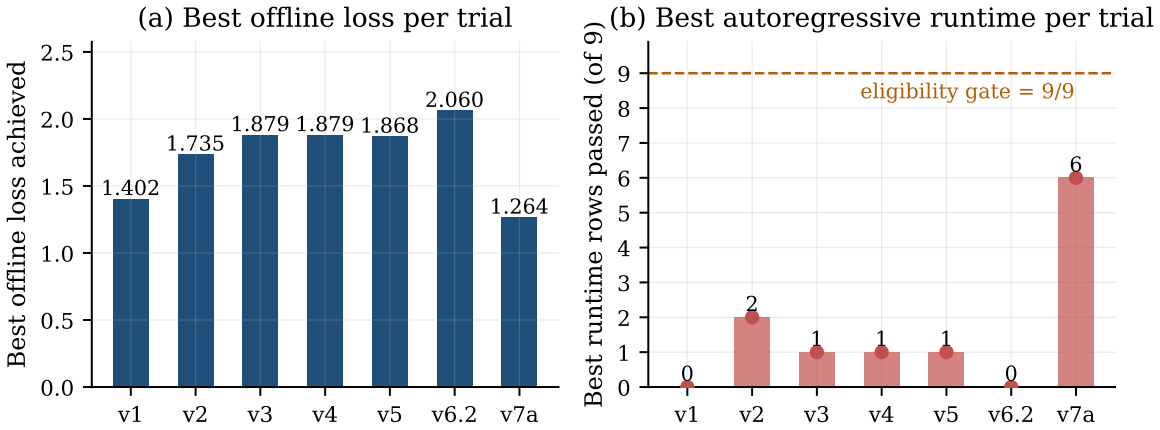
جدول ۴-۶ هفت نسل را خلاصه می‌کند. الگوی مشترک: زیان کاهش می‌یابد و شرط اجرا برآورده نمی‌شود. مقادیر کمینه زیان میان نسل‌ها مستقیماً قابل مقایسه نیستند، چون پنجره و مجموعه ارزیابی فرق دارد. برای v6.2 و v7a زیان درون‌نمونه است.

جدول ۴-۶: خلاصه هفت نسل مسیر مستقیم. «بهترین اجرا» بیشترین شمار ردیف عبورکرده از ۹ ردیف در میان چک‌پوینت‌های آن نسل است.

نسخه	پنجره (ثانیه)	نامزد	کمینه زیان	بهترین اجرا	واجد شرایط
v1	20	16	1.402	0/9	نه
v2	100	20	1.735	2/9	نه
v3	100	5	1.879	1/9	نه
v4	100	5	1.879	1/9	نه
v5	100	5	1.868	1/9	نه
v6.2	12	4	2.060	0/9	نه
v7a	12	4	1.264	6/9	نه

در v6.2 بهترین زیان متنی پس از گام 50 برابر 0.550852 است که 32.20 درصد کمتر از 0.812474 در گام 50 است و از معیار 30 درصد بالاتر می‌رود؛ یعنی آداپتر ظرفیت برازش هدف را دارد. با این حال هر چهار چک‌پوینت 0 از 9 گرفتند و در هر چک‌پوینت تنها یک ردیف از نه ردیف هم‌زمان متن و گفتار تولید کرد. شکل ۴-۳ این دو محور را در برابر هم می‌گذارد.

هیچ چک‌پوینتی واجد شرایط استقرار نیست. عبارت «مدل Moshika با موفقیت برای فارسی تنظیم شد» با این شواهد نادرست است.



شکل ۴-۳: (الف) بهترین زیان آفلاین هر نسل. (ب) بیشترین شمار ردیف عبورکرده از پنل اجرا، در برابر شرط 9/9.

نسخه هفتم. با متن لاتین‌نویسی‌شده و زمان‌بندی واژه‌به‌واژه، بهترین شمار پذیرفته در همان آزمون ظرفیت به 6/9 رسید (خط پایه کنترل‌شده 3/9) و کارساز روی 8 ردیف از 9 گفتار شنیدنی همراه با متن تولید کرد؛ اما شرط 9/9 برقرار نشد و گفتار تولیدی برای بازشناس فارسی فهم‌پذیر نبود (میانگین خطای پیشوند 0.88)، پس آموزش کامل آغاز نشد. گلوگاه توکن‌ساز واقعی است ولی تنها مانع نیست.

ورودی گفتاری. Gemma 4 با شنیدن مستقیم صوت، بی‌آموزش و با آداپتر، در مرتبط‌بودن 1.98 و 2.05 گرفت، در برابر 2.80 سامانه آبشاری؛ نتیجه طبق قاعده ازپیش‌ثبت‌شده منفی است. حذف بازشناسی حتی با همان مدل زبانی کیفیت را کم کرد (2.49 در برابر 1.98) و تنها حدود 20 میلی‌ثانیه صرفه‌جویی داشت. با داور دوم (Gemini) سامانه تولیدی پایین‌ترین امتیاز را گرفت (1.91) و مسیر گفتاری بالاتر بود (2.18 و با آداپتر 2.52)؛ نتیجه رسمی با داور نخست منفی می‌ماند و این اختلاف داورها گزارش شده است. Gemma 4 12B گفتار فارسی را از E4B هم بدتر فهمید.

۴-۸ تأخیر، حافظه و آزمون حلقه‌ای مرورگر

مرورگر بدون رابط صفحه واقعی کارخواه را با میکروفون جعلی (گفته‌های ضبط‌شده 1 تا 5 ثانیه‌ای) اجرا کرد. سرور مدل زبانی به سهم حافظه یک کارت 12 گیگابایتی محدود شد: بیشینه حافظه گرافیکی کل سامانه 11.1 GiB (سرعت همان H100). با آغاز پیش‌دستانه پس از 96 میلی‌ثانیه سکوت (برگزیده روی گفته‌های توسعه)، در 201 نوبت پنل اصلی هیچ نوبتی بی‌پاسخ نماند؛ میانگین تأخیر پایان گفتار تا نخستین صدا **372**، صدک نود **431** و بیشینه 491 میلی‌ثانیه (اجرای نخست با 160 میلی‌ثانیه: 418، 487 و 537)؛ با تأخیر خروجی مرورگر صدک نود 473. گفتار شبیه‌سازی‌شده سالمند: میانگین 382 و صدک نود 446. در 120 نوبت وقفه و بازخورد کلامی، دقت تصمیم 0.825 و F1 0.817 و میانه کم‌کردن صدا از آغاز تشخیص‌داده‌شده 44 میلی‌ثانیه بود. در 30 گفت‌وگوی ازپیش‌نوشته با پرسش تکمیلی روی پاسخ، 24 از 27 وقفه پاسخ را متوقف کرد و پاسخ پس از وقفه نزد هر دو داور به اندازه پاسخ نوبت عادی مرتبط بود. دروازه معنایی پایان نوبت (Smart Turn v3.2 [۲۲])، داوری مدل زبانی، قاعده واژگانی و یک Smart Turn تنظیم‌شده روی

فارسی) زودبستن نوبت را روی گفته‌های توسعه از 19.8 درصد کم کرد، اما هیچ نامزدی کمتر از 13 درصد پایان‌های واقعی را بی‌جا به تعویق نینداخت (مرز ازپیش‌ثبت‌شده 5 درصد). دور دوم پایان هر قطعه توسعه را برچسب زد (Gemini، دو گذر) و تنها پایان‌های کامل را شمرد: داوری مدل زبانی واجد شرایط شد (13.3 درصد زودبستن، 4.4 درصد پایان‌های کامل نگه‌داشته)، اما در آزمون حلقه‌ای 15 درصد نوبت‌های تمام‌شده را نگه داشت و صدک نود به 656 میلی‌ثانیه رسید، پس کنار گذاشته شد؛ تشخیص‌دهنده مستقر بدون تغییر ماند.

آزمون حلقه‌ای خودکار روی H100 بدون کاربر انسانی و مسیر فیزیکی؛ معیار پیشنهاده (میانگین و صدک نود) و در پنل اصلی خوانش هرنوبت برآورده است.

مطالعه شنیداری کوچک (طبیعی‌بودن دو صدای Piper و گفتار انسانی، و سه گفت‌وگوی ضبط‌شده، و ترجیح میان پاسخ‌های دو پاسخ‌گو که طبق قاعده ازپیش‌ثبت‌شده درباره جایگزینی پاسخ‌گو تصمیم می‌گیرد) با پروتکل ثبت‌شده آماده است؛ نتایج آن هنوز در دست نیست.

۹-۴ وضعیت نهایی نیازمندی‌ها

جدول ۴-۷: وضعیت نهایی هفت نیازمندی تعریف پروژه

شماره	وضعیت	شواهد پشتیبان
ن۱	برآورده (آبشاری جریانی)	آزمون معنایی نهایی؛ همه 401 نوبت حلقه‌ای پاسخ گرفتند
ن۲	برآورده در آزمون خودکار	وقفه 0.82/0.83 در مرورگر، 0.88/0.93 در شبیه‌سازی
ن۳	برآورده	میانگین 372 و صدک نود 431؛ بیشینه 491 میلی‌ثانیه
ن۴	برآورده	108.584 ساعت خروجی ممیزی‌شده (برچسب خودکار)
ن۵	هدف برآورده با روش دیگر	تأیید واژگانی؛ طبقه‌بند صوتی تنها 0.574
ن۶	انحراف اعلام‌شده	حافظه 11.1 GiB؛ سرعت روی H100
ن۷	در انتظار نتایج	ابزار و پروتکل ثبت‌شده

شواهد ن۲ ، ن۳ و ن۵ خودکار و روی H100 است؛ ن۴ برچسب انسانی ندارد؛ ن۵ با ویژگی‌های صوتی تعیین‌شده به‌تنهایی برآورده نشد.

از چهار قلم خروجی مورد انتظار، سه قلم تولید و مستند شده‌اند: نمونه اولیه آبشاری جریانی، کد منبع مستند، و مجموعه داده مکالمه فارسی. یافته‌های تجربی سالمندان پس از رسیدن پاسخ‌های مطالعه شنیداری قابل گزارش است.

فصل ۵

بحث، نتیجه‌گیری و کارهای آینده

۵-۱ فاصله زیان و تولید

یافته علمی اصلی مسیر مستقیم این است که کاهش زیان تحت تحمیل معلم از تولید خودرگرسیو معتبر جدا است. نسخه v6.2 این جداسازی را تیز می‌کند: روی همان 32 نمونه آموزشی، زیان متنی 32.20 درصد کاهش یافت اما رفتار آموخته‌شده به تولید قابل اتکا منتقل نشد. توضیح سازگار با شواهد، اریبی مواجهه است نه نبود ظرفیت. پیامد روشمند آن است که انتخاب چک‌پوینت گفتاربه‌گفتار نباید تنها بر زیان آفلاین استوار باشد.

در مسیر آبشاری، دو جداسازی مشابه دیده شد. نخست، پنل مکانیکی 9/9 با پاسخ‌گوی 0.5B کیفیت معنایی پاسخ‌گوی 4B را ثابت نمی‌کند. دوم، عبور آزمون خودکار هم‌خانواده کیفیت ادراکی را ثابت نمی‌کند. فاصله میان نرخ خطای نویسه 7.14 درصد و نرخ خطای واژه 30.41 درصد نیز نشان می‌دهد که حفظ تقریبی نویسه‌ها با فهم‌پذیری واژه‌ای یکی نیست. امتیاز پایین مرجع هم‌ترازشده در آزمون معنایی یادآوری می‌کند که نوبت بعدی پیکره لزوماً پاسخ مناسب به آخرین اظهار کاربر نیست؛ به همین دلیل آداپتر LoRA که زیان توسعه را کاهش داد، از خط پایه پیشی نگرفت.

۵-۲ علت شکست مسیر مستقیم

ممیزی پایانی نشان داد که توکن‌ساز انگلیسی Moshi برای هر واژه فارسی 6.6 نشانه می‌خواهد و 98.5 درصد نوبت‌ها از بودجه یک نشانه در قاب فراتر می‌روند. برداشتن این گلوگاه با لاتین‌نویسی واجی بهترین نتیجه تولید را از 3/9 به 6/9 رساند و خروجی ساکت را شنیدنی کرد، اما گفتار فهم‌پذیر نشد؛ پس گلوگاه توکن‌ساز واقعی است اما تنها مانع نیست. J-Moshi [۲۳] نیز برای انتقال Moshi به ژاپنی توکن‌ساز را جایگزین کرد و سپس به حدود 60,000 ساعت پیش‌آموزش گفت‌وگو نیاز داشت، بیش از پانصد برابر داده این پروژه. مدل ورودی گفتاری Gemma 4 نیز نشان داد که حذف بازشناسی، حتی با همان مدل زبانی، کیفیت را کم می‌کند.

۵-۳ محدودیت‌ها و ملاحظات

شواهد تأخیر و وقفه خودکار و روی H100 است: حافظه یک کارت 12 گیگابایتی رعایت شد اما سرعت آن نه، و کاربر انسانی، مسیر فیزیکی میکروفون و بلندگو و پژواک واقعی در کار نبود. برچسب‌های وقفه و داده خودکارند و برچسب انسانی ندارند؛ دو داور خودکار پاسخ‌گو اختلاف زیادی دارند؛ صدای سالمند در آزمون‌ها شبیه‌سازی است. تشخیص وقفه به بازشناس گفتار تکیه دارد، نه به ویژگی‌های صوتی تعیین‌شده در تعریف پروژه. مجموعه داده از آرشیو داخلی مشتق شده و قابل بازنشر نیست. نتایج مطالعه شنیداری هنوز دریافت نشده است.

۵-۴ پاسخ به پرسش‌های پژوهش

۱. تطبیق کم‌پارامتر Moshika سرگشتگی آزمون کنارگذاشته را کاهش داد (نشانه متنی 2.53 به 1.19، صوتی 13.98 به 4.71) اما گفتار فهم‌پذیر نساخت؛ توکن‌ساز انگلیسی مانع اصلی است. **۲.** در مسیر آبشاری، تشخیص پیش‌دستانه پایان گفتار با نگه‌داشت صوت تا تأیید، تولید جریانی با قید خط فارسی، بندبندی، صف پخش و کنترل وقفه دومرحله‌ای با تاریخچه شنیده‌شده، تأخیر را به میانگین 372 و صدک نود 431 میلی‌ثانیه رساند. **۳.** اندازه کیفیت نخرید: کوچک‌ترین بازشناس‌ها و گفتارساز تخصصی فارسی بهترین بده‌بستان را داشتند، پاسخ‌گوهای 9 تا 36 میلیاردی زیر هر دو داور از بهترین مدل چهارمیلیاردی بهتر نبودند، و مدل سرتاسری 7.7 میلیارد پارامتری به گفتار فهم‌پذیر نرسید. **۴.** درک سالمندان به نتایج مطالعه شنیداری وابسته است. وضعیت هر نیازمندی در جدول ۴-۷ آمده است.

۵-۵ کارهای آینده

تکمیل شواهد: اجرای همان آزمون حلقه‌ای روی کارت 12 تا 24 گیگابایتی و با مسیر فیزیکی صدا؛ گردآوری پاسخ‌های مطالعه شنیداری و یک جلسه تعامل زنده با سالمندان؛ بازبینی انسانی نمونه‌ای از برچسب‌ها؛ و داوری انسانی پاسخ‌گوها (ترجیح شرکت‌کنندگان درباره جایگزینی Qwen3.5-4B تصمیم می‌گیرد). بهبود سامانه: جداکردن آموخته واژه شنونده از محتوایی در آغاز بریده‌شده (پیش‌بافر 200 میلی‌ثانیه‌ای آزموده و رد شد)، تشخیص پایان نوبت معنایی برای درنگ‌های گفتار سالمندان (در دو دور آزموده شد و نوبت‌های تمام‌شده بسیاری را به تأخیر انداخت؛ نگه‌داشتن کوتاه‌تر یا برچسب انسانی پایان نوبت لازم است)، و بازشناس دقیق‌تر در همان بودجه تأخیر. مسیر مستقیم: توکن‌سازی متناسب با بودجه قاب و راهکاری برای شکاف واداشت معلم و تولید آزاد، و رویکرد مدل منجمد.

Bibliography

[1] A. Défossez, L. Mazaré, M. Orsini, A. Royer, P. Pérez, H. Jégou, E. Grave, and N. Zeghidour. Moshi: A speech-text foundation model for real-time dialogue. Technical report, Kyutai, 2024. arXiv:2410.00037.

[2] X. Wang, Y. Li, C. Fu, Y. Zhang, Y. Shen, L. Xie, K. Li, X. Sun, and L. Ma. Freeze-Omni: A smart and low latency speech-to-speech dialogue model with frozen LLM. In *Proceedings of the 42nd International Conference on Machine Learning*, volume 267 of *Proceedings of Machine Learning Research*, pages 63345–63354. PMLR, 2025.

[3] M. F. Qharabagh, Z. Dehghanian, and H. R. Rabiee. ManaTTS Persian: A recipe for creating TTS datasets for lower-resource languages. In *Proceedings of the 2025 Conference of the Nations of the Americas Chapter of the Association for Computational Linguistics: Human Language Technologies (Volume 1: Long Papers)*, pages 9177–9206, Albuquerque, New Mexico, 2025. Association for Computational Linguistics.

[4] J. Xu, Z. Guo, J. He, H. Hu, T. He, S. Bai, K. Chen, J. Wang, Y. Fan, K. Dang, B. Zhang, X. Wang, Y. Chu, and J. Lin. Qwen2.5-Omni technical report. *arXiv preprint arXiv:2503.20215*, 2025.

[5] Z. Xie and C. Wu. Mini-Omni2: Towards open-source GPT-4o with vision, speech and duplex capabilities. *arXiv preprint arXiv:2410.11190*, 2024.

[6] Q. Fang, Y. Zhou, S. Guo, S. Zhang, and Y. Feng. LLaMA-Omni 2: LLM-based real-time spoken chatbot with autoregressive streaming speech synthesis. In *Proceedings of the 63rd Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers)*, pages 18617–18629, Vienna, Austria, 2025. Association for Computational Linguistics.

[7] Kyutai Labs. Moshi-finetune: LoRA fine-tuning for Moshi. https://github.com/kyutai-labs/moshi-finetune, 2024.

[8] E. J. Hu, Y. Shen, P. Wallis, Z. Allen-Zhu, Y. Li, S. Wang, L. Wang, and W. Chen. LoRA: Low-rank adaptation of large language models. In *Proceedings of the 10th International Conference on Learning Representations*, 2022.

[9] M. Ranzato, S. Chopra, M. Auli, and W. Zaremba. Sequence level training with recurrent neural networks. In *Proceedings of the 4th International Conference on Learning Representations*, 2016.

[10] S. Bengio, O. Vinyals, N. Jaitly, and N. Shazeer. Scheduled sampling for sequence prediction with recurrent neural networks. In *Advances in Neural Information Processing Systems*, volume 28, pages 1171–1179, 2015.

[11] O. Kuchaiev, J. Li, H. Nguyen, O. Hrinchuk, R. Leary, B. Ginsburg, S. Kriman, S. Beliaev, V. Lavrukhin, J. Cook, and Others. NeMo: A toolkit for building AI applications using neural modules, 2019. arXiv:1909.09577.

[12] Rhasspy Project. Piper: A fast, local neural text-to-speech system. https://github.com/rhasspy/piper, 2023.

[13] S. B. Davis and P. Mermelstein. Comparison of parametric representations for monosyllabic word recognition in continuously spoken sentences. *IEEE Transactions on Acoustics, Speech, and Signal Processing*, 28(4):357–366, 1980.

[14] A. de Cheveigné and H. Kawahara. YIN, a fundamental frequency estimator for speech and music. *The Journal of the Acoustical Society of America*, 111(4):1917–1930, 2002.

[15] J. H. Friedman. Greedy function approximation: A gradient boosting machine. *Annals of Statistics*, 29(5):1189–1232, 2001.

[16] E. B. Wilson. Probable inference, the law of succession, and statistical inference. *Journal of the American Statistical Association*, 22(158):209–212, 1927.

[17] G. Skantze. Turn-taking in conversational systems and human-robot interaction: A review. *Computer Speech & Language*, 67:101178, 2021.

[18] R. Roy, J. Raiman, S.-g. Lee, T.-D. Ene, R. Kirby, S. Kim, J. Kim, and B. Catanzaro. PersonaPlex: Voice and role control for full duplex conversational speech models, 2026. arXiv:2602.06053.

[19] International Telecommunication Union. Methods for subjective determination of transmission quality. *ITU-T Recommendation P.800*, 1996.

[20] A. Yang, B. Yang, B. Zhang, B. Hui, B. Zheng, B. Yu, C. Li, D. Liu, F. Huang, H. Wei, H. Lin, J. Yang, J. Tu, J. Zhang, J. Yang, J. Zhou, J. Lin, K. Dang, and Others. Qwen2.5 technical report. *arXiv preprint arXiv:2412.15115*, 2025.

[21] A. Yang, A. Li, B. Yang, B. Zhang, B. Hui, B. Zheng, B. Yu, C. Gao, C. Huang, C. Lv, and Others. Qwen3 technical report. *arXiv preprint arXiv:2505.09388*, 2025.

[22] Daily. Smart Turn v3: Open-source semantic turn detection, 2025. Model `pipecat-ai/smart-turn-v3`, BSD-2-Clause.

[23] A. Ohashi, S. Iizuka, J. Jiang, and R. Higashinaka. Towards a Japanese full-duplex spoken dialogue system. In *Proceedings of Interspeech 2025*, 2025. arXiv:2506.02979.

Abstract

This project designs, implements and evaluates a prototype Persian speech-to-speech system that operates in full-duplex mode: the user microphone stays open while the assistant speaks, and the system reacts to interruptions. Two tracks were pursued: low-rank adaptation of the end-to-end Moshika model to Persian, and a streaming cascade of NeMo speech recognition, the Qwen3-4B-Instruct-2507 responder and Piper speech synthesis. A conversational corpus of 6,754 user/response pairs (108.584 hours, session-disjoint splits) was derived from an archive of Persian spoken content.

The final cascade detects the end of speech automatically and speculatively, streams the reply clause by clause, and handles interruptions in two stages: it ducks the assistant after one frame of speech louder than the expected residual echo, then confirms lexically with the speech recognizer after discarding listener tokens and the assistant's own echoed words. In automated real-browser loopback, end-of-speech to first assistant audio had a mean of 372 ms and a 90th percentile of 431 ms, with every turn under 500 ms and the GPU side of the stack using 11.1 GiB. Interruption handling reached accuracy 0.933 and F1 0.880, with a median of 120 ms to the duck, in a deployment simulation built from real recordings, and accuracy 0.825 (F1 0.817) in the browser; an energy/F0/MFCC classifier alone reached only 0.574 on real podcast events. The responder passed all seven predeclared automatic gates of a 40-row final test (relevance 3.150 versus 1.425). All components were re-selected on fresh panels, including speech recognition on human transcripts and synthesis with two automatic listeners.

The direct track produced no deployable model. Moshi's English tokenizer needs 6.6 tokens per Persian word and exceeds its one-token-per-frame budget; phoneme romanization doubled the best runtime result but the speech was still not intelligible, and a speech-input Gemma 4 model also underperformed the cascade. Latency and interruption evidence is automated and on an H100 (the memory of a 12 GB card was respected, its compute speed was not), labels are automatic, and the results of the human listening study are not yet available.

Keywords: Speech-to-speech, full-duplex dialogue, barge-in detection, Persian language, large language models, streaming cascade, tokenization, parameter-efficient adaptation



Sharif University of Technology

Department of Computer Engineering

B.Sc. Project Report

Concise version

A Speech-to-Speech Large Language Model for Persian

By:

Mehran Bakhtiari

Supervisor:

Dr. Hossein Sameti

October 2026