



دانشگاه صنعتی شریف
دانشکده مهندسی کامپیوتر

پروژه کارشناسی
مهندسی کامپیوتر

مدل زبانی بزرگ گفتار به گفتار برای زبان فارسی

نسخه خلاصه گزارش پروژه

نگارش

مهران بختیاری

استاد راهنما

دکتر حسین صامتی

شهریور ۱۴۰۵

چکیده

هدف این پروژه، طراحی، پیاده‌سازی و ارزیابی یک نمونه اولیه سامانه گفتاربه‌گفتار فارسی است که به‌صورت تمام‌دوطرفه کار می‌کند؛ یعنی میکروفون کاربر در هنگام پخش پاسخ نیز فعال می‌ماند و سامانه می‌تواند بر پایه یک تصمیم‌آشکارساز کلاسیک، منبع صوت در حال پخش را متوقف کند و گفتار جمع‌شده کاربر را به نوبت بعدی منتقل نماید. برای کاهش ریسک اجرایی، دو مسیر به‌طور موازی بررسی شد: نخست تطبیق مستقیم مدل متن‌باز گفتاربه‌گفتار Moshika با داده فارسی، و دوم یک سامانه آشنایی شامل بازشناسی گفتار فارسی با NeMo، تولید پاسخ متنی با Qwen3-4B-Instruct-2507 و تبدیل متن به گفتار با Piper.

از آرشید داخلی محتوای گفتاری فارسی، یک مجموعه داده مکالمه مشتق‌شده شامل 6,754 جفت «گفتار کاربر / پاسخ» با مدت نهایی 108.584 ساعت صوت استریو ساخته شد. تفکیک آموزش، اعتبارسنجی و آزمون بر پایه شناسه نشست منبع انجام گرفت و نشت گروهی مشاهده نشد. یک ماژول تشخیص وقفه نیز بر پایه ویژگی‌های انرژی، زیروبمی و MFCC به همراه یک طبقه‌بند تقویت‌گرادیانی پیاده‌سازی شد.

پس از عبور از یک مرحله صلاحیت هفت‌ردیفی ازپیش‌قفل‌شده، پاسخ‌گوی Qwen3-4B با پرامپت v2 در آزمون نهایی 40 ردیفی گروه‌ناهمپوشان از هر هفت شرط خودکار ازپیش‌تعریف‌شده عبور کرد: هر 240 فراخوانی داور معتبر بود، میانگین ارتباط پاسخ از 1.425 برای خط پایه Qwen2.5-0.5B به 3.150 رسید، میانگین انسجام 3.325 شد و نرخ برد زوجی 67.5 درصد به‌دست آمد. داور، مدل هم‌خانواده Qwen3-8-27B-FP8 بود؛ بنابراین این سنجه جایگزین ارزیابی انسانی نیست. زنجیره مکانیکی آشنایی با پاسخ‌گوی Qwen2.5-0.5B در پنل ثابت اعتبارسنجی در هر 9 ردیف رونویسی فارسی، پاسخ فارسی و صوت غیرساکت تولید کرد و از پاسخ جایگزین قاعده‌محور استفاده نکرد. بازبازشناسی همان 9 خروجی، نرخ خطای نویسه 7.14 درصد و نرخ خطای واژه 30.41 درصد را نشان داد. این پنل پس از ارتقای پاسخ‌گو به Qwen3-4B دوباره اجرا نشد.

در مقابل، مسیر مستقیم در شش نسخه آزمایشی، با آن‌که زیان آموزشی را به‌طور پیوسته کاهش داد، هیچ چک‌پوینتی تولید نکرد که از شرط اجرای خودرگرسیو عبور کند؛ نسخه v6.2 کاهش 32.20 درصدی زیان متنی درون‌آموزشی را نشان داد اما هر چهار چک‌پوینت آن در آزمون نه‌ردیفی اجرا 0 از 9 گرفتند. این مسیر به‌عنوان یک نتیجه منفی با سیگنال یادگیری مثبت گزارش شده است و سامانه آشنایی نمونه اولیه نهایی پروژه در نظر گرفته شد. آزمون مرورگر روی پردازنده گرافیکی فیزیکی 12 تا 24 گیگابایتی، اثبات تأخیر سرتاسری حداکثر 500 میلی‌ثانیه، برچسب‌گذاری مستقل انسانی وقفه و مطالعه 5 تا 10 کاربر در مهلت پروژه انجام نشد و به‌عنوان محدودیت صریح باقی می‌ماند.

کلیدواژه‌ها: گفتاربه‌گفتار، تمام‌دوطرفه، تشخیص وقفه، زبان فارسی، مدل زبانی بزرگ، سامانه آشنایی، تطبیق کم‌پارامتر

فهرست مطالب

۲	۱ مقدمه
۲	۱-۱ تعریف مسئله
۳	۲-۱ اهمیت موضوع
۳	۳-۱ نیازمندی‌های تعریف شده
۴	۴-۱ راهبرد دومسیره و چالش‌ها
۴	۵-۱ دستاوردها
۵	۶-۱ ساختار این نوشتار
۶	۲ پیشینه و مفاهیم لازم
۶	۱-۲ دو خانواده معماری
۶	۲-۲ مدل زبانی، تطبیق کم‌پارامتر، و اریبی مواجهه
۷	۳-۲ بازشناسی، گفتارسازی، و ویژگی‌های وقفه
۷	۴-۲ جایگاه در کارهای پیشین
۷	۵-۲ سنجه‌ها و داوری مدل
۹	۳ روش پیشنهادی و پیاده‌سازی
۹	۱-۳ تلاش اولیه و بازنگری
۹	۲-۳ ساخت مجموعه داده
۱۰	۳-۳ معماری سامانه آبشاری
۱۱	۴-۳ تشخیص وقفه و بستر تمام‌دوطرفه
۱۱	۵-۳ طراحی آزمایش‌های مسیر مستقیم
۱۳	۶-۳ روش کاری شواهدمحور
۱۴	۴ آزمایش‌ها و نتایج

۱۴	پوشش شروط پذیرش و وضعیت شواهد	۱-۴
۱۵	مجموعه داده	۲-۴
۱۵	سامانه آبخاری: پزل مکانیکی و فهم‌پذیری	۳-۴
۱۶	آزمون معنایی خودکار	۴-۴
۱۷	تشخیص وقفه و پیوستگی انتقال	۵-۴
۱۸	مسیر مستقیم	۶-۴
۱۹	تأخیر، سخت‌افزار و مطالعه انسانی	۷-۴
۲۰	وضعیت نهایی نیازمندی‌ها	۸-۴

۵ بحث، نتیجه‌گیری و کارهای آینده

۲۱	فاصله زیان و تولید	۱-۵
۲۱	محدودیت‌ها و ملاحظات	۲-۵
۲۲	پاسخ به پرسش پژوهش	۳-۵
۲۲	کارهای آینده	۴-۵

مراجع

۲۳

فصل ۱

مقدمه

این نوشتار نسخه خلاصه گزارش پروژه کارشناسی است. گزارش کامل، با هفت فصل، واژه‌نامه و پیوست بازتولید، در پرونده جداگانه‌ای آمده است. اعداد، نیازمندی‌ها و مرز ادعاها در هر دو نسخه یکی است؛ آنچه کوتاه شده، شرح و تکرار است نه نتیجه.

گفت‌وگوی گفتاری طبیعی‌ترین شکل تعامل انسان با ماشین است، اما تا همین اواخر تقریباً همیشه از زنجیره‌ای از مؤلفه‌های مستقل ساخته می‌شد. مدل‌هایی مانند Moshi [۱] و Freeze-Omni [۲] نشان دادند که می‌توان گفت‌وگو را به صورت یک مسئله «گفتار به گفتار» و در قالب مدلی که هم‌زمان می‌شنود و سخن می‌گوید مدل کرد. این تحول برای زبان‌های پرمنبع رخ داده است. برای فارسی، هیچ‌یک از مدل‌های متن‌باز موجود پشتیبانی رسمی ارائه نمی‌کنند و پیکره مکالمه‌ای با برجسب وقفه نیز به صورت عمومی در دسترس نیست.

پرسش عملی پروژه این است: با بودجه یک پروژه کارشناسی، تا چه اندازه می‌توان یک سامانه گفتار به گفتار فارسی تمام‌دوطرفه ساخت، و چه چیزی را می‌توان با شواهد قابل ممیزی «اثبات» کرد؟

۱-۱ تعریف مسئله

هدف تعریف‌شده، طراحی، پیاده‌سازی و ارزیابی یک نمونه اولیه مدل زبانی بزرگ گفتار به گفتار برای زبان فارسی است. سامانه باید تمام‌دوطرفه باشد: میکروفون کاربر در طول پخش پاسخ فعال بماند و سامانه بتواند به «وقفه» کاربر واکنش نشان دهد. سه ویژگی این مسئله را از پرسش و پاسخ گفتاری متعارف جدا می‌کند: هم‌زمانی شنیدن و گفتن؛ تصمیم توقف پخش در مقیاس چندده میلی‌ثانیه؛ و تداوم گفتاری که در لحظه وقفه ادا می‌شود، تا کاربر ناچار به تکرار جمله نشود.

۲-۱ اهمیت موضوع

رابط گفتاری برای کاربرانی که با صفحه کلید فارسی راحت نیستند، برای کم‌بینایان و به‌طور خاص برای سالمندان می‌تواند تنها راه مؤثر استفاده از خدمات دیجیتال باشد. برای فارسی، منابع بازشناسی و تبدیل متن به گفتار وجود دارد؛ نمونه شاخص ManaTTS [۳] با بیش از 86 ساعت گفتار تک‌گوینده است. اما این منابع خوانشی‌اند و هم‌پوشانی، وقفه و بازخورد کلامی را پوشش نمی‌دهند. از سوی دیگر، مدل‌های روز مانند Qwen2.5-Omni [۴] برای نسخه هفت‌میلیاردپارامتری خود به حافظه‌ای به‌مراتب بیش از بازه 12 تا 24 گیگابایت نیاز دارند. نشان‌دادن آنچه در این بازه قابل دستیابی است و آنچه نیست، خودش یک نتیجه مهندسی است.

۳-۱ نیازمندی‌های تعریف‌شده

تعریف پروژه هفت نیازمندی مشخص را تعیین کرده است (جدول ۱-۱). خروجی مورد انتظار نیز چهار قلم است: نمونه اولیه کارا، کد منبع مستند، مجموعه داده مکالمه فارسی، و یافته‌های مربوط به تعامل سالمندان. برای قلم چهارم، پروتکل و زیرساخت سنجش آماده شده است؛ یافته تجربی آن تنها پس از تکمیل مطالعه انسانی قابل ادعا خواهد بود و از این‌رو در این نوشتار ادعایی درباره تجربه سالمندان مطرح نمی‌شود.

جدول ۱-۱: نیازمندی‌های هفت‌گانه تعریف پروژه

شماره	نیازمندی	سنجه تعیین‌شده
ن ۱	نمونه اولیه گفتار به گفتار فارسی	تولید پاسخ گفتاری فارسی از ورودی گفتاری فارسی
ن ۲	کارکرد تمام‌دوطرفه	شنیدن در هنگام پخش و واکنش به وقفه
ن ۳	تأخیر سرتاسری	حداکثر 500 میلی‌ثانیه از دریافت گفتار تا تولید پاسخ گفتاری
ن ۴	مجموعه داده مکالمه فارسی	100 تا 200 ساعت گفتار همراه با نویز، هم‌پوشانی و قطع‌ووصل کلام
ن ۵	ماژول تشخیص وقفه	دقت بالای 80 درصد با ویژگی‌های انرژی، MFCC و زیرویمی
ن ۶	ارزیابی روی سخت‌افزار هدف	پردازنده گرافیکی با 12 تا 24 گیگابایت حافظه
ن ۷	ارزیابی انسانی	5 تا 10 گویشور فارسی، دست‌کم دو نفر بالای 60 سال

۴-۱ راهبرد دومسیره و چالش‌ها

چهار چالش شکل نهایی کار را تعیین کرد: نبود مسیر آموزشی رسمی برای فارسی در مدل‌هایی مانند Mini-Omni2 [۵] و LLaMA-Omni2 [۶]؛ نبود پیکره مکالمه‌ای برچسب‌دار فارسی؛ فاصله میان کاهش زیان آفلاین و تولید خودرگرسیو معتبر؛ و مرز میان شواهد مهندسی و ادعای علمی.

برای کاهش ریسک، دو مسیر به‌طور موازی پیش رفت. مسیر مستقیم، تطبیق کم‌پارامتر Moshika با آموزش‌دهنده رسمی خانواده Moshi [۷] است. مسیر آبشاری، زنجیره بازشناسی گفتار فارسی، مدل زبانی متنی و تبدیل متن به گفتار است که کنترل تمام‌دوطرفه و منطق وقفه به‌صورت جداگانه روی آن سوار می‌شود. هر دو مسیر از یک مجموعه داده مشترک استفاده کردند. نتیجه نامتقارن بود: مسیر آبشاری نمونه اولیه تحویل‌شده شد و مسیر مستقیم به‌عنوان نتیجه منفی مستند، با یک سیگنال یادگیری مثبت، گزارش شد.

۵-۱ دستاوردها

۱. نمونه اولیه کارکردی با کنترل تمام‌دوطرفه. جریان پیوسته PCM16 از مرورگر دریافت می‌شود، آشکارساز غلتان بر پایه انرژی، زیروبمی و MFCC درباره وقفه تصمیم می‌گیرد، منبع پخش متوقف می‌شود و پیش‌بافر 450 میلی‌ثانیه‌ای به نوبت بعدی منتقل می‌گردد. در پیل ثابت اعتبارسنجی، زنجیره با پاسخ‌گوی Qwen2.5-0.5B در هر 9 ردیف رونویسی فارسی، پاسخ فارسی و صوت غیرساکت تولید کرد و به پاسخ جایگزین قاعده‌محور بازنگشت. پاسخ‌گوی تحویل‌شده سپس به Qwen3-4B با پرامپت v2 ارتقا یافت؛ آن پیل پس از ارتقا دوباره اجرا نشد.

۲. مجموعه داده ممیزی‌شده. از موجودی 775.887 ساعتی، 6,754 جفت با 108.584 ساعت صوت استریو ساخته شد که درون بازه 100 تا 200 ساعت است. تفکیک بر پایه شناسه نشست منبع انجام شد و نشت گروهی صفر بود.

۳. نتیجه مثبت خودکار معنایی. پس از صلاحیت هفت‌ردیفی، آزمون نهایی 40 ردیفی از هر هفت شرط خودکار عبور کرد: ارتباط از 1.425 به 3.150 و انسجام به 3.325 رسید، با نرخ برد زوجی 67.5 درصد و اعتبار 240/240 فراخوانی داور. داور هم‌خانواده است و این سنجه جایگزین ارزیابی انسانی نیست.

۴. نتیجه منفی مستند برای مسیر مستقیم. شش نسل آزمایشی زیان را کاهش داد اما هیچ چک‌پوینتی از شرط اجرای خودرگرسیو عبور نکرد. نسخه v6.2 کاهش 32.20 درصدی زیان متنی درون‌نمونه داشت و هر چهار چک‌پوینت آن 0 از 9 گرفتند.

۵. روش کاری شواهدمحور. پروتکل‌ها پیش از اجرا قفل شدند، مصنوعات یک‌بارنوشت‌اند، و جمع‌کننده شکست‌بسته مانع از ارتقای تقریب خودکار به شواهد رسمی می‌شود.

برای چهار نیازمندی هنوز شواهد رسمی کامل گردآوری نشده است: تأخیر سرتاسری 500 میلی ثانیه، عبور رسمی تشخیص وقفه از 80 درصد با برچسب مستقل، ارزیابی روی پردازنده گرافیکی فیزیکی هدف، و مطالعه انسانی.

۱-۶ ساختار این نوشتار

فصل ۲ مفاهیم لازم و جایگاه کار را فشرده می‌کند. فصل ۳ روش ساخت داده، معماری آبشاری، آشکارساز وقفه، آزمایش‌های مسیر مستقیم و کلاس‌های شواهد را شرح می‌دهد. فصل ۴ نتایج اندازه‌گیری‌شده را با مرز ادعای هر یک گزارش می‌کند. فصل ۵ تفسیر، محدودیت‌ها و کارهای آینده را جمع می‌بندد.

فصل ۲

پیشینه و مفاهیم لازم

این فصل تنها مفاهیمی را می‌آورد که برای خواندن روش و نتایج ضروری است، و جایگاه پروژه را در برابر کارهای پیشین مشخص می‌کند.

۱-۲ دو خانواده معماری

سامانه‌های گفت‌وگوی گفتاری در دو خانواده قرار می‌گیرند. در خانواده **آبشاری**، بازشناسی گفتار، موتور گفت‌وگوی متنی و تبدیل متن به گفتار جداگانه اجرا می‌شوند. این معماری قابل ممیزی و قابل جایگزینی است، اما تأخیر مؤلفه‌ها جمع می‌شود و خطای هر مرحله به مرحله بعد منتقل می‌گردد. در خانواده **سرتاسری**، مدل مستقیماً از گفتار به گفتار می‌رود. مدل‌های تمام‌دوطرفه ذاتی، مانند Moshi، دو جریان صوتی را به صورت موازی مدل می‌کنند و برای نوبت‌گیری به بخش‌بندی صریح گفتار نیاز ندارند. تعریف این پروژه روح سرتاسری دارد، اما بودجه کارشناسی و نبود آموزش‌دهنده رسمی فارسی، مسیر آبشاری را به عنوان سامانه تحویل‌شده اجتناب‌ناپذیر کرد.

۲-۲ مدل زبانی، تطبیق کم‌پارامتر، و اریبی مواجهه

پاسخگوی متنی این پروژه یک مدل دستورپیرو است. تنظیم دقیق کامل یک مدل چندمیلیارد پارامتری روی سخت‌افزار محدود عملی نبود؛ بنابراین مسیر مستقیم از LoRA [۸] استفاده کرد: به‌روزرسانی وزن به صورت حاصل دو ماتریس رتبه پایین روی وزن منجمد اضافه می‌شود.

نکته تعیین‌کننده برای تفسیر نتایج مسیر مستقیم، تفاوت آموزش و استنتاج است. در آموزش، مدل در هر گام نشانه مرجع پیشین را می‌بیند؛ این شیوه **تحمیل معلم** است و زیان گزارش‌شده تحت همین شرط محاسبه می‌شود. در استنتاج، مدل باید بر نشانه‌های تولیدی خودش شرط بگذارد. اگر این دو توزیع فاصله بگیرند، خطا تجمعی می‌شود. این ناسازگاری **اریبی مواجهه** نام دارد [۹] و راهکار متعارف آن نمونه‌گیری

زمان‌بندی‌شده است [۱۰]. پیامد عملی صریح است: کاهش زیان تحت تحمیل معلم، تولید خودرگرسیو معتبر را تضمین نمی‌کند.

۳-۲ بازشناسی، گفتارسازی، و ویژگی‌های وقفه

بازشناسی گفتار سامانه، یک مدل ترکیبی RNNT-CTC از خانواده Conformer است که به‌صورت محلی با پشته NeMo [۱۱] اجرا می‌شود. تبدیل متن به گفتار با موتور Piper [۱۲] و مدل صوتی فارسی انجام می‌گیرد.

آشکارساز وقفه ویژگی‌های کلاسیک را به‌صورت غلتان محاسبه می‌کند: انرژی، نرخ گذر از صفر، ضرایب MFCC [۱۳] و بسامد پایه با روش YIN [۱۴]. طبقه‌بند، تقویت‌گرادیانی است [۱۵]. فاصله‌های اطمینان دقت با روش ویلسون [۱۶] و در سطح نشست به‌صورت بلوکی گزارش می‌شوند. در گفت‌وگوی انسانی، شکاف‌های نوبت‌گیری اغلب در حدود ۲۰۰ میلی‌ثانیه است [۱۷]؛ بنابراین تصمیم وقفه باید بسیار سریع‌تر از تولید کامل پاسخ گرفته شود.

۴-۲ جایگاه در کارهای پیشین

Mini-Omni2 و LLaMA-Omni2 مخزن استنتاج دارند اما آموزش‌دهنده کامل و رسمی گفتاربه‌گفتار ارائه نمی‌دهند. Freeze-Omni تمام‌دوطرفه است اما آموزش‌دهنده آن برای زبان جدید کامل نیست. Qwen2.5-Omni فارسی را در فهرست ورودی و خروجی گفتاری ندارد و نسخه هفت‌میلیاردپارامتری آن از بازه حافظه هدف خارج است. PersonaPlex [۱۸] بر پایه Moshi نقش و صدا را شرطی می‌کند، اما در زمان تصمیم این پروژه آموزش‌دهنده رسمی و در دسترس برای زبان جدید فراهم نبود. در میان مدل‌های بررسی‌شده، تنها خانواده Moshi هر سه شرط مسیر مستقیم را داشت: تمام‌دوطرفه ذاتی، وزن متن‌باز، و آموزش‌دهنده رسمی تطبیق کم‌پارامتر.

برای فارسی، منابع خوانشی تک‌گوینده جایگزین پیکره مکالمه‌ای تعاملی نیستند. جدول ۱-۲ این مقایسه را خلاصه می‌کند.

۵-۲ سنجه‌ها و داوری مدل

کیفیت مکانیکی زنجیره با عبور ردیف از شروط رونویسی فارسی، پاسخ فارسی و صوت غیرساکت سنجیده می‌شود. حفظ محتوای گفتار تولیدشده با بازبازشناسی و نرخ خطای نویسه و واژه تقریب زده می‌شود؛ این سنجه فهم‌پذیری انسانی نیست. کیفیت معنایی پاسخ با داوری مدل زبانی روی ارتباط و انسجام، به‌صورت دوسوکور و با دو تکرار، اندازه گرفته شد. چون داور و نامزد از یک خانواده‌اند، نتیجه در کلاس «تقریب

جدول ۲-۱: مقایسه این پروژه با کارهای پیشین از نظر قابلیت‌های تعریف پروژه

کار	تمام دوطرفه	وزن متن باز	آموزش دهنده رسمی	پشتیبانی فارسی	بازه حافظه
Mini-Omni2	فرمان محور	دارد	ندارد	ندارد	مناسب
LLaMA-Omni2	ندارد	دارد	ندارد	ندارد	مناسب
Freeze-Omni	دارد	دارد	جزئی	ندارد	مناسب
Qwen2.5-Omni	دارد	دارد	ندارد	ندارد	نامناسب
Moshi	ذاتی	دارد	دارد	ندارد	نامناسب
PersonaPlex	ذاتی	دارد	جزئی	ندارد	نامناسب
این پروژه، مسیر آبشاری	کنترل بیرونی	دارد	بی نیاز	دارد	مناسب
این پروژه، مسیر مستقیم	ذاتی	دارد	دارد	ناموفق	نامناسب

ستون «بازه حافظه» تناسب با 12 تا 24 گیگابایت تعریف پروژه است، نه کیفیت علمی مدل. «ناموفق» در مسیر مستقیم به معنای شکست شرط اجرای خودرگرسیو است، نه کاهش نیافتن زیان.

خودکار هم خانواده» می ماند و جانشین ارزیابی انسانی یا معیار ITU-T P.800 [۱۹] نیست. تفکیک آموزش، اعتبارسنجی و آزمون همیشه بر پایه شناسه نشست منبع است تا نشت گروهی رخ ندهد.

فصل ۳

روش پیشنهادی و پیاده‌سازی

این فصل ساختار سامانه تحویل‌شده، زنجیره داده، آشکارساز وقفه، طراحی آزمایش‌های مسیر مستقیم، و روش کاری شواهدمحور را شرح می‌دهد.

۱-۳ تلاش اولیه و بازنگری

نخستین پیاده‌سازی بر پایه LLaMA-Omni2 بود: کدگذار منجمد Whisper، لایه تصویرگر، مدل زبانی Qwen2.5-0.5B [۲۰] با آداپتر LoRA، و سرهای جداگانه بازشناسی و تولید. زیان کاهش یافت، اما ممیزی درونی سه اشکال بنیادی را نشان داد: مدل زبانی در تابع پیش‌رو مشارکت نداشت؛ هدف بازشناسی از درهم‌سازی‌های تصادفی در هر فرایند استفاده می‌کرد؛ و هدف تولید، بازسازی همان اظهار ورودی بود نه پاسخ گفت‌وگویی. آن مصنوع یک مدل گفتاربه‌گفتار نبود. دو تصمیم از این ممیزی آمد: سرویس‌دهی به زنجیره آبشاری با مؤلفه‌های واقعی منتقل شد، و برای مسیر مستقیم تنها مدلی پذیرفته شد که آموزش‌دهنده رسمی داشته باشد.

۲-۳ ساخت مجموعه داده


پیکره عمومی فارسی با برچسب وقفه در دسترس نبود. مجموعه داده از آرشیو داخلی محتوای گفتاری چهار کانال مشتق شد. استفاده پژوهشی داخلی با تأیید استاد راهنما ثبت شده است؛ این تأیید مجوز بازنشر صوت یا زیرنویس خام نیست و هیچ داده محدودشده‌ای در مخزن کد نیست.

در طرح نخست، برچسب متنی با اجرای مجدد سرویس بازشناسی ساخته می‌شد. همان سرویس پیش‌تر روی زیرنویس همین کانال‌ها تنظیم شده بود و یک حلقه دوری می‌ساخت. پس از شناسایی این مشکل، برچسب متنی به زیرنویس اصلی منبع تغییر یافت و بازشناسی تنها در نقش مؤلفه زمان اجرا و ابزار سنجش باقی ماند.

زنجیره چنین است: موجودی 775.887 ساعتی زیرنویس، انتخاب وزن دار برنامه، بازسازی پنجره‌های پانزده دقیقه‌ای، تفکیک گوینده، برچسب شرایط نويز، استخراج جفت «گفتار کاربر / پاسخ» بدون بازاستفاده، و ساخت استریوی ممیزی شده با کانال صفر برای دستیار بازسازی شده و کانال یک برای کاربر. تفکیک آموزش / اعتبارسنجی / آزمون بر شناسه نشست منبع است. برچسب‌های تعاملی نامزد خودکارند و شمار ردیف تأیید شده انسانی صفر است.

۳-۳ معماری سامانه آبشاری

سامانه تحویل شده یک زنجیره آبشاری با کنترل تمام دوطرفه بیرونی است (شکل ۳-۱). پیاده سازی بر PyTorch [۲۱] و Transformers [۲۲] استوار است.



شکل ۳-۱: معماری سامانه تحویل شده. ردیف بالا مسیر کنترل تمام دوطرفه و ردیف پایین زنجیره تولید پاسخ است. پیکان نقطه چین، انتقال پیش بفر میکروفون به نوبت بعدی را نشان می دهد.

جریان نوبت کاربر به بازشناسی فارسی محلی می رود و از هنجارساز قطعی متن می گذرد. پروتکل نهایی استفاده از کانال یک ممیزی شده را الزامی می کند؛ یک پنل توسعه پیشین به اشتباه کانال صفر (صدای دستیار) را رونویسی می کرد و پیش از هر ردیف اعتبارسنجی اصلاح شد.

پاسخ متنی با Qwen3-4B-Instruct-2507 [۲۳] به صورت محلی و از درخت پرونده با درهم سازی تأیید شده تولید می شود. پرامپت سامانه قفل است. نسخه v2 سه قید دارد: پاسخ فارسی، کوتاه و گفتاری، و معطوف به آخرین اظهار کاربر. اگر سهم نویسه فارسی از آستانه کمتر باشد یک تلاش دوباره انجام می شود؛ اگر هر دو تلاش شکست بخورد، پاسخ جایگزین قاعده محور تولید می گردد. شمار ردیف های جایگزین یکی از شروط پذیرش است.

پاسخ گوی تحویل شده همین مدل چهارمیلیارد پارامتری با پرامپت v2 است. پنل مکانیکی نه ردیفی و سنجه بازبازشناسی روی زنجیره پیش از ارتقا اجرا شده اند، یعنی با Qwen2.5-0.5B-Instruct (بازنگری 7ae557604adf67be50417f59c2c2f167def9a775). آن پنل پس از ارتقا دوباره اجرا نشد. آزمون معنایی 40 ردیفی روی Qwen3-4B است و داور آن Qwen3.8-27B-FP8 است (بازنگری 017b9c7af6b5689d5dd426a76e0bc077eb5ca20a).

متن پاسخ با Piper به موج تبدیل می شود. در همه ردیف های ارزیابی، شرط پذیرش این است که موتور واقعاً Piper بوده باشد. صوت خروجی از نظر متناهی بودن، طول کمینه، هنجارسازی دامنه و غیرساکت بودن با ریشه میانگین مربعات بررسی می شود.

۴-۳ تشخیص وقفه و بستر تمام دو طرفه

ویژگی‌ها روی جریان میکروفون غلتان محاسبه می‌شوند: فریم 20 میلی ثانیه، پنجره 400 میلی ثانیه، 13 ضریب MFCC با دلتا، بسامد پایه YIN در 60 تا 400 هرتز، انرژی لگاریتمی و نرخ گذر از صفر. برای هر بعد، میانگین، انحراف معیار و بیشینه روی پنجره پیوند داده می‌شود. طبقه‌بند تقویت گرادیانی 200 درخت، عمق 4، نرخ یادگیری 0.08 و کمینه 8 نمونه در برگ دارد. کلاس‌ها عبارتند از نبود رخداد، وقفه، بازخورد کلامی و نویز. خط پایه، آستانه‌گذاری انرژی و نرخ گذر از صفر است.

کنترل‌گر پخش مالک تصمیم است. آشکارساز همیشه 450 میلی ثانیه آخر میکروفون را نگه می‌دارد؛ هنگام پذیرش وقفه، این پیش‌بافر با صوت بعدی پیوند می‌خورد و ورودی نوبت بعد را می‌سازد. بستر انتقال WebSocket است. آزمون‌های بازگشتی، پیوستگی پیش‌بافر، تأیید توقف، لغو نوبت، اتصال مجدد، جداسازی نشست‌ها و حالت نگه‌داری فقط‌سنجه را پوشش می‌دهند. این آزمون‌ها پیوستگی را در سطح انتقال سرور اثبات می‌کنند. توقف منبع صوت در مرورگر واقعی با میکروفون فیزیکی اندازه‌گیری نشده است.

برای ارزیابی روی صوت واقعی، رخدادهای از مرزهای تفکیک گوینده کشف شدند. از 1,730 رخداد، 1,048 رخداد انتخاب و بر پایه نشست تقسیم شد. آستانه تصمیم تنها روی نشست‌های اعتبارسنجی انتخاب شد و یکبار روی آزمون اعمال گردید.

۵-۳ طراحی آزمایش‌های مسیر مستقیم

مسیر مستقیم، تطبیق کم‌پارامتر Moshika با آموزش دهنده رسمی است. ورودی، همان استریوی بخش ۲-۳ است. زیان، ترکیب وزن‌دار زیان متنی و زیان نشانه‌های صوتی است.

شرط پذیرش زمان اجرا پیش از آموزش قفل شد: آداپتر در سرور جویباری رسمی بار می‌شود و برای هر یک از ۹ ردیف از پیش‌تعیین‌شده باید متن، گفتار غیرساکت و قید خط فارسی برقرار باشد. چک‌پوینت تنها با 9/9 واجد شرایط است. این شرط عمداً سخت‌گیرانه است، چون کمترین زیان اعتبارسنجی در نسخه نخست تقریباً صوت ساکت و بدون متن می‌داد.

آزمایش‌ها زنجیره فرضیه‌های قابل ابطال‌اند و در هر نسل عمداً یک عامل تغییر کرد (جدول ۱-۳). نسخه v6.2 آزمون ظرفیت است نه تعمیم: آموزش و ارزیابی روی همان 32 نمونه، پنجره 12 ثانیه، و حذف تصادفی زمان‌بندی‌شده ورودی متنی از 0.25 تا 0.75. اگر زیان حتی روی داده آموزشی کاهش نیابد مشکل ظرفیت است؛ اگر کاهش یابد اما اجرا شکست بخورد، مشکل ارزیابی مواجهه است.

جدول ۳-۱: طراحی شش نسل آزمایشی مسیر مستقیم

نسخه	عامل تغییر یافته	فرضیه آزمون شده	رتبه
v1	پیکربندی پایه، پنجره 20 ثانیه	مدل با داده کافی گفتار فارسی می‌آموزد	64
v2	پنجره متن 100 ثانیه	پنجره کوتاه آغاز پاسخ را در بافت نمی‌گنجاند	64
v3	انجماد درج‌گرها، رتبه بالاتر	آموزش درج‌گرها بازنمایی پایه را تخریب می‌کند	128
v4	تنها دو درج‌گر متنی	تنها فضای متنی فارسی نیاز به تطبیق دارد	128
v5	ضریب زیان کتاب رمز نخست از 100 به 10	وزن زیاد کتاب رمز معنایی یادگیری آوایی را خفه می‌کند	128
v6.2	آزمون ظرفیت درون‌نمونه، پنجره 12 ثانیه	مدل ظرفیت یادگیری دارد و مشکل اریبی مواجهه است	64

۳-۶ روش کاری شواهدمحور

پنج قاعده عملیاتی اعمال شد. یک: پروتکل، شاخص ردیف‌ها و آستانه‌ها پیش از اجرا ثبت می‌شوند. دو: ارزیابی معنایی دومرحله‌ای است؛ تنها پس از عبور کامل صلاحیت هفت‌ردیفی، آزمون نهایی یک‌بار باز می‌شود. داور Qwen3.8-27B-FP8 با دمای صفر، ترتیب دوسوکور و دو تکرار است. سه: مصنوعات نتیجه یک‌بارنوشت‌اند. چهار: هر اندازه‌گیری یک کلاس شواهد دارد (جدول ۲-۳) و تنها کلاس رسمی می‌تواند نیازمندی تعریف پروژه را اثبات کند. پنج: تجمیع‌کننده شکست‌بسته است؛ نبود مصنوع یا کلاس پایین‌تر از حد لازم، شرط را ناموفق می‌کند نه نامعلوم.

جدول ۲-۳: کلاس‌های شواهد و توان ادعای هر کلاس

کلاس شواهد	شرایط لازم	اثبات نیازمندی
رسمی سرتاسری	نشست زنده با رضایت، تأیید پخش کارخواه، میکروفون واقعی و سخت‌افزار واجد شرایط	مجاز
زنده غیررسمی	همان پروتکل، بدون سخت‌افزار یا شرایط مطالعه واجد شرایط	غیرمجاز
مؤلفه سمت سرور	زمان‌سنجی تولید یا آشکارساز، بدون اثبات رفتار شنیدنی کارخواه	غیرمجاز
تقریب مصنوعی	صوت تولیدشده یا رخداد شبیه‌سازی‌شده	تنها آزمون بازگشتی
تقریب خودکار هم‌خانواده	داوری با مدل زبانی از خانواده نامزد	غیرمجاز

پیامد این روش آن است که وضعیت شواهد هر شرط مستقل از آمادگی گزارش برای ارائه و داوری بیان شود. نتیجه نهایی، تفکیک روشن آنچه ساخته شده از آنچه با شواهد رسمی اثبات شده است.

فصل ۴

آزمایش‌ها و نتایج

برای هر نتیجه، مقدار، مخرج و مرز ادعای مجاز مشخص شده است. همه اعداد از مصنوعات ثبت شده خوانده شده‌اند.

۴-۱ پوشش شروط پذیرش و وضعیت شواهد

جدول ۴-۱ وضعیت شواهد شروط پذیرش را نشان می‌دهد. پنج شرط از نه شرط شواهد کافی دارند و برای چهار شرط شواهد تکمیلی لازم است. این وضعیت به کفایت شواهد هر شرط مربوط است و نباید با آمادگی خود گزارش برای ارائه و داوری یکسان دانسته شود.

جدول ۴-۱: پوشش شروط پذیرش پروژه

شرط پذیرش	وضعیت شواهد
نمونه اولیه کارکردی گفتار به گفتار فارسی	کافی
عبور از آزمون نهایی معنایی خودکار	کافی
خروجی ممیزی شده در بازه 100 تا 200 ساعت	کافی
حل شدن سیاست داده تحت انصراف مستند بازبینی	کافی
انتخاب معجوز کد منبع	کافی
مدل مستقیم فارسی واجد شرایط استقرار	نتیجه مثبت تازه لازم است
آشکارساز با دقت بیش از 80 درصد روی برجسب مستقل	شواهد تکمیلی لازم است
تناسب و تأخیر زنده روی سخت افزار 12 تا 24 گیگابایتی	شواهد تکمیلی لازم است
تکمیل مطالعه انسانی	شواهد تکمیلی لازم است

پنج شرط مهندسی شواهد کافی دارند. چهار ردیف پایانی هنوز به نتیجه مثبت یا شواهد رسمی تکمیلی نیاز دارند؛ برای نتایج اثبات نشده ادعای قطعی مطرح نمی‌شود.

۲-۴ مجموعه داده

جدول ۲-۴ مشخصات نهایی را نشان می‌دهد. مقدار 108.584 ساعت درون بازه ن۴ است و ممیزی خودکار یکپارچگی، شامل ترتیب کانال‌ها، درهم‌سازی و تفکیک گروهی، بدون شکست گذشته است. جدول ۲-۴: مشخصات مجموعه داده مکالمه فارسی مشتق شده

مقدار	شاخص
775.887 ساعت	موجودی زیرنویس کانال‌ها
6,754	جفت‌های پاسخ بدون بازاستفاده
123.796 ساعت	ساعت صوت منبع جفت‌ها
407/162	گویندگان / نشست‌ها
108.584 ساعت	ساعت استریوی خروجی
6,419/131/204	تفکیک آموزش / اعتبارسنجی / آزمون
0/0	نشست گروهی / شکست ممیزی خودکار
770	نامزدهای خودکار رخداد تعاملی
0	ردیف‌های تأییدشده توسط انسان

برچسب‌های تعاملی نامزد خودکارند. این مجموعه را نمی‌توان برچسب‌گذاری شده توسط انسان نامید و داده منبع قابل بازنشر نیست.

۳-۴ سامانه آشنایی: پنل مکانیکی و فهم‌پذیری


پنل اعتبارسنجی، ۹ ردیف با فاصله ثابت از فهرست‌نامه 131 ردیفی است. شاخص ردیف‌ها پیش از اجرا قفل بود. زنجیره، سرویس واقعی بازشناسی، پاسخ‌گوی Qwen2.5-0.5B-Instruct و موتور گفتاری واقعی است و ورودی کانال یک ممیزی شده کاربر است. این پنل مکانیک زنجیره را می‌سنجد، نه کیفیت معنایی Qwen3-4B. نتیجه در جدول ۳-۴ آمده است.

جدول ۳-۴: نتیجه پنل ثابت اعتبارسنجی سامانه آشنایی

مقدار	شاخص
Qwen2.5-0.5B	پاسخ‌گوی متنی پنل
9/9	ردیف‌های عبورکرده از همه شروط
0/9	ردیف‌های با پاسخ جایگزین قاعده‌محور
1.000	کمینه سهم نویسه فارسی در رونویسی و پاسخ
9/9	پاسخ‌های صوتی غیرساکت
0.133529	کمینه ریشه میانگین مربعات صوت پاسخ
5584.7/13270.2	میان / بیشینه زمان تولید کامل (ms)
0	ردیف‌های آزمون نهایی استفاده شده

میانه، صدک نودوپنجم و بیشینه طول رونویسی 445، 3977.8 و 5031 نویسه بود. همبستگی پیرسون توصیفی میان طول رونویسی و زمان تولید کامل 0.885 است؛ بلندترین رونویسی و کندترین نوبت هر دو ردیف 32 بودند. ستون زمان، مدت تولید کامل پاسخ است نه تأخیر نخستین صوت.

بازبازشناسی همان ۹ خروجی، با متن پاسخ به عنوان مرجع، نرخ خطای نویسه تجمیع خرد 7.14 درصد (47/658) و نرخ خطای واژه 30.41 درصد (52/171) را نشان داد. هیچ ردیفی تطابق کامل واژه‌ای یا نویسه‌ای نداشت. شکل ۴-۱ هر دو محور را نشان می‌دهد.



شکل ۴-۱: (الف) زمان تولید کامل در برابر طول رونویسی برای ۹ ردیف پل. (ب) نرخ خطای واژه و نویسه بازبازشناسی همان ۹ خروجی.

نتیجه مکانیکی برون‌نمونه با پاسخ‌گوی Qwen2.5-0.5B است و به Qwen3-4B تعمیم داده نمی‌شود. نه ردیف برای تعمیم جمعیتی کافی نیست. زمان تولید کامل سنجه T_{first_audio} نیست و شرط 500 میلی‌ثانیه را برآورده نمی‌کند. بازبازشناسی فهم‌پذیری انسانی یا طبیعی بودن را اثبات نمی‌کند.

۴-۴ آزمون معنایی خودکار

مرحله صلاحیت روی هفت ردیف اعتبارسنجی استفاده‌نشده همه شروط را گذراند: 42/42 فراخوانی معتبر، ارتباط 3.857 در برابر 1.000، انسجام 3.571، برد زوجی 6/7 و ارتباط حداقل دو 100 درصد. تنها پس از این عبور، آزمون نهایی یک‌بار باز شد.

آزمون نهایی روی 40 ردیف از فهرست‌نامه 204 ردیفی و در پنج نشست کنارگذاشته اجرا شد. سه بازوی دوسوکور: خط پایه قفل‌شده Qwen2.5-0.5B، نامزد Qwen3-4B با پرامپت v2، و مرجع هم‌تراز شده خودکار نوبت بعدی. داور Qwen3.8-27B-FP8 با دمای صفر و دو تکرار در هر ردیف بود. جدول ۴-۴ نتیجه را نشان می‌دهد و جدول ۴-۵ عبور هر هفت شرط از پیش تعریف شده را.

شکل ۴-۲ میانگین و توزیع امتیازها را نشان می‌دهد. امتیاز پایین مرجع هم‌تراز شده نشان می‌دهد که «گفتن نوبت بعدی پیکره» لزوماً پاسخ مناسب به اظهار کاربر نیست.

یک آزمایش جانبی LoRA روی پاسخ‌گو زیان توسعه را 31.18 درصد کاهش داد اما در ارزیابی معنایی از خط پایه پیشی نگرفت و در سامانه نهایی به کار نرفت.

جدول ۴-۴: نتیجه آزمون نهایی معنایی خودکار روی 40 ردیف گروه ناهمپوشان

شاخص	مقدار
فراخوانی معتبر داور / مورد انتظار	240/240
نرخ توافق تکرار داور	1.00
میانگین ارتباط نامزد / خط پایه / مرجع	3.150/1.425/0.950
میانگین انسجام نامزد / خط پایه	3.325/1.525
بهبود ارتباط / انسجام نسبت به خط پایه	+1.725/+1.800
برد زوجی ارتباط	27/40 (67.5%)
ارتباط حداقل دو	35/40 (87.5%)
تلاش دوباره تولید / صوت نامعتبر نامزد	0/0

جدول ۴-۵: شروط خودکار ازپیش تعریف شده آزمون نهایی

شرط	آستانه	مشاهده	وضعیت
میانگین ارتباط نامزد	≥ 2.00	3.150	برآورده
میانگین انسجام نامزد	≥ 2.50	3.325	برآورده
بهبود ارتباط	≥ 0.50	1.725	برآورده
بهبود انسجام	≥ 0	1.800	برآورده
نرخ برد زوجی ارتباط	≥ 0.60	0.675	برآورده
نرخ ارتباط حداقل دو	≥ 0.70	0.875	برآورده
اعتبار کامل مکانیکی	240/240	240/240	برآورده


عبور از هفت شرط خودکار به معنای کیفیت ادراکی یا معیار مستقل نیست. داور و نامزد هم خانواده اند.

۴-۵ تشخیص وقفه و پیوستگی انتقال

روی داده مصنوعی، طبقه بند روی 32 نمونه کنار گذاشته به دقت 1.000 رسید؛ این عدد تنها آزمون بازگشتی است، چون داده مصنوعی از همان مدل تولیدی ساخته شده که ویژگی ها را جداپذیر می کند.

ارزیابی معنادار روی رخداد های صوت واقعی بود. آستانه 0.70 تنها روی 24 نشست اعتبارسنجی انتخاب و یکبار روی 22 نشست آزمون با 132 رخداد اعمال شد (جدول ۴-۶). ماتریس درهم ریختگی: 60 منفی درست، 6 مثبت نادرست، 19 منفی نادرست و 47 مثبت درست.

آزمون بازگشتی بستر WebSocket با چهار آزمون گذشت. ممیزی مخزن 206 آزمون موفق، پوشش شاخه ای 65 درصد و بررسی نوع بدون خطا روی 49 پرونده را ثبت کرد.



شکل ۴-۲: (الف) میانگین ارتباط و انسجام سه بازوی دوسوکور. (ب) توزیع امتیاز ارتباط در 80 فراخوانی داور برای هر بازو.

جدول ۴-۶: تقریب آشکارساز وقفه روی رخدادهای صوت ضبط شده با نشست کنارگذاشته

سنجه	آشکارساز پیشنهادی	خط پایه انرژی	فاصله اطمینان 95% (بلوکی، نشست)
دقت	81.06%	78.03%	74.44% – 87.18%
امتیاز F1 وقفه	78.99%	71.84%	72.34% – 85.71%
نرخ پذیرش نادرست	9.09%	0.00%	2.63% – 16.92%
نرخ رد نادرست	28.79%	43.94%	19.30% – 37.23%

دقت نقطه‌ای 81.06 درصد از 80 درصد بالاتر است، اما کران پایین فاصله اطمینان بلوکی نشست 74.44 درصد است. برچسب‌ها از تفکیک گوینده خودکارند. بنابراین ۵ اثبات نشده است. ۲ به صورت نرم‌افزاری برآورده و به صورت رسمی اثبات نشده است.

۴-۶ مسیر مستقیم


جدول ۴-۷ شش نسل را خلاصه می‌کند. الگوی مشترک: زیان کاهش می‌یابد و شرط اجرا برآورده نمی‌شود. مقادیر کمینه زیان میان نسل‌ها مستقیماً قابل مقایسه نیستند، چون پنجره و مجموعه ارزیابی فرق دارد. برای ۷6.2 زیان درون نمونه است.

در ۷6.2 بهترین زیان متنی پس از گام 50 برابر 0.550852 است که 32.20 درصد کمتر از 0.812474 در گام 50 است و از معیار 30 درصد بالاتر می‌رود؛ یعنی آداپتر ظرفیت برازش هدف را دارد. با این حال هر چهار چک‌پوینت 0 از 9 گرفتند و در هر چک‌پوینت تنها یک ردیف از نه ردیف هم‌زمان متن و گفتار تولید کرد. شکل ۴-۳ این دو محور را در برابر هم می‌گذارد.

هیچ چک‌پوینتی واجد شرایط استقرار نیست. عبارت «مدل Moshika با موفقیت برای فارسی تنظیم شد» با این شواهد نادرست است.

جدول ۴-۷: خلاصه شش نسل مسیر مستقیم. «بهترین اجرا» بیشترین شمار ردیف عبورکرده از ۹ ردیف در میان چک‌پوینت‌های آن نسل است.

نسخه	پنجره (ثانیه)	نامزد	کمینه زیان	بهترین اجرا	واجد شرایط
v1	20	16	1.402	0/9	نه
v2	100	20	1.735	2/9	نه
v3	100	5	1.879	1/9	نه
v4	100	5	1.879	1/9	نه
v5	100	5	1.868	1/9	نه
v6.2	12	4	2.060	0/9	نه



شکل ۴-۳: (الف) بهترین زیان آفلاین هر نسل. (ب) بیشترین شمار ردیف عبورکرده از پنل اجرا، در برابر شرط 9/9.

۷-۴ تأخیر، سخت‌افزار و مطالعه انسانی

سخت‌افزار موجود NVIDIA H100 NVL با 93.09 گیگابایت حافظه بود که از بازه ۶ خارج است. سقف نرم‌افزاری حافظه، کارت 93 گیگابایتی را به کارت 24 گیگابایتی تبدیل نمی‌کند. شمار ردیف‌های واجد شرایط رسمی سرتاسری صفر است. میانه زمان تولید کامل در پنل مکانیکی 5584.7 میلی‌ثانیه است. میانه زمان سنجی سمت سرور برای توقف پخش بدون سقف حافظه 11.71 میلی‌ثانیه بود؛ این مقدار تأیید پخش مرورگر ندارد و سنجه سرتاسری نیست.

پروتکل مطالعه انسانی، رضایت‌نامه و برگه امتیازدهی در مخزن ثبت شد. اجرا تکمیل نشد: یک شرکت‌کننده، یک نفر بالای 60 سال، و 0 مجموعه امتیاز کامل. مخرج امتیازدهی صفر است. ادعای «تأخیر سامانه کمتر از 500 میلی‌ثانیه است» مجاز نیست. هیچ ادعایی درباره طبیعی بودن، رضایت کاربری یا تجربه سالمندان مطرح نمی‌شود.

۸-۴ وضعیت نهایی نیازمندی‌ها

جدول ۸-۴: وضعیت نهایی هفت نیازمندی تعریف پروژه

شماره	وضعیت	شواهد پشتیبان
۱ن	برآورده برای مسیر آبشاری	پنل ثابت 9/9 با صفر پاسخ جایگزین
۲ن	نرم‌افزاری برآورده، رسمی	چهار آزمون بازگشتی بستر؛ بدون مرورگر فیزیکی
۳ن	اثبات نشده	صفر ردیف واجد شرایط سرتاسری
۴ن	اندازه‌گیری رسمی انجام نشده	108.584 ساعت خروجی ممیزی شده
۵ن	برآورده	دقت 81.06% با برچسب خودکار؛
	اثبات نشده	کران پایین 74.44%
۶ن	شواهد رسمی موجود نیست	سخت‌افزار موجود 93.09 گیگابایتی
۷ن	شواهد رسمی موجود نیست	یک شرکت‌کننده، صفر مجموعه امتیاز کامل

۱ن در این جدول تنها عبور مکانیکی 9/9 با پاسخگوی Qwen2.5-0.5B را پوشش می‌دهد. ۳ن، ۵ن، ۶ن و ۷ن اثبات نشده‌اند.

از چهار قلم خروجی مورد انتظار، سه قلم تولید و مستند شده‌اند: نمونه اولیه آبشاری، کد منبع مستند، و مجموعه داده مکالمه فارسی. برای قلم چهارم، پروتکل و زیرساخت سنجش آماده است؛ یافته‌های تجربی تعامل سالمندان تنها پس از تکمیل مطالعه انسانی قابل گزارش خواهد بود.

فصل ۵

بحث، نتیجه‌گیری و کارهای آینده

۵-۱ فاصله زیان و تولید

یافته علمی اصلی مسیر مستقیم این است که کاهش زیان تحت تحمیل معلم از تولید خودرگرسیو معتبر جدا است. نسخه v6.2 این جداسازی را تیز می‌کند: روی همان 32 نمونه آموزشی، زیان متنی 32.20 درصد کاهش یافت اما رفتار آموخته‌شده به تولید قابل اتکا منتقل نشد. توضیح سازگار با شواهد، اریبی مواجهه است نه نبود ظرفیت. پیامد روشمند آن است که انتخاب چک‌پوینت گفتار به گفتار نباید تنها بر زیان آفلاین استوار باشد.

در مسیر آبشاری، دو جداسازی مشابه دیده شد. نخست، پنل مکانیکی 9/9 با پاسخ‌گوی 0.5B کیفیت معنایی پاسخ‌گوی 4B را ثابت نمی‌کند. دوم، عبور آزمون خودکار هم‌خانواده کیفیت ادراکی را ثابت نمی‌کند. فاصله میان نرخ خطای نویسه 7.14 درصد و نرخ خطای واژه 30.41 درصد نیز نشان می‌دهد که حفظ تقریبی نویسه‌ها با فهم‌پذیری واژه‌ای یکی نیست.

امتیاز پایین مرجع هم‌تراز شده در آزمون معنایی یادآوری می‌کند که نوبت بعدی پیکره لزوماً پاسخ مناسب به آخرین اظهار کاربر نیست؛ به همین دلیل آداپتر LoRA که زیان توسعه را کاهش داد، از خط پایه پیشی نگرفت.

۵-۲ محدودیت‌ها و ملاحظات

برای چهار نیازمندی شواهد رسمی کامل نیست: تأخیر سرتاسری، برچسب مستقل وقفه، سخت‌افزار 12 تا 24 گیگابایتی، و مطالعه انسانی. علاوه بر این، مجموعه داده از آرشیو داخلی مشتق شده و قابل بازنشر نیست؛ برچسب‌های تعاملی خودکارند؛ داور معنایی هم‌خانواده نامزد است؛ و پنل نه‌ردیفی پس از ارتقا به Qwen3-4B تکرار نشد. هیچ ادعایی درباره مناسب بودن سامانه برای سالمندان یا طبیعی بودن صدای خروجی مجاز نیست.

۳-۵ پاسخ به پرسش پژوهش

با بودجه کارشناسی، یک سامانه کارکردی گفتاربه گفتار فارسی با معماری ماژولار و کنترل وقفه بیرونی قابل ساخت است و مرتبط بودن پاسخ آن در آزمون خودکار هم خانواده بهتر از خط پایه دیده شد. یک مدل سرتاسری فارسی، با آموزش دهنده های رسمی موجود و در این بودجه، قابل دستیابی نبود. آنچه با شواهد قابل ممیزی اثبات می شود در جدول ۴-۸ آمده است: ن ۱ و ن ۴ برآورده اند، ن ۲ نرم افزاری برآورده و رسمی اثبات نشده است، و ن ۳ و ن ۵ و ن ۶ و ن ۷ اثبات نشده اند. سهم روشمند نوشتار در همین تفکیک است.

۴-۵ کارهای آینده

چهار مورد نخست تکمیل شواهداند و پژوهش تازه نمی خواهند: اندازه گیری $T_{\text{first_audio}}$ و $T_{\text{barg_in}}$ روی کارت فیزیکی ۱۲ تا ۲۴ گیگابایتی با مرورگر و میکروفون واقعی؛ اجرای مطالعه ۵ تا ۱۰ گویشور با دست کم دو نفر بالای ۶۰ سال؛ بازبینی مستقل انسانی رخدادهای وقفه و گزارش توافق میان بازبینی؛ و بازبینی شنیداری نمونه ای از مجموعه داده.

برای بهبود فنی سامانه آبشاری، تولید جویباری متن و گفتار تنها راه عملی نزدیک شدن به ۵۰۰ میلی ثانیه در این معماری است؛ محدود کردن بافت ورودی به آخرین اظهار کاربر باید دنباله رونویسی های چند هزار نویسه ای را حذف کند. برای مسیر مستقیم، تا وقتی تولید خودرگرسیو پایدار نشود، افزایش داده یا رتبه LoRA به تنهایی کافی نیست. پس از آن، کنترل نقش در سبک PersonaPlex و آموزش دهنده های جدیدتر سرتاسری قابل بررسی اند.

Bibliography

- [1] A. Défossez, L. Mazaré, M. Orsini, A. Royer, P. Pérez, H. Jégou, E. Grave, and N. Zeghidour. Moshi: A speech-text foundation model for real-time dialogue. Technical report, Kyutai, 2024. arXiv:2410.00037.
- [2] X. Wang, Y. Li, C. Fu, Y. Zhang, Y. Shen, L. Xie, K. Li, X. Sun, and L. Ma. Freeze-Omni: A smart and low latency speech-to-speech dialogue model with frozen LLM. In *Proceedings of the 42nd International Conference on Machine Learning*, volume 267 of *Proceedings of Machine Learning Research*, pages 63345–63354. PMLR, 2025.
- [3] M. F. Qharabagh, Z. Dehghanian, and H. R. Rabiee. ManaTTS Persian: A recipe for creating TTS datasets for lower-resource languages. In *Proceedings of the 2025 Conference of the Nations of the Americas Chapter of the Association for Computational Linguistics: Human Language Technologies (Volume 1: Long Papers)*, pages 9177–9206, Albuquerque, New Mexico, 2025. Association for Computational Linguistics.
- [4] J. Xu, Z. Guo, J. He, H. Hu, T. He, S. Bai, K. Chen, J. Wang, Y. Fan, K. Dang, B. Zhang, X. Wang, Y. Chu, and J. Lin. Qwen2.5-Omni technical report. *arXiv preprint arXiv:2503.20215*, 2025.
- [5] Z. Xie and C. Wu. Mini-Omni2: Towards open-source GPT-4o with vision, speech and duplex capabilities. *arXiv preprint arXiv:2410.11190*, 2024.
- [6] Q. Fang, Y. Zhou, S. Guo, S. Zhang, and Y. Feng. LLaMA-Omni 2: LLM-based real-time spoken chatbot with autoregressive streaming speech synthesis. In *Proceedings of the 63rd Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers)*, pages 18617–18629, Vienna, Austria, 2025. Association for Computational Linguistics.
- [7] Kyutai Labs. Moshi-finetune: LoRA fine-tuning for Moshi. <https://github.com/kyutai-labs/moshi-finetune>, 2024.
- [8] E. J. Hu, Y. Shen, P. Wallis, Z. Allen-Zhu, Y. Li, S. Wang, L. Wang, and W. Chen. LoRA: Low-rank adaptation of large language models. In *Proceedings of the 10th International Conference on Learning Representations*, 2022.
- [9] M. Ranzato, S. Chopra, M. Auli, and W. Zaremba. Sequence level training with recurrent neural networks. In *Proceedings of the 4th International Conference on Learning Representations*, 2016.

- [10] S. Bengio, O. Vinyals, N. Jaitly, and N. Shazeer. Scheduled sampling for sequence prediction with recurrent neural networks. In *Advances in Neural Information Processing Systems*, volume 28, pages 1171–1179, 2015.
- [11] O. Kuchaiev, J. Li, H. Nguyen, O. Hrinchuk, R. Leary, B. Ginsburg, S. Krizan, S. Beliaev, V. Lavrukhin, J. Cook, and Others. NeMo: A toolkit for building AI applications using neural modules, 2019. arXiv:1909.09577.
- [12] Rhasspy Project. Piper: A fast, local neural text-to-speech system. <https://github.com/rhasspy/piper>, 2023.
- [13] S. B. Davis and P. Mermelstein. Comparison of parametric representations for monosyllabic word recognition in continuously spoken sentences. *IEEE Transactions on Acoustics, Speech, and Signal Processing*, 28(4):357–366, 1980.
- [14] A. de Cheveigné and H. Kawahara. YIN, a fundamental frequency estimator for speech and music. *The Journal of the Acoustical Society of America*, 111(4):1917–1930, 2002.
- [15] J. H. Friedman. Greedy function approximation: A gradient boosting machine. *Annals of Statistics*, 29(5):1189–1232, 2001.
- [16] E. B. Wilson. Probable inference, the law of succession, and statistical inference. *Journal of the American Statistical Association*, 22(158):209–212, 1927.
- [17] G. Skantze. Turn-taking in conversational systems and human-robot interaction: A review. *Computer Speech & Language*, 67:101178, 2021.
- [18] R. Roy, J. Raiman, S.-g. Lee, T.-D. Ene, R. Kirby, S. Kim, J. Kim, and B. Catanzaro. PersonaPlex: Voice and role control for full duplex conversational speech models, 2026. arXiv:2602.06053.
- [19] International Telecommunication Union. Methods for subjective determination of transmission quality. *ITU-T Recommendation P.800*, 1996.
- [20] A. Yang, B. Yang, B. Zhang, B. Hui, B. Zheng, B. Yu, C. Li, D. Liu, F. Huang, H. Wei, H. Lin, J. Yang, J. Tu, J. Zhang, J. Yang, J. Zhou, J. Lin, K. Dang, and Others. Qwen2.5 technical report. *arXiv preprint arXiv:2412.15115*, 2025.
- [21] A. Paszke, S. Gross, F. Massa, A. Lerer, J. Bradbury, G. Chanan, T. Killeen, Z. Lin, N. Gimelshein, L. Antiga, and Others. PyTorch: An imperative style, high-performance deep learning library. In *Advances in Neural Information Processing Systems*, volume 32, pages 8024–8035, 2019.
- [22] T. Wolf, L. Debut, V. Sanh, J. Chaumond, C. Delangue, A. Moi, P. Cistac, T. Rault, R. Louf, M. Funtowicz, and Others. Transformers: State-of-the-art natural language processing. In *Proceedings of the 2020 Conference on Empirical Methods in Natural Language Processing: System Demonstrations*, pages 38–45, 2020.
- [23] A. Yang, A. Li, B. Yang, B. Zhang, B. Hui, B. Zheng, B. Yu, C. Gao, C. Huang, C. Lv, and Others. Qwen3 technical report. *arXiv preprint arXiv:2505.09388*, 2025.

Abstract

This project designs, implements and evaluates a prototype Persian speech-to-speech system that operates in full-duplex mode: the user microphone stays open while the assistant reply is playing, and a classical detector decision can stop the active browser audio source and carry the captured speech forward as the next user turn. To bound execution risk, two tracks were pursued in parallel: direct low-rank adaptation of the open-weight Moshika speech-to-speech model to Persian, and a modular cascade combining NeMo Persian speech recognition, an exact Qwen3-4B-Instruct-2507 text responder under a frozen prompt, and Persian Piper speech synthesis.

A derived conversational corpus was constructed from an internal archive of Persian spoken content, yielding 6,754 user/response pairs and 108.584 measured hours of stereo training audio. Training, validation and test partitions were isolated by source session identifier, and no group leakage was observed. An interruption detector was implemented from energy, fundamental-frequency and MFCC features with a gradient-boosted classifier.

After a predeclared seven-row eligibility stage passed, the Qwen3-4B prompt-v2 responder passed every one of seven predeclared automatic gates on a 40-row, source-session-group-disjoint final test. All 240 expected judge calls were valid, mean response relevance improved from 1.425 for the frozen Qwen2.5-0.5B baseline to 3.150, mean coherence reached 3.325, and the paired relevance win rate was 67.5%. The judge was a same-family Qwen3.8-27B-FP8 model, so this metric is not a human or independent evaluation. The mechanical cascade chain, with the Qwen2.5-0.5B responder, produced a Persian transcript, a Persian reply and non-silent audio on 9 of 9 frozen validation rows with zero rule-based fallbacks. An automatic re-recognition proxy over those same nine outputs measured 7.14% character error rate and 30.41% word error rate. The nine-row mechanics panel was not re-run after the responder was promoted to Qwen3-4B.

The direct track, by contrast, reduced its teacher-forced objective across six experimental generations but never produced a checkpoint satisfying the frozen autoregressive runtime criterion. Generation v6.2 achieved a 32.20% reduction in in-sample text loss, yet all four of its checkpoints passed 0 of 9 runtime rows. That track is therefore reported as a negative result with a positive learning signal, and the cascade is treated as the delivered prototype. Browser measurement on a physical 12–24 GB GPU, proof of a 500 ms end-to-end latency bound, independently human-verified interruption labels, and a 5–10 participant listening study were not completed within the project deadline and remain explicit limitations.

Keywords: Speech-to-speech, full-duplex dialogue, barge-in detection, Persian language, large language models, cascaded systems, parameter-efficient adaptation



Sharif University of Technology
Department of Computer Engineering

B.Sc. Project Report

Concise version

A Speech-to-Speech Large Language Model for Persian

By:

Mehran Bakhtiari

Supervisor:

Dr. Hossein Sameti

September 2026