



دانشگاه صنعتی شریف
دانشکده مهندسی کامپیوتر

پروژه کارشناسی
مهندسی کامپیوتر

مدل زبانی بزرگ گفتار به گفتار برای زبان فارسی

نگارش

مهران بختیاری

استاد راهنما

دکتر حسین صامتی

شهریور ۱۴۰۵

سپاسگزاری

از استاد راهنمای این پروژه، جناب آقای دکتر حسین صامتی، برای پذیرش راهنمایی این کار، برای طرح پرسش‌های دقیق درباره مرز میان شواهد مهندسی و ادعای علمی، و برای پافشاری بر این‌که نتایج منفی نیز باید صادقانه و کامل گزارش شوند، صمیمانه سپاسگزارم. بخش عمده‌ای از شکل نهایی این نوشتار، از جمله جداسازی روشن سنجه‌های خودکار از ارزیابی انسانی، نتیجه همین راهنمایی است.

همچنین از دانشکده مهندسی کامپیوتر دانشگاه صنعتی شریف برای فراهم کردن بستر آموزشی و پژوهشی این پروژه سپاسگزارم.

بخش‌های محاسباتی سنگین این پروژه، از جمله آموزش تطبیق کم‌پارامتر مدل مستقیم و اجرای سرویس‌های بازشناسی گفتار و تفکیک گوینده، بر زیرساخت پردازنده گرافیکی سازمانی انجام شد؛ از همه کسانی که دسترسی به این منابع و آرشیو گفتاری فارسی را ممکن کردند قدردانی می‌کنم. استفاده پژوهشی داخلی از این منابع با تأیید استاد راهنما ثبت شده است و به معنای مجوز بازنشر صوت یا زیرنویس خام نیست.

در پایان، از خانواده‌ام برای پشتیبانی و شکیبایی در طول ماه‌های انجام این پروژه سپاسگزارم.

چکیده

هدف این پروژه، طراحی، پیاده‌سازی و ارزیابی یک نمونه اولیه سامانه گفتاربه‌گفتار فارسی است که به‌صورت تمام‌دوطرفه کار می‌کند؛ یعنی میکروفون کاربر در هنگام پخش پاسخ نیز فعال می‌ماند و سامانه می‌تواند بر پایه یک تصمیم‌آشکارساز کلاسیک، منبع صوت در حال پخش را متوقف کند و گفتار جمع‌شده کاربر را به نوبت بعدی منتقل نماید. برای کاهش ریسک اجرایی، دو مسیر به‌طور موازی بررسی شد: نخست تطبیق مستقیم مدل متن‌باز گفتاربه‌گفتار Moshika با داده فارسی، و دوم یک سامانه آشنایی شامل بازشناسی گفتار فارسی با NeMo، تولید پاسخ متنی با Qwen3-4B-Instruct-2507 و تبدیل متن به گفتار با Piper.

از آرشيو داخلی محتوای گفتاری فارسی، یک مجموعه داده مکالمه مشتق‌شده شامل 6,754 جفت «گفتار کاربر / پاسخ» با مدت نهایی 108.584 ساعت صوت استریو ساخته شد. تفکیک آموزش، اعتبارسنجی و آزمون بر پایه شناسه نشست منبع انجام گرفت و نشت گروهی مشاهده نشد. یک ماژول تشخیص وقفه نیز بر پایه ویژگی‌های انرژی، زیروبمی و MFCC به همراه یک طبقه‌بند تقویت‌گرادیانی پیاده‌سازی شد.

پس از عبور از یک مرحله صلاحیت هفت‌ردیفی ازپیش‌قفل‌شده، پاسخ‌گوی Qwen3-4B با پرامپت v2 در آزمون نهایی 40 ردیفی گروه‌ناهمپوشان از هر هفت شرط خودکار ازپیش‌تعریف‌شده عبور کرد: هر 240 فراخوانی داور معتبر بود، میانگین ارتباط پاسخ از 1.425 برای خط پایه Qwen2.5-0.5B به 3.150 رسید، میانگین انسجام 3.325 شد و نرخ برد زوجی 67.5 درصد به‌دست آمد. داور، مدل هم‌خانواده Qwen3-8-27B-FP8 بود؛ بنابراین این سنجه جایگزین ارزیابی انسانی نیست. زنجیره مکانیکی آشنایی با پاسخ‌گوی Qwen2.5-0.5B در پنل ثابت اعتبارسنجی در هر 9 ردیف رونویسی فارسی، پاسخ فارسی و صوت غیرساکت تولید کرد و از پاسخ جایگزین قاعده‌محور استفاده نکرد. بازبازشناسی همان 9 خروجی، نرخ خطای نویسه 7.14 درصد و نرخ خطای واژه 30.41 درصد را نشان داد. این پنل پس از ارتقای پاسخ‌گو به Qwen3-4B دوباره اجرا نشد.

در مقابل، مسیر مستقیم در شش نسخه آزمایشی، با آن‌که زیان آموزشی را به‌طور پیوسته کاهش داد، هیچ چک‌پوینتی تولید نکرد که از شرط اجرای خودرگرسیو عبور کند؛ نسخه v6.2 کاهش 32.20 درصدی زیان متنی درون‌آموزشی را نشان داد اما هر چهار چک‌پوینت آن در آزمون نه‌ردیفی اجرا 0 از 9 گرفتند. این مسیر به‌عنوان یک نتیجه منفی با سیگنال یادگیری مثبت گزارش شده است و سامانه آشنایی نمونه اولیه نهایی پروژه در نظر گرفته شد. آزمون مرورگر روی پردازنده گرافیکی فیزیکی 12 تا 24 گیگابایتی، اثبات تأخیر سرتاسری حداکثر 500 میلی‌ثانیه، برچسب‌گذاری مستقل انسانی وقفه و مطالعه 5 تا 10 کاربر در مهلت پروژه انجام نشد و به‌عنوان محدودیت صریح باقی می‌ماند.

کلیدواژه‌ها: گفتاربه‌گفتار، تمام‌دوطرفه، تشخیص وقفه، زبان فارسی، مدل زبانی بزرگ، سامانه آشنایی، تطبیق کم‌پارامتر

فهرست مطالب

۱	مقدمه	۱
۱-۱	تعریف مسئله	۱
۲-۱	اهمیت موضوع	۲
۳-۱	نیازمندی‌های تعریف شده	۳
۴-۱	چالش‌های اصلی	۳
۵-۱	راهبرد دومسیره	۴
۶-۱	دستاوردهای این پروژه	۵
۷-۱	ساختار این نوشتار	۶
۲	مفاهیم اولیه	۸
۱-۲	سیگنال گفتار و ویژگی‌های آوایی	۸
۱-۱-۲	انرژی و نرخ گذرا از صفر	۸
۲-۱-۲	بسامد پایه و روش YIN	۹
۳-۱-۲	ضرایب کپستروم بسامد مل	۹
۴-۱-۲	پنجره متن و بردار تصمیم	۱۰
۲-۲	بازشناسی گفتار	۱۰
۳-۲	تبدیل متن به گفتار	۱۱
۴-۲	مدل‌های زبانی بزرگ و تطبیق کم‌پارامتر	۱۱

۱۱	۱-۴-۲ مدل زبانی خودرگرسیو
۱۲	۲-۴-۲ تحمیل معلم و اریبی مواجهه
۱۲	۳-۴-۲ تطبیق کم پارامتر و LoRA
۱۳	۵-۲ رمزینه‌های صوتی عصبی و مدل‌های گفتار به گفتار
۱۳	۱-۵-۲ کوانتیزه‌سازی برداری باقی‌مانده
۱۳	۲-۵-۲ مدل‌سازی زبانی روی نشانه‌های صوتی
۱۴	۳-۵-۲ معماری Moshi و «تک‌گویی درونی»
۱۴	۶-۲ تمام‌دوطرفه بودن و نوبت‌گیری
۱۵	۷-۲ طبقه‌بندی با تقویت گرادیانی
۱۶	۸-۲ سنجه‌ها و مفاهیم آماری ارزیابی
۱۶	۱-۸-۲ نرخ خطای واژه و نویسه
۱۶	۲-۸-۲ سنجه‌های آشکار ساز
۱۶	۳-۸-۲ فاصله اطمینان و همبستگی گروهی
۱۷	۴-۸-۲ تفکیک گروهی داده
۱۷	۵-۸-۲ داوری خودکار با مدل زبانی
۱۷	۶-۸-۲ سنجه‌های تأخیر

۳ کارهای پیشین ۱۹

۱۹	۱-۳ از زنجیره آبشاری به مدل سرتاسری
۲۰	۲-۳ مدل‌های گفتار به گفتار متن باز
۲۰	۱-۲-۳ خانواده Mini-Omni
۲۰	۲-۲-۳ خانواده LLaMA-Omni
۲۱	۳-۲-۳ Freeze-Omni و رویکرد مدل منجمد
۲۱	۴-۲-۳ Qwen2.5-Omni و معماری «اندیشمند و گوینده»
۲۱	۵-۲-۳ Moshi و انتخاب نهایی مسیر مستقیم

۲۲	۳-۲-۶ PersonaPlex و کنترل نقش در مدل تمام‌دوطرفه
۲۲	۳-۳ منابع گفتاری زبان فارسی
۲۳	۳-۴ تشخیص وقفه و نوبت‌گیری
۲۴	۳-۵ ارزیابی خودکار کیفیت گفت‌وگو
۲۴	۳-۶ جایگاه این پروژه

۴ روش پیشنهادی و پیاده‌سازی ۲۶

۲۶	۴-۱ تلاش اولیه و بازنگری در معماری
۲۷	۴-۲ ساخت مجموعه داده مکالمه فارسی
۲۷	۴-۲-۱ منبع و راهبرد
۲۷	۴-۲-۲ مراحل زنجیره
۲۸	۴-۲-۳ استخراج جفت پاسخ و برچسب تعامل
۲۹	۴-۲-۴ تفکیک گروهی و بازسازی صدای پاسخ
۲۹	۴-۳ معماری سامانه آشنایی
۳۰	۴-۳-۱ بازشناسی گفتار
۳۱	۴-۳-۲ تولید پاسخ متنی
۳۱	۴-۳-۳ تولید گفتار
۳۲	۴-۴ مازول تشخیص وقفه و بستر تمام‌دوطرفه
۳۲	۴-۴-۱ استخراج ویژگی و طبقه‌بند
۳۲	۴-۴-۲ کنترل پخش و پیوستگی نوبت
۳۳	۴-۴-۳ ارزیابی روی داده ضبط‌شده
۳۳	۴-۵ طراحی آزمایش‌های مسیر مستقیم
۳۳	۴-۵-۱ هدف آموزشی و شرط پذیرش
۳۳	۴-۵-۲ شش نسل آزمایشی
۳۵	۴-۶ روش کاری شواهدمحور

۷-۴ پیاده‌سازی و بازتولیدپذیری ۳۶

۵ آزمایش‌ها و نتایج ۳۸

۱-۵ پوشش شروط پذیرش و وضعیت شواهد ۳۸

۲-۵ مجموعه داده ۳۸

۳-۵ سامانه آبشاری: پنل مکانیکی ۳۹

۴-۵ تقریب خودکار فهم‌پذیری گفتار تولیدشده ۴۰

۵-۵ آزمون معنایی خودکار ۴۱

۱-۵-۵ مرحله صلاحیت ۴۱

۲-۵-۵ آزمون نهایی ۴۱

۳-۵-۵ آزمایش تطبیق پاسخ‌گو با LoRA ۴۲

۶-۵ تشخیص وقفه ۴۳

۱-۶-۵ آزمون مصنوعی ۴۳

۲-۶-۵ تقریب روی داده ضبط‌شده ۴۳

۷-۵ پیوستگی انتقال تمام‌دوطرفه ۴۴

۸-۵ مسیر مستقیم: شش نسل آزمایشی ۴۴

۱-۸-۵ نتیجه کل ۴۴

۲-۸-۵ نسخه نخست: زیان کنارگذاشته مثبت، اجرای ناموفق ۴۵

۳-۸-۵ نسخه دوم: روشن‌ترین نمایش شکاف ۴۶

۴-۸-۵ نسخه‌های سوم تا پنجم: آزمون فرضیه‌های هدفمند ۴۷

۵-۸-۵ نسخه ششم: تفکیک ظرفیت از تولید ۴۷

۹-۵ تأخیر و سخت‌افزار ۴۸

۱۰-۵ مطالعه انسانی ۴۸

۱۱-۵ وضعیت نهایی نیازمندی‌ها ۴۹

۵۷	۶ بحث و محدودیت‌ها
۵۷	۱-۶ فاصله میان کاهش زیان و تولید معتبر
۵۹	۲-۶ چرا نرخ خطای واژه بسیار بیشتر از نرخ خطای نویسه است
۵۹	۳-۶ چرا تطبیق پاسخ‌گو زیان را کم کرد ولی کیفیت را بهتر نکرد
۶۰	۴-۶ تعارض ساختاری میان نیازمندی‌ها
۶۱	۵-۶ ارزش و مرز نتیجه معنایی خودکار
۶۱	۶-۶ محدودیت‌ها
۶۲	۷-۶ ملاحظات اخلاقی، حریم خصوصی و حقوقی
۶۲	۱-۷-۶ خاستگاه و حقوق داده
۶۳	۲-۷-۶ حریم خصوصی در مطالعه انسانی
۶۳	۳-۷-۶ مجوز و مرزهای آن
۶۳	۴-۷-۶ کاربرد و سوءکاربرد
۶۴	۸-۶ عبارت‌هایی که این نوشتار از آن‌ها پرهیز کرده است
۶۵	۷ نتیجه‌گیری و کارهای آینده
۶۵	۱-۷ جمع‌بندی
۶۶	۲-۷ پاسخ به پرسش پژوهش
۶۷	۳-۷ کارهای آینده
۶۷	۱-۳-۷ تکمیل شواهد باقی‌مانده
۶۷	۲-۳-۷ بهبود تأخیر سامانه آشناری
۶۸	۳-۳-۷ مسیرهای جایگزین برای مدل مستقیم
۶۹	۴-۳-۷ بهبود مازول تشخیص وقفه
۶۹	۴-۷ سخن آخر
۷۰	مراجع

۷۸	آ جزئیات پیاده‌سازی و بازتولید
۷۸	آ-۱ ساختار مخزن
۷۸	آ-۲ فرایپارامترهای آزمایش‌های مسیر مستقیم
۷۸	آ-۳ فرایپارامترهای آشکارساز و پاسخ‌گو
۷۹	آ-۴ فرمان‌های بازتولید
۸۰	آ-۵ نقشه مصنوعات شواهد
۸۰	آ-۶ محیط اجرا
۸۰	آ-۷ ساخت این نوشتار

فهرست جداول

- ۱-۱ نیازمندی‌های هفت‌گانه تعریف پروژه و محل بررسی آن‌ها در این نوشتار ۳
- ۱-۳ مقایسه این پروژه با کارهای پیشین از نظر قابلیت‌های مورد نیاز تعریف پروژه ۲۵
- ۱-۴ طراحی شش نسل آزمایشی مسیر مستقیم و فرضیه‌ای که هر نسل آزمود ۳۴
- ۲-۴ کلاس‌های شواهد و توان ادعای هر کلاس ۳۶
- ۱-۵ پوشش شروط پذیرش پروژه در تاریخ تولید مصنوع تجمیعی ۳۹
- ۲-۵ مشخصات مجموعه داده مکالمه فارسی مشتق‌شده و ممیزی خودکار آن ۵۰
- ۳-۵ نتیجه پنل ثابت اعتبارسنجی سامانه آشناری ۵۱
- ۴-۵ اندازه‌گیری‌های هر ردیف پنل اعتبارسنجی سامانه آشناری ۵۲
- ۵-۵ نتیجه تقریب خودکار بازبازشناسی گفتار تولیدشده ۵۲
- ۶-۵ نتیجه آزمون نهایی معنایی خودکار روی 40 ردیف گروه‌ناهمپوشان ۵۳
- ۷-۵ شروط خودکار ازپیش‌تعریف‌شده آزمون نهایی و مقادیر مشاهده‌شده ۵۳
- ۸-۵ نتیجه تقریب آشکارساز وقفه روی رخداد‌های صوت ضبط‌شده با نشست‌های کنارگذاشته ۵۴
- ۹-۵ خلاصه شش نسل آزمایشی مسیر مستقیم. ستون «بهترین اجرا» بیشترین شمار ردیف عبورکرده از ۹ ردیف پنل اجرا در میان همه چک‌پوینت‌های آن نسل است. ۵۴
- ۱۰-۵ نمونه‌ای از چک‌پوینت‌های نسخه دوم: زیان اعتبارسنجی به‌طور یکنوا کاهش می‌یابد در حالی که شمار ردیف‌های عبورکرده از پنل اجرا افزایش نمی‌یابد ۵۴
- ۱۱-۵ نتیجه هر چک‌پوینت نسخه‌های چهارم و پنجم روی پنل اجرای نه‌ردیفی ۵۵
- ۱۲-۵ نسخه ۷6.2: سیگنال یادگیری درون‌نمونه مثبت در برابر نتیجه اجرای خودرگرسیو منفی . ۵۵

۵-۱۳	اندازه‌گیری‌های تأخیر سمت سرور. این مقادیر کلاس شواهد «مؤلفه سمت سرور»
۵۵	دارند و رسمی نیستند.
۵-۱۴	وضعیت نهایی هفت نیازمندی تعریف پروژه و کلاس شواهد پشتیبان
۷۹	۱-آ ساختار سطح نخست مخزن کد پروژه
۸۰	۲-آ فرآپارامترهای شش نسل آزمایشی تطبیق کم‌پارامتر مسیر مستقیم
۸۲	۳-آ پیکربندی ماژول تشخیص وقفه و آداپتر پاسخ‌گوی متنی
۸۳	۴-آ فرمان‌های بازتولید مراحل اصلی پروژه
۸۳	۵-آ اسکرپت‌های ارزیابی قفل‌شده
۸۴	۶-آ نقشه ادعاها و مصنوعات مرجع. همه مسیرها نسبت به شاخه results هستند.
۸۵	۷-آ مؤلفه‌های اصلی محیط اجرا و مدل‌های به‌کاررفته

فهرست تصاویر

- ۱-۴ مراحل زنجیره ساخت مجموعه داده مکالمه فارسی. هر مرحله یک فرمان مستقل با خروجی ممیزی پذیر است. ۲۸
- ۲-۴ کاهش تدریجی مقدار صوت از موجودی زیرنویس کانال‌ها تا خروجی استریوی ممیزی شده آموزش. نوار روشن، بازه 100 تا 200 ساعت مورد نظر تعریف پروژه را نشان می‌دهد. ۳۰
- ۳-۴ معماری سامانه تحویل شده. ردیف بالا مسیر کنترل تمام دوطرفه و ردیف پایین زنجیره تولید پاسخ است. پیکان نقطه چین، انتقال پیش‌بافر میکروفون به نوبت بعدی را نشان می‌دهد. ۳۰
- ۱-۵ (الف) زمان تولید کامل پاسخ در برابر طول رونویسی ورودی برای ۹ ردیف پنل اعتبارسنجی، همراه با خط برازش و همبستگی پیرسون توصیفی. (ب) نرخ خطای واژه و نویسه بازبازشناسی برای همان ۹ خروجی، همراه با مقادیر تجمیع خرد. . . . ۴۰
- ۲-۵ (الف) میانگین امتیاز ارتباط و انسجام برای سه بازوی دوسوکور، همراه با آستانه‌های ازپیش‌تعریف شده. (ب) توزیع کامل امتیاز ارتباط در 80 فراخوانی داور برای هر بازو. . ۴۲
- ۳-۵ (الف) جست‌وجوی آستانه تصمیم روی نشست‌های اعتبارسنجی؛ خط عمودی، آستانه انتخاب شده 0.70 است. (ب) مقایسه آشکارساز پیشنهادی با خط پایه انرژی روی نشست‌های آزمون؛ میله‌های خطا، فاصله اطمینان بلوکی در سطح نشست‌اند. ۴۴
- ۴-۵ (الف) بهترین زیان آفلاین هر نسل. (ب) بیشترین شمار ردیف عبورکرده از پنل اجرای نه‌ردیفی در هر نسل، در برابر شرط پذیرش 9 از 9. ۴۵

- ۵-۵ (الف) زیان آموزش نسخه نخست تحت تحمیل معلم، به همراه میانگین غلتان.
 (ب) زیان اعتبارسنجی بازارزیابی شده به تفکیک مؤلفه متنی و صوتی؛ خط عمودی،
 چک پوینت انتخاب شده است. ۴۵
- ۶-۵ نسخه دوم: زیان اعتبارسنجی روی 202 بازه در هر چک پوینت به طور یکنوا کاهش می یابد
 (خط)، در حالی که شمار ردیف های عبور کرده از پنل اجرای نه ردیفی (میلها) هرگز به
 شرط پذیرش نمی رسد. ۴۶
- ۷-۵ نسخه ۷6.2: (الف) زیان درون نمونه به طور پیوسته کاهش می یابد و کاهش زیان متنی از
 گام 50 به بهترین گام بعدی 32.20 درصد است. (ب) با این حال هر چهار چک پوینت
 0 از 9 ردیف پنل اجرا را می گذرانند. ۴۷

فصل ۱

مقدمه

گفت‌وگوی گفتاری، طبیعی‌ترین شکل تعامل انسان با ماشین است. با این حال، تا همین اواخر سامانه‌های گفت‌وگوی گفتاری تقریباً همیشه از زنجیره‌ای از مؤلفه‌های مستقل ساخته می‌شدند: تشخیص فعالیت گفتاری، بازشناسی گفتار، یک موتور گفت‌وگوی متنی و سپس تبدیل متن به گفتار. معرفی مدل‌هایی مانند Moshi [۱] و Freeze-Omni [۲] نشان داد که می‌توان گفت‌وگوی گفتاری را به صورت یک مسئله «گفتار به گفتار» و در قالب یک مدل یکپارچه مدل کرد؛ مدلی که هم‌زمان می‌شنود و سخن می‌گوید و برای نوبت‌گیری به بخش‌بندی صریح گفتار نیاز ندارد.

این تحول برای زبان‌های پرمنبع مانند انگلیسی و چینی رخ داده است. برای زبان فارسی هیچ‌یک از مدل‌های گفتار به گفتار متن‌باز موجود پشتیبانی رسمی ارائه نمی‌کنند، و مجموعه داده‌های مکالمه‌ای فارسی که هم‌پوشانی گفتار، وقفه و بازخورد کلامی را پوشش دهند نیز به صورت عمومی در دسترس نیستند. پرسش عملی این پروژه از همین شکاف برمی‌آید: با بودجه محاسباتی و زمانی یک پروژه کارشناسی، تا چه اندازه می‌توان یک سامانه گفتار به گفتار فارسی تمام‌دوطرفه ساخت، و مهم‌تر از آن، چه چیزی را می‌توان درباره آن با شواهد قابل‌ممیزی «اثبات» کرد؟

۱-۱ تعریف مسئله

هدف تعریف‌شده این پروژه، طراحی، پیاده‌سازی و ارزیابی یک نمونه اولیه از یک مدل زبانی بزرگ گفتار به گفتار برای زبان فارسی است. سامانه باید به صورت «تمام‌دوطرفه»^۱ کار کند؛ یعنی برخلاف

^۱ full-duplex

سامانه‌های نیم‌دوطرفه که تنها پس از پایان یافتن پاسخ به کاربر گوش می‌دهند، میکروفون کاربر در طول پخش پاسخ نیز فعال بماند و سامانه بتواند در صورت «وقفه»^۲ کاربر واکنش نشان دهد. سه ویژگی این مسئله را از یک سامانه پرسش و پاسخ گفتاری متعارف جدا می‌کند:

- **هم‌زمانی شنیدن و گفتن.** سامانه باید در حالی که خروجی صوتی خود را پخش می‌کند، جریان ورودی میکروفون را نیز پردازش کند و درباره ادامه یا توقف پخش تصمیم بگیرد.
- **تصمیم‌گیری زمان‌حساس.** تصمیم توقف پخش باید در مقیاس چندده میلی‌ثانیه گرفته شود، وگرنه کاربر احساس می‌کند سامانه حرف او را نمی‌شنود.
- **تداوم گفتار قطع شده.** گفتاری که کاربر در لحظه وقفه ادا می‌کند نباید از دست برود؛ این گفتار باید به نوبت بعدی منتقل شود، در غیر این صورت کاربر ناچار می‌شود جمله خود را تکرار کند.

۲-۱ اهمیت موضوع

پرداختن به این مسئله برای زبان فارسی از چند جهت اهمیت دارد.

نخست، **دسترس‌پذیری.** رابط گفتاری برای کاربرانی که با صفحه‌کلید فارسی راحت نیستند، برای کاربران کم‌بینا و به‌طور خاص برای سالمندان، می‌تواند تنها راه مؤثر استفاده از خدمات دیجیتال باشد. در گفت‌وگوی طبیعی سالمندان، مکث‌های بلندتر و اصلاح‌های میان‌جمله‌ای بیشتر رخ می‌دهد؛ یک سامانه نیم‌دوطرفه که تا پایان پاسخ خود گوش نمی‌دهد، در این شرایط تجربه‌ای آزارنده می‌سازد.

دوم، **کم‌منبع‌بودن فارسی در این حوزه خاص.** برای فارسی مجموعه داده‌های بازشناسی گفتار و تبدیل متن به گفتار در دسترس است؛ نمونه شاخص آن ManaTTS [۲] با بیش از 86 ساعت گفتار تک‌گوینده است. اما این منابع، تک‌گوینده و خوانشی‌اند و پدیده‌های تعاملی‌ای که یک مدل تمام‌دوطرفه باید یاد بگیرد، یعنی هم‌پوشانی و وقفه و بازخورد کلامی، در آن‌ها وجود ندارد.

سوم، **هزینه محاسباتی.** مدل‌های گفتار به گفتار روز، مانند Qwen2.5-Omni [۴]، برای اجرا به حافظه‌ای بسیار بیش از یک کارت گرافیک آزمایشگاهی نیاز دارند. نشان دادن این‌که چه چیزی در بازه حافظه 12 تا 24 گیگابایت «قابل دستیابی» و چه چیزی «قابل دستیابی نیست»، خودش یک نتیجه مهندسی سودمند است.

^۲ interruption

۳-۱ نیازمندی‌های تعریف شده

تعریف پروژه هفت نیازمندی مشخص را تعیین کرده است. این نیازمندی‌ها در سراسر این نوشتار به عنوان معیار سنجش دستاورد به کار می‌روند و در جدول ۱-۱ فهرست شده‌اند. برای هر نیازمندی، فصل مربوط به نتایج (فصل ۵) وضعیت نهایی و کلاس شواهد پشتیبان آن را گزارش می‌کند.

جدول ۱-۱: نیازمندی‌های هفت‌گانه تعریف پروژه و محل بررسی آن‌ها در این نوشتار

شماره	نیازمندی	سنجه تعیین شده
۱ن	نمونه اولیه گفتار به گفتار فارسی	تولید پاسخ گفتاری فارسی از ورودی گفتاری فارسی
۲ن	کارکرد تمام دوطرفه	شنیدن در هنگام پخش و واکنش به وقفه
۳ن	تأخیر سرتاسری	حداکثر 500 میلی ثانیه از دریافت گفتار تا تولید پاسخ گفتاری
۴ن	مجموعه داده مکالمه فارسی	100 تا 200 ساعت گفتار همراه با نویز، هم پوشانی و قطع و وصل کلام
۵ن	ماژول تشخیص وقفه	دقت بالای 80 درصد با ویژگی‌های انرژی، زیروبمی و MFCC
۶ن	ارزیابی روی سخت افزار هدف	پردازنده گرافیکی با 12 تا 24 گیگابایت حافظه
۷ن	ارزیابی انسانی	5 تا 10 گویشور فارسی، دست کم دو نفر بالای 60 سال

خروجی نهایی مورد انتظار نیز شامل چهار قلم است: یک نمونه اولیه کارا، کد منبع مستند، یک مجموعه داده مکالمه فارسی، و یافته‌های مربوط به نحوه تعامل سالمندان فارسی زبان با سامانه. برای قلم چهارم، پروتکل و زیرساخت سنجش آماده شده است؛ یافته تجربی آن تنها پس از تکمیل مطالعه انسانی قابل ادعا خواهد بود و از این رو در این نوشتار ادعایی درباره تجربه سالمندان مطرح نمی‌شود.

۴-۱ چالش‌های اصلی

در جریان اجرای پروژه، چهار چالش تعیین کننده ظاهر شد که شکل نهایی کار را تغییر داد.

نبود یک مسیر آموزشی رسمی برای فارسی. مدل Mini-Omni2 [۵] که در تعریف پروژه به عنوان نمونه مدل پایه نام برده شده است، و همچنین LLaMA-Omni2 [۶]، مخزن‌هایی برای استنتاج منتشر کرده‌اند اما آموزش‌دهنده کامل و رسمی گفتار به گفتار ارائه نمی‌دهند. در میان مدل‌های بررسی‌شده، تنها خانواده Moshi یک آموزش‌دهنده رسمی تطبیق کم‌پارامتر منتشر کرده بود [۷]؛ به همین دلیل مسیر مستقیم این پروژه بر پایه Moshika، نسخه هفت‌میلیارد پارامتری این خانواده، بنا شد.

نبود داده مکالمه‌ای برجسب‌دار فارسی. هیچ پیکره عمومی فارسی با برجسب وقفه و هم‌پوشانی در اختیار نبود. مجموعه داده این پروژه ناچار از یک آرشیو داخلی محتوای گفتاری فارسی و با یک زنجیره خودکار شامل بازسازی پنجره، تفکیک گوینده و استخراج جفت پاسخ ساخته شد. پیامد این انتخاب آن است که برجسب‌های تعاملی حاصل «خودکار» اند و نه تأییدشده توسط انسان؛ این مرز در سراسر نوشتار حفظ شده است.

فاصله میان کاهش زیان و تولید معتبر. مهم‌ترین یافته منفی پروژه همین است. تطبیق کم‌پارامتر مدل مستقیم، در شش نسل آزمایشی، زیان «تحمیل معلم»^۳ را به‌طور پیوسته کاهش داد، اما هیچ‌گاه به تولید «خودگرسیو»^۴ معتبر گفتار فارسی نرسید. این مشاهده نشان می‌دهد که کاهش زیان آفلاین به‌تنهایی معیار کافی برای انتخاب مدل گفتار به گفتار نیست.

مرز میان شواهد مهندسی و ادعای علمی. سنجه‌های خودکار در دسترس بودند، اما ارزیابی انسانی، سخت‌افزار هدف و برجسب‌گذاری مستقل وقفه در مهلت پروژه فراهم نشد. تصمیم روشمند پروژه این بود که هر سنجه با «کلاس شواهد» خود برجسب‌گذاری شود و هیچ تقریب خودکاری به جای شواهد رسمی ارائه نگردد. این تصمیم در بخش ۴-۶ به یک روش کاری تبدیل شده است.

۵-۱ راهبرد دومسیره

برای کاهش ریسک اجرایی، پروژه دو مسیر را به‌طور موازی پیش برد:

۱. مسیر مستقیم. تطبیق کم‌پارامتر مدل Moshika با داده مکالمه فارسی، به این امید که یک مدل واحد گفتار به گفتار فارسی به دست آید. این مسیر پاسخ مستقیم به روح تعریف پروژه است.

^۳ teacher forcing
^۴ autoregressive

۲. مسیر آشنایی. یک زنجیره ماژولار شامل بازشناسی گفتار فارسی، تولید پاسخ متنی با یک مدل زبانی بزرگ و تبدیل متن به گفتار، که کنترل تمام دوطرفه و منطق وقفه به صورت جداگانه روی آن سوار می‌شود. این مسیر تضمین می‌کند که پروژه یک سامانه کارکردی قابل نمایش داشته باشد.

هر دو مسیر از یک مجموعه داده مشترک استفاده کردند. نتیجه نهایی، همان‌طور که در فصل ۵ گزارش می‌شود، نامتقارن بود: مسیر آشنایی از همه شروط خودکار ازپیش‌تعریف‌شده عبور کرد و به‌عنوان نمونه اولیه تحویل‌شده انتخاب شد، در حالی که مسیر مستقیم به‌عنوان یک نتیجه منفی مستند، همراه با یک سیگنال یادگیری مثبت، گزارش شده است.

۱-۶ دستاوردهای این پروژه

دستاوردهای این پروژه را می‌توان در پنج مورد خلاصه کرد.

۱. یک نمونه اولیه کارکردی گفتار به گفتار فارسی با کنترل تمام دوطرفه. سامانه، جریان پیوسته صوت PCM16 را از مرورگر دریافت می‌کند، با یک آشکارساز غلتان بر پایه انرژی، زیروبمی و MFCC درباره وقفه تصمیم می‌گیرد، منبع صوت در حال پخش را متوقف می‌کند و پیش‌بافر 450 میلی‌ثانیه‌ای میکروفون را به نوبت بعدی منتقل می‌کند. در یک پنل ثابت و ازپیش‌فعل‌شده اعتبارسنجی، زنجیره مکانیکی با پاسخ‌گوی Qwen2.5-0.5B در هر 9 ردیف رونویسی فارسی، پاسخ فارسی و صوت غیرساکت تولید کرد و هیچ‌گاه به پاسخ جایگزین قاعده‌محور بازنگشت. پاسخ‌گوی متنی سامانه تحویل‌شده سپس به Qwen3-4B با پرامپت v2 ارتقا یافت؛ پنل مکانیکی نه‌ردیفی پس از این ارتقا دوباره اجرا نشد.

۲. یک مجموعه داده مکالمه فارسی مشتق‌شده و ممیزی‌شده. از یک موجودی 775.887 ساعتی، مجموعه‌ای شامل 6,754 جفت «گفتار کاربر / پاسخ» با 108.584 ساعت صوت استریو ساخته شد که درون بازه 100 تا 200 ساعت مورد نظر تعریف پروژه قرار دارد. تفکیک آموزش، اعتبارسنجی و آزمون بر پایه شناسه نشست منبع انجام شد و ممیزی خودکار، نشأت گروهی صفر را تأیید کرد.

۳. یک نتیجه مثبت خودکار برای کیفیت معنایی پاسخ. پس از عبور از یک مرحله صلاحیت هفت‌ردیفی، آزمون نهایی 40 ردیفی گروه‌ناهمپوشان از هر هفت شرط خودکار ازپیش‌تعریف‌شده عبور کرد: میانگین ارتباط پاسخ از 1.425 به 3.150 و میانگین انسجام به 3.325 رسید، با نرخ برد زوجی 67.5 درصد و اعتبار کامل هر 240 فراخوانی داور. داور و نامزد هم‌خانواده‌اند و این سنجه جایگزین ارزیابی انسانی نیست.

۴. یک نتیجه منفی مستند و قابل استناد برای مسیر مستقیم. شش نسل آزمایشی، هر یک با تغییر یک عامل قابل ابطال، طراحی و اجرا شد. آخرین نسل کاهش 32.20 درصدی زیان متنی درون نمونه را نشان داد اما هر چهار چک پوینت آن در آزمون اجرای خودرگرسیو نه ردیفی 0 از 9 گرفتند. این تفکیک میان «ظرفیت یادگیری» و «توانایی تولید» یافته علمی اصلی این نوشتار است.

۵. یک روش کاری شواهدمحور. همه پروتکل های ارزیابی، شاخص ردیف ها و آستانه های پذیرش پیش از اجرا قفل و ثبت شدند، مصنوعات نتیجه یک بارنوشت هستند، و یک تجمیع کننده «شکست بسته»^۵ مانع از ارتقای تقریب های خودکار به شواهد رسمی می شود.

برای چهار نیازمندی هنوز شواهد رسمی کامل گردآوری نشده است: تأخیر سرتاسری 500 میلی ثانیه، عبور رسمی تشخیص وقفه از 80 درصد با برچسب مستقل، ارزیابی روی پردازنده گرافیکی فیزیکی هدف، و مطالعه انسانی. دامنه دقیق نتایج موجود و این محدودیت ها در فصل ۶ گزارش شده اند.

۷-۱ ساختار این نوشتار

این نوشتار در هفت فصل سازمان یافته است.

فصل ۲ مفاهیم اولیه مورد نیاز را معرفی می کند: نمایش سیگنال گفتار و ویژگی های آوایی، بازشناسی گفتار و تبدیل متن به گفتار، مدل های زبانی بزرگ و تطبیق کم پارامتر، رمزینه های صوتی عصبی و معماری مدل های گفتار به گفتار، و سنجه ها و مفاهیم آماری به کاررفته در ارزیابی.

فصل ۳ کارهای پیشین را بررسی می کند و جایگاه این پروژه را در میان سامانه های آبخاری و مدل های سرتاسری گفت و گوی گفتاری، منابع گفتاری فارسی و پیشینه تشخیص وقفه مشخص می سازد.

فصل ۴ روش پیشنهادی را شرح می دهد: زنجیره ساخت مجموعه داده، معماری سامانه آبخاری، ماژول تشخیص وقفه و بستر انتقال تمام دو طرفه، طراحی آزمایش های مسیر مستقیم، و روش کاری شواهدمحور.

فصل ۵ نتایج را با جداول و شکل های مربوط ارائه می کند و برای هر نتیجه، مرز ادعای مجاز آن را می نویسد.

فصل ۶ به تفسیر نتایج می پردازد، به ویژه فاصله میان کاهش زیان و تولید معتبر، و سپس محدودیت ها و ملاحظات اخلاقی و حقوقی را برمی شمارد.

^۵ fail-closed

فصل ۷ جمع‌بندی و پیشنهادهای کار آینده را ارائه می‌کند. در پیوست نیز فرمان‌های بازتولید، فرآپارامترهای دقیق آزمایش‌ها و نقشه مصنوعات شواهد آمده است.

فصل ۲

مفاهیم اولیه

این فصل مفاهیم و ابزارهایی را معرفی می‌کند که در فصل‌های بعدی به کار می‌روند. ترتیب مطالب از سیگنال گفتار و ویژگی‌های آوایی آغاز می‌شود، به مؤلفه‌های زنجیره آبخاری و سپس به معماری مدل‌های سرتاسری گفتار به گفتار می‌رسد، و با سنج‌ها و مفاهیم آماری ارزیابی پایان می‌یابد.

۲-۱ سیگنال گفتار و ویژگی‌های آوایی

گفتار در این پروژه به صورت سیگنال تک‌کاناله با بسامد نمونه برداری 16 کیلوهرتز و نمونه‌های صحیح ۱۶ بیتی نمایش داده می‌شود. سیگنال پیوسته $x[n]$ به «فریم»‌هایی با طول ثابت تقسیم می‌شود؛ در این پروژه طول فریم 20 میلی‌ثانیه است، که با 320 نمونه معادل است. تقسیم به فریم بر این فرض استوار است که خواص آماری گفتار در بازه‌های کوتاه تقریباً ثابت‌اند.

۲-۱-۱ انرژی و نرخ گذر از صفر

ساده‌ترین ویژگی، انرژی فریم است. برای فریم t با N نمونه، انرژی لگاریتمی به صورت زیر محاسبه می‌شود:

$$E_t = \log \left(\frac{1}{N} \sum_{n=1}^N x_t^2[n] + \epsilon \right), \quad (2-1)$$

که در آن ϵ یک مقدار مثبت کوچک برای پرهیز از لگاریتم صفر است. انرژی به تنهایی برای تشخیص گفتار کافی نیست، زیرا نویز پرتوان نیز انرژی بالایی دارد. ویژگی مکمل، نرخ گذر از صفر است که تعداد تغییر علامت سیگنال را در فریم می‌شمارد:

$$Z_t = \frac{1}{2(N-1)} \sum_{n=2}^N |\text{sgn}(x_t[n]) - \text{sgn}(x_t[n-1])|. \quad (2-2)$$

آواهای واک‌دار نرخ گذر از صفر پایین و آواهای سایشی نرخ بالا دارند؛ ترکیب این دو ویژگی مبنای آشکارسازهای کلاسیک تشخیص فعالیت گفتاری است [۸].

۲-۱-۲ بسامد پایه و روش YIN

بسامد پایه یا F_0 ، بسامد ارتعاش تارهای صوتی و همان چیزی است که به‌طور ادراکی به‌عنوان زیروبمی شنیده می‌شود. تخمین F_0 در این پروژه با روش YIN [۹] انجام می‌شود. این روش بر تابع اختلاف مربعی هم‌بستگی استوار است:

$$d_t(\tau) = \sum_{n=1}^W (x_t[n] - x_t[n+\tau])^2, \quad (3-2)$$

که در آن τ تأخیر و W طول پنجره تحلیل است. سپس نسخه «هنجارشده تجمعی» این تابع ساخته می‌شود و نخستین کمینه محلی که از یک آستانه پایین‌تر بیفتد به‌عنوان دوره تناوب $\hat{\tau}$ انتخاب می‌گردد؛ بسامد پایه برابر $F_0 = f_s/\hat{\tau}$ خواهد بود. اگر هیچ کمینه‌ای از آستانه پایین‌تر نرود، فریم «بی‌واک» علامت‌گذاری می‌شود. در این پروژه بازه جست‌وجوی بسامد پایه 60 تا 400 هرتز در نظر گرفته شده است که گستره گویندگان مرد و زن را پوشش می‌دهد.

اهمیت F_0 در تشخیص وقفه آن است که آغاز یک گفتار انسانی معمولاً با ظهور ساختار واک‌دار همراه است، در حالی که نویز محیط یا صدای پخش بلندگو الگوی زیروبمی پایدار ندارد.

۳-۱-۲ ضرایب کپستروم بسامد مل

MFCC یا ضرایب کپستروم بسامد مل [۱۰] پرکاربردترین نمایش کوتاه‌مدت گفتار است و طیف فریم را به شکلی فشرده می‌کند که با ادراک شنوایی انسان هم‌خوان باشد. مراحل محاسبه چنین است:

۱. اعمال پنجره (مثلاً پنجره همینگ) و محاسبه تبدیل فوریه گسسته فریم؛

۲. محاسبه توان طیفی و عبور آن از یک بانک فیلتر مثلی که مراکز آن روی مقیاس مل توزیع شده‌اند. رابطه مقیاس مل با بسامد خطی چنین است:

$$m(f) = 2595 \log_{10} \left(1 + \frac{f}{700} \right); \quad (2-4)$$

۳. لگاریتم‌گیری از خروجی هر فیلتر؛

۴. اعمال تبدیل کسینوسی گسسته برای ناهم‌بسته کردن مؤلفه‌ها و نگه‌داشتن نخستین ضرایب.

در این پروژه 13 ضریب نگه داشته می‌شود. برای آن‌که ویژگی‌ها اطلاعات «تغییر» در زمان را نیز حمل کنند، مشتق مرتبه اول این ضرایب، که به «دلتا» شناخته می‌شود، نیز محاسبه و به بردار ویژگی افزوده می‌گردد. مجموع ویژگی‌های هر فریم بنابراین شامل انرژی، نرخ گذر از صفر، بسامد پایه، پرچم واکداری، 13 ضریب MFCC و 13 دلتای متناظر است.

۴-۱-۲ پنجره متن و بردار تصمیم

تصمیم درباره وقفه بر پایه یک فریم واحد قابل اتکا نیست. به همین دلیل ویژگی‌های فریم‌های یک «پنجره متن» گردآوری می‌شوند. در این پروژه پنجره متن 400 میلی‌ثانیه است، یعنی 20 فریم متوالی. برای هر بعد از بردار ویژگی فریم، سه آماره میانگین، انحراف معیار و بیشینه روی پنجره محاسبه و در یک بردار واحد به هم پیوند داده می‌شود. این بردار ورودی طبقه‌بند است.

۲-۲ بازشناسی گفتار

بازشناسی گفتار نگاشت یک سیگنال صوتی به رشته‌ای از واژه‌ها است. معماری‌های امروزی معمولاً یک کدگذار عصبی را با یک هدف آموزشی هم‌ترازی آزاد ترکیب می‌کنند. دو هدف پرکاربرد عبارت‌اند از «طبقه‌بندی زمانی پیوندگرا»^۱ [۱۱] که با فرض استقلال شرطی، احتمال همه هم‌ترازی‌های ممکن را حاشیه‌ای می‌کند، و «مبدل عصبی بازگشتی»^۲ [۱۲] که یک شبکه پیش‌بین زبانی را نیز در تصمیم دخیل می‌سازد و برای بازشناسی جویباری مناسب‌تر است.

^۱ Connectionist Temporal Classification (CTC)
^۲ RNN Transducer (RNNT)

معماری کدگذار مورد استفاده در سرویس بازشناسی این پروژه از خانواده Conformer [۱۳] است که لایه‌های خودتوجهی^۳ [۱۴] را با لایه‌های پیچشی ترکیب می‌کند: خودتوجهی وابستگی‌های بلندبرد و پیچش الگوهای محلی طیفی را مدل می‌کند. مدل مورد استفاده یک مدل ترکیبی RNNT-CTC با واحدهای زیرواژه است که در بستر NeMo [۱۵] پیاده‌سازی و به‌صورت یک سرویس محلی در دسترس قرار گرفته است. رویکرد جایگزین، آموزش نظارت‌ضعیف در مقیاس بزرگ است؛ نمونه شاخص آن Whisper [۱۶] است که با صدها هزار ساعت داده چندزبانه آموزش دیده و در این پروژه تنها در آزمون‌های مقایسه مؤلفه‌ای به کار رفته است.

۳-۲ تبدیل متن به گفتار

سامانه‌های تبدیل متن به گفتار امروزی معمولاً سرتاسری‌اند. معماری VITS [۱۷] که مبنای موتور Piper [۱۸] است، یک خودکدگذار وردشی شرطی را با آموزش هم‌ستیزانه و یک پیش‌بین طول جریان‌محور ترکیب می‌کند و بدون نیاز به یک نوسان‌ساز جداگانه، مستقیماً موج صوتی تولید می‌کند.

برای فارسی، مرحله پیش‌پردازش متنی اهمیت خاصی دارد. نوشتار فارسی واژه‌های کوتاه را ثبت نمی‌کند، فاصله مجازی یا «نیم‌فاصله»^۴ مرز اجزای واژه‌های مرکب را تعیین می‌کند، و شکل نوشتاری واژه‌ها ممکن است میان منابع مختلف متفاوت باشد. به همین دلیل در این پروژه یک «هنجارساز» قطعی متن فارسی پیش از هر دو مرحله ارزیابی و تولید گفتار اعمال می‌شود تا شکل نویسه‌ها، نیم‌فاصله‌ها و ارقام یکسان شوند.

استفاده از یک موتور گفتاری «قطعی» با یک مدل صوتی ثابت، یک تصمیم روشمند است: چون خروجی صوتی برای یک متن ورودی مشخص همیشه یکسان است، اندازه‌گیری‌های مبتنی بر آن قابل بازتولید می‌شوند.

۴-۲ مدل‌های زبانی بزرگ و تطبیق کم‌پارامتر

۱-۴-۲ مدل زبانی خودرگرسیو

یک مدل زبانی احتمال یک رشته نشانه $y_{1:T}$ را به‌صورت زنجیره‌ای تجزیه می‌کند:

^۳ self-attention
^۴ zero-width non-joiner (ZWNJ)

$$p_{\theta}(y_{1:T}) = \prod_{t=1}^T p_{\theta}(y_t | y_{<t}), \quad (5-2)$$

و با کمینه کردن زیان آنتروپی متقاطع روی داده آموزشی برازش می شود. معماری غالب، ترانسفورمر تنهاکدگشا [۱۴] است. مدل های «دستورپیرو»^۵ با یک مرحله تنظیم دقیق نظارت شده روی جفت های دستور و پاسخ ساخته می شوند [۱۹]؛ پاسخ گوی متنی این پروژه از همین دسته است.

۲-۴-۲ تحمیل معلم و اریبی مواجهه

نکته ای که برای تفسیر نتایج فصل ۵ تعیین کننده است، تفاوت میان شرایط آموزش و شرایط استنتاج است. در آموزش، مدل در هر گام نشانه های «درست» پیشین را به عنوان شرط دریافت می کند؛ این شیوه تحمیل معلم نامیده می شود. زبانی که در آموزش و اعتبارسنجی گزارش می شود، تحت همین شرط محاسبه می گردد. اما در استنتاج، مدل باید بر نشانه های «تولیدی خودش» شرط بگذارد. اگر توزیع نشانه های تولیدی از توزیع نشانه های مرجع فاصله بگیرد، مدل در ناحیه ای از فضای حالت قرار می گیرد که در آموزش ندیده است و خطا می تواند به صورت تجمعی رشد کند. این ناسازگاری با نام اریبی مواجهه^۶ شناخته می شود [۲۰] و راهکار متعارف آن، «نمونه گیری زمان بندی شده» است که در طول آموزش به تدریج نشانه های مرجع را با نشانه های تولیدی جانشین می کند [۲۱].

پیامد عملی این مفهوم صریح است: «کاهش زیان تحت تحمیل معلم، به خودی خود تضمین نمی کند که مدل در تولید خودرگرسیو خروجی قابل استفاده بدهد». آزمایش مسیر مستقیم این پروژه نمونه ای روشن از همین شکاف است.

۳-۴-۲ تطبیق کم پارامتر و LoRA

تنظیم دقیق کامل یک مدل چندمیلیارد پارامتری بر سخت افزار محدود عملی نیست. روش های تطبیق کم پارامتر تنها شمار کوچکی از پارامترها را آموزش می دهند [۲۲، ۲۳]. روش مورد استفاده در این پروژه LoRA [۲۴] است. ایده آن این است که به روزرسانی مورد نیاز برای یک ماتریس وزن، «رتبه پایین» دارد. برای وزن منجمد $W_0 \in \mathbb{R}^{d \times k}$ ، به جای یادگیری ΔW کامل، دو ماتریس کوچک $A \in \mathbb{R}^{r \times k}$ و $B \in \mathbb{R}^{d \times r}$ با $r \ll \min(d, k)$ آموزش داده می شوند و خروجی لایه چنین می شود:

^۵ instruction-following
^۶ exposure bias

$$h = W_0 x + \frac{\alpha}{r} B A x. \quad (6-2)$$

در آغاز، B صفر است تا مدل تطبیق‌یافته با مدل پایه یکسان باشد. پارامتر r رتبه و α ضریب مقیاس است. در این پروژه رتبه‌های 64 و 128 آزمایش شده‌اند. مزیت کلیدی LoRA برای این کار آن است که وزن‌های پایه منجمد می‌مانند و بنابراین یک آداپتر شکست‌خورده هرگز مدل پایه را خراب نمی‌کند و می‌توان آن را به‌سادگی برداشت.

۵-۲ رمزینه‌های صوتی عصبی و مدل‌های گفتار به گفتار

۱-۵-۲ کوانتیزه‌سازی برداری باقی‌مانده

برای آن‌که یک مدل زبانی بتواند گفتار تولید کند، صوت باید به رشته‌ای از نشانه‌های گسسته تبدیل شود. رمزینه صوتی عصبی این کار را با یک خودکدگذار انجام می‌دهد که در گلوگاه آن یک «کوانتیزه‌ساز برداری باقی‌مانده»^۷ قرار دارد. نمونه‌های شاخص SoundStream [۲۵] و EnCodec [۲۶] هستند. در کوانتیزه‌سازی باقی‌مانده، بردار نهفته z به‌صورت پی‌درپی تقریب زده می‌شود. اگر Q_i کتاب رمز i ام باشد، با $z = r_0$ داریم:

$$q_i = Q_i(r_{i-1}), \quad r_i = r_{i-1} - q_i, \quad \hat{z} = \sum_{i=1}^{N_q} q_i. \quad (7-2)$$

کتاب رمز نخست، اطلاعات درشت و بیشتر «معنایی» را حمل می‌کند و کتاب‌های رمز بعدی جزئیات «آوایی» را می‌افزایند. این سلسله‌مراتب دلیل آن است که در آموزش مدل‌های گفتاری، برای زیان کتاب رمز نخست ضریب بزرگ‌تری در نظر گرفته می‌شود؛ همین ضریب در یکی از آزمایش‌های این پروژه عامل تغییر بوده است.

۲-۵-۲ مدل‌سازی زبانی روی نشانه‌های صوتی

با گسسته‌شدن صوت، می‌توان همان ماشین مدل‌سازی زبانی را روی نشانه‌های صوتی اعمال کرد؛ این ایده در AudioLM [۲۷] و VALL-E [۲۸] به کار رفته است. چالش اصلی آن است که هر گام زمانی نه یک

^۷Residual Vector Quantizer (RVQ)

نشانه، بلکه N_q نشانه (یکی برای هر کتاب رمز) دارد. راه حل «ترانسفورمر کوانتیزه سازی باقی مانده»^۸ است: یک ترانسفورمر بزرگ «زمانی» روی محور زمان کار می کند و یک ترانسفورمر کوچک «عمقی» در هر گام زمانی، N_q نشانه را به صورت خودرگرسیو تولید می کند [۲۹].

۳-۵-۲ معماری Moshi و «تک گویی درونی»

مدل Moshi [۱] گفت و گو را به صورت گفتار به گفتار مدل می کند و سه ویژگی آن برای این پروژه اهمیت دارد.

نخست، رمزینه Mimi: یک رمزینه صوتی جویباری که بازنمایی معنایی را با بازنمایی آوایی در کتاب های رمز باقی مانده تلفیق می کند و با گام زمانی 80 میلی ثانیه کار می کند.

دوم، جریان های موازی: مدل به طور هم زمان دو جریان صوتی را مدل می کند، یکی گفتار خودش و دیگری گفتار کاربر. به همین دلیل مفهوم «نوبت» صریح حذف می شود و هم پوشانی، وقفه و بازخورد کلامی به طور طبیعی در مدل جای می گیرند. این ویژگی، همان چیزی است که Moshi را به یک نامزد طبیعی برای نیازمندی تمام دو طرفه بودن تبدیل می کند.

سوم، تک گویی درونی^۹: پیش از تولید نشانه های صوتی هر گام، مدل نشانه های «متنی» هم ترازشده با زمان را پیش بینی می کند. این متن میانی کیفیت زبانی گفتار تولیدی را به طور محسوس بهبود می دهد. پیامد آن برای عیب یابی این است که می توان زیان متنی و زیان صوتی را جداگانه پایش کرد؛ در فصل ۵ از همین تفکیک برای نشان دادن محل شکست مسیر مستقیم استفاده شده است.

نسخه ای از این مدل که در این پروژه به کار رفته Moshika است؛ یک مدل هفت میلیارد پارامتری با صدای زنانه، 32 لایه ترانسفورمر، بعد نهفته 4096 و 16 کتاب رمز صوتی که هشت مورد از آن ها در ترانسفورمر عمقی پیش بینی می شوند.

۶-۲ تمام دو طرفه بودن و نوبت گیری

در گفت و گوی انسانی، نوبت گیری فرایندی دقیق و سریع است. کار کلاسیک سازمان نوبت نشان داد که فاصله میان نوبت ها کوتاه و منظم است [۳۰]؛ مرورهای مهندسی بعدی، مقدار متعارف این فاصله را در حدود دودهم ثانیه گزارش کرده اند [۳۱].

^۸RQ-Transformer
^۹Inner Monologue

از دید مهندسی، سه سطح از قابلیت را باید تفکیک کرد:

- نیم‌دوطرفه: سامانه در هنگام پخش پاسخ به میکروفون گوش نمی‌دهد. کاربر باید منتظر بماند.
- تمام‌دوطرفه با کنترل بیرونی: میکروفون در هنگام پخش فعال است و یک مؤلفه «جداگانه» درباره توقف پخش تصمیم می‌گیرد. این همان معماری‌ای است که در این پروژه پیاده و ارزیابی شده است.
- تمام‌دوطرفه ذاتی: خود مدل مولد، جریان کاربر و جریان خودش را هم‌زمان مدل می‌کند و نوبت‌گیری بخشی از توزیع آموخته‌شده است؛ مانند Moshi.

در سه رخداد تعاملی که در این نوشتار برجسته‌گذاری می‌شوند تمایز زیر برقرار است: «وقفه» زمانی است که گوینده دوم آغاز به سخن می‌کند و گفتار او ادامه می‌یابد و نوبت را می‌گیرد؛ «بازخورد کلامی» یک اظهار کوتاه تأییدی است که نوبت را نمی‌گیرد؛ و «نوبت پاک» حالتی است که گوینده دوم تنها پس از پایان گفتار گوینده اول آغاز می‌کند.

۷-۲ طبقه‌بندی با تقویت گرادیانی

آشکارساز وقفه این پروژه از یک مدل تقویت گرادیانی درختی استفاده می‌کند [۳۲] که در کتابخانه scikit-learn [۳۳] پیاده‌سازی شده است. این روش یک مدل جمعی می‌سازد که در آن هر درخت جدید، گرادیان منفی زیان مدل فعلی را برازش می‌کند:

$$F_m(x) = F_{m-1}(x) + \nu h_m(x), \quad (۸-۲)$$

که در آن h_m درخت تازه و ν نرخ یادگیری است. انتخاب این خانواده مدل سه دلیل دارد: تعریف پروژه صریحاً یک ماژول مبتنی بر ویژگی‌های دست‌ساز را خواسته است؛ استنتاج آن روی پردازنده مرکزی در بودجه چندمیلی‌ثانیه‌ای هر گام صوتی جای می‌گیرد؛ و با شمار محدود رخداد‌های آموزشی، مدل‌های درختی از شبکه‌های عصبی عمیق پایدارترند.

۸-۲ سنجه‌ها و مفاهیم آماری ارزیابی

۱-۸-۲ نرخ خطای واژه و نویسه

فاصله لَوْنِشتاین [۳۴] کمینه شمار عملیات درج، حذف و جانشینی لازم برای تبدیل یک رشته به رشته دیگر است. بر پایه آن، «نرخ خطای واژه» و «نرخ خطای نویسه» تعریف می‌شوند. در این نوشتار دو شکل تجمیع گزارش می‌شود. شکل «خرد» که مجموع ویرایش‌ها را بر مجموع طول مرجع‌ها تقسیم می‌کند:

$$WER_{\text{micro}} = \frac{\sum_i d(\hat{w}^{(i)}, w^{(i)})}{\sum_i |w^{(i)}|}, \quad (9-2)$$

و شکل «کلان» که میانگین ساده نرخ خطای هر نمونه است. برای فارسی، تعریف مرز واژه اهمیت دارد: در این پروژه نشانه‌های واژه با فاصله سفید جدا می‌شوند و نیم فاصله نیز مرز به شمار می‌آید. نشانه‌های نویسه، نقاط کد یونی‌کد بدون احتساب فاصله سفید و نیم فاصله‌اند. همین تعریف باعث می‌شود نرخ خطای واژه در فارسی بسیار سخت‌گیرانه‌تر از نرخ خطای نویسه باشد؛ نکته‌ای که در فصل ۶ تفسیر می‌شود.

۲-۸-۲ سنجه‌های آشکارساز

برای رخداد دوکلاسه «وقفه در برابر غیروقفه»، ماتریس درهم‌ریختگی چهار مقدار مثبت درست، مثبت نادرست، منفی درست و منفی نادرست را می‌دهد. از آن‌ها «دقت»، «امتیاز F1» کلاس وقفه، «نرخ پذیرش نادرست»^{۱۰} و «نرخ رد نادرست»^{۱۱} محاسبه می‌شوند. در سامانه‌های تمام‌دوطرفه این دو نرخ خطا هم‌ارز نیستند: پذیرش نادرست باعث می‌شود پاسخ سامانه بی‌دلیل قطع شود، در حالی که رد نادرست باعث می‌شود سامانه به وقفه کاربر بی‌اعتنا بماند.

۳-۸-۲ فاصله اطمینان و همبستگی گروهی

برای نسبت‌ها، فاصله اطمینان ویلسون [۳۵] گزارش می‌شود که برخلاف تقریب نرمال ساده، برای نمونه‌های کوچک و نسبت‌های نزدیک به مرز نیز معتبر می‌ماند.

نکته مهم‌تر آن است که رخداد‌های برگرفته از یک نشست گفتاری «مستقل» نیستند؛ گوینده، شرایط آکوستیکی و سبک گفت‌وگو میان آن‌ها مشترک است. بنابراین یک فاصله اطمینان در سطح رخداد،

^{۱۰} False Accept Rate (FAR)

^{۱۱} False Reject Rate (FRR)

عدم قطعیت واقعی را کم برآورد می‌کند. راه‌حل به کاررفته در این پروژه «خودراه‌انداز بلوکی در سطح نشست» است: در هر تکرار باز نمونه‌گیری، «نشست»ها با جای‌گذاری انتخاب می‌شوند و نه رخدادهای تک‌تک [۳۶]. در فصل ۵ هر دو فاصله گزارش شده‌اند تا اثر این تفاوت دیده شود.

۴-۸-۲ تفکیک گروهی داده

اگر دو بخش از یک نشست گفتاری واحد در مجموعه آموزش و مجموعه آزمون قرار بگیرند، مدل می‌تواند گوینده یا موضوع را به‌خاطر بسپارد و نتیجه آزمون خوش‌بینانه شود. برای پرهیز از این «نشست گروهی»، در این پروژه واحد تفکیک «شناسه نشست منبع» است: همه جفت‌های برآمده از یک نشست، به‌طور کامل در یک و تنها یک بخش قرار می‌گیرند. تخصیص با درهم‌سازی قطعی شناسه نشست انجام می‌شود تا تفکیک بازتولیدپذیر باشد.

۵-۸-۲ داوری خودکار با مدل زبانی

سنجش کیفیت معنایی پاسخ گفت‌وگو با سنجه‌های سطح رشته ممکن نیست، زیرا برای یک پرسش، پاسخ‌های درست متعددی وجود دارد. یک جانشین متعارف، استفاده از یک مدل زبانی بزرگ به‌عنوان «داور» است [۳۷]. در این روش، پاسخ نامزد و پاسخ‌های مقایسه‌ای به‌صورت «دوسوکور» و با ترتیب تصادفی شده به داور داده می‌شوند و داور بر پایه یک سنجه‌نامه از پیش تعیین‌شده امتیاز می‌دهد.

محدودیت‌های شناخته‌شده این روش عبارت‌اند از اریبی نسبت به ترتیب ارائه، اریبی نسبت به طول پاسخ، و اریبی نسبت به پاسخ‌های تولیدشده توسط مدل‌های هم‌خانواده با داور. در این پروژه سه اقدام برای کاهش این اثرها انجام شده است: دوسوکورسازی ترتیب، کدگشایی قطعی داور با دمای صفر، و تکرار هر فراخوانی و گزارش نرخ توافق. با این حال، همان‌طور که در فصل ۶ تأکید شده است، این سنجه یک «تقریب خودکار» است و جانشین ارزیابی انسانی نمی‌شود؛ به‌ویژه آن‌که در این پروژه داور و نامزد از یک خانواده مدل‌اند.

۶-۸-۲ سنجه‌های تأخیر

دو سنجه زمانی در این نوشتار تعریف می‌شوند:

- $T_{\text{first_audio}}$: زمان از پایان گفتار کاربر تا نخستین نمونه صوتی «شنیدنی» پاسخ. مقدار رسمی این سنجه باید از سمت کارخواه گزارش شود، زیرا تنها مرورگر می‌داند که منبع صوت واقعاً زمان‌بندی شده است.

- $T_{\text{barge_in}}$: زمان از آغاز آوایی گفتار وقفه‌ای کاربر تا لحظه‌ای که پخش پاسخ «واقعاً» متوقف می‌شود؛ این مقدار نیز به تأیید کارخواه نیاز دارد.

نکته روشمند مهم آن است که «زمان تولید کامل پاسخ در سمت سرور»، سنجه $T_{\text{first_audio}}$ نیست. زمان تولید سرور یک اندازه‌گیری سودمند برای عیب‌یابی است، اما نه شرط پذیرش تأخیر. این تفکیک در فصل ۵ با دقت رعایت شده است.

فصل ۳

کارهای پیشین

این فصل پیشینه پژوهشی مرتبط را در چهار محور بررسی می‌کند: سامانه‌های گفت‌وگوی گفتاری آبشاری در برابر سرتاسری، مدل‌های گفتار به گفتار متن‌باز و قابلیت‌های تمام‌دوطرفه آن‌ها، منابع گفتاری زبان فارسی، و پیشینه تشخیص وقفه و نوبت‌گیری. در پایان فصل، جایگاه این پروژه در برابر کارهای پیشین مشخص می‌شود.

۳-۱ از زنجیره آبشاری به مدل سرتاسری

معماری متعارف سامانه‌های گفت‌وگوی گفتاری، زنجیره‌ای از چهار مؤلفه مستقل است: تشخیص فعالیت گفتاری، بازشناسی گفتار، یک موتور گفت‌وگوی متنی و تبدیل متن به گفتار. مزیت این معماری، ماژولار بودن آن است: هر مؤلفه را می‌توان جداگانه بهبود داد، اشکال‌زدایی کرد و با بهترین مدل موجود برای آن زبان جانشین ساخت. برای زبان‌های کم‌منبع، این ماژولار بودن مزیت تعیین‌کننده‌ای است، زیرا برای هر مؤلفه احتمال یافتن یک مدل فارسی قابل قبول بیشتر از یافتن یک مدل گفتار به گفتار فارسی است.

در برابر آن، نویسندگان Moshi [۱] سه ایراد بنیادی برای معماری آبشاری برمی‌شمارند. نخست، انباشت تأخیر در زنجیره که فاصله میان دو نوبت گفت‌وگو را به چند ثانیه می‌رساند. دوم، ازدست‌رفتن اطلاعات غیرزبانی: چون متن، تنها واسطه میان ورودی و خروجی است، عاطفه، لحن و صداهای غیرگفتاری که معنا را تغییر می‌دهند از میان می‌روند. سوم، وابستگی به بخش‌بندی صریح گفتار به نوبت‌ها، که هم‌پوشانی و وقفه و اظهارهای کوتاه تأییدی را نمی‌تواند نمایش دهد.

مشاهدات فصل ۵ هر دو سوی این استدلال را پشتیبانی می‌کنند. ایراد تأخیر در اندازه‌گیری‌های مسیر آبشاری دیده می‌شود: زمان تولید کامل پاسخ در زنجیره آبشاری، حتی روی سخت‌افزار پرتوان، در حدود چند ثانیه است و برای ورودی‌های بلند رشد می‌کند (بخش ۳-۵). در همان حال، مزیت ماژولار بودن نیز دیده می‌شود: تنها همین معماری بود که در بازه زمانی پروژه به یک سامانه فارسی کارکردی و قابل ارزیابی رسید.

۲-۳ مدل‌های گفتار به گفتار متن باز

۱-۲-۳ خانواده Mini-Omni

مدل Mini-Omni2 [۵]، که در تعریف پروژه به‌عنوان نمونه مدل پایه نام برده شده است، یک دستیار چندوجهی بر پایه Qwen2-0.5B است که کدگذارهای Whisper و CLIP را برای ورودی صوتی و تصویری به کار می‌گیرد و با راهبرد «تولید موازی با تأخیر متن‌راهنما» گفتار تولید می‌کند. برای مسئله ما دو ویژگی آن اهمیت دارد: نخست آن‌که سازوکار وقفه در آن «فرمان‌محور» است و نه یک تصمیم‌آوایی پیوسته؛ دوم آن‌که این پروژه آموزش‌دهنده کامل و رسمی گفتار به گفتار منتشر نکرده است، و بنابراین تطبیق آن با فارسی مستلزم بازنویسی زنجیره آموزش از صفر بود.

۲-۲-۳ خانواده LLaMA-Omni

نسخه نخست این خانواده [۳۸] از یک کدگشای گفتاری غیرخودرگرسیو برای کاهش تأخیر استفاده می‌کرد. LLaMA-Omni2 [۶] مجموعه‌ای از مدل‌های گفتاری ماژولار از 0.5 تا 14 میلیارد پارامتر است که بر پایه مدل‌های Qwen2.5-Instruct ساخته شده‌اند، کدگذار Whisper را برای ورودی و یک کدگشای گفتاری جویباری خودرگرسیو الهام‌گرفته از CosyVoice 2 [۳۹] را برای خروجی به کار می‌برند. این مدل با تنها 200 هزار نمونه گفت‌وگوی چندنوبتی آموزش دیده و از GLM-4-Voice [۴۰] که بر میلیون‌ها ساعت گفتار آموزش دیده بود پیشی گرفته است.

این مدل در آغاز پروژه گزینه اصلی بود، زیرا اندازه 0.5 میلیارد پارامتری آن در بودجه حافظه هدف جای می‌گرفت و پشته آن (کدگذار Whisper به اضافه Qwen2.5) با ابزارهای در دسترس هم‌خوان بود. اما مخزن منتشرشده تنها استنتاج را پوشش می‌دهد. تلاش نخست این پروژه برای ساخت یک زنجیره آموزش از این معماری، همان‌طور که در بخش ۴-۱ شرح داده می‌شود، به مصنوعی رسید که در واقع بازسازی ورودی را

می‌آموخت و نه تولید پاسخ گفت‌وگویی؛ این تجربه، انگیزه اصلی حرکت به سوی یک آموزش‌دهنده رسمی شد.

۳-۲-۳ Freeze-Omni و رویکرد مدل منجمد

Freeze-Omni [۲] راهبرد متفاوتی دارد: وزن‌های مدل زبانی متنی در سراسر آموزش «منجمد» می‌مانند و تنها کدگذار گفتاری ورودی و کدگشای گفتاری خروجی آموزش می‌بینند. این طراحی دو مزیت مهم دارد که برای شرایط کم‌منبع بسیار مرتبط است: هوشمندی مدل پایه دست‌نخورده می‌ماند و مسئله «فراموشی فاجعه‌بار» پیش نمی‌آید، و آموزش با داده و منابع محاسباتی بسیار کمتری امکان‌پذیر می‌شود. قابلیت تمام‌دوطرفه نیز در آن با افزودن یک لایه طبقه‌بندی حالت روی آخرین لایه مدل زبانی به دست می‌آید که پیش‌بینی می‌کند آیا کاربر گفت‌وگو را قطع کرده است یا نه.

از دید پس‌نگرانه، این رویکرد یکی از امیدبخش‌ترین گزینه‌ها برای فارسی است و در فصل ۷ به‌عنوان کار آینده پیشنهاد شده است؛ در زمان تصمیم‌گیری این پروژه، آموزش‌دهنده رسمی و در دسترس آن برای یک زبان جدید فراهم نبود.

۴-۲-۳ Qwen2.5-Omni و معماری «اندیشمند و گوینده»

Qwen2.5-Omni [۴] یک مدل سرتاسری چندوجهی است که با معماری «اندیشمند و گوینده» تولید هم‌زمان متن و گفتار را ممکن می‌سازد: بخش اندیشمند یک مدل زبانی است که متن تولید می‌کند و بخش گوینده یک مدل خودرگرسیو دومسیره است که مستقیماً از بازنمایی‌های نهفته اندیشمند، نشانه‌های صوتی می‌سازد. این مدل برای پروژه ما به دو دلیل کنار گذاشته شد: نسخه هفت‌میلیارد پارامتری آن به حافظه‌ای به‌مراتب بیش از بازه هدف ۱۲ تا ۲۴ گیگابایت نیاز دارد، و فهرست‌های منتشرشده ورودی و خروجی گفتاری آن فارسی را شامل نمی‌شوند.

۵-۲-۳ Moshi و انتخاب نهایی مسیر مستقیم

از میان مدل‌های بررسی‌شده، Moshi [۱] تنها موردی بود که هر سه شرط لازم برای این پروژه را برآورده می‌کرد: قابلیت تمام‌دوطرفه «ذاتی» از طریق مدل‌سازی موازی دو جریان صوتی، وزن‌های متن‌باز، و مهم‌تر از همه یک «آموزش‌دهنده رسمی تطبیق کم‌پارامتر» که به‌طور مستقیم از سوی سازندگان مدل منتشر شده بود [۷]. همان‌طور که در بخش ۲-۵ توضیح داده شد، سازوکار «تک‌گویی درونی» این مدل امکان پایش

جداگانه زیان متنی و زیان صوتی را نیز فراهم می‌کند که برای عیب‌یابی آزمایش‌های ناموفق ارزش عملی داشت.

پیشینه نزدیک‌تر به این ایده، dGSLM [۴۱] است که مدل‌سازی مولد گفت‌وگوی گفتاری را با دو جریان موازی و بدون واسطه متنی معرفی کرد و نشان داد که پدیده‌هایی مانند هم‌پوشانی و بازخورد کلامی را می‌توان به‌صورت آموخته‌شده بازتولید کرد.

۳-۲-۶ PersonaPlex و کنترل نقش در مدل تمام‌دوطرفه

PersonaPlex [۴۲] یک مدل گفتاربه‌گفتار تمام‌دوطرفه بر پایه معماری Moshi است که با پرامپت ترکیبی متنی و نمونه صوتی، نقش و صدای دستیار را شرطی می‌کند. وزن‌های متن‌باز آن منتشر شده‌اند و قابلیت تمام‌دوطرفه ذاتی را حفظ می‌کنند. برای این پروژه اما دو محدودیت تعیین‌کننده داشت: انتشار آن انگلیسی‌محور است و فارسی در آن پشتیبانی نشده است، و سخت‌افزار آزمون‌شده مستند آن خارج از بازه 12 تا 24 گیگابایت نیازمندی ۶ است. همچنین یک آموزش‌دهنده رسمی برای تطبیق آن با زبانی جدید، در زمان تصمیم‌گیری این پروژه، در دسترس نبود. بنابراین به‌عنوان گزینه مقایسه در نظر گرفته شد و برای مسیر مستقیم انتخاب نشد.

۳-۳ منابع گفتاری زبان فارسی

برای فارسی، وضعیت منابع در سه حوزه نامتقارن است.

در **بازشناسی گفتار**، مدل‌های قابل استفاده وجود دارند. پیکره چندزبانه Common Voice [۴۳] بخش فارسی دارد، و مدل‌های بومی‌سازی‌شده بر پایه معماری Conformer در بستر NeMo [۱۵] به کیفیت قابل قبولی رسیده‌اند. سرویس بازشناسی به‌کاررفته در این پروژه از همین دسته است.

در **تبدیل متن به گفتار**، شاخص‌ترین منبع عمومی ManaTTS [۳] است: بزرگ‌ترین پیکره عمومی تک‌گوینده فارسی با حدود 86 ساعت صوت با بسامد نمونه‌برداری 44.1 کیلوهرتز و مجوز آزاد، همراه با یک زنجیره پردازش متن‌باز شامل ابزار بخش‌بندی جمله و یک روش هم‌ترازی اجباری طراحی شده برای زبان‌های کم‌منبع. مدل صوتی فارسی مورد استفاده در این پروژه از همین منبع مشتق شده است.

در **داده مکالمه‌ای تمام‌دوطرفه** اما شکاف جدی است. آنچه یک مدل تمام‌دوطرفه برای یادگیری نیاز دارد، گفتار دوطرفه طبیعی همراه با هم‌پوشانی، وقفه و بازخورد کلامی است. منابع فارسی موجود، عمدتاً تک‌گوینده و خوانشی‌اند و این پدیده‌ها را در بر ندارند. پیکره‌های تلفنی گفت‌وگویی فارسی در آرشیوهای

پژوهشی موجودند اما مجوز محدود دارند و مقیاس آن‌ها کمتر از بازه 100 تا 200 ساعت مورد نظر تعریف پروژه است. همین شکاف است که ساخت مجموعه داده مشتق شده در فصل ۴ را ضروری کرد.

۳-۴ تشخیص وقفه و نوبت‌گیری

پیشینه این حوزه دو شاخه دارد.

شاخه کلاسیک بر ویژگی‌های آوایی دست‌ساز و آشکارسازهای آماری استوار است. آشکارساز فعالیت گفتاری مبتنی بر مدل آماری [۸] نمونه مرجع این شاخه است. تشخیص وقفه در سامانه‌های تلفنی گفتاری سنتی نیز عملاً یک آشکارساز فعالیت گفتاری با آستانه محافظه‌کارانه بود؛ مشکل شناخته شده این سامانه‌ها آن بود که صدای بلندگو یا نویز محیط به اشتباه به عنوان وقفه شناخته می‌شد. مرور جامع سازوکارهای نوبت‌گیری در سامانه‌های گفت‌وگو و تعامل انسان و ربات در [۳۱] آمده است، که نشان می‌دهد نوبت‌گیری صرفاً یک مسئله تشخیص سکوت نیست و به نشانه‌های نوایی و نحوی وابسته است. مبنای زبان‌شناختی این موضوع به کار کلاسیک [۳۰] بازمی‌گردد که نشان داد فاصله میان نوبت‌ها در گفت‌وگوی انسانی به طور شگفت‌آوری کوتاه و منظم است.

شاخه یادگیری شده نوبت‌گیری را در خود مدل مولد جای می‌دهد. در Moshi و dGSLM هیچ آشکارساز جداگانه‌ای وجود ندارد و نوبت‌گیری بخشی از توزیع آموخته شده روی دو جریان موازی است. در Freeze-Omni یک راه میانی به کار رفته است: یک سر طبقه‌بندی سبک روی مدل زبانی، حالت گفت‌وگو را پیش‌بینی می‌کند.

تعریف پروژه صریحاً شاخه کلاسیک را خواسته است: یک ماژول بر پایه انرژی، زیروبمی و MFCC با هدف دقت بالای 80 درصد. پیاده‌سازی این پروژه همین مسیر را دنبال می‌کند، با این تفاوت روشمند که به جای آستانه‌گذاری دستی، یک طبقه‌بند تقویت گرادیانی روی بردار ویژگی پنجره متن آموزش می‌بیند و آستانه تصمیم آن تنها بر نشست‌های اعتبارسنجی انتخاب می‌شود.

برای برچسب‌گذاری خودکار رخدادهای تعاملی در داده ضبط شده، از تفکیک گوینده استفاده شده است. ابزارهای مرجع این حوزه pyannote.audio [۴۴] و روش‌های تفکیک چندمقیاسی با وزن‌دهی پویا [۴۵] هستند؛ سرویس تفکیک گوینده مورد استفاده در این پروژه از خانواده دوم است.

۵-۳ ارزیابی خودکار کیفیت گفت‌وگو

سنجش کیفیت پاسخ گفت‌وگو با سنجه‌های تطابق رشته‌ای معنادار نیست. رویکردی که در سال‌های اخیر مرجع شده است، به‌کارگیری یک مدل زبانی بزرگ به‌عنوان داور است. کار مرجع این حوزه [۳۷] نشان داد که داوری خودکار با مدل‌های قوی، همبستگی بالایی با ترجیح انسانی دارد، اما در همان کار اریبی‌های سامانه‌ای آن نیز مستند شده است: اریبی موقعیت، اریبی طول پاسخ و اریبی خودپسندی نسبت به خروجی مدل‌های هم‌خانواده.

این پروژه از همین روش به‌عنوان «تنها» سنجه معنایی در دسترس استفاده کرده است، اما با سه محدودسازی: دوسوکورسازی و تصادفی‌سازی ترتیب بازوها، کدگشایی قطعی، و تکرار هر فراخوانی داور با گزارش نرخ توافق. مهم‌تر آن‌که چون داور و نامزد در این پروژه از یک خانواده مدل‌اند، نتیجه صریحاً به‌عنوان یک «تقریب خودکار هم‌خانواده» برچسب‌گذاری شده و جانشین ارزیابی انسانی یا یک معیار مستقل شمرده نشده است. برای سنجش انسانی، پروتکل مرجع، امتیاز میانگین نظر بر پایه توصیه‌نامه ITU-T P.800 [۴۶] است که در این پروژه طراحی شد اما اجرا نشد.

۶-۳ جایگاه این پروژه

جدول ۱-۳ جایگاه این پروژه را در برابر کارهای پیشین خلاصه می‌کند. ستون «بازه حافظه» به تناسب با بازه ۱۲ تا ۲۴ گیگابایت مورد نظر تعریف پروژه اشاره دارد و برای مسیر مستقیم این پروژه بر پایه حافظه اندازه‌گیری‌شده آموزش روی سخت‌افزار موجود گزارش شده است، نه یک اندازه‌گیری روی سخت‌افزار هدف. از این مقایسه سه نکته برمی‌آید.

نخست، هیچ‌یک از مدل‌های سرتاسری موجود از فارسی پشتیبانی نمی‌کند؛ بنابراین هر مسیر مستقیمی ناچار از تطبیق است و تطبیق نیز به آموزش‌دهنده رسمی نیاز دارد. تنها Moshi این شرط را به‌طور کامل برآورده می‌کرد. PersonaPlex نیز تمام‌دوطرفه ذاتی دارد اما انگلیسی‌محور است و آموزش‌دهنده تطبیق آن برای فارسی در دسترس نبود.

دوم، مدل‌هایی که قابلیت تمام‌دوطرفه ذاتی دارند، در بازه حافظه هدف جای نمی‌گیرند. این تعارض میان نیازمندی ن ۲ و ن ۶ در تعریف پروژه، یک محدودیت ساختاری است و نه یک نقص پیاده‌سازی.

سوم، سهم متمایز این پروژه در جای دیگری است. کارهای پیشین، «مدل» منتشر می‌کنند؛ این پروژه، برای یک زبان کم‌منبع مشخص، «یک زنجیره داده و یک چارچوب ارزیابی شواهدمحور» می‌سازد و نشان می‌دهد کدام ادعاها با این شواهد قابل اثبات و کدام‌ها غیرقابل اثبات‌اند. به‌طور خاص، نتیجه منفی مسیر

جدول ۳-۱: مقایسه این پروژه با کارهای پیشین از نظر قابلیت‌های مورد نیاز تعریف پروژه

کار	تمام دوطرفه	وزن متن‌باز	آموزش‌دهنده رسمی	پشتیبانی فارسی	بازه حافظه
Mini-Omni2	فرمان‌محور	دارد	ندارد	ندارد	مناسب
LLaMA-Omni2	ندارد	دارد	ندارد	ندارد	مناسب
Freeze-Omni	دارد	دارد	جزئی	ندارد	مناسب
Qwen2.5-Omni	دارد	دارد	ندارد	ندارد	نامناسب
Moshi	ذاتی	دارد	دارد	ندارد	نامناسب
PersonaPlex	ذاتی	دارد	جزئی	ندارد	نامناسب
این پروژه، مسیر آبشاری	کنترل بیرونی	دارد	بی‌نیاز	دارد	مناسب
این پروژه، مسیر مستقیم	ذاتی	دارد	دارد	ناموفق	نامناسب

مستقیم، که در بخش ۵-۸ گزارش شده است، یک یافته قابل استناد برای پژوهشگران بعدی است: کاهش زیان تحت تحمیل معلم، در تطبیق کم‌پارامتر یک مدل گفتاربه‌گفتار به زبانی جدید، معیار کافی برای انتخاب چک‌پوینت نیست.

فصل ۴

روش پیشنهادی و پیاده‌سازی

این فصل، ساختار سامانه و روش ساخت داده و طراحی آزمایش‌ها را شرح می‌دهد. ترتیب مطالب چنین است: نخست تلاش اولیه و درسی که از آن گرفته شد؛ سپس زنجیره ساخت مجموعه داده؛ آنگاه معماری سامانه آبخاری تحویل‌شده و مازول تشخیص وقفه و بستر انتقال تمام‌دوطرفه؛ سپس طراحی آزمایش‌های مسیر مستقیم؛ و در پایان روش کاری شواهدمحوری که چارچوب همه ارزیابی‌های فصل بعد است.

۴-۱ تلاش اولیه و بازنگری در معماری

نخستین پیاده‌سازی پروژه بر پایه معماری LLaMA-Omni2 بنا شد: یک کدگذار گفتاری منجمد Whisper، یک لایه تصویرگر آموزش‌پذیر، یک مدل زبانی Qwen2.5-0.5B [۴۷] با آداپتر LoRA، و سرهای جداگانه برای بازشناسی و تولید نشانه‌های گفتاری. این مصنوع آموزش دید و زیان آن کاهش یافت.

یک ممیزی درونی کد پیش از هرگونه گزارش نتیجه، سه اشکال بنیادی را آشکار کرد که ثبت آن‌ها برای صداقت روشمند این نوشتار ضروری است:

- مدل زبانی در تابع پیش‌رو مشارکت نداشت؛ بنابراین آنچه آموزش می‌دید یک شبکه نگاشت صوتی بود و نه یک مدل زبانی گفت‌وگومحور.
- هدف بازشناسی از درهم‌سازی‌های تصادفی‌شده در هر فرایند استفاده می‌کرد و در نتیجه برچسب‌های آموزشی میان اجراها ناپایدار بودند.
- هدف تولید گفتار، «بازسازی همان اظهار ورودی» بود و نه تولید یک پاسخ گفت‌وگویی؛ و برای شنیدن خروجی، موتور گفتاری بیرونی مسیر مصنوع آموخته‌شده را دور می‌زد.

نتیجه‌گیری این ممیزی صریح بود: آن مصنوع یک مدل گفتار به گفتار نبود و نمی‌توانست به‌عنوان چنین چیزی گزارش شود. این تجربه دو تصمیم تعیین‌کننده را رقم زد. نخست، سرویس‌دهی سامانه به‌طور کامل به یک زنجیره آشناری با مؤلفه‌های واقعی و قابل آزمون منتقل شد. دوم، برای مسیر مستقیم تنها مدلی پذیرفته شد که «آموزش‌دهنده رسمی» داشته باشد، تا هدف آموزشی و زنجیره داده به‌جای بازنویسی محلی، از سوی سازندگان مدل تعیین شود. این دو تصمیم، شکل نهایی پروژه را ساختند.

۲-۴ ساخت مجموعه داده مکالمه فارسی

۱-۲-۴ منبع و راهبرد


از آنجا که پیکره عمومی فارسی با برچسب وقفه در دسترس نبود (بخش ۳-۳)، مجموعه داده این پروژه از یک آرشیو داخلی محتوای گفتاری فارسی مشتق شد. این آرشیو شامل برنامه‌های گفت‌وگویی بلند از چهار کانال با سبک‌های متفاوت است. استفاده پژوهشی داخلی از این منابع با تأیید استاد راهنما ثبت شده است؛ این تأیید مجوز بازنشر صوت یا زیرنویس خام نیست و هیچ داده محدودشده‌ای در مخزن کد قرار نگرفته است.

نکته روشمندی که در میانه کار اصلاح شد ارزش ثبت دارد. در طرح نخست، برچسب متنی هر بازه با اجرای مجدد سرویس بازشناسی گفتار تولید می‌شد. اما سرویس بازشناسی مورد استفاده، خودش پیش‌تر روی زیرنویس‌های همین کانال‌ها تنظیم شده بود. بنابراین استفاده از آن به‌عنوان «معلم» یک «حلقه دوری» می‌ساخت و خطاهای سامانه‌ای خودش را به‌عنوان برچسب مرجع تثبیت می‌کرد. پس از شناسایی این مشکل، برچسب متنی به زیرنویس‌های اصلی منبع تغییر یافت و سرویس بازشناسی تنها در نقش مؤلفه زمان اجرا و ابزار سنجش باقی ماند.

۲-۲-۴ مراحل زنجیره

شکل ۱-۴ مراحل زنجیره ساخت داده را نشان می‌دهد.

موجودی و انتخاب. موجودی قابل اندازه‌گیری آرشیو برابر 775.887 ساعت زیرنویس در 1,442 برنامه بلند بود. یک انتخاب وزن‌دار و «قطعی» روی این موجودی اجرا شد که هدف آن ایجاد تعادل میان کانال‌ها و پرهیز از تسلط یک سبک گفتاری بود. خروجی این مرحله 309 برنامه و 1,129 پنجره با مجموع 219.946 ساعت نامزد است.



شکل ۴-۱: مراحل زنجیره ساخت مجموعه داده مکالمه فارسی. هر مرحله یک فرمان مستقل با خروجی ممیزی پذیر است.

بازسازی پنجره. برنامه‌های منبع به صورت قطعه‌های کوچک ذخیره شده بودند. برای آنکه ساختار گفت‌وگو حفظ شود، قطعه‌ها به پنجره‌های پیوسته ۱۵ دقیقه‌ای بازسازی شدند. این طول به قدری بلند است که چند نوبت کامل گفت‌وگو را در بر بگیرد.

تفکیک گوینده. هر پنجره به سرویس تفکیک گوینده داده شد که مرزهای زمانی و شناسه گوینده هر بازه گفتار و همچنین بازه‌های هم‌پوشانی را برمی‌گرداند. مجموع بازه‌های چندگویندگی طبقه‌بندی شده به صورت خودکار ۲۰۷.۱۵۴ ساعت است.

برچسب‌گذاری شرایط نویز. برای هر بازه، یک برچسب شرایط نویز بر پایه تخمین نسبت سیگنال به نویز افزوده شد تا در تحلیل‌های بعدی بتوان اثر شرایط آکوستیکی را جدا کرد.

۴-۲-۳ استخراج جفت پاسخ و برچسب تعامل

از بازه‌های تفکیک شده، جفت‌های «گفتار کاربر و پاسخ گوینده بعدی» استخراج می‌شود. نخست بازه‌های متوالی یک گوینده که فاصله آن‌ها از نیم‌ثانیه کمتر است در هم ادغام می‌شوند تا یک نوبت کامل به دست آید. سپس برای هر دو نوبت متوالی از دو گوینده متفاوت، یک جفت ساخته می‌شود.

قید مهم این مرحله «عدم بازاستفاده» است: هر بازه از صوت منبع تنها در یک جفت ظاهر می‌شود. این قید از آن جهت لازم است که بازاستفاده، شمار ساعت گزارش شده را به طور مصنوعی بالا می‌برد و در آموزش نیز به صورت تکرار داده عمل می‌کند.

برای هر جفت، یک برچسب تعامل خودکار نیز محاسبه می‌شود. اگر نوبت دوم پیش از پایان نوبت اول آغاز شود، هم‌پوشانی وجود دارد. در این حالت، اگر نوبت دوم کوتاه باشد و پیش از پایان نوبت اول تمام شود، برچسب «بازخورد کلامی» و در غیر این صورت برچسب «وقفه» داده می‌شود. اگر نسبت‌دهی هم‌پوشانی به گوینده مشخص نباشد، برچسب «هم‌پوشانی بی‌نسبت» ثبت می‌گردد.

خروجی این مرحله 6,754 جفت با 123,796 ساعت صوت منبع است. همچنین 770 نامزد محافظه کارانه رخداد تعاملی (717 مورد وقفه‌مانند و 53 مورد بازخوردمانند) از مرزهای گوینده بازیابی شد. این برچسب‌ها به‌طور کامل «خودکار» اند. بازیابی شنیداری چهل‌ردیفی داده و بازیابی بیست‌و‌چهارردیفی رخدادهای تعاملی، تحت یک سند انصراف زمانی مستند، اجرا نشد. بنابراین در سراسر این نوشتار هیچ ردیفی به‌عنوان «تأییدشده توسط انسان» گزارش نمی‌شود و شمار برچسب‌های تأییدشده انسانی صفر است.

۴-۲-۴ تفکیک گروهی و بازسازی صدای پاسخ


تفکیک آموزش، اعتبارسنجی و آزمون بر پایه «شناسه نشست منبع» و با درهم‌سازی قطعی انجام شد (بخش ۲-۸-۴). نتیجه، 6,419 جفت آموزش، 131 جفت اعتبارسنجی و 204 جفت آزمون است و ممیزی خودکار، نشأت گروهی صفر را تأیید می‌کند.

برای مسیر مستقیم، کانال «دستیار» نباید صدای گویندگان متعدد منبع را داشته باشد، زیرا مدل باید یک صدای هدف پایدار بیاموزد. به همین دلیل، متن نوبت پاسخ با موتور گفتاری فارسی و یک مدل صوتی «قطعی» و ثابت بازسازی شد. این همان رسم متعارف در آموزش مدل‌های گفتاربه‌گفتار است. خروجی نهایی، یک پرونده صوتی استریو برای هر جفت است که در آن کانال صفر گفتار دستیار و کانال یک گفتار کاربر است، همراه با یک پرونده هم‌ترازی متنی مجاور.


مجموع صوت استریوی خروجی 108,584 ساعت اندازه‌گیری‌شده است که درون بازه 100 تا 200 ساعت مورد نظر نیازمندی ن ۴ قرار می‌گیرد. شکل ۲-۴ کاهش تدریجی حجم از موجودی خام تا خروجی ممیزی‌شده را نشان می‌دهد.

۴-۳ معماری سامانه آبشاری

سامانه تحویل‌شده پروژه یک زنجیره آبشاری است که کنترل تمام‌دوطرفه روی آن سوار شده است. شکل ۴-۳ این معماری را نشان می‌دهد.



شکل ۴-۲: کاهش تدریجی مقدار صوت از موجودی زیرنویس کانال‌ها تا خروجی استریوی ممیزی شده آموزش. نوار روشن، بازه 100 تا 200 ساعت مورد نظر تعریف پروژه را نشان می‌دهد.



شکل ۴-۳: معماری سامانه تحویل شده. ردیف بالا مسیر کنترل تمام‌دوطرفه و ردیف پایین زنجیره تولید پاسخ است. پیکان نقطه‌چین، انتقال پیش‌بافر میکروفون به نوبت بعدی را نشان می‌دهد.

۴-۳-۱ بازشناسی گفتار

جریان صوتی نوبت کاربر به سرویس بازشناسی گفتار فارسی فرستاده می‌شود. این سرویس یک مدل ترکیبی RNNT-CTC از خانواده Conformer است که به صورت محلی و روی رابط شبکه حلقه بازگشتی اجرا می‌شود. متن بازگشتی از هنجارساز قطعی متن فارسی می‌گذرد تا شکل نویسه‌ها و نیم‌فاصله‌ها یکسان شود. نکته‌ای که در ممیزی مهم شد، «انتخاب کانال ورودی» است. پرونده‌های مجموعه داده استریواند و کانال صفر گفتار دستیار و کانال یک گفتار کاربر است. یک پنل توسعه پیشین به اشتباه کانال صفر را به بازشناسی داده بود، یعنی عملاً صدای بازسازی شده دستیار را رونویسی می‌کرد. این اشکال پیش از اجرای هر ردیف اعتبارسنجی شناسایی و اصلاح شد و پروتکل نهایی، استفاده از کانال یک «ممیزی شده» را الزامی می‌کند.

۴-۳-۲ تولید پاسخ متنی

پاسخ متنی با مدل Qwen3-4B-Instruct-2507 از خانواده Qwen3 [۴۸] تولید می‌شود. مدل به صورت محلی و از یک درخت پرونده با درهم‌سازی تأییدشده بارگذاری می‌گردد، و بازنگری مدل و درهم‌سازی درخت در مصنوع نتیجه ثبت می‌شود تا ادعای «مدل دقیقاً همین بود» قابل ممیزی باشد.

پرامپت سامانه «قفل‌شده» است: متن آن پیش از اجرای ارزیابی تثبیت و درهم‌سازی آن ثبت شده است. نسخه دوم این پرامپت که در ارزیابی نهایی به کار رفت، سه قید را به مدل تحمیل می‌کند: پاسخ باید به فارسی باشد، باید کوتاه و گفتاری باشد، و باید به آخرین اظهار کاربر پاسخ دهد و نه به کل متن رونویسی شده.

روی خروجی مدل دو نگهبان اعمال می‌شود. نخست یک «قید خط فارسی»: اگر سهم نویسه‌های فارسی در پاسخ از یک آستانه کمتر باشد، یک تلاش تولید دوباره با پرامپت تأکیدی انجام می‌گیرد. دوم یک «کران تلاش»: شمار تلاش‌های تولید حداکثر دو است. اگر هر دو تلاش شکست بخورد، یک پاسخ جایگزین قاعده‌محور تولید می‌شود. شمار ردیف‌هایی که به این پاسخ جایگزین رسیده‌اند، یکی از شروط پذیرش ارزیابی است.

پاسخ‌گوی متنی سامانه تحویل‌شده، همان Qwen3-4B-Instruct-2507 با پرامپت v2 است. پنل مکانیکی نه‌ردیفی اعتبارسنجی و سنجه بازبازشناسی فصل ۵ اما روی زنجیره پیش از این ارتقا اجرا شده‌اند، یعنی با پاسخ‌گوی Qwen2.5-0.5B-Instruct (بازنگری 7ae557604adf67be50417f59c2c2f167def9a775). آن پنل پس از ارتقا دوباره اجرا نشد. آزمون معنایی 40 ردیفی روی پاسخ‌گوی Qwen3-4B است و داور آن مدل هم‌خانواده Qwen3.8-27B-FP8 است (بازنگری 017b9c7af6b5689d5dd426a76e0bc077eb5ca20a)؛ بنابراین کیفیت معنایی گزارش‌شده، سنجه خودکار هم‌خانواده است و نه اثبات مکانیکی زنجیره چهارمیلیاردپارامتری روی همان نُ ردیف.

۴-۳-۳ تولید گفتار

متن پاسخ با موتور Piper و مدل صوتی فارسی به موج صوتی تبدیل می‌شود. یک مسیر جایگزین مبتنی بر ترکیب فورمانتی نیز پیاده شده است که تنها در نبود مدل صوتی و برای آزمون‌های نرم‌افزاری به کار می‌رود؛ در همه ردیف‌های ارزیابی، شرط پذیرش این است که موتور واقعاً Piper بوده باشد. صوت خروجی از نظر متناهی بودن مقادیر، طول کمینه، هنجارسازی دامنه و «غیرساکت بودن» با معیار ریشه میانگین مربعات بررسی می‌شود.

۴-۴ مازول تشخیص وقفه و بستر تمام دو طرفه

۱-۴-۴ استخراج ویژگی و طبقه‌بند

ویژگی‌های توضیح داده شده در بخش ۱-۲ به صورت غلتان روی جریان میکروفون محاسبه می‌شوند. فریم 20 میلی ثانیه، پنجره متن 400 میلی ثانیه، 13 ضریب MFCC با دلتاهای متناظر، بسامد پایه با روش YIN در بازه 60 تا 400 هرتز، انرژی لگاریتمی و نرخ گذر از صفر. برای هر بعد، سه آماره میانگین، انحراف معیار و بیشینه روی پنجره محاسبه و به هم پیوند داده می‌شود.

بردار حاصل، پس از هنجارسازی، به یک طبقه‌بند تقویت گرادیانی داده می‌شود (بخش ۷-۲) با 200 درخت، عمق بیشینه 4، نرخ یادگیری 0.08 و کمینه 8 نمونه در برگ. کلاس‌های هدف عبارت‌اند از نبود رخداد، وقفه، بازخورد کلامی و نویز. برای مقایسه، یک «خط پایه» مبتنی بر آستانه گذاری انرژی و نرخ گذر از صفر نیز پیاده شده است.

۲-۴-۴ کنترل پخش و پیوستگی نوبت

یک مؤلفه «کنترل گر پخش» مالک مسیر تصمیم است. این مؤلفه وضعیت پخش را نگه می‌دارد، در هنگام پخش قطعه‌های میکروفون را به آشکارساز می‌دهد و در صورت مثبت شدن تصمیم، رویداد توقف را به کارخواه می‌فرستد و زمان آغاز آوایی تا تأیید توقف را ثبت می‌کند.

سازوکاری که برای تجربه کاربری تعیین کننده است، «پیش بافر» است. آشکارساز همیشه 450 میلی ثانیه آخر جریان میکروفون را در یک بافر غلتان نگه می‌دارد. هنگامی که وقفه پذیرفته می‌شود، این پیش بافر دور ریخته نمی‌شود، بلکه با صوتی که پس از آن دریافت می‌گردد به هم پیوند می‌خورد و ورودی نوبت بعدی را می‌سازد. بدون این سازوکار، آغاز جمله کاربر از دست می‌رفت و او ناچار می‌شد جمله را از نو بگوید.

بستر انتقال، یک اتصال WebSocket است که جریان PCM16 پیوسته را از مرورگر می‌گیرد و رویدادهای کنترلی را در هر دو جهت ردوبدل می‌کند. آزمون‌های بازگشتی خودکار این بستر، پیوستگی پیش بافر و صوت پس از آن، دریافت تأیید توقف از کارخواه، لغو نوبت، اتصال مجدد، جداسازی وضعیت نشست‌ها، بازیابی از خطای تولید و حالت نگه‌داری فقط سنجه بدون ذخیره پرونده صوتی را پوشش می‌دهند.

این آزمون‌ها پیوستگی را در «سطح انتقال» اثبات می‌کنند. توقف منبع صوت در یک مرورگر واقعی با میکروفون فیزیکی اندازه‌گیری نشده است و بنابراین سنجه‌های رسمی T_{first_audio} و T_{barge_in} در این نوشتار گزارش نمی‌شوند.

۴-۳ ارزیابی روی داده ضبط شده

برای سنجش آشکارساز روی صوت واقعی، رخدادهای تعاملی از مرزهای تفکیک گوینده در پنجره‌های مجموعه داده کشف شدند. از 1,730 رخداد کشف شده، 1,048 رخداد با شرط تعادل کلاس‌ها انتخاب و بر پایه نشست به سه بخش تقسیم شد. آستانه تصمیم «تنها» روی نشست‌های اعتبارسنجی و با معیار ازپیش تعریف شده انتخاب گردید و سپس یک‌بار روی نشست‌های آزمون اعمال شد.

۴-۵ طراحی آزمایش‌های مسیر مستقیم

۴-۵-۱ هدف آموزشی و شرط پذیرش

مسیر مستقیم، تطبیق کم‌پارامتر مدل Moshika با آموزش دهنده رسمی آن است. داده ورودی، همان پرونده‌های استریوی بخش ۴-۲ است: کانال صفر گفتار دستیار بازسازی شده و کانال یک گفتار کاربر، همراه با هم‌ترازی متنی که سازوکار «تک‌گویی درونی» به آن نیاز دارد. زیان کل، ترکیب وزن دار زیان نشانه‌های متنی و زیان نشانه‌های صوتی هر کتاب رمز است.

تصمیم روشمند مرکزی این بخش، تعریف یک «شرط پذیرش زمان اجرا» پیش از آغاز آموزش بود. برای هر چک‌پوینت نامزد، آداپتر در سرور جویباری رسمی مدل بارگذاری می‌شود، نه در یک اسکریپت محلی، و برای هر یک از ۹ ردیف ورودی از پیش تعیین شده باید هم‌زمان چند شرط برقرار باشد: مدل باید متن تولید کند، باید گفتار غیرساکت تولید کند، و متن تولیدی باید از قید خط فارسی بگذرد. یک چک‌پوینت تنها در صورتی «واجد شرایط» است که هر 9 ردیف را با موفقیت بگذراند.

این شرط سخت‌گیرانه است و به‌طور عمدی چنین طراحی شده. تجربه نسخه نخست نشان داد که چک‌پوینت‌هایی با کمترین زیان اعتبارسنجی، در تولید خودرگرسیو صوت تقریباً ساکت و بدون متن می‌دهند. اگر انتخاب چک‌پوینت تنها بر زیان استوار بود، همان مصنوع بی‌فایده به‌عنوان «مدل فارسی» گزارش می‌شد.

۴-۵-۲ شش نسل آزمایشی

آزمایش‌ها به‌صورت زنجیره‌ای از فرضیه‌های قابل ابطال طراحی شدند و در هر نسل تلاش شد «تنها یک عامل» تغییر کند. جدول ۴-۱ این طراحی را خلاصه می‌کند.

جدول ۴-۱: طراحی شش نسل آزمایشی مسیر مستقیم و فرضیه‌ای که هر نسل آزمود

نسخه	عامل تغییر یافته	فرضیه آزمون شده	رتبه
v1	پیکربندی پایه، پنجره 20 ثانیه، آموزش همه درج‌گراها	مدل با داده کافی، گفتار فارسی می‌آموزد	64
v2	پنجره متن به 100 ثانیه	پنجره کوتاه، آغاز پاسخ را در بافت نمی‌گنجاند	64
v3	انجماد همه درج‌گراها و رتبه بالاتر	آموزش درج‌گراها بازنمایی پایه را تخریب می‌کند	128
v4	آموزش تنها دو درج‌گر متنی	تنها فضای متنی فارسی نیاز به تطبیق دارد	128
v5	ضریب زیان کتاب رمز نخست از 100 به 10	وزن زیاد کتاب رمز معنایی، یادگیری آوایی را خفه می‌کند	128
v6.2	آزمون ظرفیت درون‌نمونه با حذف تصادفی ورودی متنی و پنجره 12 ثانیه	مدل ظرفیت یادگیری دارد و مشکل، اریبی مواجهه است	64

سه نسخه نخست، مسیر متعارف تنظیم فراپارامتر را می‌پیمایند. نسخه‌های چهارم و پنجم، فرضیه‌های دقیق‌تری را می‌آزمایند که از تحلیل شکست نسخه‌های پیشین برآمده‌اند: اگر مشکل، نبود بازنمایی متنی فارسی است، آموزش گزینشی تنها دو درج‌گر متنی باید کافی باشد؛ و اگر مشکل، غلبه زیان معنایی بر زیان آوایی است، کاهش ضریب کتاب رمز نخست باید آن را برطرف کند.

نسخه ششم، طراحی متفاوتی دارد و به‌عمد یک «آزمون ابطال» است. در این نسخه، مدل روی تنها 32 نمونه و با پنجره متن 12 ثانیه آموزش می‌بیند و روی «همان» 32 نمونه ارزیابی می‌شود. هدف، سنجش تعمیم نیست، بلکه پاسخ به یک پرسش دوگزینه‌ای است: آیا این آداپتر «ظرفیت» یادگیری هدف را دارد یا نه؟ اگر مدل نتواند حتی روی داده آموزشی خودش زیان را به‌قدر کافی کاهش دهد، مشکل در ظرفیت است؛ اگر بتواند اما در تولید خودرگرسیو شکست بخورد، مشکل در اریبی مواجهه است (بخش ۲-۴-۲). نسخه v6.2 همچنین «حذف تصادفی زمان‌بندی‌شده ورودی متنی» را اضافه می‌کند: سهم نشانه‌های متنی

مرجع که در آموزش پنهان می‌شوند به تدریج از 0.25 به 0.75 افزایش می‌یابد تا مدل بیاموزد بر پیش‌بینی خودش تکیه کند.

۴-۶ روش کاری شواهدمحور

بخش بزرگی از سهم روشمند این پروژه، در چگونگی «گزارش» نتایج است. تجربه تلاش اولیه (بخش ۴-۱) نشان داد که یک مصنوع می‌تواند زیان کاهنده و ظاهر موفق داشته باشد و در همان حال هیچ ادعای معناداری را پشتیبانی نکند. برای پرهیز از تکرار این وضعیت، پنج قاعده عملیاتی تعریف و در کد اعمال شد.

یک. **تعریف پیشینی پروتکل.** برای هر ارزیابی، یک سند پروتکل شامل شاخص دقیق ردیف‌های آزمون، آستانه‌های پذیرش، بازنگری مدل‌ها و درهم‌سازی پرونده‌ها، پیش از اجرا نوشته و در مخزن ثبت می‌شود. آستانه پذیرش پس از مشاهده نتیجه ساخته نمی‌شود.

دو. **تفکیک مرحله صلاحیت از آزمون نهایی.** ارزیابی معنایی دو مرحله‌ای است. نخست یک مرحله صلاحیت روی شمار کوچکی از ردیف‌های اعتبارسنجی اجرا می‌شود. تنها در صورت عبور کامل از این مرحله، آزمون نهایی روی ردیف‌های آزمون «یک‌بار» باز می‌شود. این طراحی از انتخاب پس از مشاهده نتیجه جلوگیری می‌کند. داور این ارزیابی، مدل Qwen3.8-27B-FP8 با بازنگری 017b9c7af6b5689d5dd426a76e0bc077eb5ca20a، دمای صفر، ترتیب بازوی دوسوکور و دو تکرار در هر ردیف است. چون داور و نامزد از یک خانواده‌اند، نتیجه در کلاس «تقریب خودکار هم‌خانواده» می‌ماند و نیازمندی تعریف پروژه را اثبات نمی‌کند.

سه. **مصنوعات یک‌بارنوشت.** هر نتیجه نهایی در یک پرونده ساختارمند ثبت می‌شود که شامل مقادیر اندازه‌گیری شده، وضعیت هر شرط پذیرش، درهم‌سازی‌های ورودی، مشخصات سخت‌افزار و یک فهرست صریح محدودیت‌ها است. این پرونده بازنویسی نمی‌شود.

چهار. **کلاس‌بندی شواهد.** هر اندازه‌گیری با یک «کلاس شواهد» برچسب می‌خورد. جدول ۴-۲ این کلاس‌ها را تعریف می‌کند. قاعده بنیادی آن است که تنها کلاس رسمی می‌تواند برآورده شدن یک نیازمندی تعریف پروژه را اثبات کند.

جدول ۴-۲: کلاس‌های شواهد و توان ادعای هر کلاس

کلاس شواهد	شرایط لازم	اثبات نیازمندی
رسمی سرتاسری	نشست زنده با رضایت کاربر، تأیید پخش از سوی کارخواه، میکروفون واقعی و سخت‌افزار واجد شرایط	مجاز
زنده غیررسمی	همان پروتکل، اما سخت‌افزار یا شرایط مطالعه واجد شرایط نیست	غیرمجاز
مؤلفه سمت سرور	زمان‌سنجی تولید یا آشکارساز، بدون اثبات رفتار شنیدنی کارخواه	غیرمجاز
تقریب مصنوعی	صوت تولیدشده یا رخداد شبیه‌سازی‌شده	تنها آزمون بازگشتی
تقریب خودکار هم‌خانواده	داوری با مدل زبانی از خانواده نامزد	غیرمجاز

پنج. تجمیع شکست‌بسته. یک مؤلفه تجمیع‌کننده، همه مصنوعات نتیجه را می‌خواند و وضعیت کلی پروژه را می‌سازد. این مؤلفه «شکست‌بسته» است: اگر مصنوع پشتیبان یک شرط وجود نداشته باشد، یا درهم‌سازی آن با ورودی مورد انتظار نخواند، یا کلاس شواهد آن پایین‌تر از حد لازم باشد، آن شرط «ناموفق» گزارش می‌شود و نه «نامعلوم». همچنین این مؤلفه صریحاً مانع از ارتقای یک تقریب به شواهد رسمی می‌شود.

پیامد این روش کاری آن است که وضعیت شواهد هر شرط، همان‌طور که در فصل ۵ گزارش می‌شود، مستقل از آمادگی گزارش برای ارائه و داوری بیان شود. نتیجه نهایی، تفکیک روشن آنچه ساخته شده از آنچه با شواهد رسمی اثبات شده است.

۷-۴ پیاده‌سازی و بازتولیدپذیری

کد پروژه در یک بسته پایتون با رابط خط فرمان یکپارچه سازمان یافته است که هر مرحله زنجیره داده، آموزش، ارزیابی و سرویس‌دهی را به‌صورت یک زیرفرمان مستقل ارائه می‌کند. پیاده‌سازی مدل‌ها بر PyTorch [۴۹] و کتابخانه Transformers [۵۰] استوار است. دو محیط مجازی جداگانه نگه داشته می‌شود: یکی برای سامانه اصلی و یکی برای پشته مسیر مستقیم که وابستگی‌های سخت‌گیرانه‌تری دارد.

سه سازوکار، بازتولیدپذیری را پشتیبانی می‌کنند. نخست، یک پرونده قفل «مخازن بالادستی» که برای هر مدل و مخزن بیرونی، بازنگری دقیق و درهم‌سازی وزن‌ها را ثبت می‌کند. دوم، بذر تصادفی ثابت برای هر آزمایش که در مصنوع نتیجه گزارش می‌شود. سوم، مجموعه آزمون خودکار به همراه یکپارچه‌سازی پیوسته که در آن، بررسی سبک کد، بررسی نوع، ممیزی آسیب‌پذیری وابستگی‌ها، ممیزی مصنوعات ثبت‌شده و پوشش آزمون اجرا می‌شود.

فرمان‌های بازتولید هر مرحله در پیوست [آ-۴](#) فهرست شده‌اند.

فصل ۵

آزمایش‌ها و نتایج

این فصل نتایج اندازه‌گیری‌شده را ارائه می‌کند. برای هر نتیجه، سه چیز مشخص شده است: مقدار مشاهده‌شده، مخرج و شرایط اندازه‌گیری، و «مرز ادعای مجاز» بر پایه کلاس شواهد آن (جدول ۴-۲). همه اعداد این فصل از مصنوعات ثبت‌شده و درهم‌سازی‌شده پروژه خوانده شده‌اند و هیچ مقداری تخمینی نیست.

۱-۵ پوشش شروط پذیرش و وضعیت شواهد

جدول ۱-۵ وضعیت شواهد شروط پذیرش پروژه را، همان‌طور که تجمیع‌کننده شکست‌بسته تولید کرده است، نشان می‌دهد. پنج شرط از نه شرط شواهد کافی دارند و برای چهار شرط شواهد تکمیلی لازم است. این وضعیت به کفایت شواهد هر شرط مربوط است و نباید با آمادگی خود گزارش برای ارائه و داوری یکسان دانسته شود.

پنج شرط مهندسی شواهد کافی دارند. چهار ردیف پایانی هنوز به نتیجه مثبت یا شواهد رسمی تکمیلی نیاز دارند؛ گزارش این فاصله‌ها را صریحاً به‌عنوان محدودیت و کارآینده ارائه می‌کند و برای نتایج اثبات‌نشده ادعای قطعی نمی‌سازد.

۲-۵ مجموعه داده

جدول ۲-۵ مشخصات نهایی مجموعه داده را نشان می‌دهد.

جدول ۵-۱: پوشش شروط پذیرش پروژه در تاریخ تولید مصنوع تجمیعی

شرط پذیرش	وضعیت شواهد
نمونه اولیه کارکردی گفتار به گفتار فارسی	کافی
عبور از آزمون نهایی معنایی خودکار	کافی
خروجی ممیزی شده در بازه 100 تا 200 ساعت	کافی
حل شدن سیاست داده تحت انصراف مستند بازبینی	کافی
انتخاب مجوز کد منبع	کافی
مدل مستقیم فارسی واجد شرایط استقرار	نتیجه مثبت تازه لازم است
آشکارساز با دقت بیش از 80 درصد روی برجسب مستقل	شواهد تکمیلی لازم است
تناسب و تأخیر زنده روی سخت افزار 12 تا 24 گیگابایتی	شواهد تکمیلی لازم است
تکمیل مطالعه انسانی	شواهد تکمیلی لازم است

مقدار 108.584 ساعت درون بازه 100 تا 200 ساعت نیازمندی ن ۴ قرار می گیرد و ممیزی خودکار یکپارچگی، شامل بررسی ترتیب کانال ها، درهم سازی پرونده ها و تفکیک گروهی، بدون شکست گذشته است.

این نتیجه، یک خروجی ممیزی شده «خودکار» است. برجسب های تعاملی نامزد خودکارند و شمار ردیف های تأیید شده انسانی صفر است؛ بنابراین این مجموعه داده را نمی توان «برجسب گذاری شده توسط انسان» نامید. همچنین داده منبع قابل بازنشر نیست.

۳-۵ سامانه آبشاری: پنل مکانیکی


پنل اعتبارسنجی، ۹ ردیف با فاصله ثابت از فهرست نامه 131 ردیفی اعتبارسنجی است. شاخص این ردیف ها پیش از اجرا قفل شده بود. زنجیره اجرا شده، سرویس واقعی بازشناسی گفتار، پاسخ گوی محلی Qwen2.5-0.5B-Instruct و موتور گفتاری واقعی است و کانال ورودی، کانال یک ممیزی شده کاربر است. این پنل مکانیک زنجیره را می سنجد و نه کیفیت معنایی پاسخ گوی Qwen3-4B سامانه تحویل شده. نتیجه تجمیعی این پنل در جدول ۳-۵ آمده است.

جدول ۴-۵ جزئیات هر ردیف را نشان می دهد. ستون زمان، مدت «تولید کامل پاسخ» است و نه تأخیر نخستین صوت.

یک تحلیل توصیفی پس نگر و حریم خصوصی محور نیز روی همین گزارش اجرا شد که تنها مقادیر تجمیعی و درهم سازی ها را می خواند و متن رونویسی یا پاسخ را نمی خواند و منتشر نمی کند. یافته های آن

چنین است: هیچ شکست مکانیکی رخ نداد؛ میانه، صدک نودوپنجم و بیشینه طول رونویسی 3977.8، 445 و 5031 نویسه بود؛ میانه، صدک نودوپنجم و بیشینه زمان تولید کامل 13045.919، 5584.736 و 13270.249 میلی‌ثانیه بود؛ سه ردیف رونویسی بیش از 1000 نویسه داشتند و دو ردیف زمان تولید بیش از 10 ثانیه.

مهم‌ترین ریسک مهندسی مشاهده‌شده، رشد زمان تولید کامل با طول ورودی است. همبستگی پیرسون توصیفی میان طول رونویسی و زمان تولید کامل 0.885 است و بلندترین رونویسی و کندترین نوبت، هر دو ردیف 32 بودند. شکل ۵-۱ (الف) این رابطه را نشان می‌دهد.



شکل ۵-۱: (الف) زمان تولید کامل پاسخ در برابر طول رونویسی ورودی برای ۹ ردیف پل اعتبارسنجی، همراه با خط برازش و همبستگی پیرسون توصیفی. (ب) نرخ خطای واژه و نویسه بازبازشناسی برای همان ۹ خروجی، همراه با مقادیر تجمیع خرد.

این یک نتیجه مثبت مکانیکی و برون‌نمونه روی یک پل گروه‌ناهمپوشان با پاسخ‌گوی Qwen2.5-0.5B است. پل نه‌ردیفی برای اثبات تعمیم جمعیتی یا کیفیت معنایی کافی نیست و به پاسخ‌گوی Qwen3-4B سامانه تحویل‌شده تعمیم داده نمی‌شود. همبستگی گزارش‌شده توصیفی است و نه استنباطی. زمان تولید کامل روی سخت‌افزار موجود، سنج T_{first_audio} نیست و نمی‌تواند شرط 500 میلی‌ثانیه را برآورده کند.

۴-۵ تقریب خودکار فهم‌پذیری گفتار تولیدشده

برای سنجش این‌که آیا گفتار تولیدشده محتوای متن پاسخ را حفظ می‌کند، یک اندازه‌گیری بازبازشناسی روی همان ۹ خروجی زنجیره با پاسخ‌گوی Qwen2.5-0.5B اجرا شد: متن پاسخ تولیدشده مرجع است و رونویسی سرویس بازشناسی از موج صوتی خروجی، فرضیه. پروتکل این اندازه‌گیری، شامل هنجارسازی، تعریف نشانه‌ها و شروط اعتبار، پیش از اجرا ثبت شده بود و همه درهم‌سازی‌های ورودی بازتولید شدند. نتیجه در جدول ۵-۵ گزارش شده است.

شکل ۵-۱ (ب) توزیع این دو نرخ خطا را به صورت ردیف به ردیف نشان می دهد. فاصله چشمگیر میان نرخ خطای نویسه و نرخ خطای واژه، در بخش ۶-۲ تفسیر شده است.

این سنجه یک تقریب خودکار «حفظ محتوا» با یک صدای واحد و روی خروجی پاسخگوی Qwen2.5-0.5B است. از آنجا که سرویس بازشناسی هم در سامانه و هم در اندازه گیری مشارکت دارد، و از آنجا که ۹ خروجی برای برآورد فاصله اطمینان کافی نیست، این نتیجه فهم پذیری انسانی، درستی تلفظ، طبیعی بودن یا کیفیت معنایی را اثبات نمی کند و به پاسخگوی Qwen3-4B تعمیم داده نمی شود. هیچ آستانه قبولی نیز پس از مشاهده نتیجه ساخته نشد.

۵-۵ آزمون معنایی خودکار

۱-۵-۵ مرحله صلاحیت

طراحی این ارزیابی دو مرحله ای است. مرحله نخست روی هفت ردیف اعتبارسنجی که پیش تر استفاده نشده بودند اجرا شد و همه شروط را گذراند: هر 42 فراخوانی داور معتبر بود، میانگین ارتباط نامزد 3.857 در برابر 1.000 خط پایه، بهبود ارتباط 2.857، میانگین انسجام 3.571 با بهبود 2.286+، نرخ برد زوجی 85.7 درصد (6/7) و نرخ ارتباط حداقل دو، 100 درصد. تنها پس از این عبور کامل، آزمون نهایی «یک بار» باز شد.

۲-۵-۵ آزمون نهایی

آزمون نهایی روی 40 ردیف از فهرست نامه 204 ردیفی آزمون و در پنج نشست منبع کنار گذاشته اجرا شد. سه بازو به صورت دوسوکور و با ترتیب تصادفی شده به داور داده شدند: خط پایه قفل شده Qwen2.5-0.5B، نامزد Qwen3-4B با پرامپت v2، و مرجع هم ترازشده خودکار نوبت گوینده بعدی. داور، مدل Qwen3.8-27B-FP8 با بازنگری 017b9c7af6b5689d5dd426a76e0bc077eb5ca20a، دمای صفر و دو تکرار در هر ردیف بود. هر بازو و هر ردیف دو فراخوانی داور برای ارتباط و انسجام دریافت کرد. جدول ۵-۶ نتیجه این آزمون را نشان می دهد.


جدول ۵-۷ نشان می دهد که هر هفت شرط خودکار از پیش تعریف شده برآورده شده اند. هیچ آستانه ای پس از مشاهده نتیجه تغییر نکرد.

عبور از هفت شرط خودکار به معنای کیفیت ادراکی یا معیار مستقل نیست. داور و نامزد هم خانواده اند و این نتیجه در کلاس تقریب خودکار باقی می ماند.

شکل ۵-۲ میانگین امتیاز هر بازو و توزیع کامل امتیازها را نشان می دهد. نکته قابل توجه در بخش (ب)، توزیع دوقطبی خط پایه است: مدل 0.5 میلیارد پارامتری در بخشی از ردیف ها امتیاز کامل و در بخش

بزرگ‌تری امتیاز صفر گرفته است. همچنین بازوی مرجع هم‌تراز شده خودکار، پایین‌ترین امتیاز را دارد؛

تفسیر این مشاهده در بخش ۳-۶ آمده است.



شکل ۲-۵: (الف) میانگین امتیاز ارتباط و انسجام برای سه بازوی دوسوکور، همراه با آستانه‌های

ازپیش‌تعریف‌شده. (ب) توزیع کامل امتیاز ارتباط در 80 فراخوانی داور برای هر بازو.

این یک نتیجه مثبت «خودکار» با داوری مدل زبانی هم‌خانواده با نامزد است. ارزیابی انسانی، معیار مستقل گفت‌وگو، سنجش واقعیت یا ایمنی، اثبات طبیعی بودن، تعمیم جمعیتی، تناسب سخت‌افزار هدف و تأخیر مرورگر را اثبات نمی‌کند.

۳-۵-۵ آزمایش تطبیق پاسخ‌گو با LoRA

یک آزمایش جانبی بررسی کرد که آیا تطبیق کم‌پارامتر پاسخ‌گوی متنی روی نوبت‌های پاسخ همین مجموعه داده، کیفیت معنایی را بهبود می‌دهد. آموزش با موفقیت اجرا شد و زیان توسعه کاهش یافت: زیان نشانه‌های پاسخ مدل پایه 3.723 بود، پس از دوره نخست 2.643 و پس از دوره دوم 2.562، یعنی 31.18 درصد کاهش نسبت به مدل پایه. چک‌پوینت دوره دوم بر پایه کمترین زیان توسعه انتخاب شد.

اما ارزیابی معنایی روی چهل ردیف آزمون نشان داد که این آداپتر از خط پایه پیشی نمی‌گیرد. نتیجه به‌عنوان یک «نتیجه منفی معتبر» ثبت شد و آداپتر در سامانه نهایی به کار نرفت. تفسیر این تناقض ظاهری در بخش ۳-۶ آمده است.

۶-۵ تشخیص وقفه

۱-۶-۵ آزمون مصنوعی


روی داده مصنوعی، طبقه‌بند تقویت گرادیانی روی 32 نمونه کنارگذاشته (با 128 نمونه آموزش) به دقت 1.000، امتیاز F1 کلاس وقفه 1.000، نرخ پذیرش نادرست 0.000 و نرخ رد نادرست 0.000 رسید، در حالی که خط پایه انرژی و نرخ گذر از صفر دقت 0.375، امتیاز F1 0.545 و نرخ پذیرش نادرست 1.000 داشت. فاصله اطمینان ویلسون 95 درصد برای دقت مصنوعی 89.28 تا 100 درصد است. زمان استنتاج هر گام روی پردازنده مرکزی 7.931 میلی ثانیه بود که در بودجه 20 میلی ثانیه‌ای هر فریم جای می‌گیرد. دقت کامل روی داده مصنوعی، یک نتیجه معنادار درباره عملکرد واقعی نیست؛ داده مصنوعی از همان مدل تولیدی ساخته شده که ویژگی‌ها را جداپذیر می‌کند. این عدد تنها به عنوان آزمون بازگشتی نرم‌افزاری ارزش دارد و در این نوشتار به عنوان شاهد کارایی آشکارساز ارائه نمی‌شود.

۲-۶-۵ تقریب روی داده ضبط‌شده

ارزیابی معنادار روی رخدادهای برگرفته از صوت واقعی مجموعه داده انجام شد. از 1,730 رخداد کشف‌شده، 1,048 رخداد انتخاب و بر پایه نشست به سه بخش تقسیم شد. آستانه تصمیم تنها روی 24 نشست اعتبارسنجی انتخاب شد (مقدار 0.70) و سپس یک‌بار روی 22 نشست آزمون با 132 رخداد اعمال گردید. نتیجه در جدول ۵-۸ آمده است.

ماتریس درهم‌ریختگی آشکارساز پیشنهادی روی مجموعه آزمون چنین است: 60 منفی درست، 6 مثبت نادرست، 19 منفی نادرست و 47 مثبت درست. فاصله اطمینان ویلسون 95 درصد در سطح رخداد برای دقت 73.53% تا 86.83%، برای نرخ پذیرش نادرست 4.23% تا 18.45% و برای نرخ رد نادرست 19.27% تا 40.64% است؛ فاصله امتیاز F1 در همین سطح، خودراه‌انداز رخدادی است (69.47% تا 86.33%). شکل ۳-۵ جست‌وجوی آستانه روی نشست‌های اعتبارسنجی و مقایسه نهایی با خط پایه را نشان می‌دهد.

آشکارساز پیشنهادی در برابر خط پایه، بهبود روشی در امتیاز F1 کلاس وقفه و کاهش چشمگیر نرخ رد نادرست نشان می‌دهد. خط پایه انرژی نرخ پذیرش نادرست صفر دارد اما این به بهای رد 43.94 درصد از وقفه‌های واقعی به دست آمده است، که در یک سامانه تعاملی به معنای بی‌اعتنایی مکرر به کاربر است. دقت نقطه‌ای 81.06 درصد از 80 درصد بالاتر است، اما کران پایین فاصله اطمینان بلوکی در سطح نشست 74.44 درصد است و از 80 درصد پایین‌تر می‌رود. مهم‌تر آن که برچسب‌های مرجع این ارزیابی، از تفکیک‌گوینده خودکار به دست آمده‌اند و بازبینی مستقل انسانی ندارند. بنابراین نیازمندی ۵ با این شواهد «اثبات نشده» است.



شکل ۵-۳: (الف) جست و جوی آستانه تصمیم روی نشست‌های اعتبارسنجی؛ خط عمودی، آستانه انتخاب شده 0.70 است. (ب) مقایسه آشکارساز پیشنهادی با خط پایه انرژی روی نشست‌های آزمون؛ میله‌های خطا، فاصله اطمینان بلوکی در سطح نشست‌اند.

۷-۵ پیوستگی انتقال تمام دو طرفه

آزمون بازگشتی خودکار بستر WebSocket با چهار آزمون گذشت. این آزمون‌ها تأیید می‌کنند که پیش‌بافر 3,200 نمونه‌ای پیش از وقفه با 1,600 نمونه دریافت‌شده پس از آن ترکیب می‌شود و یک ورودی 4,800 نمونه‌ای برای نوبت بعدی می‌سازد. همچنین دریافت تأیید توقف از کارخواه، تله‌متری شناسه زمان اجرا، لغو نوبت، اتصال هم‌زمان، اتصال مجدد، جداسازی وضعیت نشست‌ها، ورودی ناقص یا ساکت، بازیابی از خطای تولید و کمبود حافظه، و حالت نگهداری فقط‌سنجی بدون نوشتن پرونده صوتی پوشش داده شده‌اند. ممیزی نهایی مخزن نیز 206 آزمون موفق با پوشش شاخه‌ای 65 درصد (در برابر حد لازم 60 درصد) و بررسی نوع بدون خطا روی 49 پرونده را ثبت کرده است.

این شواهد پیوستگی را در سطح انتقال سرور اثبات می‌کنند. اجرای مرورگر فیزیکی انجام نشده است و اجرای سخت‌افزار هدف نیز انجام نشده است؛ بنابراین نیازمندی ن ۲ به صورت نرم‌افزاری برآورده و به صورت رسمی اثبات نشده باقی می‌ماند.

۸-۵ مسیر مستقیم: شش نسل آزمایشی


۱-۸-۵ نتیجه کل

جدول ۵-۹ خلاصه شش نسل آزمایشی را نشان می‌دهد. الگوی مشترک همه نسل‌ها یکسان است: زیان کاهش می‌یابد و شرط اجرای خودرگرسیو برآورده نمی‌شود.

مقادیر کمینه زیان میان نسل‌ها «مستقیماً قابل مقایسه نیستند»، زیرا پنجره متن، مجموعه اعتبارسنجی و شمار نمونه‌های ارزیابی میان نسل‌ها تفاوت دارد. برای نسخه v6.2، زیان روی همان داده آموزشی محاسبه شده و یک سنجه درون‌نمونه است. این ستون تنها برای نشان‌دادن روند کاهش زیان در هر نسل آورده شده است.

شکل ۴-۵ همین دو محور را در برابر یکدیگر می‌گذارد: کاهش زیان آفلاین در همه نسل‌ها رخ داده


است، اما هیچ نسلی به شرط 9 از 9 نرسیده است.



شکل ۴-۵: (الف) بهترین زیان آفلاین هر نسل. (ب) بیشترین شمار ردیف عبورکرده از پنل اجرای نهردیفی در هر نسل، در برابر شرط پذیرش 9 از 9.

۲-۸-۵ نسخه نخست: زیان کنارگذاشته مثبت، اجرای ناموفق

نسخه نخست تا 8000 گام و با پنجره 20 ثانیه آموزش دید. شکل ۵-۵ (الف) روند زیان آموزش و بخش (ب) زیان اعتبارسنجی بازارزیابی شده 16 چک‌پوینت را نشان می‌دهد. زیان اعتبارسنجی به‌طور یکنوا کاهش یافت و چک‌پوینت 8000 گام با زیان 1.402444 انتخاب شد.



شکل ۵-۵: (الف) زیان آموزش نسخه نخست تحت تحمیل معلم، به همراه میانگین غلطان. (ب) زیان اعتبارسنجی بازارزیابی شده به تفکیک مؤلفه متنی و صوتی؛ خط عمودی، چک‌پوینت انتخاب‌شده است.


روی مجموعه آزمون کنارگذاشته با 204 ردیف و 331 بازه، این آداپتر زیان کل 1.7272 با فاصله اطمینان 95 درصد 1.5866 تا 1.8678 داد، در برابر 3.5670 برای مدل پایه تطبیق نیافته و 9.9871 برای یک گروه کنترل که در آن علامت همه ماتریس‌های B آداپتر معکوس شده بود. یعنی از دید هدف آموزشی، آداپتر هم نسبت به مدل پایه و هم نسبت به کنترل، بهبود معنادار داشت.

با این حال، همان آداپتر انتخاب‌شده در سرور جویباری رسمی، صوت تقریباً ساکت و هیچ متنی تولید نکرد. این تناقض، همان مشاهده‌ای است که تعریف شرط پذیرش زمان اجرا برای نسل‌های بعدی را ضروری کرد.

۳-۸-۵ نسخه دوم: روشن‌ترین نمایش شکاف

نسخه دوم با پنجره متن 100 ثانیه و 20 چک‌پوینت نامزد، روشن‌ترین نمایش الگوی مرکزی این پروژه است. جدول ۱۰-۵ چند نقطه از این روند را نشان می‌دهد و شکل ۵-۶ تصویر کامل را ارائه می‌کند.

Trial v2: validation loss decreases monotonically while no checkpoint ever passes the full nine-row autoregressive runtime panel



شکل ۵-۶: نسخه دوم: زیان اعتبارسنجی روی 202 بازه در هر چک‌پوینت به‌طور یکنوا کاهش می‌یابد (خط)، در حالی که شمار ردیف‌های عبورکرده از پنل اجرای نهردیفی (میل‌ها) هرگز به شرط پذیرش نمی‌رسد. نکته تعیین‌کننده آن است که بهترین رفتار زمان اجرا در گام 400 رخ می‌دهد، یعنی جایی که زیان «بالا تر» است، و با ادامه کاهش زیان تا گام 2000 رفتار زمان اجرا «بدتر» می‌شود و به صفر می‌رسد. این یعنی زیان اعتبارسنجی در این تنظیم، حتی همبستگی مثبت با کیفیت تولید ندارد.

۴-۸-۵ نسخه‌های سوم تا پنجم: آزمون فرضیه‌های هدفمند


سه نسخه بعدی، فرضیه‌های مشخصی را آزمودند (جدول ۴-۱). نسخه سوم همه درج‌گراها را منجمد کرد و رتبه را به 128 افزایش داد. نسخه چهارم تنها دو درج‌گر متنی را آموزش داد و نسخه پنجم ضریب زیان کتاب رمز نخست را از 100 به 10 کاهش داد. جدول ۵-۱۱ نتیجه ردیف‌به‌ردیف دو نسخه آخر را نشان می‌دهد.

الگوی مشترک این دو جدول قابل توجه است: با کاهش زیان، شمار ردیف‌هایی که «اصلاً گفتاری» تولید می‌کنند از 9 به 4 یا 5 کاهش می‌یابد. یعنی مدل هم‌زمان که هدف آموزشی را بهتر برآزش می‌کند، در تولید خودرگرسیو بیشتر به سکوت میل می‌کند. بیشینه حافظه اختصاص یافته نسخه چهارم 28.640 گیگابایت بود.

هر سه نسخه با صفر چک‌پوینت واجد شرایط «شکست‌بسته» شدند، هیچ آداپتری انتخاب نشد و دیوار آتش آزمون نهایی هیچ‌گاه باز نگردید.

۵-۸-۵ نسخه ششم: تفکیک ظرفیت از تولید

نسخه v6.2 یک آزمون ابطال درون‌نمونه است: آموزش و ارزیابی روی همان 32 نمونه. نتیجه، همان‌طور که در جدول ۵-۱۲ و شکل ۷-۵ آمده است، دوبخشی و روشن است.



شکل ۷-۵: نسخه v6.2: (الف) زیان درون‌نمونه به‌طور پیوسته کاهش می‌یابد و کاهش زیان متنی از گام 50 به بهترین گام بعدی 32.20 درصد است. (ب) با این حال هر چهار چک‌پوینت 0 از 9 ردیف پنل اجرا را می‌گذرانند. بهترین زیان متنی پس از گام 50 برابر 0.550852 است که 32.20 درصد کمتر از مقدار گام 50 (0.812474) و بالاتر از معیار ازپیش‌تعریف‌شده 30 درصد است. یعنی این آداپتر «ظرفیت» برآزش هدف آموزشی را دارد.

در همان حال، هر چهار چک پوینت 0 از 9 ردیف پنل اجرا را می‌گذرانند و در هر چک پوینت تنها یک ردیف از نه ردیف هم‌زمان متن و گفتار تولید می‌کند. نتیجه‌گیری دقیق چنین است:

نسخه v6.2 هدف آموزشی محدود درون‌نمونه را آموخت، اما رفتار آموخته‌شده به تولید خودرگرسیو قابل اتکای گفتار و متن فارسی منتقل نشد.

هیچ چک پوینتی از هیچ‌یک از شش نسل، واجد شرایط استقرار نیست و هیچ آزمون نهایی برای مسیر مستقیم باز نشد. عبارت «مدل Moshika با موفقیت برای فارسی تنظیم شد» با این شواهد «نادرست» است. نتیجه صحیح، «آزمایش منفی با سیگنال یادگیری مثبت» است.

۹-۵ تأخیر و سخت‌افزار

سخت‌افزار در دسترس پروژه یک پردازنده گرافیکی H100 NVL با 93.09 گیگابایت حافظه بود، که در بازه 12 تا 24 گیگابایت نیازمندی ن ۶ قرار نمی‌گیرد. دو آزمون تأخیر سمت سرور اجرا شد: یکی با سقف نرم‌افزاری 24 گیگابایت و یکی بدون سقف. مقادیر اندازه‌گیری‌شده در جدول ۵-۱۳ آمده است.

این مقادیر با صوت مصنوعی و زمان‌سنجی سمت سرور به دست آمده‌اند و تأیید پخش از سوی مرورگر ندارند؛ همچنین سقف نرم‌افزاری حافظه، یک کارت 93 گیگابایتی را به یک کارت 24 گیگابایتی تبدیل نمی‌کند. شمار ردیف‌های واجد شرایط رسمی سرتاسری «صفر» است. بنابراین ادعای «تأخیر سامانه کمتر از 500 میلی‌ثانیه است» با این شواهد مجاز نیست. اندازه‌گیری معنادار عملی، همان زمان تولید کامل پاسخ در جدول ۵-۴ است که میانه آن 5584.7 میلی‌ثانیه است.

۱۰-۵ مطالعه انسانی

پروتکل مطالعه انسانی، شامل سند رضایت‌نامه، برگه امتیازدهی و مجموعه سناریوهای تعاملی، طراحی و در مخزن ثبت شد. حالت‌های نگه‌داری داده نیز پیاده شد تا مطالعه بتواند بدون ذخیره پرونده صوتی و تنها با نگه‌داری بردار ویژگی یا سنجه اجرا شود.

اجرای مطالعه اما تکمیل نشد. وضعیت ثبت‌شده: یک شرکت‌کننده، یک شرکت‌کننده بالای 60 سال، و 0 مجموعه امتیاز کامل. مخرج امتیازدهی صفر است و بنابراین هیچ فاصله اطمینانی قابل برآورد نیست. برای نیازمندی ن ۷ شواهد رسمی کافی وجود ندارد. هیچ ادعایی درباره طبیعی بودن گفتار خروجی، رضایت کاربری یا تجربه سالمندان فارسی‌زبان در این نوشتار مطرح نمی‌شود، و در جداول این فصل هیچ خانه مربوط به ارزیابی انسانی با مقدار تخمینی پر نشده است.

۱۱-۵ وضعیت نهایی نیازمندی‌ها

جدول ۱۴-۵ وضعیت هر هفت نیازمندی جدول ۱-۱ را در برابر شواهد به دست آمده قرار می دهد. ن ۱ در این جدول تنها عبور مکانیکی 9/9 زنجیره با پاسخگوی Qwen2.5-0.5B را پوشش می دهد. ن ۳، ن ۵، ن ۶ و ن ۷ اثبات نشده اند؛ ن ۵ حتی با دقت نقطه ای 81.06 درصد، به دلیل برجسب خودکار و کران پایین فاصله اطمینان نشست، عبور رسمی از 80 درصد شمرده نمی شود.

از چهار قلم خروجی مورد انتظار تعریف پروژه، سه قلم تولید و مستند شده اند: نمونه اولیه کارا برای مسیر آبشاری، کد منبع مستند با مجوز آزاد و مجموعه آزمون خودکار، و مجموعه داده مکالمه فارسی. برای قلم چهارم، پروتکل، رضایت نامه و زیرساخت سنجش آماده است؛ یافته های تجربی تعامل سالمندان تنها پس از تکمیل مطالعه انسانی قابل گزارش خواهد بود و در فصل ۷ به عنوان کار آینده معرفی می شود.

جدول ۵-۲: مشخصات مجموعه داده مکالمه فارسی مشتق شده و ممیزی خودکار آن

مقدار	شاخص
775.887 ساعت	موجودی زیرنویس کانال‌ها
1,442	برنامه‌های بلند موجودی
309	برنامه‌های انتخاب شده
1,129	پنجره‌های نامزد
219.946 ساعت	ساعت نامزد پس از انتخاب
207.154 ساعت	ساعت چندگویندگی طبقه‌بندی شده خودکار
6,754	جفت‌های پاسخ بدون بازاستفاده
123.796 ساعت	ساعت صوت منبع جفت‌ها
407	گویندگان
162	نشست‌ها
6,754	جفت‌های خروجی استریو
108.584 ساعت	ساعت استریوی خروجی
6,419/131/204	تفکیک آموزش / اعتبارسنجی / آزمون
0	نشت گروهی
0	پرونده‌های گم شده در ممیزی
0	شکست ممیزی خودکار
770	نامزدهای خودکار رخداد تعاملی
717/53	از آن، وقفه مانند / بازخورد مانند
0	ردیف‌های تأیید شده توسط انسان

جدول ۵-۳: نتیجه پنل ثابت اعتبارسنجی سامانه آبخاری

مقدار	شاخص
131	ردیف‌های فهرست‌نامه اعتبارسنجی
شناسه نشست منبع	واحد تفکیک
0	نشست تفکیک
9	ردیف‌های ارزیابی شده از پیش تعریف شده
Qwen2.5-0.5B-	پاسخ‌گوی متنی پنل
Instruct	
9/9	ردیف‌های عبور کرده از همه شروط
0/9	ردیف‌های با پاسخ جایگزین قاعده‌محور
0/9	ردیف‌های با تلاش دوباره زبانی
0	خطای سرویس بازشناسی
0/9	شکست بارگذاری یا تولید مدل زبانی
1.000	کمینه سهم نویسه فارسی در رونویسی
1.000	کمینه سهم نویسه فارسی در پاسخ
9/9	پاسخ‌های صوتی غیر ساکت
0.133529	کمینه ریشه میانگین مربعات صوت پاسخ
0	ردیف‌های آزمون نهایی استفاده شده

جدول ۴-۵: اندازه‌گیری‌های هر ردیف پنل اعتبارسنجی سامانه آبشاری

ردیف فهرست‌نامه	نویسه رونویسی	مدت صوت پاسخ (ثانیه)	ریشه میانگین مربعات	زمان تولید کامل (ms)	عبور
0	35	4.644	0.184925	4895.3	بله
16	541	5.352	0.162841	5473.7	بله
32	5031	7.535	0.210650	13270.2	بله
48	1237	9.857	0.191641	7414.3	بله
65	445	9.288	0.162643	6664.3	بله
81	2398	7.465	0.133529	12709.4	بله
97	77	3.448	0.193290	2072.4	بله
113	405	5.259	0.191777	3674.2	بله
130	142	8.824	0.154569	5584.7	بله

جدول ۵-۵: نتیجه تقریب خودکار بازبازشناسی گفتار تولیدشده

شاخص	مقدار
ردیف‌های معتبر / خطای سرویس بازشناسی 9/0	
واژه‌های مرجع / ویرایش‌های واژه	171/52
نرخ خطای واژه تجمیع خرد	30.41%
نرخ خطای واژه میانگین کلان	32.01%
نرخ خطای واژه، میانه / صدک ۹۵ / بیشینه	28.00%/49.40%/54.55%
نویسه‌های مرجع / ویرایش‌های نویسه 658/47	
نرخ خطای نویسه تجمیع خرد	7.14%
نرخ خطای نویسه میانگین کلان	7.13%
نرخ خطای نویسه، میانه / صدک ۹۵ / بیشینه	7.50%/9.40%/9.62%
ردیف‌های با تطابق کامل واژه‌ای	0/9
ردیف‌های با تطابق کامل نویسه‌ای	0/9

جدول ۵-۶: نتیجه آزمون نهایی معنایی خودکار روی 40 ردیف گروه ناهمپوشان

شاخص	مقدار
ردیف‌های آزمون	40
نشست‌های منبع	5
فراخوانی معتبر داور / مورد انتظار	240/240
فراخوانی ناموفق داور	0
نرخ توافق تکرار داور	1.00
میانگین ارتباط نامزد	3.150
میانگین ارتباط خط پایه	1.425
میانگین ارتباط مرجع هم‌تراز شده	0.950
میانگین انسجام نامزد	3.325
میانگین انسجام خط پایه	1.525
بهبود ارتباط نسبت به خط پایه	+1.725
بهبود انسجام نسبت به خط پایه	+1.800
برد زوجی ارتباط	27/40 (67.5%)
ارتباط حداقل دو	35/40 (87.5%)
تلاش دوباره تولید نامزد	0
صوت نامعتبر نامزد	0

جدول ۵-۷: شروط خودکار از پیش تعریف شده آزمون نهایی و مقادیر مشاهده شده

شرط	آستانه	مشاهده	وضعیت
میانگین ارتباط نامزد	≥ 2.00	3.150	برآورده
میانگین انسجام نامزد	≥ 2.50	3.325	برآورده
بهبود ارتباط	≥ 0.50	1.725	برآورده
بهبود انسجام	≥ 0	1.800	برآورده
نرخ برد زوجی ارتباط	≥ 0.60	0.675	برآورده
نرخ ارتباط حداقل دو	≥ 0.70	0.875	برآورده
اعتبار کامل مکانیکی	240/240	240/240	برآورده

جدول ۵-۸: نتیجه تقریب آشکارساز وقفه روی رخداد‌های صوت ضبط‌شده با نشست‌های کنارگذاشته

سنجه	آشکارساز	خط پایه	فاصله اطمینان 95% آشکارساز
	پیشنهادی	انرژی	(بلوکی در سطح نشست)
دقت	81.06%	78.03%	74.44% – 87.18%
امتیاز F1 وقفه	78.99%	71.84%	72.34% – 85.71%
نرخ پذیرش نادرست	9.09%	0.00%	2.63% – 16.92%
نرخ رد نادرست	28.79%	43.94%	19.30% – 37.23%

جدول ۵-۹: خلاصه شش نسل آزمایشی مسیر مستقیم. ستون «بهترین اجرا» بیشترین شمار ردیف عبورکرده از ۹ ردیف پنل اجرا در میان همه چک‌پوینت‌های آن نسل است.

نسخه	پنجره	نامزد	کمینه	بهترین	واجد
			زیان	اجرا	شرایط
v1	20	16	1.402	0/9	نه
v2	100	20	1.735	2/9	نه
v3	100	5	1.879	1/9	نه
v4	100	5	1.879	1/9	نه
v5	100	5	1.868	1/9	نه
v6.2	12	4	2.060	0/9	نه

جدول ۵-۱۰: نمونه‌ای از چک‌پوینت‌های نسخه دوم: زیان اعتبارسنجی به‌طور یکنوا کاهش می‌یابد در حالی که شمار ردیف‌های عبورکرده از پنل اجرا افزایش نمی‌یابد

گام	زیان کل	زیان متنی	زیان صوتی	عبور از پنل
100	2.312407	0.402789	1.909618	0/9
400	1.894230	0.201763	1.692467	2/9
800	1.792216	0.164635	1.627582	1/9
1000	1.768085	0.155691	1.612394	1/9
1500	1.739114	0.144936	1.594178	0/9
2000	1.734574	0.143414	1.591161	0/9

جدول ۵-۱۱: نتیجه هر چک پوینت نسخه‌های چهارم و پنجم روی پنل اجرای نهردیفی

نسخه پنجم			نسخه چهارم			گام
عبور	گفتار	زیان	عبور	گفتار	زیان	
0/9	9/9	2.082676	1/9	9/9	2.082125	100
0/9	7/9	1.943459	0/9	7/9	1.948315	200
0/9	6/9	1.889862	0/9	4/9	1.899640	300
1/9	5/9	1.870719	1/9	5/9	1.881632	400
1/9	4/9	1.867859	0/9	5/9	1.879061	500

جدول ۵-۱۲: نسخه ۷۶.۲: سیگنال یادگیری درون نمونه مثبت در برابر نتیجه اجرای خودرگرسو منفی

گام	زیان کل	زیان متنی	زیان صوتی	عبور از پنل
50	2.636405	0.812474	1.823931	0/9
100	2.245344	0.638987	1.606357	0/9
150	2.071542	0.550852	1.520690	0/9
200	2.060297	0.551183	1.509114	0/9

جدول ۵-۱۳: اندازه‌گیری‌های تأخیر سمت سرور. این مقادیر کلاس شواهد «مؤلفه سمت سرور» دارند و رسمی نیستند.

آزمون	تعداد	میانه	صدک ۹۵	رسمی
		(ms)	(ms)	
نخستین صوت، با سقف حافظه	16	60.24	121.87	نه
نخستین صوت، بدون سقف	16	44.81	80.26	نه
توقف پخش، با سقف حافظه	16	17.71	18.21	نه
توقف پخش، بدون سقف	16	11.71	16.02	نه
ردیف‌های رسمی سرتاسری	0	-	-	-

جدول ۵-۱۴: وضعیت نهایی هفت نیازمندی تعریف پروژه و کلاس شواهد پشتیبان

شماره	وضعیت	شواهد پشتیبان
۱ن	برآورده برای مسیر آشناری	پنل ثابت ۹ از ۹ با صفر پاسخ جایگزین
۲ن	نرم افزاری برآورده، رسمی	چهار آزمون بازگشتی بستر انتقال؛ بدون مرورگر فیزیکی
۳ن	اثبات نشده اندازه گیری رسمی انجام نشده	صفر ردیف واجد شرایط سرتاسری
۴ن	برآورده	108.584 ساعت خروجی ممیزی شده، درون بازه هدف
۵ن	پیاپی سازی شده، عبور رسمی	دقت 81.06% با برچسب خودکار؛ کران پایین فاصله اطمینان 74.44%
۶ن	اثبات نشده شواهد رسمی موجود نیست	سخت افزار موجود 93.09 گیگابایتی، خارج از بازه هدف
۷ن	شواهد رسمی موجود نیست	یک شرکت کننده، صفر مجموعه امتیاز کامل

فصل ۶

بحث و محدودیت‌ها

این فصل نتایج فصل ۵ را تفسیر می‌کند. چهار مشاهده کلیدی به تفصیل بررسی می‌شوند و سپس محدودیت‌ها و ملاحظات اخلاقی و حقوقی برشمرده می‌شوند.

۶-۱ فاصله میان کاهش زیان و تولید معتبر

مهم‌ترین یافته این پروژه، الگویی است که در هر شش نسل آزمایشی مسیر مستقیم تکرار شد: زیان تحت تحمیل معلم به‌طور یکنوا کاهش یافت و در همان حال شرط اجرای خودرگرسو هیچ‌گاه برآورده نشد. نسخه دوم روشن‌ترین نمایش این الگو است، زیرا در آن بهترین رفتار زمان اجرا در گام 400 رخ می‌دهد، یعنی جایی که زیان اعتبارسنجی «بالا تر» است، و با کاهش بیشتر زیان تا گام 2000، رفتار زمان اجرا به صفر می‌رسد (شکل ۵-۶).

سه توضیح ممکن برای این مشاهده وجود دارد و شواهد پروژه به تفکیک آن‌ها کمک می‌کند.

توضیح یک: نبود ظرفیت یادگیری. ممکن است آداپتر کم‌رتبه ظرفیت کافی برای نمایش فارسی نداشته باشد. نسخه v6.2 به‌طور خاص برای ابطال همین فرضیه طراحی شد: آموزش و ارزیابی روی همان 32 نمونه. کاهش 32.20 درصدی زیان متنی درون‌نمونه نشان می‌دهد که آداپتر «ظرفیت» برازش هدف را دارد. بنابراین این توضیح رد می‌شود.

توضیح دو: اربیبی مواجهه. توضیح سازگارتر با شواهد، همان مفهومی است که در بخش ۲-۴-۲ معرفی شد. در آموزش، مدل همیشه نشانه‌های متنی و صوتی «درست» پیشین را به‌عنوان شرط دریافت می‌کند و

پیش‌بینی یک گام جلوتر مسئله‌ای آسان است، به‌ویژه در معماری «تک‌گویی درونی» که متن هم‌تراز شده با زمان در ورودی حاضر است. اما در تولید خودرگرسیو، مدل باید هم متن و هم صوت را از صفر بسازد. اگر نشانه‌های نخست کمی از توزیع مرجع فاصله بگیرند، مدل به ناحیه‌ای می‌رود که در آموزش ندیده است و خطا به‌صورت تجمعی رشد می‌کند.

مشاهده‌ای که این توضیح را تقویت می‌کند، در جدول ۵-۱۱ دیده می‌شود: با کاهش زیان، شمار ردیف‌هایی که «اصلاً» گفتاری تولید می‌کنند از ۹ به ۴ یا ۵ کاهش می‌یابد. یعنی مدل با برازش بهتر هدف، در تولید مستقل به سکوت میل می‌کند. این رفتار با یک مدل که تنها «به‌قدر کافی یاد نگرفته» سازگار نیست؛ با مدلی سازگار است که آموخته است در حضور متن ورودی مرجع به‌درستی پیش‌بینی کند و در غیاب آن فرو می‌ریزد.

نسخه v6.2 کوشید همین را جبران کند: حذف تصادفی زمان‌بندی‌شده ورودی متنی، سهم نشانه‌های مرجع پنهان‌شده را از ۰.۲۵ به ۰.۷۵ افزایش می‌داد تا مدل بیاموزد بر پیش‌بینی خودش تکیه کند. این مداخله، سیگنال یادگیری را حفظ کرد اما به تولید معتبر منتقل نشد. توضیح احتمالی آن است که با ۳۲ نمونه آموزشی و ۲۰۰ گام، بودجه در دسترس برای بازآموزی یک رفتار تولیدی پایدار به‌مراتب کمتر از حد لازم است.

توضیح سه: انگلیسی محوری مدل پایه. مدل پایه به‌شدت انگلیسی‌محور است. در نسل‌های نخست مشاهده شد که خروجی چک‌پوینت‌های میانی، گفتار «انگلیسی» است و نه فارسی. یعنی آداپتر نتوانسته توزیع زبان تولیدی را جابه‌جا کند و تنها بر جزئیات آوایی اثر گذاشته است. تلاش نسخه چهارم برای آموزش گزینشی درج‌گرهای متنی، پاسخ مستقیم به همین فرضیه بود و آن نیز کافی نبود.

نتیجه‌گیری روشمند. فارغ از این‌که کدام توضیح سهم بیشتری دارد، یک نتیجه عملی قطعی است و به نظر ما مهم‌ترین سهم علمی این نوشتار است:

در تطبیق کم‌پارامتریک مدل گفتار به گفتار به زبانی جدید، زیان اعتبارسنجی تحت تحمیل معلم معیار کافی و حتی معیار قابل اتکایی برای انتخاب چک‌پوینت نیست. آزمون تولید خودرگرسیو در زمان اجرا باید بخشی از معیار انتخاب باشد و نه یک بررسی پس از انتخاب.

اگر پروژه معیار انتخاب را تنها بر زیان بنا کرده بود، چک‌پوینت گام ۸۰۰۰ نسخه نخست، با کمترین زیان اعتبارسنجی و با بهبود معنادار نسبت به مدل پایه (۱.۷۲۷۲ در برابر ۳.۵۶۷۰ روی داده کنارگذاشته)، به‌عنوان «مدل گفتار به گفتار فارسی» گزارش می‌شد؛ در حالی که همان چک‌پوینت در سرور رسمی صوت تقریباً ساکت و هیچ متنی تولید نمی‌کرد.

۲-۶ چرا نرخ خطای واژه بسیار بیشتر از نرخ خطای نویسه است

در سنجه بازبازشناسی همان 9 خروجی پنل مکانیکی با پاسخگوی Qwen2.5-0.5B، نرخ خطای نویسه 7.14 درصد و نرخ خطای واژه 30.41 درصد است؛ یعنی نرخ خطای واژه بیش از چهار برابر است. این نسبت در نگاه اول نگران‌کننده به نظر می‌رسد اما تا حد زیادی یک اثر «تعریفی» در زبان فارسی است.

سه سازوکار در این فاصله سهم دارند. نخست، **مرز واژه در فارسی**. در تعریف به کاررفته، نیم فاصله یک مرز واژه به شمار می‌آید. اگر سرویس بازبازشناسی یک واژه مرکب را با فاصله کامل بنویسد در حالی که مرجع آن را با نیم فاصله نوشته است، یک واژه به دو واژه تبدیل می‌شود و این تنها اختلاف، دو ویرایش واژه‌ای تولید می‌کند، در حالی که در سطح نویسه تنها یک نویسه تفاوت دارد. دوم، **یکسان نبودن صورت نوشتاری**. برای بسیاری از واژه‌های فارسی چند صورت نوشتاری پذیرفته وجود دارد. سوم، **اثر طول**. میانگین طول واژه در داده این پنل حدود چهار نویسه است؛ در چنین شرایطی هر خطای یک نویسه‌ای به طور خودکار به یک خطای کامل واژه‌ای تبدیل می‌شود.

شاهد پشتیبان این تفسیر در داده هست: در هر 9 ردیف، شمار نویسه‌های فرضیه و مرجع تقریباً یکسان است (برای نمونه 52 و 52 در ردیف نخست) در حالی که شمار واژه‌ها تفاوت دارد (11 و 12). یعنی محتوای نویسه‌ای تقریباً حفظ شده و اختلاف عمدتاً در بخش بندی است.

با این حال، دو محدودیت این تفسیر را باید صریح گفت. نخست، بخشی از خطا می‌تواند از تلفظ نادرست موتور گفتاری بیاید و نه از بخش بندی؛ تفکیک این دو سهم بدون گوش دادن انسانی ممکن نیست. دوم، سرویس بازبازشناسی هم در سامانه و هم در اندازه گیری مشارکت دارد؛ خطای مشترک آن‌ها می‌تواند نتیجه را به هر دو سمت جابه‌جا کند. بنابراین نرخ خطای نویسه 7.14 درصد را نمی‌توان به «گفتار تولیدی برای انسان کاملاً قابل فهم است» ترجمه کرد.

۳-۶ چرا تطبیق پاسخ‌گو زیان را کم کرد ولی کیفیت را بهتر نکرد

آزمایش بخش ۳-۵-۵ یک تناقض ظاهری دارد: تطبیق کم‌پارامتر پاسخ‌گو زیان توسعه را 31.18 درصد کاهش داد اما در ارزیابی معنایی از خط پایه پیشی نگرفت. پاسخ این تناقض در ماهیت «هدف» آموزشی نهفته است.

هدف آموزشی این آداپتر، بازتولید «نوبت گوینده بعدی» در داده مکالمه بود. اما نوبت گوینده بعدی در یک برنامه گفت‌وگوی طبیعی، پاسخ یک دستیار به یک پرسش نیست. آن نوبت می‌تواند یک تأیید کوتاه، یک تغییر موضوع، یک شوخی، یک پرسش متقابل یا ادامه روایت خود گوینده باشد. مدل با آموزش روی

این هدف، «سبک» نوبت‌گیری طبیعی را بهتر می‌آموزد و زیان کاهش می‌یابد، اما دستورپیروی و پاسخ‌دهی مرتبط را نمی‌آموزد و ممکن است آن را حتی تخریب کند.

شاهد مستقیم و تعیین‌کننده این تفسیر در آزمون نهایی معنایی است: بازوی «مرجع هم‌تراز شده خودکار نوبت‌گوینده بعدی» کمترین امتیاز ارتباط را گرفت، 0.950، که حتی از خط پایه 0.5 میلیارد پارامتری (1.425) نیز پایین‌تر است (شکل ۵-۲). یعنی داور خودکار، همان هدفی را که آداپتر کوشیده بود تقلید کند، به‌عنوان پاسخ نامرتب ارزیابی کرده است.

نتیجه عملی این مشاهده برای پژوهش‌های بعدی روشن است: نوبت‌های هم‌تراز شده خودکار از مکالمه طبیعی، مواد «ارزشمندی» برای یادگیری زمان‌بندی گفتار، نوبت‌گیری و پدیده‌های تعاملی‌اند، اما بدون یک مرحله گزینش و بازنویسی، هدف «ضعیفی» برای آموزش پاسخ‌دهی دستورپیرو هستند. همین نکته احتمالاً بخشی از شکست مسیر مستقیم را نیز توضیح می‌دهد، زیرا مدل مستقیم روی همان جفت‌ها آموزش دیده است.

۴-۶ تعارض ساختاری میان نیازمندی‌ها

تحلیل جدول ۳-۱ یک تعارض ساختاری در تعریف پروژه را آشکار می‌کند که ارزش ثبت دارد. نیازمندی ن ۲ قابلیت تمام‌دوطرفه را می‌خواهد و نیازمندی ن ۳ تأخیر حداکثر 500 میلی‌ثانیه، در حالی که نیازمندی ن ۶ اجرا روی پردازنده گرافیکی با 12 تا 24 گیگابایت حافظه را الزام می‌کند.

مدل‌هایی که قابلیت تمام‌دوطرفه «ذاتی» دارند، یعنی جریان کاربر و جریان خود را هم‌زمان مدل می‌کنند، در زمان انجام این پروژه در بازه حافظه هدف جای نمی‌گرفتند. مدل پایه مسیر مستقیم این پروژه در آموزش تا 28.640 گیگابایت حافظه مصرف کرد. در سوی دیگر، معماری آبخاری در بازه حافظه هدف جای می‌گیرد اما تأخیر آن، همان‌طور که در جدول ۵-۴ دیده می‌شود، با میانه 5584.7 میلی‌ثانیه برای تولید کامل پاسخ، از هدف 500 میلی‌ثانیه بسیار دور است.

این یک نقص پیاده‌سازی نیست، بلکه یک محدودیت واقعی حوزه در زمان انجام پروژه است. راه‌های عبور از آن در فصل ۷ پیشنهاد شده است، به‌ویژه تولید جویباری که در آن نخستین قطعه صوت پیش از تکمیل پاسخ پخش می‌شود و بنابراین سنجه نخستین صوت از زمان تولید کامل جدا می‌گردد.

۵-۶ ارزش و مرز نتیجه معنایی خودکار

نتیجه آزمون نهایی معنایی، مثبت و از هر هفت شرط ازپیش تعریف شده عبور کرده است. طراحی این آزمون چند نقطه قوت روشمند دارد: مرحله صلاحیت جدا از آزمون نهایی، شاخص ردیف ها و آستانه های قفل شده پیش از اجرا، دوسوکورسازی و تصادفی سازی ترتیب بازوها، کدگشایی قطعی داور، و اعتبار کامل هر 240 فراخوانی با نرخ توافق تکرار 1.00.

با این حال، سه محدودیت آن را از یک نتیجه انسانی جدا می کند. نخست، هم خانواده بودن داور و نامزد. داور و نامزد از یک خانواده مدل اند؛ پیشینه ارزیابی خودکار نشان داده است که داورها به خروجی مدل های هم خانواده تمایل نشان می دهند [۳۷]. دوم، کالبره نبودن سنجه نامه. سنجه نامه امتیازدهی با امتیاز انسانی فارسی زبان کالبره نشده است؛ بنابراین نمی دانیم امتیاز 3.150 از 4 به چه سطحی از رضایت کاربر واقعی متناظر است. سوم، محدوده معنایی. این آزمون تنها ارتباط و انسجام را می سنجد و درباره درستی واقعی محتوا، ایمنی پاسخ یا طبیعی بودن گفتار چیزی نمی گوید.

با این مرزها، تفسیر درست چنین است: زنجیره آبخاری، پاسخ هایی تولید می کند که یک داور خودکار آن ها را به طور نظام مند و با فاصله زیاد (+1.725 در ارتباط) مرتبط تر از خط پایه ارزیابی می کند. این یک شاهد مهندسی معتبر برای کارکرد سامانه است و نه یک ادعای کیفیت ادراکی.

۶-۶ محدودیت ها

محدودیت های این پروژه به صورت صریح و فهرست شده چنین است.

۱. سخت افزار هدف. ارزیابی روی هیچ پردازنده گرافیکی فیزیکی با 12 تا 24 گیگابایت حافظه انجام نشد. سخت افزار موجود 93.09 گیگابایت حافظه داشت و سقف نرم افزاری حافظه، آن را به یک کارت واجد شرایط تبدیل نمی کند.

۲. تأخیر سرتاسری. سنجه $T_{\text{first_audio}}$ با رویداد تأیید شده مرورگر اندازه گیری نشد و شمار ردیف های واجد شرایط رسمی صفر است. زمان تولید کامل پاسخ جانشین آن نیست. ادعای تأخیر کمتر از 500 میلی ثانیه با شواهد موجود مجاز نیست.

۳. مطالعه انسانی. مطالعه 5 تا 10 گویشور فارسی با دست کم دو نفر بالای 60 سال انجام نشد. وضعیت ثبت شده یک شرکت کننده و صفر مجموعه امتیاز کامل است. بنابراین هیچ یافته ای درباره طبیعی بودن گفتار خروجی، رضایت کاربری یا تعامل سالمندان فارسی زبان قابل ادعا نیست.

۴. کیفیت معنایی. کیفیت معنایی تنها با یک تقریب خودکار هم‌خانواده سنجیده و مثبت شد. طبیعی بودن، درستی تلفظ، رضایت کاربر و درستی واقعی محتوا با قضاوت انسانی سنجیده نشد.
۵. برجسب‌های وقفه. برجسب‌های مرجع ارزیابی آشکارساز از تفکیک گوینده خودکار به دست آمده‌اند و بازیابی مستقل انسانی ندارند. دقت نقطه‌ای 81.06 درصد از 80 درصد بالاتر است، اما کران پایین فاصله اطمینان بلوکی در سطح نشست 74.44 درصد است. عبور رسمی از نیازمندی ۵ اثبات نشده است.
۶. بازیابی شنیداری داده. بازیابی شنیداری چهل‌ردیفی داده و بازیابی بیست‌و‌چهارردیفی رخدادهای تعاملی، تحت یک سند انصراف زمانی مستند، انجام نشد. هیچ ردیفی از مجموعه داده «تأیید شده توسط انسان» نیست.
۷. مسیر مستقیم. هیچ‌یک از شش نسل آزمایشی، چک‌پوینت واجد شرایط استقرار تولید نکرد. نتیجه این مسیر یک نتیجه منفی با سیگنال یادگیری مثبت است و نه یک مدل گفتار به گفتار فارسی موفق.
۸. مرورگر و میکروفون فیزیکی. پیوستگی تمام‌دوطرفه در سطح انتقال سرور آزموده شد، اما توقف واقعی منبع صوت در یک مرورگر واقعی با میکروفون فیزیکی اندازه‌گیری نشد.
۹. تعمیم مجموعه داده. مجموعه داده از چهار کانال برنامه گفت‌وگویی مشتق شده است و سبک گفتاری آن‌ها نماینده همه گونه‌های گفتار فارسی نیست. صدای کانال دستیار نیز با یک صدای واحد بازسازی شده است.
۱۰. بازتولید کامل. تنسورهای بخشی از چک‌پوینت‌های نامزد ارتقا نیافته به‌عمد حذف شده‌اند و بازتولید دقیق آن‌ها مستلزم اجرای مجدد دستور آموزش قفل شده است. همه نتایج علمی، پیکربندی‌ها، خروجی‌های زمان اجرا و درهم‌سازی‌ها حفظ شده‌اند.

۷-۶ ملاحظات اخلاقی، حریم خصوصی و حقوقی

۱-۷-۶ خاستگاه و حقوق داده

مجموعه داده از یک آرشیو داخلی محتوای گفتاری فارسی مشتق شده است. استفاده پژوهشی داخلی از این منابع با تأیید استاد راهنما ثبت شده است. این تأیید «مجوز باز نشر» نیست: صوت خام، زیرنویس خام و مشتقات آن‌ها در مخزن کد قرار نگرفته‌اند و در بسته تحویل پروژه نیز منتشر نمی‌شوند. عبارت «داده عمومی در دسترس، مجوز آموزش یا باز نشر آزاد دارد» نادرست است و در این نوشتار به کار نرفته است.

۶-۷-۲ حریم خصوصی در مطالعه انسانی

سامانه سه حالت نگه‌داری داده دارد: نگه‌داری پرونده صوتی، نگه‌داری تنها بردار ویژگی کاهش‌یافته، و نگه‌داری تنها سنجه‌ها. حالت پیش‌فرض پیشنهادی برای مطالعه انسانی، حالت فقط‌ویژگی است تا گفتار قابل بازسازی شرکت‌کننده ذخیره نشود. آزمون خودکار نیز بررسی می‌کند که در حالت فقط‌سنجه هیچ پرونده صوتی نوشته نمی‌شود.

در ارزیابی‌های خودکار نیز اصل کمینه‌سازی داده رعایت شده است: مصنوعات نتیجه، متن رونویسی، متن پاسخ و توضیح داور را به‌صورت متن آشکار ذخیره نمی‌کند و تنها درهم‌سازی و مقادیر تجمیعی نگه می‌دارند. تحلیل توصیفی پس‌نگر بخش ۵-۳ نیز به‌طور صریح بدون خواندن متن آشکار اجرا شد.

۶-۷-۳ مجوز و مرزهای آن

کد منبع و مستندات متعلق به این پروژه با مجوز Apache-2.0 منتشر می‌شوند. این مجوز «شامل» موارد زیر نیست و شرایط مستقل هر یک همچنان حاکم است: اجزای نرم‌افزاری شخص ثالث، وزن‌های مدل‌های زبانی و صوتی، مجموعه داده منبع و مشتقات آن، آداپترهای آموزش دیده، رسانه محدودشده و زیرنویس‌ها، و مواد شرکت‌کنندگان مطالعه انسانی. به‌طور خاص، موتور گفتاری مورد استفاده مجوز متفاوتی دارد و تعهدات آن جداگانه باقی می‌ماند.

۶-۷-۴ کاربرد و سوء‌کاربرد

سامانه‌ای که گفتار فارسی طبیعی تولید می‌کند، قابلیت سوء‌کاربرد دارد. در شکل کنونی، دو عامل این خطر را محدود می‌کند: صدای خروجی، یک صدای هم‌آمایش شده واحد و شناخته‌شده است و شبیه‌سازی صدای افراد پیاده نشده است؛ و پاسخ‌گوی متنی با یک پرامپت قفل شده کار می‌کند. با این حال، پروژه هیچ سنجش ایمنی محتوا انجام نداده است و مدل پاسخ‌گو می‌تواند محتوای نادرست تولید کند؛ استفاده از این نمونه اولیه در هر زمینه‌ای که پاسخ نادرست پیامد جدی دارد، بدون یک لایه سنجش ایمنی مجاز نیست.

۸-۶ عبارتهایی که این نوشتار از آن‌ها پرهیز کرده است

برای شفافیت، هشت عبارت زیر با شواهد این پروژه قابل ادعا نیستند. هر عبارت در گیومه نقل شده است تا روشن باشد که این‌ها ادعاهای این نوشتار نیستند، بلکه فهرست صریح چیزهایی‌اند که گفته نشده‌اند و نباید از این پروژه نتیجه گرفته شوند:

- «مدل Moshika با موفقیت برای فارسی تنظیم شد.»
- «تأخیر سامانه کمتر از 500 میلی ثانیه است.»
- «دقت رسمی تشخیص وقفه بیش از 80 درصد است.»
- «خروجی گفتاری برای انسان طبیعی و کاملاً قابل فهم است.»
- «سامانه برای استفاده سالمندان مناسب است.»
- «پنل نه‌ردیفی، تعمیم سامانه به گفتار فارسی را اثبات می‌کند.»
- «داده منبع مجوز بازنشر یا آموزش آزاد دارد.»
- «مجموعه داده توسط انسان برچسب‌گذاری و تأیید شده است.»

فصل ۷

نتیجه‌گیری و کارهای آینده

۷-۱ جمع‌بندی

هدف این پروژه، طراحی، پیاده‌سازی و ارزیابی یک نمونه اولیه مدل زبانی بزرگ گفتار به گفتار تمام‌دوطرفه برای زبان فارسی بود. برای کاهش ریسک اجرایی، دو مسیر به‌طور موازی پیش برده شد: تطبیق کم‌پارامتر یک مدل سرتاسری گفتار به گفتار متن‌باز، و یک سامانه آشناری ماژولار با کنترل تمام‌دوطرفه بیرونی. نتیجه، نامتقارن بود.

مسیر آشناری به یک سامانه کارکردی و قابل ارزیابی رسید. در یک پنل ثابت و ازپیش‌قفل‌شده اعتبارسنجی، زنجیره با پاسخ‌گوی Qwen2.5-0.5B در هر 9 ردیف رونویسی فارسی، پاسخ فارسی و صوت غیرساکت تولید کرد و هیچ‌گاه به پاسخ جایگزین قاعده‌محور بازنگشت. پس از عبور از یک مرحله صلاحیت هفت‌ردیفی، آزمون نهایی 40 ردیفی گروه‌ناهمپوشان روی پاسخ‌گوی Qwen3-4B از هر هفت شرط خودکار ازپیش‌تعریف‌شده عبور کرد: میانگین ارتباط پاسخ از 1.425 به 3.150، میانگین انسجام به 3.325، نرخ برد زوجی به 67.5 درصد رسید و هر 240 فراخوانی داور معتبر بود. این سنجه داوری هم‌خانواده است و جایگزین ارزیابی انسانی نیست. سنجه خودکار بازبازشناسی روی همان 9 خروجی 0.5B، نرخ خطای نویسه 7.14 درصد را اندازه گرفت.

مسیر مستقیم در شش نسل آزمایشی به هدف نرسید. در هر نسل، زیان تحت تحمیل معلم کاهش یافت اما شرط اجرای خودرگرسیو نه‌ردیفی هیچ‌گاه برآورده نشد و هیچ چک‌پوینتی واجد شرایط استقرار نشد. آخرین نسل با کاهش 32.20 درصدی زیان متنی درون‌نمونه نشان داد که آداپتر ظرفیت یادگیری هدف را دارد، اما هر چهار چک‌پوینت آن 0 از 9 گرفتند. این مسیر به‌عنوان یک نتیجه منفی مستند با سیگنال یادگیری مثبت گزارش شده است.

مجموعه داده از یک موجودی 775.887 ساعتی به 6,754 جفت «گفتار کاربر و پاسخ» با 108.584 ساعت صوت استریوی ممیزی شده رسید که درون بازه 100 تا 200 ساعت مورد نظر تعریف پروژه قرار دارد، با تفکیک گروهی بر پایه نشست منبع و نشن گروهی صفر.

ماژول تشخیص وقفه با ویژگی‌های انرژی، زیروبمی و MFCC و یک طبقه‌بند تقویت گرادینانی پیاده شد و روی رخدادهای صوت واقعی با نشست‌های کنارگذاشته به دقت نقطه‌ای 81.06 درصد رسید؛ کران پایین فاصله اطمینان بلوکی در سطح نشست 74.44 درصد است و برچسب‌ها خودکارند، بنابراین عبور رسمی از 80 درصد اثبات نشده است. خط پایه انرژی دقت 78.03 درصد گرفت و نرخ رد نادرست آن 43.94 درصد بود.

برای چهار نیازمندی هنوز شواهد رسمی کامل گردآوری نشد: تأخیر سرتاسری 500 میلی‌ثانیه، عبور رسمی تشخیص وقفه از 80 درصد با برچسب مستقل انسانی، ارزیابی روی پردازنده گرافیکی فیزیکی 12 تا 24 گیگابایتی، و مطالعه انسانی با 5 تا 10 گویشور فارسی. از این رو، این نوشتار درباره تعامل سالمندان فارسی‌زبان ادعای تجربی مطرح نمی‌کند.

۷-۲ پاسخ به پرسش پژوهش

پرسش عملی این پروژه، که در بخش ۱-۱ مطرح شد، دو بخش داشت.

بخش نخست: با بودجه محاسباتی و زمانی یک پروژه کارشناسی، تا چه اندازه می‌توان یک سامانه گفتاربه‌گفتار فارسی تمام‌دوطرفه ساخت؟ پاسخ این است که یک سامانه «کارکردی» با معماری ماژولار و کنترل وقفه بیرونی قابل ساخت است و مرتبط‌بودن پاسخ آن در یک آزمون خودکار هم‌خانواده بهتر از خط پایه دیده شد، نه کیفیت ادراکی یا مستقل؛ اما یک مدل سرتاسری فارسی، با آموزش دهنده‌های رسمی موجود و در این بودجه، قابل دستیابی نبود.

بخش دوم، که مهم‌تر بود: چه چیزی را می‌توان با شواهد قابل ممیزی «اثبات» کرد؟ پاسخ در جدول ۵-۱۴ خلاصه شده است. دو نیازمندی ۱ و ۴ شواهد کافی دارند؛ دو نیازمندی ۲ و ۵ پیاده‌سازی شده‌اند اما شواهد رسمی آن‌ها کامل نیست؛ و برای سه نیازمندی ۳، ۶ و ۷ شواهد رسمی موجود نیست. سهم روشمند این نوشتار در همین تفکیک است: پروژه به‌جای ارائه یک ادعای کلی موفقیت، برای هر سنجه مرز ادعای مجاز آن را مشخص کرده و در کد نیز یک سازوکار شکست‌بسته مانع از ارتقای تقریب‌ها به شواهد رسمی شده است.

۳-۷ کارهای آینده

پیشنهادهای کار آینده به ترتیب اولویت و به تفکیک «تکمیل شواهد» و «بهبود فنی» ارائه می شود.

۱-۳-۷ تکمیل شواهد باقی مانده

این چهار مورد به پژوهش تازه نیاز ندارند و تنها اجرای پروتکل های ازپیش نوشته شده را لازم دارند.

۱. اندازه گیری تأخیر روی سخت افزار هدف. اجرای پروتکل ثبت شده روی یک پردازنده گرافیکی فیزیکی در بازه 12 تا 24 گیگابایت، با یک مرورگر واقعی و میکروفون فیزیکی، و گزارش T_{first_audio} و T_{bargo_in} بر پایه رویداد تأیید شده کارخواه. این کار نیازمندی ن ۳ و ن ۶ را به کلاس شواهد رسمی می برد.

۲. مطالعه انسانی. اجرای مطالعه با 5 تا 10 گویشور فارسی شامل دست کم دو نفر بالای 60 سال، با سند رضایت نامه و برگه امتیازدهی موجود و در حالت نگه داری فقط ویرگی. این کار نیازمندی ن ۷ و قلم چهارم خروجی پروژه را تحویل می دهد.

۳. برچسب گذاری مستقل رخدادهای وقفه. بازبینی شنیداری نمونه ای از رخدادهای آشکارساز توسط دو یا چند بازبین انسانی مستقل، همراه با گزارش توافق میان بازبینی، و سپس ارزیابی مجدد آشکارساز روی برچسب انسانی. این کار نیازمندی ن ۵ را قابل اثبات می کند.

۴. بازبینی شنیداری مجموعه داده. اجرای بازبینی چهل ردیفی و بیست و چهار ردیفی که تحت انصراف زمانی معلق ماند، تا بتوان بخشی از مجموعه داده را «تأیید شده توسط انسان» نامید.

۲-۳-۷ بهبود تأخیر سامانه آبخاری

مشاهده بخش ۳-۵ نشان داد که زمان تولید کامل پاسخ با طول ورودی رشد می کند و میانه آن چند ثانیه است. سه مداخله می تواند این را به طور اساسی بهبود دهد.

نخست، تولید جویباری. در معماری کنونی، کل متن پاسخ تولید و سپس کل موج صوتی ساخته می شود. اگر تولید متن به صورت جویباری انجام شود و هر عبارت کامل بی درنگ به موتور گفتاری برود، نخستین قطعه صوت می تواند پیش از تکمیل پاسخ پخش شود. این تغییر سنجه نخستین صوت را از زمان تولید کامل جدا می کند و تنها راه عملی نزدیک شدن به هدف 500 میلی ثانیه در این معماری است.

دوم، کوتاه کردن بافت ورودی. ردیف 32 پنل، با 5031 نویسه رونویسی، کندترین نوبت را داشت. محدود کردن ورودی مدل زبانی به آخرین اظهار کاربر، به جای کل متن رونویسی، باید این دنباله را حذف کند.

سوم، مدل پاسخگوی کوچک‌تر یا کوانتیزه. دو چک‌پوینت جایگزین محلی در جریان پروژه بررسی و تنها در سطح راه‌اندازی آزموده شدند. یک نسخه کم‌حافظه‌تر می‌تواند هم تأخیر و هم تناسب با بازه حافظه هدف را بهبود دهد. هرگونه جانشینی مدل پاسخگو باید با یک آزمون معنایی تازه و «ازپیش تعریف شده» روی ردیف‌های گروه‌ناهمپوشان انجام شود؛ پنل آزمون نهایی کنونی یک‌بار باز شده است و بازاستفاده از آن برای انتخاب مدل مجاز نیست.

۳-۳-۷ مسیرهای جایگزین برای مدل مستقیم

بر پایه تحلیل بخش ۶-۱، سه راهبرد امیدبخش‌تر از تکرار دستور کنونی به نظر می‌رسد.

نخست، رویکرد مدل منجمد. معماری Freeze-Omni [۲] وزن‌های مدل زبانی را منجمد نگه می‌دارد و تنها کدگذار و کدگشای گفتاری را آموزش می‌دهد. این طراحی دقیقاً مسئله‌ای را هدف می‌گیرد که در این پروژه شکست خورد: چون توزیع زبانی مدل پایه دست‌نخورده می‌ماند، مشکل فروریختن رفتار تولیدی و بازگشت به زبان پایه پیش نمی‌آید. برای فارسی این احتمالاً کوتاه‌ترین مسیر به یک مدل سرتاسری کارکردی است.

دوم، اصلاح کیفیت هدف آموزشی. تحلیل بخش ۶-۳ نشان داد که نوبت‌های هم‌تراز شده خودکار، اهداف ضعیفی برای پاسخ‌دهی دستورپیرو هستند. یک مرحله گزینش که تنها جفت‌هایی را نگه می‌دارد که در آن‌ها نوبت دوم واقعاً پاسخی به نوبت اول است، حتی اگر حجم داده را چند برابر کاهش دهد، احتمالاً هدف آموزشی بهتری می‌سازد. مجموعه داده کنونی برای یادگیری «زمان‌بندی» گفتار و پدیده‌های تعاملی مناسب است و برای یادگیری «محتوای» پاسخ نامناسب؛ تفکیک این دو نقش در طراحی آموزش می‌تواند مؤثر باشد.

سوم، تفکیک صریح مرحله زبان و مرحله گفت‌وگو. به جای یک مرحله تطبیق که هم‌زمان زبان تولیدی و رفتار گفت‌وگویی را هدف می‌گیرد، می‌توان نخست با داده تک‌گوینده فراوان فارسی، مانند ManaTTS [۳]، توانایی تولید گفتار فارسی را تثبیت کرد و تنها در مرحله دوم رفتار گفت‌وگویی و نوبت‌گیری را روی داده مکالمه آموخت.

۴-۳-۷ بهبود ماژول تشخیص وقفه

دو بهبود مشخص قابل انجام است. نخست، کاهش نرخ رد نادرست. مقدار کنونی 28.79 درصد است، یعنی نزدیک به یک وقفه از هر سه وقفه نادیده می‌ماند. افزودن ویژگی‌های نوایی بلندبردتر و پنجره متن طولانی‌تر می‌تواند مؤثر باشد. دوم، استفاده از نشانه سمت سامانه. آشکارساز کنونی فقط جریان میکروفون را می‌بیند. اگر سیگنال صوتی که سامانه در همان لحظه پخش می‌کند نیز به عنوان ورودی مرجع در دسترس باشد، می‌توان پس‌خورد آکوستیکی بلندگو را از گفتار واقعی کاربر جدا کرد و نرخ پذیرش نادرست 9.09 درصدی را کاهش داد.

۴-۷ سخن آخر

این پروژه نشان داد که ساخت یک نمونه اولیه گفتار به گفتار فارسی با کنترل تمام‌دوطرفه، در بودجه یک پروژه کارشناسی، امکان‌پذیر است؛ و در همان حال نشان داد که تطبیق یک مدل سرتاسری گفتار به گفتار به یک زبان جدید، با دستور تطبیق کم‌پارامتر و داده مشتق‌شده خودکار، به سادگی به دست نمی‌آید.

نتیجه منفی مسیر مستقیم، از دید ما ارزشی کمتر از نتیجه مثبت مسیر آشنایی ندارد. این نتیجه، همراه با شواهد ثبت‌شده آن، یک هشدار روشمند برای پژوهش‌های بعدی است: در این حوزه، کاهش زیان آفلاین می‌تواند به‌طور کامل گمراه‌کننده باشد و آزمون تولید در زمان اجرا باید بخشی از معیار انتخاب باشد. اگر این نوشتار تنها یک چیز را منتقل کند، همین است.

Bibliography

- [1] A. Défossez, L. Mazaré, M. Orsini, A. Royer, P. Pérez, H. Jégou, E. Grave, and N. Zeghidour. Moshi: A speech-text foundation model for real-time dialogue. Technical report, Kyutai, 2024. arXiv:2410.00037.
- [2] X. Wang, Y. Li, C. Fu, Y. Zhang, Y. Shen, L. Xie, K. Li, X. Sun, and L. Ma. Freeze-Omni: A smart and low latency speech-to-speech dialogue model with frozen LLM. In *Proceedings of the 42nd International Conference on Machine Learning*, volume 267 of *Proceedings of Machine Learning Research*, pages 63345–63354. PMLR, 2025.
- [3] M. F. Qharabagh, Z. Dehghanian, and H. R. Rabiee. ManaTTS Persian: A recipe for creating TTS datasets for lower-resource languages. In *Proceedings of the 2025 Conference of the Nations of the Americas Chapter of the Association for Computational Linguistics: Human Language Technologies (Volume 1: Long Papers)*, pages 9177–9206, Albuquerque, New Mexico, 2025. Association for Computational Linguistics.
- [4] J. Xu, Z. Guo, J. He, H. Hu, T. He, S. Bai, K. Chen, J. Wang, Y. Fan, K. Dang, B. Zhang, X. Wang, Y. Chu, and J. Lin. Qwen2.5-Omni technical report. *arXiv preprint arXiv:2503.20215*, 2025.
- [5] Z. Xie and C. Wu. Mini-Omni2: Towards open-source GPT-4o with vision, speech and duplex capabilities. *arXiv preprint arXiv:2410.11190*, 2024.
- [6] Q. Fang, Y. Zhou, S. Guo, S. Zhang, and Y. Feng. LLaMA-Omni 2: LLM-based real-time spoken chatbot with autoregressive streaming speech synthesis. In *Proceedings of the 63rd Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers)*, pages 18617–18629, Vienna, Austria, 2025. Association for Computational Linguistics.
- [7] Kyutai Labs. Moshi-finetune: LoRA fine-tuning for Moshi. <https://github.com/kyutai-labs/moshi-finetune>, 2024.
- [8] J. Sohn, N. S. Kim, and W. Sung. A statistical model-based voice activity detection. *IEEE Signal Processing Letters*, 6(1):1–3, 1999.

- [9] A. de Cheveigné and H. Kawahara. YIN, a fundamental frequency estimator for speech and music. *The Journal of the Acoustical Society of America*, 111(4):1917–1930, 2002.
- [10] S. B. Davis and P. Mermelstein. Comparison of parametric representations for monosyllabic word recognition in continuously spoken sentences. *IEEE Transactions on Acoustics, Speech, and Signal Processing*, 28(4):357–366, 1980.
- [11] A. Graves, S. Fernández, F. Gomez, and J. Schmidhuber. Connectionist temporal classification: Labelling unsegmented sequence data with recurrent neural networks. In *Proceedings of the 23rd International Conference on Machine Learning*, pages 369–376, 2006.
- [12] A. Graves. Sequence transduction with recurrent neural networks. In *ICML Workshop on Representation Learning*, 2012. arXiv:1211.3711.
- [13] A. Gulati, J. Qin, C.-C. Chiu, N. Parmar, Y. Zhang, J. Yu, W. Han, S. Wang, Z. Zhang, Y. Wu, and R. Pang. Conformer: Convolution-augmented transformer for speech recognition. In *Proceedings of Interspeech*, pages 5036–5040, 2020.
- [14] A. Vaswani, N. Shazeer, N. Parmar, J. Uszkoreit, L. Jones, A. N. Gomez, Ł. Kaiser, and I. Polosukhin. Attention is all you need. In *Advances in Neural Information Processing Systems*, volume 30, pages 5998–6008, 2017.
- [15] O. Kuchaiev, J. Li, H. Nguyen, O. Hrinchuk, R. Leary, B. Ginsburg, S. Krizan, S. Beliaev, V. Lavrukhin, J. Cook, and Others. NeMo: A toolkit for building AI applications using neural modules, 2019. arXiv:1909.09577.
- [16] A. Radford, J. W. Kim, T. Xu, G. Brockman, C. McLeavey, and I. Sutskever. Robust speech recognition via large-scale weak supervision. In *Proceedings of the 40th International Conference on Machine Learning*, pages 28492–28518, 2023.
- [17] J. Kim, J. Kong, and J. Son. Conditional variational autoencoder with adversarial learning for end-to-end text-to-speech. In *Proceedings of the 38th International Conference on Machine Learning*, pages 5530–5540, 2021.
- [18] Rhasspy Project. Piper: A fast, local neural text-to-speech system. <https://github.com/rhasspy/piper>, 2023.
- [19] L. Ouyang, J. Wu, X. Jiang, D. Almeida, C. Wainwright, P. Mishkin, C. Zhang, S. Agarwal, K. Slama, A. Ray, and Others. Training language models to follow instructions with human feedback. In *Advances in Neural Information Processing Systems*, volume 35, pages 27730–27744, 2022.

- [20] M. Ranzato, S. Chopra, M. Auli, and W. Zaremba. Sequence level training with recurrent neural networks. In *Proceedings of the 4th International Conference on Learning Representations*, 2016.
- [21] S. Bengio, O. Vinyals, N. Jaitly, and N. Shazeer. Scheduled sampling for sequence prediction with recurrent neural networks. In *Advances in Neural Information Processing Systems*, volume 28, pages 1171–1179, 2015.
- [22] N. Houlsby, A. Giurgiu, S. Jastrzebski, B. Morrone, Q. De Laroussilhe, A. Gesmundo, M. Attariyan, and S. Gelly. Parameter-efficient transfer learning for NLP. In *Proceedings of the 36th International Conference on Machine Learning*, pages 2790–2799, 2019.
- [23] X. L. Li and P. Liang. Prefix-tuning: Optimizing continuous prompts for generation. In *Proceedings of the 59th Annual Meeting of the Association for Computational Linguistics*, pages 4582–4597, 2021.
- [24] E. J. Hu, Y. Shen, P. Wallis, Z. Allen-Zhu, Y. Li, S. Wang, L. Wang, and W. Chen. LoRA: Low-rank adaptation of large language models. In *Proceedings of the 10th International Conference on Learning Representations*, 2022.
- [25] N. Zeghidour, A. Luebs, A. Omran, J. Skoglund, and M. Tagliasacchi. SoundStream: An end-to-end neural audio codec. *IEEE/ACM Transactions on Audio, Speech, and Language Processing*, 30:495–507, 2021.
- [26] A. Défossez, J. Copet, G. Synnaeve, and Y. Adi. High fidelity neural audio compression. *Transactions on Machine Learning Research*, 2023.
- [27] Z. Borsos, R. Marinier, D. Vincent, E. Kharitonov, O. Pietquin, M. Sharifi, D. Roblek, O. Teboul, D. Grangier, M. Tagliasacchi, and N. Zeghidour. AudioLM: A language modeling approach to audio generation. *IEEE/ACM Transactions on Audio, Speech, and Language Processing*, 31:2523–2533, 2023.
- [28] C. Wang, S. Chen, Y. Wu, Z. Zhang, L. Zhou, S. Liu, Z. Chen, Y. Liu, H. Wang, J. Li, L. He, S. Zhao, and F. Wei. Neural codec language models are zero-shot text to speech synthesizers. *arXiv preprint arXiv:2301.02111*, 2023.
- [29] D. Lee, C. Kim, S. Kim, M. Cho, and W.-S. Han. Autoregressive image generation using residual quantization. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, pages 11523–11532, 2022.
- [30] H. Sacks, E. A. Schegloff, and G. Jefferson. A simplest systematics for the organization of turn-taking for conversation. *Language*, 50(4):696–735, 1974.

- [31] G. Skantze. Turn-taking in conversational systems and human-robot interaction: A review. *Computer Speech & Language*, 67:101178, 2021.
- [32] J. H. Friedman. Greedy function approximation: A gradient boosting machine. *Annals of Statistics*, 29(5):1189–1232, 2001.
- [33] F. Pedregosa, G. Varoquaux, A. Gramfort, V. Michel, B. Thirion, O. Grisel, M. Blondel, P. Prettenhofer, R. Weiss, V. Dubourg, J. Vanderplas, A. Passos, D. Cournapeau, M. Brucher, M. Perrot, and É. Duchesnay. Scikit-learn: Machine learning in Python. *Journal of Machine Learning Research*, 12:2825–2830, 2011.
- [34] V. I. Levenshtein. Binary codes capable of correcting deletions, insertions, and reversals. *Soviet Physics Doklady*, 10(8):707–710, 1966.
- [35] E. B. Wilson. Probable inference, the law of succession, and statistical inference. *Journal of the American Statistical Association*, 22(158):209–212, 1927.
- [36] B. Efron and R. J. Tibshirani. *An Introduction to the Bootstrap*. Chapman & Hall/CRC, 1994.
- [37] L. Zheng, W.-L. Chiang, Y. Sheng, S. Zhuang, Z. Wu, Y. Zhuang, Z. Lin, Z. Li, D. Li, E. P. Xing, H. Zhang, J. E. Gonzalez, and I. Stoica. Judging LLM-as-a-judge with MT-Bench and chatbot arena. In *Advances in Neural Information Processing Systems*, volume 36, pages 46595–46623, 2023.
- [38] Q. Fang, S. Guo, Y. Zhou, Z. Ma, S. Zhang, and Y. Feng. LLaMA-Omni: Seamless speech interaction with large language models. In *Proceedings of the 13th International Conference on Learning Representations*, 2025.
- [39] Z. Du, Y. Wang, Q. Chen, X. Shi, X. Lv, T. Zhao, Z. Gao, Y. Yang, C. Gao, H. Wang, F. Yu, H. Liu, Z. Sheng, Y. Gu, C. Deng, W. Wang, S. Zhang, Z. Yan, and J. Zhou. CosyVoice 2: Scalable streaming speech synthesis with large language models. *arXiv preprint arXiv:2412.10117*, 2024.
- [40] A. Zeng, Z. Du, M. Liu, K. Wang, S. Jiang, L. Zhao, Y. Dong, and J. Tang. GLM-4-Voice: Towards intelligent and human-like end-to-end spoken chatbot. *arXiv preprint arXiv:2412.02612*, 2024.
- [41] T. A. Nguyen, E. Kharitonov, J. Copet, Y. Adi, W.-N. Hsu, A. Elkahky, P. Tomasello, R. Algayres, B. Sagot, A. Mohamed, and E. Dupoux. Generative spoken dialogue language modeling. *Transactions of the Association for Computational Linguistics*, 11:250–266, 2023.
- [42] R. Roy, J. Raiman, S.-g. Lee, T.-D. Ene, R. Kirby, S. Kim, J. Kim, and B. Catanzaro. PersonaPlex: Voice and role control for full duplex conversational speech models, 2026. *arXiv:2602.06053*.

- [43] R. Ardila, M. Branson, K. Davis, M. Kohler, J. Meyer, M. Henretty, R. Morais, L. Saunders, F. Tyers, and G. Weber. Common voice: A massively-multilingual speech corpus. In *Proceedings of the 12th Language Resources and Evaluation Conference*, pages 4218–4222, 2020.
- [44] H. Bredin, R. Yin, J. M. Coria, G. Gelly, P. Korshunov, M. Lavechin, D. Fustes, H. Titeux, W. Bouaziz, and M.-P. Gill. Pyannote.audio: Neural building blocks for speaker diarization. In *Proceedings of the IEEE International Conference on Acoustics, Speech and Signal Processing*, pages 7124–7128, 2020.
- [45] T. J. Park, N. R. Koluguri, J. Balam, and B. Ginsburg. Multi-scale speaker diarization with dynamic scale weighting. In *Proceedings of Interspeech*, pages 5080–5084, 2022.
- [46] International Telecommunication Union. Methods for subjective determination of transmission quality. *ITU-T Recommendation P.800*, 1996.
- [47] A. Yang, B. Yang, B. Zhang, B. Hui, B. Zheng, B. Yu, C. Li, D. Liu, F. Huang, H. Wei, H. Lin, J. Yang, J. Tu, J. Zhang, J. Yang, J. Zhou, J. Lin, K. Dang, and Others. Qwen2.5 technical report. *arXiv preprint arXiv:2412.15115*, 2025.
- [48] A. Yang, A. Li, B. Yang, B. Zhang, B. Hui, B. Zheng, B. Yu, C. Gao, C. Huang, C. Lv, and Others. Qwen3 technical report. *arXiv preprint arXiv:2505.09388*, 2025.
- [49] A. Paszke, S. Gross, F. Massa, A. Lerer, J. Bradbury, G. Chanan, T. Killeen, Z. Lin, N. Gimelshein, L. Antiga, and Others. PyTorch: An imperative style, high-performance deep learning library. In *Advances in Neural Information Processing Systems*, volume 32, pages 8024–8035, 2019.
- [50] T. Wolf, L. Debut, V. Sanh, J. Chaumond, C. Delangue, A. Moi, P. Cistac, T. Rault, R. Louf, M. Funtowicz, and Others. Transformers: State-of-the-art natural language processing. In *Proceedings of the 2020 Conference on Empirical Methods in Natural Language Processing: System Demonstrations*, pages 38–45, 2020.

واژه‌نامه

الف

fundamental frequency بسامد پایه
sample rate بسامد نمونه‌برداری

cascade آبشاری
regression test آزمون بازگشتی
threshold آستانه
detector آشکارساز
acoustic onset آغاز آوایی
episode اپیزود
relevance ارتباط
exposure bias اریبی مواجهه
validation اعتبارسنجی
decision horizon افق تصمیم
end of speech انتهای گفتار
energy انرژی
coherence انسجام
waiver انصراف مستند
adapter آداپتر
safety ایمنی

پ

playback پخش
prompt پرامپت
protocol پروتکل
context window پنجره متن
panel پنل
pre-roll پیش‌بافر
corpus پیکره

ت

latency تأخیر
text-to-speech تبدیل متن به گفتار
tokenizer تجزیه‌گر نشانه
teacher forcing تحمیل معلم
transformer ترانسفورمر
voice activity detection تشخیص فعالیت گفتاری
adaptation تطبیق
diarization تفکیک گوینده
proxy تقریب جانشین
gradient boosting تقویت گرادیانی
full-duplex تمام‌دوطرفه

ب

rights review بازبینی حقوق
reproducibility بازتولیدپذیری
backchannel بازخورد کلامی
speech recognition بازشناسی گفتار
seed بذرتصادفی

نوبت‌گیری turn-taking	ر
تنظیم دقیق fine-tuning	رمزینه صوتی audio codec

جفت پاسخ response pair	ج
جویباری streaming	زیان loss
	زیرنویس caption
	زیرویمی pitch

چک‌پوینت checkpoint	چ
چندکاناله multi-channel	سرگشتگی perplexity
چندگویندگی multi-speaker	سرور server

حذف تصادفی dropout	ح
حریم خصوصی privacy	شرط پذیرش gate
حقیقت مبنا ground truth	شکست‌بسته fail-closed
	شواهد evidence

خاستگاه provenance	خ
خط پایه baseline	ضرایب کپستروم بسامد مل mel-frequency cepstral
خودراه‌انداز bootstrap	ضریب زیان loss weight
خودرگرسیو autoregressive	
خودکار automatic	

درون‌نمونه in-sample	ط
دقت accuracy	طبقه‌بند classifier
دوسویه bidirectional	طبیعی‌بودن naturalness

دوسوکور double-blind	د
	ع
	عامل agent

microphone میکروفون

ف

hyperparameter فرایارامتر

frame فریم

manifest فهرست‌نامه

intelligibility فهم‌پذیری

ن

negative result نتیجه منفی

rate نرخ

group leakage نشت گروهی

session نشست

prototype نمونه اولیه

noise نویز

half-duplex نیم‌دوطرفه

ق

deterministic قطعی

locked قفل‌شده

frozen منجمد

و

voiced واک‌دار

weights وزن‌ها

interruption وقفه

barge-in وقفه

feature ویژگی

ک

codebook کتاب رمز

decoding کدگشایی

parameter-efficient کم‌پارامتر

low-rank کم‌رتبه

held-out کنارگذاشته

quantization کوانتیزه‌سازی

ه

synthesis هم‌آمایش

overlap هم‌پوشانی

alignment هم‌ترازی

normalization هنجارسازی

گ

group-disjoint گروه‌ناهمپوشان

speech-to-speech گفتاربه‌گفتار

speaker گوینده

ی

learning یادگیری

م

dataset مجموعه داده

model مدل

پیوست آ

جزئیات پیاده‌سازی و بازتولید

این پیوست جزئیاتی را گرد آورده است که برای بازتولید نتایج لازم‌اند اما در متن اصلی جای نمی‌گرفتند: ساختار مخزن، فرآپارامترهای دقیق آزمایش‌ها، فرمان‌های بازتولید و نقشه مصنوعات شواهد.

آ-۱ ساختار مخزن

جدول آ-۱ ساختار سطح نخست مخزن کد را نشان می‌دهد.

آ-۲ فرآپارامترهای آزمایش‌های مسیر مستقیم

جدول آ-۲ فرآپارامترهای دقیق شش نسل آزمایشی را نشان می‌دهد. همه اجراها از بهینه‌ساز AdamW و نقطه‌گذاری گرادین استفاده کردند.

نسخه‌های ۷۴ و ۷۵ تنها در ضریب زیان کتاب رمز نخست تفاوت دارند: ۱۰۰ در برابر ۱۰. نسخه ۷۶.۲ علاوه بر فرآپارامترهای بالا، حذف تصادفی زمان‌بندی‌شده ورودی متنی از ۰.۲۵ به ۰.۷۵ و ضریب زیان صوتی ۰.۱ داشت و روی همان ۳۲ نمونه آموزش و ارزیابی شد.

آ-۳ فرآپارامترهای آشکارساز و پاسخ‌گو

جدول آ-۳ پیکربندی مازول تشخیص وقفه و آداپتر پاسخ‌گوی متنی را گرد آورده است.

جدول آ-۱: ساختار سطح نخست مخزن کد پروژه

مسیر	محتوا
src/thesis_s2s/runtime/	زنجیره آبشاری، سرور تمام دوطرفه، تبدیل متن به گفتار، ثبت نشست
src/thesis_s2s/bargain/	استخراج ویژگی، آشکارساز، کنترل گر پخش، ارزیابی روی داده ضبط شده
src/thesis_s2s/data/	زنجیره ساخت مجموعه داده، تفکیک گوینده، استخراج جفت، خروجی و ممیزی
src/thesis_s2s/eval/	سنجه ها، آزمون های مقایسه ای و تجمیع کننده شکست بسته شواهد
src/thesis_s2s/model/	مصنوع آزمایشی اولیه، تنها برای مرجع تاریخی
configs/	پیکربندی داده، آشکارساز، سنجه ها و شش نسل آزمایشی مسیر مستقیم
scripts/	پیش بررسی، آموزش، بازار ارزیابی، انتخاب چک پوینت و ارزیابی های قفل شده
docs/	پروتکل های از پیش تعریف شده، سند انصراف بازبینی و تصمیم های ثبت شده
results/	مصنوعات نتیجه یک بار نوشت
tests/	مجموعه آزمون خودکار
third_party/	پرونده قفل مخازن و مدل های بالادستی

آ-۴ فرمان های بازتولید

فرمان های زیر مراحل اصلی را بازتولید می کنند. متغیر PYTHONPATH باید به شاخه src اشاره کند؛ زیرفرمان هر مرحله در جدول آ-۴ فهرست شده است.

ارزیابی های قفل شده به صورت اسکریپت مستقل در شاخه scripts اجرا می شوند؛ جدول آ-۵ آن ها را فهرست می کند.

این اسکریپت ها روی مصنوعات یک بار نوشت کار می کنند و نباید برای بازگشایی یک آزمون نهایی یا بازنگری یک انتخاب نهایی شده به کار روند. شکل های این نوشتار با `scripts/make_thesis_figures.py` از همین مصنوعات تولید شده اند.

جدول آ-۲: فرآپارامترهای شش نسل آزمایشی تطبیق کم پارامتر مسیر مستقیم

نسخه	گام	پنجره	رتبه	بذر	بیشینه	درج‌گرهای
	بیشینه	(ثانیه)			حافظه (GB)	آموزش‌دیده
v1	8000	20	64	20260823	22.920	کلید بالادستی
v2	2000	100	64	20260827	—	کلید بالادستی
v3	500	100	128	20260827	26.504	هیچ
v4	500	100	128	20260827	28.640	دو درج‌گر متنی
v5	500	100	128	20260827	28.640	دو درج‌گر متنی
v6.2	200	12	64	20260901	16.577	سه تنسور متنی

آ-۵ نقشه مصنوعات شواهد

جدول آ-۶ برای هر ادعای این نوشتار، مصنوع مرجع آن را مشخص می‌کند.

آ-۶ محیط اجرا

جدول آ-۷ مؤلفه‌های اصلی محیط اجرا و شناسه مدل‌های به کاررفته را نشان می‌دهد.

بازنگری دقیق و درهم‌سازی وزن هر مدل در پرونده قفل مخازن بالادستی ثبت شده است و در مصنوع هر نتیجه نیز تکرار می‌شود، تا ادعای «مدل استفاده‌شده دقیقاً همین بود» قابل ممیزی باشد.

آ-۷ ساخت این نوشتار

این نوشتار با XeLaTeX و افزونه XePersian حروف‌چینی شده است. برای بازتولید آن، اجرای `./build.sh`. در شاخه نوشتار کافی است؛ این اسکریپت زنجیره حروف‌چینی و کتاب‌نامه را در یک بستر جداشده اجرا می‌کند و بنابراین به نصب محلی TeX نیازی نیست.

دو نکته فنی که در جریان آماده‌سازی این نوشتار اصلاح شد و ممکن است برای کاربران بعدی همین قالب سودمند باشد: نخست، نام گزینه محلی‌سازی افزونه XePersian در نسخه‌های تازه تغییر کرده است و گزینه پیشین دیگر پذیرفته نمی‌شود؛ دوم، وصله جدول‌های راست‌به‌چپ افزونه `bidir` با نسخه جاری بسته

array سازگار نیست و باید نسخه تاریخ‌دار آن درخواست شود. هر دو اصلاح در `styles/common.tex` با توضیح ثبت شده‌اند.

نکته سوم به حروف چینی اعداد مربوط است. در متن راست‌به‌چپ، الگوریتم دوسویه یک عدد اعشاری را در محل جداکننده به دو بخش می‌شکند و ترتیب آن دو بخش را برعکس می‌کند؛ در نتیجه مقدار 3.150 به صورت «3/150» نمایش داده می‌شود. به همین دلیل، در این نوشتار همه کمیت‌های اندازه‌گیری شده در یک محیط چپ‌به‌راست صریح قرار گرفته‌اند، در حالی که شماره‌گذاری ساختاری، یعنی شماره فصل‌ها، بخش‌ها، صفحه‌ها، جدول‌ها و شکل‌ها، با ارقام فارسی خودکار باقی مانده است.

جدول آ-۳: پیکربندی ماژول تشخیص وقفه و آداپتر پاسخ‌گوی متنی

پارامتر	مقدار
ماژول تشخیص وقفه	
بسامد نمونه‌برداری	16000 هرتز
طول فریم	20 میلی‌ثانیه
طول پنجره متن	400 میلی‌ثانیه
شمار ضرایب MFCC	13 به همراه دلتا
بازه جست‌وجوی بسامد پایه	60 تا 400 هرتز
شمار درخت‌ها	200
عمق بیشینه درخت	4
نرخ یادگیری	0.08
کمینه نمونه در برگ	8
افق تصمیم پس از آغاز آوایی	120 میلی‌ثانیه
آستانه تصمیم انتخاب‌شده	0.70
زمان استنتاج هر گام روی پردازنده مرکزی	7.931 میلی‌ثانیه
آداپتر پاسخ‌گوی متنی	
رتبه و ضریب مقیاس	16 و 32
حذف تصادفی	0.05
دوره‌های آموزش	2
بذر تصادفی	20260906
ردیف‌های واجد شرایط آموزش	2576 از 6419
ردیف‌های واجد شرایط توسعه	12 از 131
زیان نشانه‌های پاسخ مدل پایه	3.723
زیان دوره نخست و دوم	2.643 و 2.562
کاهش نسبت به مدل پایه	31.18%

جدول آ-۴: فرمان‌های بازتولید مراحل اصلی پروژه

مرحله	زیرفرمان
طرح انتخاب پیکره	plan-conversation-corpus
بازسازی پنجره‌ها	prepare-conversation-episodes
ممیزی پنجره‌های آماده	audit-prepared-episodes
تفکیک گوینده	diarize-conversation-episodes
ممیزی تفکیک گوینده	audit-diarized-episodes
برچسب شرایط نویز	annotate-conversation-noise
برآورد بازده پیکره	estimate-conversation-yield
ساخت جفت‌های پاسخ	build-conversations
ممیزی جفت‌ها	audit-conversations
خروجی استریوی آموزش	export-moshi-data
ممیزی خروجی	audit-moshi-data
اجرای سامانه	serve
وضعیت تجمیعی شواهد	evidence-status
پیش‌بررسی سخت‌افزار	gpu-preflight

جدول آ-۵: اسکریپت‌های ارزیابی قفل‌شده

ارزیابی	اسکریپت
پنل مکانیکی سامانه آبخاری	validation.py
سنجه بازیازشناسی	evaluate_cascade_
آزمون معنایی دومرحله‌ای	intelligibility.py
تقریب آشکارساز وقفه	evaluate_qwen4b_
تولید شکل‌های این نوشتار	responder_v2.py
	evaluate_recorded_
	bargein_proxy.py
	make_thesis_figures.py

جدول آ-۶: نقشه ادعاها و مصنوعات مرجع. همه مسیرها نسبت به شاخه results هستند.

ادعا	مصنوع مرجع
وضعیت تجمیعی و شروط پذیرش	eval/EVIDENCE_STATUS.json
خلاصه قابل خواندن	eval/SUMMARY.md
پنل مکانیکی سامانه آبشاری	eval/cascade_real_ service_validation_panel.json
تحلیل توصیفی پس‌نگر	eval/cascade_validation_ descriptive_analysis.json
تقریب فهم‌پذیری	eval/cascade_ intelligibility_proxy.json
مرحله صلاحیت معنایی	eval/qwen4b_responder_ v2_development_proxy.json
آزمون نهایی معنایی	eval/qwen4b_responder_ v2_final_test_proxy.json
تطبیق پاسخ‌گو	responder_lora_v1.json training/
تقریب آشکارساز وقفه	eval/ interrupt_recorded_proxy.json
آزمون مصنوعی آشکارساز	eval/interrupt_bench.json
ممیزی مجموعه داده	conversation_audit.json
گزارش خروجی آموزش	moshi_export_report.json
انتخاب چک‌پوینت نسخه نخست	selection.json moshi_checkpoint_ model_eval.json moshi_heldout_ moshi_v2_checkpoint_ selection.json
نتیجه نسخه v6.2	moshi_v6_text_dropout_ reevaluation.json
اجرای نسخه v6.2	moshi_v6_text_dropout_ runtime.json
تأخیر سمت سرور	eval/latency_bench.json
مطالعه انسانی	eval/human_study.json
ممیزی نهایی مخزن	release/final_audit.json

جدول آ-۷: مؤلفه‌های اصلی محیط اجرا و مدل‌های به‌کاررفته

مؤلفه	شناسه
پاسخ‌گوی متنی سامانه نهایی	Qwen3-4B-Instruct-2507 cdbee75f17c01a7cc42f958dc650907174af0554
پاسخ‌گوی پزل مکانیکی 9/9 و بازباشناسی	Qwen2.5-0.5B-Instruct 7ae557604adf67be50417f59c2c2f167def9a775
خط پایه پاسخ‌گو در آزمون معنایی	Qwen2.5-0.5B-Instruct
مدل پایه مسیر مستقیم	Moshika، هفت میلیارد پارامتر
رمزینه صوتی مسیر مستقیم	Mimi
بازشناسی گفتار	مدل ترکیبی RNNT-CTC خانواده Conformer
تبدیل متن به گفتار	Piper با مدل صوتی فارسی
داور آزمون معنایی	Qwen3.8-27B-FP8 017b9c7af6b5689d5dd426a76e0bc077eb5ca20a
سخت‌افزار آموزش و ارزیابی	93.09 گیگابایت، NVIDIA H100 NVL

Abstract

This project designs, implements and evaluates a prototype Persian speech-to-speech system that operates in full-duplex mode: the user microphone stays open while the assistant reply is playing, and a classical detector decision can stop the active browser audio source and carry the captured speech forward as the next user turn. To bound execution risk, two tracks were pursued in parallel: direct low-rank adaptation of the open-weight Moshika speech-to-speech model to Persian, and a modular cascade combining NeMo Persian speech recognition, an exact Qwen3-4B-Instruct-2507 text responder under a frozen prompt, and Persian Piper speech synthesis.

A derived conversational corpus was constructed from an internal archive of Persian spoken content, yielding 6,754 user/response pairs and 108.584 measured hours of stereo training audio. Training, validation and test partitions were isolated by source session identifier, and no group leakage was observed. An interruption detector was implemented from energy, fundamental-frequency and MFCC features with a gradient-boosted classifier.

After a predeclared seven-row eligibility stage passed, the Qwen3-4B prompt-v2 responder passed every one of seven predeclared automatic gates on a 40-row, source-session-group-disjoint final test. All 240 expected judge calls were valid, mean response relevance improved from 1.425 for the frozen Qwen2.5-0.5B baseline to 3.150, mean coherence reached 3.325, and the paired relevance win rate was 67.5%. The judge was a same-family Qwen3.8-27B-FP8 model, so this metric is not a human or independent evaluation. The mechanical cascade chain, with the Qwen2.5-0.5B responder, produced a Persian transcript, a Persian reply and non-silent audio on 9 of 9 frozen validation rows with zero rule-based fallbacks. An automatic re-recognition proxy over those same nine outputs measured 7.14% character error rate and 30.41% word error rate. The nine-row mechanics panel was not re-run after the responder was promoted to Qwen3-4B.

The direct track, by contrast, reduced its teacher-forced objective across six experimental generations but never produced a checkpoint satisfying the frozen autoregressive runtime criterion. Generation v6.2 achieved a 32.20% reduction in in-sample text loss, yet all four of its checkpoints passed 0 of 9 runtime rows. That track is therefore reported as a negative result with a positive learning signal, and the cascade is treated as the delivered prototype. Browser measurement on a physical 12–24 GB GPU, proof of a 500 ms end-to-end latency bound, independently human-verified interruption labels, and a 5–10 participant listening study were not completed within the project deadline and remain explicit limitations.

Keywords: Speech-to-speech, full-duplex dialogue, barge-in detection, Persian language, large language models, cascaded systems, parameter-efficient adaptation



Sharif University of Technology
Department of Computer Engineering

B.Sc. Thesis

A Speech-to-Speech Large Language Model for Persian

By:

Mehran Bakhtiari

Supervisor:

Dr. Hossein Sameti

September 2026