

دانشگاه صنعتی شریف
دانشکده مهندسی کامپیوتر

پروژه کارشناسی
مهندسی کامپیوتر

مدل زبانی بزرگ گفتاربه‌گفتار برای زبان فارسی

نگارش

مهران بختیاری

استاد راهنما

دکتر حسین صامتی

مهر ۱۴۰۵

سپاسگزاری

از استاد راهنمای این پروژه، جناب آقای دکتر حسین صامتی، برای پذیرش راهنمایی این کار، برای طرح پرسش‌های دقیق درباره مرز میان شواهد مهندسی و ادعای علمی، و برای پافشاری بر این‌که نتایج منفی نیز باید صادقانه و کامل گزارش شوند، صمیمانه سپاسگزارم. بخش عمده‌ای از شکل نهایی این نوشتار، از جمله جداسازی روشن سنجه‌های خودکار از ارزیابی انسانی، نتیجه همین راهنمایی است.

همچنین از دانشکده مهندسی کامپیوتر دانشگاه صنعتی شریف برای فراهم‌کردن بستر آموزشی و پژوهشی این پروژه سپاسگزارم.

بخش‌های محاسباتی سنگین این پروژه، از جمله آموزش تطبیق کم‌پارامتر مدل مستقیم و اجرای سرویس‌های بازشناسی گفتار و تفکیک گوینده، بر زیرساخت پردازنده گرافیکی سازمانی انجام شد؛ از همه کسانی که دسترسی به این منابع و آرشیو گفتاری فارسی را ممکن کردند قدردانی می‌کنم. استفاده پژوهشی داخلی از این منابع با تأیید استاد راهنما ثبت شده است و به معنای مجوز بازنشر صوت یا زیرنویس خام نیست.

در پایان، از خانواده‌ام برای پشتیبانی و شکیبایی در طول ماه‌های انجام این پروژه سپاسگزارم.

چکیده

هدف این پروژه، طراحی، پیاده‌سازی و ارزیابی یک نمونه اولیه سامانه گفتاربه‌گفتار فارسی تمام‌دوطرفه است؛ یعنی میکروفون کاربر در هنگام پخش پاسخ فعال می‌ماند و سامانه به وقفه کاربر واکنش نشان می‌دهد. دو مسیر بررسی شد: تطبیق مدل سرتاسری Moshika با داده فارسی، و یک سامانه آبشاری جریانی شامل بازشناسی گفتار NeMo، پاسخ‌گوی Qwen3-4B-Instruct-2507 و گفتارساز Piper. از آرشیو گفتاری فارسی یک مجموعه داده مکالمه با 6,754 جفت و 108.584 ساعت صوت با تفکیک گروهی بر پایه نشست ساخته شد.

سامانه آبشاری نهایی پایان گفتار را خودکار و پیش‌دستانه تشخیص می‌دهد، پاسخ را جریانی و بندبه‌بند می‌سازد، و وقفه را در دو مرحله مدیریت می‌کند: کم‌کردن صدا پس از یک قاب گفتار بلندتر از پژواک مورد انتظار دستیار، و تأیید واژگانی با بازشناس پس از کنارگذاشتن واژه‌های شنونده و پژواک خود دستیار. در آزمون حلقه‌ای با مرورگر واقعی، میانگین تأخیر پایان گفتار تا نخستین صدای پاسخ 372 و صدک نود آن 431 میلی‌ثانیه بود، همه نوبت‌ها زیر 500 میلی‌ثانیه، و بخش گرافیکی سامانه GiB 11.1 حافظه گرفت. تشخیص وقفه در شبیه‌سازی استقرار از ضبط‌های واقعی به دقت 0.933 و F1 0.880 با میانه 120 میلی‌ثانیه تا کم‌کردن صدا، و در مرورگر به دقت 0.825 و F1 0.817 رسید؛ طبقه‌بند صوتی انرژی/زیروبمی/MFCC به‌تنهایی روی رخدادهای واقعی 0.574 گرفت. پاسخ‌گو در آزمون معنایی نهایی 40 ردیفی از هر هفت شرط خودکار گذشت (مرتبط‌بودن 3.150 در برابر 1.425). اجزا روی پنل‌های تازه دوباره برگزیده شدند، از جمله بازشناس روی رونوشت انسانی و گفتارساز با دو شنونده خودکار.

مسیر مستقیم به مدل قابل استقرار نرسید؛ نشان داده شد که توکن‌ساز انگلیسی Moshi برای هر واژه فارسی 6.6 نشانه می‌خواهد و از بودجه یک نشانه در قاب فراتر می‌رود. لاتین‌نویسی واجی بهترین نتیجه را دو برابر کرد اما گفتار هنوز فهم‌پذیر نبود، و مدل ورودی گفتاری Gemma 4 نیز از سامانه آبشاری ضعیف‌تر بود. شواهد تأخیر و وقفه خودکار و روی H100 است (حافظه یک کارت 12 گیگابایتی رعایت شد، سرعت آن نه) و برچسب‌ها خودکارند؛ مطالعه شنیداری انسانی در انتظار پاسخ شرکت‌کنندگان است.

کلیدواژه‌ها: گفتاربه‌گفتار، تمام‌دوطرفه، تشخیص وقفه، زبان فارسی، مدل زبانی بزرگ، سامانه آبشاری جریانی، توکن‌ساز، تطبیق کم‌پارامتر

فهرست مطالب

۱ مقدمه ۱

۱-۱ تعریف مسئله ۱

۱-۲ اهمیت موضوع ۲

۱-۳ نیازمندی‌های تعریف‌شده ۳

۱-۴ پرسش‌های پژوهش ۳

۱-۵ چالش‌های اصلی ۴

۱-۶ راهبرد دومسیره ۵

۱-۷ دستاوردهای این پروژه ۵

۱-۸ ساختار این نوشتار ۶

۲ مفاهیم اولیه ۸

۲-۱ سیگنال گفتار و ویژگی‌های آوایی ۸

۲-۱-۱ انرژی و نرخ گذر از صفر ۸

۲-۱-۲ بسامد پایه و روش YIN ۹

۲-۱-۳ ضرایب کپستروم بسامد مل ۹

۲-۱-۴ پنجره متن و بردار تصمیم ۱۰

۲-۲ بازشناسی گفتار ۱۰

۲-۳ تبدیل متن به گفتار ۱۱

۲-۴ مدل‌های زبانی بزرگ و تطبیق کم‌پارامتر ۱۱
۲-۴-۱ مدل زبانی خودرگرسیو ۱۱
۲-۴-۲ تحمیل معلم و اریبی مواجهه ۱۲
۲-۴-۳ تطبیق کم‌پارامتر و LoRA ۱۲
۲-۵ رمزینه‌های صوتی عصبی و مدل‌های گفتاربه‌گفتار ۱۳
۲-۵-۱ کوانتیزه‌سازی برداری باقی‌مانده ۱۳
۲-۵-۲ مدل‌سازی زبانی روی نشانه‌های صوتی ۱۳
۲-۵-۳ معماری Moshi و «تک‌گویی درونی» ۱۴
۲-۶ تمام‌دوطرفه بودن و نوبت‌گیری ۱۴
۲-۷ طبقه‌بندی با تقویت گرادیانی ۱۵
۲-۸ سنجه‌ها و مفاهیم آماری ارزیابی ۱۶
۲-۸-۱ نرخ خطای واژه و نویسه ۱۶
۲-۸-۲ سنجه‌های آشکارساز ۱۶
۲-۸-۳ فاصله اطمینان و همبستگی گروهی ۱۶
۲-۸-۴ تفکیک گروهی داده ۱۷
۲-۸-۵ داوری خودکار با مدل زبانی ۱۷
۲-۸-۶ سنجه‌های تأخیر ۱۷

۳ کارهای پیشین **۱۹**
۳-۱ از زنجیره آبشاری به مدل سرتاسری ۱۹
۳-۲ مدل‌های گفتاربه‌گفتار متن‌باز ۲۰
۳-۲-۱ خانواده Mini-Omni ۲۰
۳-۲-۲ SpeechGPT و واحدهای گسسته گفتار ۲۰
۳-۲-۳ خانواده LLaMA-Omni ۲۱
۳-۲-۴ Freeze-Omni و رویکرد مدل منجمد ۲۱

۳-۲-۵ Qwen2.5-Omni و معماری «اندیشمند و گوینده» ۲۲
۳-۲-۶ Moshi و انتخاب نهایی مسیر مستقیم ۲۲
۳-۲-۷ PersonaPlex و کنترل نقش در مدل تمام‌دوطرفه ۲۲
۳-۳ منابع گفتاری زبان فارسی ۲۳
۳-۴ استنتاج جریانی کم‌تأخیر ۲۳
۳-۵ تعامل سالمندان با دستیار صوتی ۲۴
۳-۶ تشخیص وقفه و نوبت‌گیری ۲۵
۳-۷ ارزیابی خودکار کیفیت گفت‌وگو ۲۶
۳-۸ جایگاه این پروژه ۲۶

۴ روش پیشنهادی و پیاده‌سازی ۲۸
۴-۱ تلاش اولیه و بازنگری در معماری ۲۸
۴-۲ ساخت مجموعه داده مکالمه فارسی ۲۹
۴-۲-۱ منبع و راهبرد ۲۹
۴-۲-۲ مراحل زنجیره ۲۹
۴-۲-۳ استخراج جفت پاسخ و برچسب تعامل ۳۱
۴-۲-۴ تفکیک گروهی و بازسازی صدای پاسخ ۳۱
۴-۳ معماری سامانه آبشاری جریانی ۳۲
۴-۳-۱ کارخواه مرورگر و قالب قاب‌ها ۳۳
۴-۳-۲ تشخیص پایان گفتار و آغاز پیش‌دستانه ۳۳
۴-۳-۳ بازشناسی گفتار ۳۳
۴-۳-۴ تولید پاسخ متنی جریانی ۳۴
۴-۳-۵ بندبندی و تولید گفتار ۳۴
۴-۴ کنترل تمام‌دوطرفه و تشخیص وقفه ۳۴
۴-۴-۱ مرحله نخست: کم‌کردن صدا ۳۵

۴-۴-۲ مرحله دوم: تأیید واژگانی با حذف پژواک ۳۵
۴-۴-۳ سه سطح ارزیابی ۳۶
۴-۵ طراحی آزمایش‌های مسیر مستقیم ۳۶
۴-۵-۱ هدف آموزشی و شرط پذیرش ۳۶
۴-۵-۲ نسل‌های آزمایشی ۳۷
۴-۵-۳ نسخه هفتم: آزمون علت ریشه‌ای در توکن‌ساز ۳۷
۴-۵-۴ مسیر ورودی گفتاری: Gemma 4 . . . . . ۳۸
۴-۶ روش کاری شواهدمحور ۳۸
۴-۷ پیاده‌سازی و بازتولیدپذیری ۴۰

۵ آزمایش‌ها و نتایج ۴۳
۵-۱ پوشش شروط پذیرش و وضعیت شواهد ۴۳
۵-۲ مجموعه داده ۴۳
۵-۳ سامانه آبشاری: پنل مکانیکی ۴۵
۵-۴ تقریب خودکار فهم‌پذیری گفتار تولیدشده ۴۶
۵-۵ آزمون معنایی خودکار ۴۷
۵-۵-۱ مرحله صلاحیت ۴۷
۵-۵-۲ آزمون نهایی ۴۷
۵-۵-۳ آزمایش تطبیق پاسخ‌گو با LoRA ۴۸
۵-۶ بازگزینش اجزا روی پنل‌های تازه ۴۸
۵-۶-۱ بازشناسی گفتار روی رونوشت‌های انسانی ۴۹
۵-۶-۲ پاسخ‌گو با پنل درخواست‌های سالمندان ۴۹
۵-۶-۳ صدای گفتار با دو شنونده خودکار ۵۰
۵-۷ تشخیص وقفه ۵۱
۵-۷-۱ آزمون مصنوعی ۵۱

۵-۷-۲ تقریب روی داده ضبط‌شده ۵۱
۵-۷-۳ شبیه‌سازی موقعیت استقرار ۵۲
۵-۸ پیوستگی انتقال تمام‌دوطرفه ۵۳
۵-۹ مسیر مستقیم: هفت نسل آزمایشی ۵۳
۵-۹-۱ نتیجه کل ۵۳
۵-۹-۲ نسخه نخست: زیان کنارگذاشته مثبت، اجرای ناموفق ۵۳
۵-۹-۳ نسخه دوم: روشن‌ترین نمایش شکاف ۵۵
۵-۹-۴ نسخه‌های سوم تا پنجم: آزمون فرضیه‌های هدفمند ۵۵
۵-۹-۵ نسخه ششم: تفکیک ظرفیت از تولید ۵۶
۵-۹-۶ نسخه هفتم: برداشتن گلوگاه توکن‌ساز ۵۷
۵-۱۰ مسیر ورودی گفتاری ۵۷
۵-۱۱ تأخیر، حافظه و آزمون حلقه‌ای مرورگر ۵۸
۵-۱۲ تحلیل خطا ۵۹
۵-۱۳ مطالعه انسانی ۶۰
۵-۱۴ بده‌بستان تأخیر، اندازه و کیفیت ۶۰
۵-۱۵ وضعیت نهایی نیازمندی‌ها ۶۱

۶ بحث و محدودیت‌ها **۷۴**
۶-۱ فاصله میان کاهش زیان و تولید معتبر ۷۴
۶-۲ چرا نرخ خطای واژه بسیار بیشتر از نرخ خطای نویسه است ۷۶
۶-۳ چرا تطبیق پاسخ‌گو زیان را کم کرد ولی کیفیت را بهتر نکرد ۷۶
۶-۴ تعارض ساختاری میان نیازمندی‌ها ۷۷
۶-۵ ارزش و مرز نتیجه معنایی خودکار ۷۸
۶-۶ محدودیت‌ها ۷۸
۶-۷ ملاحظات اخلاقی، حریم خصوصی و حقوقی ۷۹

۶-۷-۱ خاستگاه و حقوق داده ۷۹
۶-۷-۲ حریم خصوصی در مطالعه انسانی ۸۰
۶-۷-۳ مجوز و مرزهای آن ۸۰
۶-۷-۴ کاربرد و سوءکاربرد ۸۰
۶-۸ عبارت‌هایی که این نوشتار از آن‌ها پرهیز کرده است ۸۱

۷ نتیجه‌گیری و کارهای آینده **۸۲**
۷-۱ جمع‌بندی ۸۲
۷-۲ پاسخ به پرسش پژوهش ۸۳
۷-۳ پاسخ به پرسش‌های پژوهش پیشنهاده ۸۴
۷-۴ کارهای آینده ۸۵
۷-۴-۱ تکمیل شواهد ۸۵
۷-۴-۲ بهبود سامانه ۸۵
۷-۴-۳ مسیر مستقیم ۸۶
۷-۵ سخن آخر ۸۶

مراجع **۸۷**

واژه‌نامه **۹۳**

آ جزئیات پیاده‌سازی و بازتولید **۹۶**
آ-۱ ساختار مخزن ۹۶
آ-۲ فراپارامترهای آزمایش‌های مسیر مستقیم ۹۶
آ-۳ فراپارامترهای آشکارساز و پاسخ‌گو ۹۶
آ-۴ فرمان‌های بازتولید ۹۷
آ-۵ نقشه مصنوعات شواهد ۹۸

آـ۶ محیط اجرا ۹۸
آـ۷ ساخت این نوشتار ۹۸

فهرست جداول

۱-۱ نیازمندی‌های هفت‌گانه تعریف پروژه و محل بررسی آن‌ها در این نوشتار ۳

۱-۳ مقایسه این پروژه با کارهای پیشین از نظر قابلیت‌های مورد نیاز تعریف پروژه ۲۷

۱-۴ طراحی هفت نسل آزمایشی مسیر مستقیم و فرضیه‌ای که هر نسل آزمود ۴۱

۲-۴ کلاس‌های شواهد و توان ادعای هر کلاس ۴۲

۱-۵ شروط پذیرش رسمی پروژه و شواهد خودکار مرحله پایانی ۴۴

۲-۵ مشخصات مجموعه داده مکالمه فارسی مشتق‌شده و ممیزی خودکار آن ۶۲

۳-۵ نتیجه پنل ثابت اعتبارسنجی سامانه آبشاری ۶۳

۴-۵ اندازه‌گیری‌های هر ردیف پنل اعتبارسنجی سامانه آبشاری ۶۴

۵-۵ نتیجه تقریب خودکار بازبازشناسی گفتار تولیدشده ۶۴

۶-۵ نتیجه آزمون نهایی معنایی خودکار روی 40 ردیف گروه‌ناهمپوشان ۶۵

۷-۵ شروط خودکار ازپیش‌تعریف‌شده آزمون نهایی و مقادیر مشاهده‌شده ۶۵

۸-۵ مقایسه نامزدهای بازشناسی گفتار روی 344 قطعه PSRB با رونوشت انسانی ۶۶

۹-۵ پاسخ‌گوهای نامزد زیر دو داور (مقیاس 0 تا 4؛ افزایش نسبت به سامانه مستقر) ۶۶

۱۰-۵ فهم‌پذیری خودکار صداهای فارسی Piper (میانگین خطای نویسه دو شنونده) ۶۶

۱۱-۵ نتیجه تقریب آشکارساز وقفه روی رخدادهای صوت ضبط‌شده با نشست‌های کنارگذاشته ۶۷

۱۲-۵ اجراهای توسعه شبیه‌سازی (فقط بخش آموزشی) ۶۷

۱۳-۵ نتیجه یک‌باره شبیه‌سازی روی 600 سناریوی آزمون (بازه اطمینان 95 درصد ویلسون) . ۶۷

۵-۱۴ خلاصه هفت نسل آزمایشی مسیر مستقیم. ستون «بهترین اجرا» بیشترین شمار ردیف عبورکرده از ۹ ردیف پنل اجرا در میان همه چک‌پوینت‌های آن نسل است. ۶۸

۵-۱۵ نمونه‌ای از چک‌پوینت‌های نسخه دوم: زیان اعتبارسنجی به‌طور یکنوا کاهش می‌یابد در حالی که شمار ردیف‌های عبورکرده از پنل اجرا افزایش نمی‌یابد ۶۸

۵-۱۶ نتیجه هر چک‌پوینت نسخه‌های چهارم و پنجم روی پنل اجرای نه‌ردیفی ۶۹

۵-۱۷ نسخه v6.2: سیگنال یادگیری درون‌نمونه مثبت در برابر نتیجه اجرای خودرگرسیو منفی . ۶۹

۵-۱۸ شمار ردیف‌های پذیرفته پنل نُه‌ردیفی در آزمون ظرفیت درون‌نمونه ۶۹

۵-۱۹ مسیر ورودی گفتاری در برابر سامانه آبشاری (داور Qwen3.8-27B) ۷۰

۵-۲۰ تأخیر پایان گفتار تا نخستین صدای دستیار در آزمون حلقه‌ای مرورگر (میلی‌ثانیه). پنل اصلی: 61 گفته PSRB و 140 گفته پیکره؛ سالمند: همان روش با سرعت 0.85 و 3 دسی‌بل آرام‌تر؛ وقفه: نوبت‌های پایه دو پنل وقفه. ستون آخر تأخیر خروجی گزارش‌شده مرورگر را می‌افزاید. ۷۰

۵-۲۱ حالت‌های شکست سامانه و علت سنجیده‌شده هر یک ۷۱

۵-۲۲ بده‌بستان اندازه، کیفیت و تأخیر نامزدها (کیفیت و تأخیر از همان آزمون‌های بخش‌های پیشین) ۷۲

۵-۲۳ وضعیت نهایی هفت نیازمندی تعریف پروژه و کلاس شواهد پشتیبان ۷۳

آ-۱ ساختار سطح نخست مخزن کد پروژه ۹۷

آ-۲ فراپارامترهای هفت نسل آزمایشی تطبیق کم‌پارامتر مسیر مستقیم ۹۸

آ-۳ پیکربندی ماژول تشخیص وقفه و آداپتر پاسخ‌گوی متنی ۱۰۰

آ-۴ فرمان‌های بازتولید مراحل اصلی پروژه ۱۰۱

آ-۵ اسکریپت‌های ارزیابی قفل‌شده ۱۰۱

آ-۶ نقشه ادعاها و مصنوعات مرجع. همه مسیرها نسبت به شاخه `results` هستند. . . . ۱۰۲

آ-۷ مؤلفه‌های اصلی محیط اجرا و مدل‌های به‌کاررفته ۱۰۳

فهرست تصاویر

۴-۱ مراحل زنجیره ساخت مجموعه داده مکالمه فارسی. هر مرحله یک فرمان مستقل با خروجی ممیزی‌پذیر است. ۳۰

۴-۲ کاهش تدریجی مقدار صوت از موجودی زیرنویس کانال‌ها تا خروجی استریوی ممیزی‌شده آموزش. نوار روشن، بازه 100 تا 200 ساعت مورد نظر تعریف پروژه را نشان می‌دهد. ۳۲

۴-۳ معماری جریانی سامانه تحویل‌شده. ردیف پایین زنجیره تولید پاسخ در حالت شنیدن و ردیف بالا کنترل وقفه در حالت سخن‌گفتن دستیار است. پیکان نقطه‌چین انتقال آغاز گفتار کاربر به نوبت بعد را نشان می‌دهد. ۳۲

۵-۱ (الف) زمان تولید کامل پاسخ در برابر طول رونویسی ورودی برای ۹ ردیف پنل اعتبارسنجی، همراه با خط برازش و همبستگی پیرسون توصیفی. (ب) نرخ خطای واژه و نویسه بازبازشناسی برای همان ۹ خروجی، همراه با مقادیر تجمیع خرد. ۴۶

۵-۲ (الف) میانگین امتیاز ارتباط و انسجام برای سه بازوی دوسوکور، همراه با آستانه‌های ازپیش‌تعریف‌شده. (ب) توزیع کامل امتیاز ارتباط در 80 فراخوانی داور برای هر بازو. . ۴۸

۵-۳ (الف) جست‌وجوی آستانه تصمیم روی نشست‌های اعتبارسنجی؛ خط عمودی، آستانه انتخاب‌شده 0.70 است. (ب) مقایسه آشکارساز پیشنهادی با خط پایه انرژی روی نشست‌های آزمون؛ میله‌های خطا، فاصله اطمینان بلوکی در سطح نشست‌اند. ۵۲

۵-۴ (الف) بهترین زیان آفلاین هر نسل. (ب) بیشترین شمار ردیف عبورکرده از پنل اجرای نه‌ردیفی در هر نسل، در برابر شرط پذیرش 9 از 9. . . . . ۵۴

۵-۵ (الف) زیان آموزش نسخه نخست تحت تحمیل معلم، به همراه میانگین غلتان. (ب) زیان اعتبارسنجی بازارزیابی‌شده به تفکیک مؤلفه متنی و صوتی؛ خط عمودی، چک‌پوینت انتخاب‌شده است. ۵۴

۵-۶ نسخه دوم: زیان اعتبارسنجی روی 202 بازه در هر چک‌پوینت به‌طور یکنوا کاهش می‌یابد (خط)، در حالی که شمار ردیف‌های عبورکرده از پنل اجرای نه‌ردیفی (میله‌ها) هرگز به شرط پذیرش نمی‌رسد. ۵۵

۵-۷ نسخه v6.2: (الف) زیان درون‌نمونه به‌طور پیوسته کاهش می‌یابد و کاهش زیان متنی از گام 50 به بهترین گام بعدی 32.20 درصد است. (ب) با این حال هر چهار چک‌پوینت 0 از 9 ردیف پنل اجرا را می‌گذرانند. ۵۶

فصل ۱

مقدمه

گفت‌وگوی گفتاری، طبیعی‌ترین شکل تعامل انسان با ماشین است. با این حال، تا همین اواخر سامانه‌های گفت‌وگوی گفتاری تقریباً همیشه از زنجیره‌ای از مؤلفه‌های مستقل ساخته می‌شدند: تشخیص فعالیت گفتاری، بازشناسی گفتار، یک موتور گفت‌وگوی متنی و سپس تبدیل متن به گفتار. معرفی مدل‌هایی مانند Moshi [۱] و Freeze-Omni [۲] نشان داد که می‌توان گفت‌وگوی گفتاری را به‌صورت یک مسئله «گفتاربه‌گفتار» و در قالب یک مدل یکپارچه مدل کرد؛ مدلی که هم‌زمان می‌شنود و سخن می‌گوید و برای نوبت‌گیری به بخش‌بندی صریح گفتار نیاز ندارد.

این تحول برای زبان‌های پرمنبع مانند انگلیسی و چینی رخ داده است. برای زبان فارسی هیچ‌یک از مدل‌های گفتاربه‌گفتار متن‌باز موجود پشتیبانی رسمی ارائه نمی‌کنند، و مجموعه داده‌های مکالمه‌ای فارسی که هم‌پوشانی گفتار، وقفه و بازخورد کلامی را پوشش دهند نیز به‌صورت عمومی در دسترس نیستند. پرسش عملی این پروژه از همین شکاف برمی‌آید: با بودجه محاسباتی و زمانی یک پروژه کارشناسی، تا چه اندازه می‌توان یک سامانه گفتاربه‌گفتار فارسی تمام‌دوطرفه ساخت، و مهم‌تر از آن، چه چیزی را می‌توان درباره آن با شواهد قابل ممیزی «اثبات» کرد؟

۱-۱ تعریف مسئله

هدف تعریف‌شده این پروژه، طراحی، پیاده‌سازی و ارزیابی یک نمونه اولیه از یک مدل زبانی بزرگ گفتاربه‌گفتار برای زبان فارسی است. سامانه باید به‌صورت «تمام‌دوطرفه»[۱] کار کند؛ یعنی برخلاف

[۱] full-duplex

سامانه‌های نیم‌دوطرفه که تنها پس از پایان‌یافتن پاسخ به کاربر گوش می‌دهند، میکروفون کاربر در طول پخش پاسخ نیز فعال بماند و سامانه بتواند در صورت «وقفه»[۲] کاربر واکنش نشان دهد.

سه ویژگی این مسئله را از یک سامانه پرسش‌وپاسخ گفتاری متعارف جدا می‌کند:

- **هم‌زمانی شنیدن و گفتن.** سامانه باید در حالی که خروجی صوتی خود را پخش می‌کند، جریان ورودی میکروفون را نیز پردازش کند و درباره ادامه یا توقف پخش تصمیم بگیرد.
- **تصمیم‌گیری زمان‌حساس.** تصمیم توقف پخش باید در مقیاس چنده میلی‌ثانیه گرفته شود، وگرنه کاربر احساس می‌کند سامانه حرف او را نمی‌شنود.
- **تداوم گفتار قطع‌شده.** گفتاری که کاربر در لحظه وقفه ادا می‌کند نباید از دست برود؛ این گفتار باید به نوبت بعدی منتقل شود، در غیر این صورت کاربر ناچار می‌شود جمله خود را تکرار کند.

۱-۲ اهمیت موضوع

پرداختن به این مسئله برای زبان فارسی از چند جهت اهمیت دارد.

نخست، **دسترس‌پذیری**. رابط گفتاری برای کاربرانی که با صفحه‌کلید فارسی راحت نیستند، برای کاربران کم‌بینا و به‌طور خاص برای سالمندان، می‌تواند تنها راه مؤثر استفاده از خدمات دیجیتال باشد. در گفت‌وگوی طبیعی سالمندان، مکث‌های بلندتر و اصلاح‌های میان‌جمله‌ای بیشتر رخ می‌دهد؛ یک سامانه نیم‌دوطرفه که تا پایان پاسخ خود گوش نمی‌دهد، در این شرایط تجربه‌ای آزارنده می‌سازد.

دوم، **کم‌منبع‌بودن فارسی در این حوزه خاص**. برای فارسی مجموعه داده‌های بازشناسی گفتار و تبدیل متن به گفتار در دسترس است؛ نمونه شاخص آن ManaTTS [۳] با بیش از 86 ساعت گفتار تک‌گوینده است. اما این منابع، تک‌گوینده و خوانشی‌اند و پدیده‌های تعاملی‌ای که یک مدل تمام‌دوطرفه باید یاد بگیرد، یعنی هم‌پوشانی و وقفه و بازخورد کلامی، در آن‌ها وجود ندارد.

سوم، **هزینه محاسباتی**. مدل‌های گفتاربه‌گفتار روز، مانند Qwen2.5-Omni [۴]، برای اجرا به حافظه‌ای بسیار بیش از یک کارت گرافیک آزمایشگاهی نیاز دارند. نشان‌دادن این‌که چه چیزی در بازه حافظه 12 تا 24 گیگابایت «قابل دستیابی» و چه چیزی «قابل دستیابی نیست»، خودش یک نتیجه مهندسی سودمند است.

[۲] interruption

۱-۳ نیازمندی‌های تعریف‌شده

تعریف پروژه هفت نیازمندی مشخص را تعیین کرده است. این نیازمندی‌ها در سراسر این نوشتار به‌عنوان معیار سنجش دستاورد به کار می‌روند و در جدول ۱-۱ فهرست شده‌اند. برای هر نیازمندی، فصل مربوط به نتایج (فصل ۵) وضعیت نهایی و کلاس شواهد پشتیبان آن را گزارش می‌کند.

جدول ۱-۱: نیازمندی‌های هفت‌گانه تعریف پروژه و محل بررسی آن‌ها در این نوشتار

شماره	نیازمندی	سنجه تعیین‌شده
ن۱	نمونه اولیه گفتاربه‌گفتار فارسی	تولید پاسخ گفتاری فارسی از ورودی گفتاری فارسی
ن۲	کارکرد تمام‌دوطرفه	شنیدن در هنگام پخش و واکنش به وقفه
ن۳	تأخیر سرتاسری	حداکثر 500 میلی‌ثانیه از دریافت گفتار تا تولید پاسخ گفتاری
ن۴	مجموعه داده مکالمه فارسی	100 تا 200 ساعت گفتار همراه با نویز، هم‌پوشانی و قطع‌ووصل کلام
ن۵	ماژول تشخیص وقفه	دقت بالای 80 درصد با ویژگی‌های انرژی، زیروبمی و MFCC
ن۶	ارزیابی روی سخت‌افزار هدف	پردازنده گرافیکی با 12 تا 24 گیگابایت حافظه
ن۷	ارزیابی انسانی	5 تا 10 گویشور فارسی، دست‌کم دو نفر بالای 60 سال

خروجی نهایی مورد انتظار نیز شامل چهار قلم است: یک نمونه اولیه کارا، کد منبع مستند، یک مجموعه داده مکالمه فارسی، و یافته‌های مربوط به نحوه تعامل سالمندان فارسی‌زبان با سامانه. برای قلم چهارم، پروتکل و زیرساخت سنجش آماده شده است؛ یافته تجربی آن تنها پس از تکمیل مطالعه انسانی قابل ادعا خواهد بود و ازاین‌رو در این نوشتار ادعایی درباره تجربه سالمندان مطرح نمی‌شود.

۱-۴ پرسش‌های پژوهش

پیشنهاده پروژه چهار پرسش پژوهشی مطرح می‌کند که فصل ۷ (بخش ۷-۳) به هر یک با شواهد همین نوشتار پاسخ می‌دهد:

۱. **پرسش ۱.** چگونه می‌توان یک مدل گفتاربه‌گفتار انگلیسی یا چینی موجود را با کمترین هزینه آموزش مجدد برای فارسی تطبیق داد؟

۲. **پرسش ۲.** چه تغییرات معماری، مانند بافر دوگانه یا ماژول تشخیص وقفه، برای کارکرد تمام‌دوطرفه با تأخیر کمتر از 500 میلی‌ثانیه لازم است؟

۳. **پرسش ۳.** بده‌بستان میان تأخیر، اندازه مدل و کیفیت گفتار برای فارسی در اجرای بی‌درنگ چیست؟

۴. **پرسش ۴.** سالمندان فارسی‌زبان پاسخ‌گویی و طبیعی‌بودن چنین سامانه‌ای را چگونه درک می‌کنند؟

۱-۵ چالش‌های اصلی

در جریان اجرای پروژه، چهار چالش تعیین‌کننده ظاهر شد که شکل نهایی کار را تغییر داد.

نبود یک مسیر آموزشی رسمی برای فارسی. مدل Mini-Omni2 [۵] که در تعریف پروژه به‌عنوان نمونه مدل پایه نام برده شده است، و همچنین LLaMA-Omni2 [۶]، مخزن‌هایی برای استنتاج منتشر کرده‌اند اما آموزش‌دهنده کامل و رسمی گفتاربه‌گفتار ارائه نمی‌دهند. در میان مدل‌های بررسی‌شده، تنها خانواده Moshi یک آموزش‌دهنده رسمی تطبیق کم‌پارامتر منتشر کرده بود [۷]؛ به همین دلیل مسیر مستقیم این پروژه بر پایه Moshika، نسخه هفت‌میلیاردپارامتری این خانواده، بنا شد.

نبود داده مکالمه‌ای برچسب‌دار فارسی. هیچ پیکره عمومی فارسی با برچسب وقفه و هم‌پوشانی در اختیار نبود. مجموعه داده این پروژه ناچار از یک آرشیو داخلی محتوای گفتاری فارسی و با یک زنجیره خودکار شامل بازسازی پنجره، تفکیک گوینده و استخراج جفت پاسخ ساخته شد. پیامد این انتخاب آن است که برچسب‌های تعاملی حاصل «خودکار»اند و نه تأییدشده توسط انسان؛ این مرز در سراسر نوشتار حفظ شده است.

فاصله میان کاهش زیان و تولید معتبر. مهم‌ترین یافته منفی پروژه همین است. تطبیق کم‌پارامتر مدل مستقیم، در هفت نسل آزمایشی، زیان «تحمیل معلم»[۳] را به‌طور پیوسته کاهش داد، اما هیچ‌گاه به تولید «خودرگرسیو»[۴] معتبر گفتار فارسی نرسید. ممیزی پایانی علت ساختاری آن را نشان داد: توکن‌ساز انگلیسی مدل برای هر واژه فارسی بیش از شش نشانه می‌خواهد و از بودجه یک نشانه در قاب فراتر می‌رود.

[۳] teacher forcing
[۴] autoregressive

مرز میان شواهد مهندسی و ادعای علمی. سنجه‌های خودکار در دسترس بودند، اما سخت‌افزار هدف 12 تا 24 گیگابایتی، برچسب‌گذاری انسانی وقفه و یک مطالعه انسانی بزرگ در مهلت پروژه فراهم نشد؛ به‌جای آن‌ها آزمون حلقه‌ای مرورگر با بودجه حافظه یک کارت 12 گیگابایتی، برچسب خودکار مستقل دومرحله‌ای و یک مطالعه شنیداری کوچک طراحی شد. تصمیم روشمند پروژه این بود که هر سنجه با «کلاس شواهد» خود برچسب‌گذاری شود و هیچ تقریب خودکاری به جای شواهد رسمی ارائه نگردد. این تصمیم در بخش ۴–۶ به یک روش کاری تبدیل شده است.

۱–۶ راهبرد دومسیره

برای کاهش ریسک اجرایی، پروژه دو مسیر را به‌طور موازی پیش برد:

۱. **مسیر مستقیم.** تطبیق کم‌پارامتر مدل Moshika با داده مکالمه فارسی، به این امید که یک مدل واحد گفتاربه‌گفتار فارسی به دست آید. این مسیر پاسخ مستقیم به روح تعریف پروژه است.

۲. **مسیر آبشاری.** یک زنجیره ماژولار شامل بازشناسی گفتار فارسی، تولید پاسخ متنی با یک مدل زبانی بزرگ و تبدیل متن به گفتار، که کنترل تمام‌دوطرفه و منطق وقفه به‌صورت جداگانه روی آن سوار می‌شود. این مسیر تضمین می‌کند که پروژه یک سامانه کارکردی قابل نمایش داشته باشد.

هر دو مسیر از یک مجموعه داده مشترک استفاده کردند. نتیجه نهایی، همان‌طور که در فصل ۵ گزارش می‌شود، نامتقارن بود: مسیر آبشاری به یک سامانه جریانی تمام‌دوطرفه رسید که معیارهای عددی تأخیر و تشخیص وقفه را در آزمون‌های خودکار برآورده می‌کند، در حالی که مسیر مستقیم، و یک مسیر ورودی گفتاری با Gemma 4، به‌عنوان نتیجه منفی همراه با علت سنجیده‌شده گزارش شده‌اند.

۱–۷ دستاوردهای این پروژه

دستاوردهای این پروژه را می‌توان در شش مورد خلاصه کرد.

۱. **یک دستیار گفتاری فارسی تمام‌دوطرفه جریانی.** سامانه با میکروفون باز کار می‌کند، پایان گفتار را خودکار و پیش‌دستانه تشخیص می‌دهد و پاسخ را بندبه‌بند تولید و پخش می‌کند. در آزمون حلقه‌ای با مرورگر واقعی، میانگین تأخیر پایان گفتار تا نخستین صدای پاسخ 372 و صدک نود آن 431 میلی‌ثانیه بود، هیچ نوبتی از 500 میلی‌ثانیه نگذشت و بخش گرافیکی سامانه در 11.1 GiB حافظه جا شد.

۲. **تشخیص وقفه دومرحله‌ای با تأیید واژگانی.** کم‌کردن صدا پس از یک قاب گفتار بلندتر از پژواک مورد انتظار، و تأیید با بازشناس گفتار پس از حذف واژه‌های شنونده و پژواک خود دستیار؛ دقت 0.933 و 0.880 F1 در شبیه‌سازی استقرار و دقت 0.825 در مرورگر واقعی، در برابر 0.574 برای طبقه‌بند صوتی تنها؛ پاسخ پس از وقفه، با نگه‌داشتن فقط بخش شنیده‌شده پاسخ قطع‌شده در تاریخچه، به اندازه پاسخ نوبت عادی مرتبط بود.

۳. **یک مجموعه داده مکالمه فارسی مشتق‌شده و ممیزی‌شده.** 6,754 جفت «گفتار کاربر / پاسخ» با 108.584 ساعت صوت استریو، با تفکیک گروهی بر پایه نشست و نشت گروهی صفر؛ یک شنونده خودکار مستقل مرز نوبت را در 93.8 درصد نمونه‌ها تأیید کرد.

۴. **گزینش اجزا با شواهد.** آزمون معنایی نهایی پاسخ‌گو (مرتبط‌بودن 3.150 در برابر 1.425)، و بازگزینش بازشناس روی رونوشت انسانی، پاسخ‌گو روی درخواست‌های سالمندان و گفتارساز با دو شنونده خودکار، همه با پروتکل پیش‌ثبت‌شده؛ و بهینه‌سازی گفتارساز آزمایشگاه بدون آموزش مجدد، که چند خطای جلوی متنی آن (حذف واژه پایانی، خواندن نادرست اعداد) را یافت و رفع کرد.

۵. **علت سنجیده‌شده شکست مسیر مستقیم.** هفت نسل آزمایشی Moshika و یک مدل ورودی گفتاری؛ نشان داده شد که گلوگاه توکن‌ساز واقعی است و برداشتن آن بهترین نتیجه را دو برابر می‌کند، اما برای گفتار فهم‌پذیر کافی نیست.

۶. **یک روش کاری شواهدمحور.** پروتکل‌ها و آستانه‌ها پیش از اجرا ثبت شدند، بخش‌های آزمون تنها یک‌بار گشوده شدند، مصنوعات نتیجه یک‌بارنوشت‌اند و یک تجمیع‌کننده «شکست‌بسته»[۵] مانع از ارتقای تقریب‌های خودکار به شواهد رسمی می‌شود.

شواهد تأخیر و وقفه خودکار و روی H100 است، برچسب‌ها انسانی نیستند و مطالعه شنیداری در انتظار پاسخ شرکت‌کنندگان است. دامنه دقیق این نتایج در فصل ۶ گزارش شده است.

۱-۸ ساختار این نوشتار

این نوشتار در هفت فصل سازمان یافته است.

فصل ۲ مفاهیم اولیه مورد نیاز را معرفی می‌کند: نمایش سیگنال گفتار و ویژگی‌های آوایی، بازشناسی گفتار و تبدیل متن به گفتار، مدل‌های زبانی بزرگ و تطبیق کم‌پارامتر، رمزینه‌های صوتی عصبی و معماری مدل‌های گفتاربه‌گفتار، و سنجه‌ها و مفاهیم آماری به‌کاررفته در ارزیابی.

[۵] fail-closed

فصل ۳ کارهای پیشین را بررسی می‌کند و جایگاه این پروژه را در میان سامانه‌های آبشاری و مدل‌های سرتاسری گفت‌وگوی گفتاری، منابع گفتاری فارسی و پیشینه تشخیص وقفه مشخص می‌سازد.

فصل ۴ روش پیشنهادی را شرح می‌دهد: زنجیره ساخت مجموعه داده، معماری سامانه آبشاری، ماژول تشخیص وقفه و بستر انتقال تمام‌دوطرفه، طراحی آزمایش‌های مسیر مستقیم، و روش کاری شواهدمحور.

فصل ۵ نتایج را با جداول و شکل‌های مربوط ارائه می‌کند و برای هر نتیجه، مرز ادعای مجاز آن را می‌نویسد.

فصل ۶ به تفسیر نتایج می‌پردازد، به‌ویژه فاصله میان کاهش زیان و تولید معتبر، و سپس محدودیت‌ها و ملاحظات اخلاقی و حقوقی را برمی‌شمارد.

فصل ۷ جمع‌بندی و پیشنهادهای کار آینده را ارائه می‌کند. در پیوست نیز فرمان‌های بازتولید، فراپارامترهای دقیق آزمایش‌ها و نقشه مصنوعات شواهد آمده است.

فصل ۲

مفاهیم اولیه

این فصل مفاهیم و ابزارهایی را معرفی می‌کند که در فصل‌های بعدی به کار می‌روند. ترتیب مطالب از سیگنال گفتار و ویژگی‌های آوایی آغاز می‌شود، به مؤلفه‌های زنجیره آبشاری و سپس به معماری مدل‌های سرتاسری گفتاربه‌گفتار می‌رسد، و با سنجه‌ها و مفاهیم آماری ارزیابی پایان می‌یابد.

۲-۱ سیگنال گفتار و ویژگی‌های آوایی

گفتار در این پروژه به‌صورت سیگنال تک‌کاناله با بسامد نمونه‌برداری 16 کیلوهرتز و نمونه‌های صحیح ۱۶بیتی نمایش داده می‌شود. سیگنال پیوسته $x[n]$ به «فریم»هایی با طول ثابت تقسیم می‌شود؛ در این پروژه طول فریم 20 میلی‌ثانیه است، که با 320 نمونه معادل است. تقسیم به فریم بر این فرض استوار است که خواص آماری گفتار در بازه‌های کوتاه تقریباً ثابت‌اند.

۲-۱-۱ انرژی و نرخ گذر از صفر

ساده‌ترین ویژگی، **انرژی فریم** است. برای فریم t با N نمونه، انرژی لگاریتمی به‌صورت زیر محاسبه می‌شود:

$$E_t = \log\left(\frac{1}{N}\sum_{n=1}^{N} x_t^2[n] + \epsilon\right), \qquad (۱-۲)$$

که در آن ϵ یک مقدار مثبت کوچک برای پرهیز از لگاریتم صفر است. انرژی به‌تنهایی برای تشخیص گفتار کافی نیست، زیرا نویز پرتوان نیز انرژی بالایی دارد. ویژگی مکمل، **نرخ گذر از صفر** است که تعداد تغییر علامت سیگنال را در فریم می‌شمارد:

$$Z_t = \frac{1}{2(N-1)} \sum_{n=2}^{N} \left|\mathrm{sgn}(x_t[n]) - \mathrm{sgn}(x_t[n-1])\right|. \qquad (۲-۲)$$

آواهای واک‌دار نرخ گذر از صفر پایین و آواهای سایشی نرخ بالا دارند؛ ترکیب این دو ویژگی مبنای آشکارسازهای کلاسیک تشخیص فعالیت گفتاری است [۸].

۲-۱-۲ بسامد پایه و روش YIN

بسامد پایه یا F_0، بسامد ارتعاش تارهای صوتی و همان چیزی است که به‌طور ادراکی به‌عنوان زیروبمی شنیده می‌شود. تخمین F_0 در این پروژه با روش YIN [۹] انجام می‌شود. این روش بر تابع اختلاف مربعی هم‌بستگی استوار است:

$$d_t(\tau) = \sum_{n=1}^{W} \big(x_t[n] - x_t[n+\tau]\big)^2, \qquad (۲-۳)$$

که در آن τ تأخیر و W طول پنجره تحلیل است. سپس نسخه «هنجارشده تجمعی» این تابع ساخته می‌شود و نخستین کمینه محلی که از یک آستانه پایین‌تر بیفتد به‌عنوان دوره تناوب $\hat{\tau}$ انتخاب می‌گردد؛ بسامد پایه برابر $F_0 = f_s/\hat{\tau}$ خواهد بود. اگر هیچ کمینه‌ای از آستانه پایین‌تر نرود، فریم «بی‌واک» علامت‌گذاری می‌شود. در این پروژه بازه جست‌وجوی بسامد پایه 60 تا 400 هرتز در نظر گرفته شده است که گستره گویندگان مرد و زن را پوشش می‌دهد.

اهمیت F_0 در تشخیص وقفه آن است که آغاز یک گفتار انسانی معمولاً با ظهور ساختار واک‌دار همراه است، در حالی که نویز محیط یا صدای پخش بلندگو الگوی زیروبمی پایدار ندارد.

۲-۱-۳ ضرایب کپستروم بسامد مل

MFCC یا **ضرایب کپستروم بسامد مل** [۱۰] پرکاربردترین نمایش کوتاه‌مدت گفتار است و طیف فریم را به شکلی فشرده می‌کند که با ادراک شنوایی انسان هم‌خوان باشد. مراحل محاسبه چنین است:

۱. اعمال پنجره (مثلاً پنجره هَمینگ) و محاسبه تبدیل فوریه گسسته فریم؛

۲. محاسبه توان طیفی و عبور آن از یک بانک فیلتر مثلثی که مراکز آن روی مقیاس مل توزیع شده‌اند. رابطه مقیاس مل با بسامد خطی چنین است:

$$m(f) = 2595 \log_{10}\left(1 + \frac{f}{700}\right); \qquad (۴-۲)$$

۳. لگاریتم‌گیری از خروجی هر فیلتر؛

۴. اعمال تبدیل کسینوسی گسسته برای ناهم‌بسته‌کردن مؤلفه‌ها و نگه‌داشتن نخستین ضرایب.

در این پروژه 13 ضریب نگه داشته می‌شود. برای آن‌که ویژگی‌ها اطلاعات «تغییر» در زمان را نیز حمل کنند، مشتق مرتبه اول این ضرایب، که به «دلتا» شناخته می‌شود، نیز محاسبه و به بردار ویژگی افزوده می‌گردد. مجموع ویژگی‌های هر فریم بنابراین شامل انرژی، نرخ گذر از صفر، بسامد پایه، پرچم واک‌داری، 13 ضریب MFCC و 13 دلتای متناظر است.

۲-۱-۴ پنجره متن و بردار تصمیم

تصمیم درباره وقفه بر پایه یک فریم واحد قابل اتکا نیست. به همین دلیل ویژگی‌های فریم‌های یک «پنجره متن» گردآوری می‌شوند. در این پروژه پنجره متن 400 میلی‌ثانیه است، یعنی 20 فریم متوالی. برای هر بعد از بردار ویژگی فریم، سه آماره میانگین، انحراف معیار و بیشینه روی پنجره محاسبه و در یک بردار واحد به هم پیوند داده می‌شود. این بردار ورودی طبقه‌بند است.

۲-۲ بازشناسی گفتار

بازشناسی گفتار نگاشت یک سیگنال صوتی به رشته‌ای از واژه‌ها است. معماری‌های امروزی معمولاً یک کدگذار عصبی را با یک هدف آموزشی هم‌ترازی‌آزاد ترکیب می‌کنند. دو هدف پرکاربرد عبارت‌اند از «طبقه‌بندی زمانی پیوندگرا»[۱] [۱۱] که با فرض استقلال شرطی، احتمال همه هم‌ترازی‌های ممکن را حاشیه‌ای می‌کند، و «مبدل عصبی بازگشتی»[۲] [۱۲] که یک شبکه پیش‌بین زبانی را نیز در تصمیم دخیل می‌سازد و برای بازشناسی جویباری مناسب‌تر است.

[۱] Connectionist Temporal Classification (CTC)
[۲] RNN Transducer (RNNT)

معماری کدگذار مورد استفاده در سرویس بازشناسی این پروژه از خانواده Conformer [۱۳] است که لایه‌های خودتوجهی[۳] [۱۴] را با لایه‌های پیچشی ترکیب می‌کند: خودتوجهی وابستگی‌های بلندبرد و پیچش الگوهای محلی طیفی را مدل می‌کند. مدل مورد استفاده یک مدل ترکیبی RNNT-CTC با واحدهای زیرواژه است که در بستر NeMo [۱۵] پیاده‌سازی و به‌صورت یک سرویس محلی در دسترس قرار گرفته است.

رویکرد جایگزین، آموزش نظارت‌ضعیف در مقیاس بزرگ است؛ نمونه شاخص آن Whisper [۱۶] است که با صدها هزار ساعت داده چندزبانه آموزش دیده و در این پروژه تنها در آزمون‌های مقایسه مؤلفه‌ای به کار رفته است.

۲-۳ تبدیل متن به گفتار

سامانه‌های **تبدیل متن به گفتار** امروزی معمولاً سرتاسری‌اند. معماری VITS [۱۷] که مبنای موتور Piper [۱۸] است، یک خودکدگذار وردشی شرطی را با آموزش هم‌ستیزانه و یک پیش‌بین طول جریان‌محور ترکیب می‌کند و بدون نیاز به یک نوسان‌ساز جداگانه، مستقیماً موج صوتی تولید می‌کند.

برای فارسی، مرحله پیش‌پردازش متنی اهمیت خاصی دارد. نوشتار فارسی واکه‌های کوتاه را ثبت نمی‌کند، فاصله مجازی یا «نیم‌فاصله»[۴] مرز اجزای واژه‌های مرکب را تعیین می‌کند، و شکل نوشتاری واژه‌ها ممکن است میان منابع مختلف متفاوت باشد. به همین دلیل در این پروژه یک «هنجارساز» قطعی متن فارسی پیش از هر دو مرحله ارزیابی و تولید گفتار اعمال می‌شود تا شکل نویسه‌ها، نیم‌فاصله‌ها و ارقام یکسان شوند.

استفاده از یک موتور گفتاری «قطعی» با یک مدل صوتی ثابت، یک تصمیم روشمند است: چون خروجی صوتی برای یک متن ورودی مشخص همیشه یکسان است، اندازه‌گیری‌های مبتنی بر آن قابل بازتولید می‌شوند.

۲-۴ مدل‌های زبانی بزرگ و تطبیق کم‌پارامتر

۲-۴-۱ مدل زبانی خودرگرسیو

یک **مدل زبانی** احتمال یک رشته نشانه $y_{1:T}$ را به‌صورت زنجیره‌ای تجزیه می‌کند:

[۳] self-attention
[۴] zero-width non-joiner (ZWNJ)

$$p_\theta(y_{1:T}) = \prod_{t=1}^{T} p_\theta(y_t \mid y_{<t}), \tag{۵-۲}$$

و با کمینه‌کردن زیان آنتروپی متقاطع روی داده آموزشی برازش می‌شود. معماری غالب، ترانسفورمر تنهاکدگشا [۱۴] است. مدل‌های «دستورپیرو»[۵] با یک مرحله تنظیم دقیق نظارت‌شده روی جفت‌های دستور و پاسخ ساخته می‌شوند [۱۹]؛ پاسخ‌گوی متنی این پروژه از همین دسته است.

۲-۴-۲ تحمیل معلم و اریبی مواجهه

نکته‌ای که برای تفسیر نتایج فصل ۵ تعیین‌کننده است، تفاوت میان شرایط آموزش و شرایط استنتاج است. در آموزش، مدل در هر گام نشانه‌های «درست» پیشین را به‌عنوان شرط دریافت می‌کند؛ این شیوه **تحمیل معلم** نامیده می‌شود. زیانی که در آموزش و اعتبارسنجی گزارش می‌شود، تحت همین شرط محاسبه می‌گردد.

اما در استنتاج، مدل باید بر نشانه‌های «تولیدی خودش» شرط بگذارد. اگر توزیع نشانه‌های تولیدی از توزیع نشانه‌های مرجع فاصله بگیرد، مدل در ناحیه‌ای از فضای حالت قرار می‌گیرد که در آموزش ندیده است و خطا می‌تواند به‌صورت تجمعی رشد کند. این ناسازگاری با نام **اریبی مواجهه**[۶] شناخته می‌شود [۲۰] و راهکار متعارف آن، «نمونه‌گیری زمان‌بندی‌شده» است که در طول آموزش به‌تدریج نشانه‌های مرجع را با نشانه‌های تولیدی جانشین می‌کند [۲۱].

پیامد عملی این مفهوم صریح است: «کاهش زیان تحت تحمیل معلم، به‌خودی‌خود تضمین نمی‌کند که مدل در تولید خودرگرسیو خروجی قابل استفاده بدهد». آزمایش مسیر مستقیم این پروژه نمونه‌ای روشن از همین شکاف است.

۲-۴-۳ تطبیق کم‌پارامتر و LoRA

تنظیم دقیق کامل یک مدل چندمیلیاردپارامتری بر سخت‌افزار محدود عملی نیست. روش‌های **تطبیق کم‌پارامتر** تنها شمار کوچکی از پارامترها را آموزش می‌دهند [۲۲، ۲۳]. روش مورد استفاده در این پروژه LoRA [۲۴] است. ایده آن این است که به‌روزرسانی مورد نیاز برای یک ماتریس وزن، «رتبه پایین» دارد. برای وزن منجمد $W_0 \in \mathbb{R}^{d\times k}$، به‌جای یادگیری ΔW کامل، دو ماتریس کوچک $A \in \mathbb{R}^{r\times k}$ و $B \in \mathbb{R}^{d\times r}$ با $r \ll \min(d,k)$ آموزش داده می‌شوند و خروجی لایه چنین می‌شود:

[۵] instruction-following
[۶] exposure bias

$$h = W_0 x + \frac{\alpha}{r} BAx. \tag{۶-۲}$$

در آغاز، B صفر است تا مدل تطبیق‌یافته با مدل پایه یکسان باشد. پارامتر r رتبه و α ضریب مقیاس است. در این پروژه رتبه‌های 64 و 128 آزمایش شده‌اند. مزیت کلیدی LoRA برای این کار آن است که وزن‌های پایه منجمد می‌مانند و بنابراین یک آداپتر شکست‌خورده هرگز مدل پایه را خراب نمی‌کند و می‌توان آن را به‌سادگی برداشت.

۲-۵ رمزینه‌های صوتی عصبی و مدل‌های گفتاربه‌گفتار

۲-۵-۱ کوانتیزه‌سازی برداری باقی‌مانده

برای آن‌که یک مدل زبانی بتواند گفتار تولید کند، صوت باید به رشته‌ای از نشانه‌های گسسته تبدیل شود. **رمزینه صوتی عصبی** این کار را با یک خودکدگذار انجام می‌دهد که در گلوگاه آن یک «کوانتیزه‌ساز برداری باقی‌مانده»[۷] قرار دارد. نمونه‌های شاخص SoundStream [۲۵] و EnCodec [۲۶] هستند.

در کوانتیزه‌سازی باقی‌مانده، بردار نهفته z به‌صورت پی‌درپی تقریب زده می‌شود. اگر Q_i کتاب رمز iام باشد، با $r_0 = z$ داریم:

$$q_i = Q_i(r_{i-1}), \qquad r_i = r_{i-1} - q_i, \qquad \hat{z} = \sum_{i=1}^{N_q} q_i. \tag{۷-۲}$$

کتاب رمز نخست، اطلاعات درشت و بیشتر «معنایی» را حمل می‌کند و کتاب‌های رمز بعدی جزئیات «آوایی» را می‌افزایند. این سلسله‌مراتب دلیل آن است که در آموزش مدل‌های گفتاری، برای زیان کتاب رمز نخست ضریب بزرگ‌تری در نظر گرفته می‌شود؛ همین ضریب در یکی از آزمایش‌های این پروژه عامل تغییر بوده است.

۲-۵-۲ مدل‌سازی زبانی روی نشانه‌های صوتی

با گسسته‌شدن صوت، می‌توان همان ماشین مدل‌سازی زبانی را روی نشانه‌های صوتی اعمال کرد؛ این ایده در AudioLM [۲۷] و VALL-E [۲۸] به کار رفته است. چالش اصلی آن است که هر گام زمانی نه یک

[۷] Residual Vector Quantizer (RVQ)

نشانه، بلکه N_q نشانه (یکی برای هر کتاب رمز) دارد. راه‌حل «ترانسفورمر کوانتیزه‌سازی باقی‌مانده»[۸] است: یک ترانسفورمر بزرگ «زمانی» روی محور زمان کار می‌کند و یک ترانسفورمر کوچک «عمقی» در هر گام زمانی، N_q نشانه را به‌صورت خودرگرسیو تولید می‌کند [۲۹].

۲-۵-۳ معماری Moshi و «تک‌گویی درونی»

مدل Moshi [۱] گفت‌وگو را به‌صورت گفتاربه‌گفتار مدل می‌کند و سه ویژگی آن برای این پروژه اهمیت دارد.

نخست، **رمزینه Mimi**: یک رمزینه صوتی جویباری که بازنمایی معنایی را با بازنمایی آوایی در کتاب‌های رمز باقی‌مانده تلفیق می‌کند و با گام زمانی 80 میلی‌ثانیه کار می‌کند.

دوم، **جریان‌های موازی**: مدل به‌طور هم‌زمان دو جریان صوتی را مدل می‌کند، یکی گفتار خودش و دیگری گفتار کاربر. به همین دلیل مفهوم «نوبت» صریح حذف می‌شود و هم‌پوشانی، وقفه و بازخورد کلامی به‌طور طبیعی در مدل جای می‌گیرند. این ویژگی، همان چیزی است که Moshi را به یک نامزد طبیعی برای نیازمندی تمام‌دوطرفه بودن تبدیل می‌کند.

سوم، **تک‌گویی درونی**[۹]: پیش از تولید نشانه‌های صوتی هر گام، مدل نشانه‌های «متنی» هم‌ترازشده با زمان را پیش‌بینی می‌کند. این متن میانی کیفیت زبانی گفتار تولیدی را به‌طور محسوس بهبود می‌دهد. پیامد آن برای عیب‌یابی این است که می‌توان زبان متنی و زبان صوتی را جداگانه پایش کرد؛ در فصل ۵ از همین تفکیک برای نشان‌دادن محل شکست مسیر مستقیم استفاده شده است.

نسخه‌ای از این مدل که در این پروژه به کار رفته Moshika است؛ یک مدل هفت‌میلیاردپارامتری با صدای زنانه، 32 لایه ترانسفورمر، بعد نهفته 4096 و 16 کتاب رمز صوتی که هشت مورد از آن‌ها در ترانسفورمر عمقی پیش‌بینی می‌شوند.

۲-۶ تمام‌دوطرفه بودن و نوبت‌گیری

در گفت‌وگوی انسانی، نوبت‌گیری فرایندی دقیق و سریع است. کار کلاسیک سازمان نوبت نشان داد که فاصله میان نوبت‌ها کوتاه و منظم است [۳۰]؛ مرورهای مهندسی بعدی، مقدار متعارف این فاصله را در حدود دودهم ثانیه گزارش کرده‌اند [۳۱].

[۸] RQ-Transformer
[۹] Inner Monologue

از دید مهندسی، سه سطح از قابلیت را باید تفکیک کرد:

- **نیم‌دوطرفه**: سامانه در هنگام پخش پاسخ به میکروفون گوش نمی‌دهد. کاربر باید منتظر بماند.
- **تمام‌دوطرفه با کنترل بیرونی**: میکروفون در هنگام پخش فعال است و یک مؤلفه «جداگانه» درباره توقف پخش تصمیم می‌گیرد. این همان معماری‌ای است که در این پروژه پیاده و ارزیابی شده است.
- **تمام‌دوطرفه ذاتی**: خود مدل مولد، جریان کاربر و جریان خودش را هم‌زمان مدل می‌کند و نوبت‌گیری بخشی از توزیع آموخته‌شده است؛ مانند Moshi.

در سه رخداد تعاملی که در این نوشتار برچسب‌گذاری می‌شوند تمایز زیر برقرار است: «وقفه» زمانی است که گوینده دوم آغاز به سخن می‌کند و گفتار او ادامه می‌یابد و نوبت را می‌گیرد؛ «بازخورد کلامی» یک اظهار کوتاه تأییدی است که نوبت را نمی‌گیرد؛ و «نوبت پاک» حالتی است که گوینده دوم تنها پس از پایان گفتار گوینده اول آغاز می‌کند.

۲-۷ طبقه‌بندی با تقویت گرادیانی

آشکارساز وقفه این پروژه از یک **مدل تقویت گرادیانی درختی** استفاده می‌کند [۳۲] که در کتابخانه scikit-learn [۳۳] پیاده‌سازی شده است. این روش یک مدل جمعی می‌سازد که در آن هر درخت جدید، گرادیان منفی زیان مدل فعلی را برازش می‌کند:

$$F_m(x) = F_{m-1}(x) + \nu\, h_m(x), \tag{۸-۲}$$

که در آن h_m درخت تازه و ν نرخ یادگیری است. انتخاب این خانواده مدل سه دلیل دارد: تعریف پروژه صریحاً یک ماژول مبتنی بر ویژگی‌های دست‌ساز را خواسته است؛ استنتاج آن روی پردازنده مرکزی در بودجه چندمیلی‌ثانیه‌ای هر گام صوتی جای می‌گیرد؛ و با شمار محدود رخدادهای آموزشی، مدل‌های درختی از شبکه‌های عصبی عمیق پایدارترند.

۲-۸ سنجه‌ها و مفاهیم آماری ارزیابی

۲-۸-۱ نرخ خطای واژه و نویسه

فاصله **لِونشتاین** [۳۴] کمینه شمار عملیات درج، حذف و جانشینی لازم برای تبدیل یک رشته به رشته دیگر است. بر پایه آن، «نرخ خطای واژه» و «نرخ خطای نویسه» تعریف می‌شوند. در این نوشتار دو شکل تجمیع گزارش می‌شود. شکل «خرد» که مجموع ویرایش‌ها را بر مجموع طول مرجع‌ها تقسیم می‌کند:

$$\mathrm{WER}_{\mathrm{micro}} = \frac{\sum_i d\big(\hat{w}^{(i)}, w^{(i)}\big)}{\sum_i \big|w^{(i)}\big|}, \tag{۹-۲}$$

و شکل «کلان» که میانگین ساده نرخ خطای هر نمونه است. برای فارسی، تعریف مرز واژه اهمیت دارد: در این پروژه نشانه‌های واژه با فاصله سفید جدا می‌شوند و نیم‌فاصله نیز مرز به شمار می‌آید. نشانه‌های نویسه، نقاط کد یونی‌کد بدون احتساب فاصله سفید و نیم‌فاصله‌اند. همین تعریف باعث می‌شود نرخ خطای واژه در فارسی بسیار سخت‌گیرانه‌تر از نرخ خطای نویسه باشد؛ نکته‌ای که در فصل ۶ تفسیر می‌شود.

۲-۸-۲ سنجه‌های آشکارساز

برای رخداد دوکلاسه «وقفه در برابر غیروقفه»، ماتریس درهم‌ریختگی چهار مقدار مثبت درست، مثبت نادرست، منفی درست و منفی نادرست را می‌دهد. از آن‌ها «دقت»، «امتیاز F1» کلاس وقفه، «نرخ پذیرش نادرست»[۱۰] و «نرخ رد نادرست»[۱۱] محاسبه می‌شوند. در سامانه‌های تمام‌دوطرفه این دو نرخ خطا هم‌ارز نیستند: پذیرش نادرست باعث می‌شود پاسخ سامانه بی‌دلیل قطع شود، در حالی که رد نادرست باعث می‌شود سامانه به وقفه کاربر بی‌اعتنا بماند.

۲-۸-۳ فاصله اطمینان و همبستگی گروهی

برای نسبت‌ها، فاصله اطمینان **ویلسون** [۳۵] گزارش می‌شود که برخلاف تقریب نرمال ساده، برای نمونه‌های کوچک و نسبت‌های نزدیک به مرز نیز معتبر می‌ماند.

نکته مهم‌تر آن است که رخدادهای برگرفته از یک نشست گفتاری «مستقل» نیستند؛ گوینده، شرایط آکوستیکی و سبک گفت‌وگو میان آن‌ها مشترک است. بنابراین یک فاصله اطمینان در سطح رخداد،

[۱۰] False Accept Rate (FAR)
[۱۱] False Reject Rate (FRR)

عدم‌قطعیت واقعی را کم‌برآورد می‌کند. راه‌حل به‌کاررفته در این پروژه «خودراه‌انداز بلوکی در سطح نشست» است: در هر تکرار بازنمونه‌گیری، «نشست»ها با جای‌گذاری انتخاب می‌شوند و نه رخدادهای تک‌تک [۳۶]. در فصل ۵ هر دو فاصله گزارش شده‌اند تا اثر این تفاوت دیده شود.

۲-۸-۴ تفکیک گروهی داده

اگر دو بخش از یک نشست گفتاری واحد در مجموعه آموزش و مجموعه آزمون قرار بگیرند، مدل می‌تواند گوینده یا موضوع را به‌خاطر بسپارد و نتیجه آزمون خوش‌بینانه شود. برای پرهیز از این «نشت گروهی»، در این پروژه واحد تفکیک «شناسه نشست منبع» است: همه جفت‌های برآمده از یک نشست، به‌طور کامل در یک و تنها یک بخش قرار می‌گیرند. تخصیص با درهم‌سازی قطعی شناسه نشست انجام می‌شود تا تفکیک بازتولیدپذیر باشد.

۲-۸-۵ داوری خودکار با مدل زبانی

سنجش کیفیت معنایی پاسخ گفت‌وگو با سنجه‌های سطح رشته ممکن نیست، زیرا برای یک پرسش، پاسخ‌های درست متعددی وجود دارد. یک جانشین متعارف، استفاده از یک مدل زبانی بزرگ به‌عنوان «داور» است [۳۷]. در این روش، پاسخ نامزد و پاسخ‌های مقایسه‌ای به‌صورت «دوسوکور» و با ترتیب تصادفی‌شده به داور داده می‌شوند و داور بر پایه یک سنجه‌نامه از پیش تعیین‌شده امتیاز می‌دهد.

محدودیت‌های شناخته‌شده این روش عبارت‌اند از اریبی نسبت به ترتیب ارائه، اریبی نسبت به طول پاسخ، و اریبی نسبت به پاسخ‌های تولیدشده توسط مدل‌های هم‌خانواده با داور. در این پروژه سه اقدام برای کاهش این اثرها انجام شده است: دوسوکورسازی ترتیب، کدگشایی قطعی داور با دمای صفر، و تکرار هر فراخوانی و گزارش نرخ توافق. با این حال، همان‌طور که در فصل ۶ تأکید شده است، این سنجه یک «تقریب خودکار» است و جانشین ارزیابی انسانی نمی‌شود؛ به‌ویژه آن‌که در این پروژه داور و نامزد از یک خانواده مدل‌اند.

۲-۸-۶ سنجه‌های تأخیر

دو سنجه زمانی در این نوشتار تعریف می‌شوند:

- $T_{\text{first_audio}}$: زمان از پایان گفتار کاربر تا نخستین نمونه صوتی «شنیدنی» پاسخ. مقدار رسمی این سنجه باید از سمت کارخواه گزارش شود، زیرا تنها مرورگر می‌داند که منبع صوت واقعاً زمان‌بندی شده است.

- $T_{\text{barge_in}}$: زمان از آغاز آوایی گفتار وقفه‌ای کاربر تا لحظه‌ای که پخش پاسخ «واقعاً» متوقف می‌شود؛ این مقدار نیز به تأیید کارخواه نیاز دارد.

نکته روشمند مهم آن است که «زمان تولید کامل پاسخ در سمت سرور»، سنجه $T_{\text{first_audio}}$ نیست. زمان تولید سرور یک اندازه‌گیری سودمند برای عیب‌یابی است، اما نه شرط پذیرش تأخیر. این تفکیک در فصل ۵ با دقت رعایت شده است.

فصل ۳

کارهای پیشین

این فصل پیشینه پژوهشی مرتبط را در چهار محور بررسی می‌کند: سامانه‌های گفت‌وگوی گفتاری آبشاری در برابر سرتاسری، مدل‌های گفتاربه‌گفتار متن‌باز و قابلیت‌های تمام‌دوطرفه آن‌ها، منابع گفتاری زبان فارسی، و پیشینه تشخیص وقفه و نوبت‌گیری. در پایان فصل، جایگاه این پروژه در برابر کارهای پیشین مشخص می‌شود.

۳-۱ از زنجیره آبشاری به مدل سرتاسری

معماری متعارف سامانه‌های گفت‌وگوی گفتاری، زنجیره‌ای از چهار مؤلفه مستقل است: تشخیص فعالیت گفتاری، بازشناسی گفتار، یک موتور گفت‌وگوی متنی و تبدیل متن به گفتار. مزیت این معماری، ماژولار بودن آن است: هر مؤلفه را می‌توان جداگانه بهبود داد، اشکال‌زدایی کرد و با بهترین مدل موجود برای آن زبان جانشین ساخت. برای زبان‌های کم‌منبع، این ماژولار بودن مزیت تعیین‌کننده‌ای است، زیرا برای هر مؤلفه احتمال یافتن یک مدل فارسی قابل قبول بیشتر از یافتن یک مدل گفتاربه‌گفتار فارسی است.

در برابر آن، نویسندگان Moshi [۱] سه ایراد بنیادی برای معماری آبشاری برمی‌شمارند. نخست، انباشت تأخیر در زنجیره که فاصله میان دو نوبت گفت‌وگو را به چند ثانیه می‌رساند. دوم، ازدست‌رفتن اطلاعات غیرزبانی: چون متن، تنها واسطه میان ورودی و خروجی است، عاطفه، لحن و صداهای غیرگفتاری که معنا را تغییر می‌دهند از میان می‌روند. سوم، وابستگی به بخش‌بندی صریح گفتار به نوبت‌ها، که هم‌پوشانی و وقفه و اظهارهای کوتاه تأییدی را نمی‌تواند نمایش دهد.

مشاهدات فصل ۵ هر دو سوی این استدلال را پشتیبانی می‌کنند. ایراد تأخیر در اندازه‌گیری‌های مسیر آبشاری دیده می‌شود: زمان تولید کامل پاسخ در زنجیره آبشاری، حتی روی سخت‌افزار پرتوان، در حدود چند ثانیه است و برای ورودی‌های بلند رشد می‌کند (بخش ۵-۳). در همان حال، مزیت ماژولار بودن نیز دیده می‌شود: تنها همین معماری بود که در بازه زمانی پروژه به یک سامانه فارسی کارکردی و قابل ارزیابی رسید.

۳-۲ مدل‌های گفتاربه‌گفتار متن‌باز

۳-۲-۱ خانواده Mini-Omni

مدل Mini-Omni2 [۵]، که در تعریف پروژه به‌عنوان نمونه مدل پایه نام برده شده است، یک دستیار چندوجهی بر پایه Qwen2-0.5B است که کدگذارهای Whisper و CLIP را برای ورودی صوتی و تصویری به کار می‌گیرد و با راهبرد «تولید موازی با تأخیر متن‌راهنما» گفتار تولید می‌کند. برای مسئله ما دو ویژگی آن اهمیت دارد: نخست آن‌که سازوکار وقفه در آن «فرمان‌محور» است و نه یک تصمیم آوایی پیوسته؛ دوم آن‌که این پروژه آموزش‌دهنده کامل و رسمی گفتاربه‌گفتار منتشر نکرده است، و بنابراین تطبیق آن با فارسی مستلزم بازنویسی زنجیره آموزش از صفر بود.

۳-۲-۲ SpeechGPT و واحدهای گسسته گفتار

SpeechGPT [۳۸] از نخستین مدل‌های زبانی بزرگی است که گفتار را مستقیماً به‌صورت واحدهای گسسته در واژگان خود می‌پذیرد و تولید می‌کند، به‌جای آن‌که گفتار را از راه بازشناس و گفتارساز جداگانه به متن تبدیل کند. این مدل در سه مرحله آموزش دید: پیش‌آموزش برای سازگاری با وجه گفتاری، تنظیم دستوری میان‌وجهی، و تنظیم دستوری «زنجیره وجه‌ها» که در آن مدل نخست پاسخ را به متن می‌اندیشد و سپس آن را به واحدهای گفتار برمی‌گرداند. ایده تکیه بر متن میانی درون یک مدل یکپارچه، همان چیزی است که در Moshi به‌صورت «تک‌گویی درونی» هم‌زمان با صوت پیاده شده است. SpeechGPT اما نوبتی و غیرجریانی است: پیش از پاسخ، کل گفته کاربر را می‌گیرد و تمام‌دوطرفه نیست؛ بنابراین برای هدف تأخیر و وقفه این پروژه مدل پایه مناسبی نبود.

۳-۲-۳ خانواده LLaMA-Omni

نسخه نخست این خانواده [۳۹] از یک کدگشای گفتاری غیرخودرگرسیو برای کاهش تأخیر استفاده می‌کرد. LLaMA-Omni2 [۶] مجموعه‌ای از مدل‌های گفتاری ماژولار از 0.5 تا 14 میلیارد پارامتر است که بر پایه مدل‌های Qwen2.5-Instruct ساخته شده‌اند، کدگذار Whisper را برای ورودی و یک کدگشای گفتاری جویباری خودرگرسیو الهام‌گرفته از CosyVoice 2 [۴۰] را برای خروجی به کار می‌برند. این مدل با تنها 200 هزار نمونه گفت‌وگوی چندنوبتی آموزش دیده و از GLM-4-Voice [۴۱] که بر میلیون‌ها ساعت گفتار آموزش دیده بود پیشی گرفته است.

این مدل در آغاز پروژه گزینه اصلی بود، زیرا اندازه 0.5 میلیارد پارامتری آن در بودجه حافظه هدف جای می‌گرفت و پشته آن (کدگذار Whisper به اضافه Qwen2.5) با ابزارهای در دسترس هم‌خوان بود. اما مخزن منتشرشده تنها استنتاج را پوشش می‌دهد. تلاش نخست این پروژه برای ساخت یک زنجیره آموزش از این معماری، همان‌طور که در بخش ۴-۱ شرح داده می‌شود، به مصنوعی رسید که در واقع بازسازی ورودی را می‌آموخت و نه تولید پاسخ گفت‌وگویی؛ این تجربه، انگیزه اصلی حرکت به‌سوی یک آموزش‌دهنده رسمی شد.

۳-۲-۴ Freeze-Omni و رویکرد مدل منجمد

Freeze-Omni [۲] راهبرد متفاوتی دارد: وزن‌های مدل زبانی متنی در سراسر آموزش «منجمد» می‌مانند و تنها کدگذار گفتاری ورودی و کدگشای گفتاری خروجی آموزش می‌بینند. این طراحی دو مزیت مهم دارد که برای شرایط کم‌منبع بسیار مرتبط است: هوشمندی مدل پایه دست‌نخورده می‌ماند و مسئله «فراموشی فاجعه‌بار» پیش نمی‌آید، و آموزش با داده و منابع محاسباتی بسیار کمتری امکان‌پذیر می‌شود. قابلیت تمام‌دوطرفه نیز در آن با افزودن یک لایه طبقه‌بندی حالت روی آخرین لایه مدل زبانی به دست می‌آید که پیش‌بینی می‌کند آیا کاربر گفت‌وگو را قطع کرده است یا نه.

از دید پس‌نگرانه، این رویکرد یکی از امیدبخش‌ترین گزینه‌ها برای فارسی است و در فصل ۷ به‌عنوان کار آینده پیشنهاد شده است؛ در زمان تصمیم‌گیری این پروژه، آموزش‌دهنده رسمی و در دسترس آن برای یک زبان جدید فراهم نبود.

۳-۲-۵ Qwen2.5-Omni و معماری «اندیشمند و گوینده»

Qwen2.5-Omni [۴] یک مدل سرتاسری چندوجهی است که با معماری «اندیشمند و گوینده» تولید هم‌زمان متن و گفتار را ممکن می‌سازد: بخش اندیشمند یک مدل زبانی است که متن تولید می‌کند و بخش گوینده یک مدل خودرگرسیو دومسیره است که مستقیماً از بازنمایی‌های نهفته اندیشمند، نشانه‌های صوتی می‌سازد. این مدل برای پروژه ما به دو دلیل کنار گذاشته شد: نسخه هفت‌میلیاردپارامتری آن به حافظه‌ای به‌مراتب بیش از بازه هدف 12 تا 24 گیگابایت نیاز دارد، و فهرست‌های منتشرشده ورودی و خروجی گفتاری آن فارسی را شامل نمی‌شوند.

۳-۲-۶ Moshi و انتخاب نهایی مسیر مستقیم

از میان مدل‌های بررسی‌شده، Moshi [۱] تنها موردی بود که هر سه شرط لازم برای این پروژه را برآورده می‌کرد: قابلیت تمام‌دوطرفه «ذاتی» از طریق مدل‌سازی موازی دو جریان صوتی، وزن‌های متن‌باز، و مهم‌تر از همه یک «آموزش‌دهنده رسمی تطبیق کم‌پارامتر» که به‌طور مستقیم از سوی سازندگان مدل منتشر شده بود [۷]. همان‌طور که در بخش ۲-۵ توضیح داده شد، سازوکار «تک‌گویی درونی» این مدل امکان پایش جداگانه زیان متنی و زیان صوتی را نیز فراهم می‌کند که برای عیب‌یابی آزمایش‌های ناموفق ارزش عملی داشت.

پیشینه نزدیک‌تر به این ایده، dGSLM [۴۲] است که مدل‌سازی مولد گفت‌وگوی گفتاری را با دو جریان موازی و بدون واسطه متنی معرفی کرد و نشان داد که پدیده‌هایی مانند هم‌پوشانی و بازخورد کلامی را می‌توان به‌صورت آموخته‌شده بازتولید کرد.

۳-۲-۷ PersonaPlex و کنترل نقش در مدل تمام‌دوطرفه

PersonaPlex [۴۳] یک مدل گفتاربه‌گفتار تمام‌دوطرفه بر پایه معماری Moshi است که با پرامپت ترکیبی متنی و نمونه صوتی، نقش و صدای دستیار را شرطی می‌کند. وزن‌های متن‌باز آن منتشر شده‌اند و قابلیت تمام‌دوطرفه ذاتی را حفظ می‌کنند. برای این پروژه اما دو محدودیت تعیین‌کننده داشت: انتشار آن انگلیسی‌محور است و فارسی در آن پشتیبانی نشده است، و سخت‌افزار آزمون‌شده مستند آن خارج از بازه 12 تا 24 گیگابایت نیازمندی ن۶ است. همچنین یک آموزش‌دهنده رسمی برای تطبیق آن با زبانی جدید، در زمان تصمیم‌گیری این پروژه، در دسترس نبود. بنابراین به‌عنوان گزینه مقایسه در نظر گرفته شد و برای مسیر مستقیم انتخاب نشد.

۳-۳ منابع گفتاری زبان فارسی

برای فارسی، وضعیت منابع در سه حوزه نامتقارن است.

در **بازشناسی گفتار**، مدل‌های قابل استفاده وجود دارند. پیکره چندزبانه Common Voice [۴۴] بخش فارسی دارد، و مدل‌های بومی‌سازی‌شده بر پایه معماری Conformer در بستر NeMo [۱۵] به کیفیت قابل قبولی رسیده‌اند. سرویس بازشناسی به‌کاررفته در این پروژه از همین دسته است.

در **تبدیل متن به گفتار**، شاخص‌ترین منبع عمومی ManaTTS [۳] است: بزرگ‌ترین پیکره عمومی تک‌گوینده فارسی با حدود 86 ساعت صوت با بسامد نمونه‌برداری 44.1 کیلوهرتز و مجوز آزاد، همراه با یک زنجیره پردازش متن‌باز شامل ابزار بخش‌بندی جمله و یک روش هم‌ترازی اجباری طراحی‌شده برای زبان‌های کم‌منبع. مدل صوتی فارسی مورد استفاده در این پروژه از همین منبع مشتق شده است. ParsVoice [۴۵] پیکره بزرگ‌تری از کتاب‌های گویای فارسی با چند هزار ساعت گفتار و صدها گوینده است که برای گفتارسازی چندگوینده ساخته شده و مدل XTTS تنظیم‌شده روی آن در فصل ۵ سنجیده شد.

پیشنهاده پروژه FarsTalk و Persian VoxCeleb را به‌عنوان نمونه پیکره فارسی نام می‌برد؛ در جست‌وجوی این پروژه پیکره منتشرشده‌ای با این نام‌ها یافت نشد. نزدیک‌ترین منبع مکالمه‌ای منتشرشده، «پیکره رونوشت‌های گفت‌وگوی فارسی» [۴۶] است: رونوشت حدود 20 ساعت گفت‌وگوی غیررسمی به گویش تهرانی، که صوت آن منتشر نشده است و بنابراین برای آموزش مدل گفتاری به کار نمی‌آید.

در **داده مکالمه‌ای تمام‌دوطرفه** اما شکاف جدی است. آنچه یک مدل تمام‌دوطرفه برای یادگیری نیاز دارد، گفتار دوطرفه طبیعی همراه با هم‌پوشانی، وقفه و بازخورد کلامی است. منابع فارسی موجود، عمدتاً تک‌گوینده و خوانشی‌اند و این پدیده‌ها را در بر ندارند. پیکره‌های تلفنی گفت‌وگویی فارسی در آرشیوهای پژوهشی موجودند اما مجوز محدود دارند و مقیاس آن‌ها کمتر از بازه 100 تا 200 ساعت مورد نظر تعریف پروژه است. همین شکاف است که ساخت مجموعه داده مشتق‌شده در فصل ۴ را ضروری کرد.

۴-۳ استنتاج جریانی کم‌تأخیر

سامانه گفتاری کم‌تأخیر باید هر جزء را «جریانی» اجرا کند، یعنی پیش از رسیدن کل ورودی، خروجی را آغاز کند. سنجه رایج سرعت، **ضریب بی‌درنگی** (RTF) است: نسبت زمان پردازش به طول صوت؛ RTF کمتر از یک یعنی پردازش از پخش عقب نمی‌ماند. اما برای گفت‌وگو، RTF کافی نیست و آنچه کاربر حس می‌کند «تأخیر تا نخستین خروجی» است.

در **بازشناسی گفتار**، توجه کامل کدگذار به کل گفته نیاز دارد. راه رایج، توجه قطعه‌ای است: کدگذار هر قطعه را با زمینه محدودی از گذشته و نگاه کوتاهی به آینده پردازش می‌کند [۴۷]. کدگذار Conformer با حافظه نهان حالت [۴۸] زمینه گذشته و آینده را در آموزش نیز محدود می‌کند و فعال‌سازی‌های قطعه‌های پیشین را نگه می‌دارد تا استنتاج گام به گام با آموزش هم‌خوان باشد. در **مدل زبانی**، تولید توکن‌به‌توکن ذاتاً جریانی است؛ برای گفت‌وگوهای طولانی، پنجره لغزان روی حافظه نهان کلیدومقدار به‌همراه نگه‌داشتن چند توکن آغازین («چاهک توجه») پایداری را حفظ می‌کند [۴۹]. در **گفتارسازی**، تولید بندبه‌بند یا قطعه‌به‌قطعه اجازه می‌دهد پخش پیش از تولید کل پاسخ آغاز شود.

این پروژه از هر سه سطح بهره می‌گیرد اما با انتخاب‌هایی ساده‌تر (بخش ۴-۳): گفته‌های کاربر کوتاه‌اند و بازشناس CTC هر گفته را پس از تشخیص پایان آن در حدود 60 میلی‌ثانیه پردازش می‌کند؛ مدل زبانی جریانی با حافظه نهان پیشوند اجرا می‌شود؛ گفتارساز بند به بند کار می‌کند؛ و تشخیص پیش‌دستانه پایان گفتار کار را پیش از قطعی‌شدن پایان آغاز می‌کند.

۵-۳ تعامل سالمندان با دستیار صوتی

صدای سالمندان از نظر آوایی با صدای بزرگسالان جوان‌تر تفاوت دارد و این تفاوت به بازشناسی گفتار آسیب می‌زند: در یک مطالعه، نرخ خطای واژه برای گویندگان سالمند حدود 9 واحد درصد بیشتر بود و بسامد پایه، لرزش بسامد و دامنه و هماهنگی صدا میان دو گروه تفاوت معنادار داشت [۵۰]. همین الگو در پنل انسانی این پروژه نیز دیده شد: خطای نویسه بازشناس مستقر روی گویندگان سالمند 15.6 درصد در برابر 8.6 درصد برای دیگران بود (بخش ۵-۶).

در سوی کاربر، استقرار سه‌هفته‌ای یک بلندگوی هوشمند در خانه هفت سالمند کم‌آشنا با فناوری نشان داد که جست‌وجوی اطلاعات، به‌ویژه اطلاعات سلامت، پایدارترین کاربرد بود و اعتمادپذیری پاسخ صوتی برای آنان دغدغه جدی بود؛ یادآورها مفید تلقی می‌شدند اما به دلیل تردید در قابل اتکا بودنشان کمتر به کار رفتند [۵۱]. کارگاه‌های دیگری با سالمندان، هم فرصت‌ها و هم موانع تعامل صوتی را برشمردند [۵۲]. این یافته‌ها چند انتخاب طراحی این پروژه را توضیح می‌دهند: پاسخ کوتاه و ساده و صادق درباره محدودیت‌ها (پرامپت سالمندان)، تحمل مکث‌های طولانی‌تر در تشخیص پایان گفتار، گفتار کمی آهسته‌تر، و ارجاع به پزشک یا اورژانس در موضوعات پرخطر. اثر این انتخاب‌ها بر تجربه سالمندان را تنها مطالعه انسانی می‌تواند بسنجد.

۳-۶ تشخیص وقفه و نوبت‌گیری

پیشینه این حوزه دو شاخه دارد.

شاخه **کلاسیک** بر ویژگی‌های آوایی دست‌ساز و آشکارسازهای آماری استوار است. آشکارساز فعالیت گفتاری مبتنی بر مدل آماری [۸] نمونه مرجع این شاخه است. تشخیص وقفه در سامانه‌های تلفنی گفتاری سنتی نیز عملاً یک آشکارساز فعالیت گفتاری با آستانه محافظه‌کارانه بود؛ مشکل شناخته‌شده این سامانه‌ها آن بود که صدای بلندگو یا نویز محیط به‌اشتباه به‌عنوان وقفه شناخته می‌شد. مرور جامع سازوکارهای نوبت‌گیری در سامانه‌های گفت‌وگو و تعامل انسان و ربات در [۳۱] آمده است، که نشان می‌دهد نوبت‌گیری صرفاً یک مسئله تشخیص سکوت نیست و به نشانه‌های نوایی و نحوی وابسته است. مبنای زبان‌شناختی این موضوع به کار کلاسیک [۳۰] بازمی‌گردد که نشان داد فاصله میان نوبت‌ها در گفت‌وگوی انسانی به‌طور شگفت‌آوری کوتاه و منظم است.

شاخه **یادگیری‌شده** نوبت‌گیری را در خود مدل مولد جای می‌دهد. در Moshi و dGSLM هیچ آشکارساز جداگانه‌ای وجود ندارد و نوبت‌گیری بخشی از توزیع آموخته‌شده روی دو جریان موازی است. در Freeze-Omni یک راه میانی به کار رفته است: یک سر طبقه‌بندی سبک روی مدل زبانی، حالت گفت‌وگو را پیش‌بینی می‌کند.

تعریف پروژه صریحاً شاخه کلاسیک را خواسته است: یک ماژول بر پایه انرژی، زیروبمی و MFCC با هدف دقت بالای 80 درصد. پیاده‌سازی این پروژه همین مسیر را دنبال می‌کند، با این تفاوت روشمند که به‌جای آستانه‌گذاری دستی، یک طبقه‌بند تقویت گرادیانی روی بردار ویژگی پنجره متن آموزش می‌بیند و آستانه تصمیم آن تنها بر نشست‌های اعتبارسنجی انتخاب می‌شود.

برای برچسب‌گذاری خودکار رخدادهای تعاملی در داده ضبط‌شده، از **تفکیک گوینده** استفاده شده است. ابزارهای مرجع این حوزه pyannote.audio [۵۳] و روش‌های تفکیک چندمقیاسی با وزن‌دهی پویا [۵۴] هستند؛ سرویس تفکیک گوینده مورد استفاده در این پروژه از خانواده دوم است.

برای آموزش و سنجش آشکارساز در شرایط نزدیک به استقرار، گفتار با نویز و پاسخ اتاق افزوده می‌شود. پیکره‌های رایج این کار MUSAN [۵۵] (موسیقی، گفتار و نویز)، DEMAND [۵۶] (نویز چندکاناله محیط‌های گوناگون) و مجموعه پاسخ‌های اتاق و نویز OpenSLR [۵۷] هستند.

۳-۷ ارزیابی خودکار کیفیت گفت‌وگو

سنجش کیفیت پاسخ گفت‌وگو با سنجه‌های تطابق رشته‌ای معنادار نیست. رویکردی که در سال‌های اخیر مرجع شده است، به‌کارگیری یک مدل زبانی بزرگ به‌عنوان داور است. کار مرجع این حوزه [۳۷] نشان داد که داوری خودکار با مدل‌های قوی، همبستگی بالایی با ترجیح انسانی دارد، اما در همان کار اریبی‌های سامانه‌ای آن نیز مستند شده است: اریبی موقعیت، اریبی طول پاسخ و اریبی خودپسندی نسبت به خروجی مدل‌های هم‌خانواده.

این پروژه از همین روش به‌عنوان «تنها» سنجه معنایی در دسترس استفاده کرده است، اما با سه محدودسازی: دوسوکورسازی و تصادفی‌سازی ترتیب بازوها، کدگشایی قطعی، و تکرار هر فراخوانی داور با گزارش نرخ توافق. مهم‌تر آن‌که چون داور و نامزد در این پروژه از یک خانواده مدل‌اند، نتیجه صریحاً به‌عنوان یک «تقریب خودکار هم‌خانواده» برچسب‌گذاری شده و جانشین ارزیابی انسانی یا یک معیار مستقل شمرده نشده است. برای سنجش انسانی، پروتکل مرجع، امتیاز میانگین نظر بر پایه توصیه‌نامه ITU-T P.800 [۵۸] است که در این پروژه طراحی شد اما اجرا نشد.

۳-۸ جایگاه این پروژه

جدول ۳-۱ جایگاه این پروژه را در برابر کارهای پیشین خلاصه می‌کند.

ستون «بازه حافظه» به تناسب با بازه 12 تا 24 گیگابایت مورد نظر تعریف پروژه اشاره دارد و برای مسیر مستقیم این پروژه بر پایه حافظه اندازه‌گیری‌شده آموزش روی سخت‌افزار موجود گزارش شده است، نه یک اندازه‌گیری روی سخت‌افزار هدف.

از این مقایسه سه نکته برمی‌آید.

نخست، هیچ‌یک از مدل‌های سرتاسری موجود از فارسی پشتیبانی نمی‌کند؛ بنابراین هر مسیر مستقیمی ناچار از تطبیق است و تطبیق نیز به آموزش‌دهنده رسمی نیاز دارد. تنها Moshi این شرط را به‌طور کامل برآورده می‌کرد. PersonaPlex نیز تمام‌دوطرفه ذاتی دارد اما انگلیسی‌محور است و آموزش‌دهنده تطبیق آن برای فارسی در دسترس نبود.

دوم، مدل‌هایی که قابلیت تمام‌دوطرفه ذاتی دارند، در بازه حافظه هدف جای نمی‌گیرند. این تعارض میان نیازمندی ن۲ و ن۶ در تعریف پروژه، یک محدودیت ساختاری است و نه یک نقص پیاده‌سازی.

سوم، سهم متمایز این پروژه در جای دیگری است. کارهای پیشین، «مدل» منتشر می‌کنند؛ این پروژه، برای یک زبان کم‌منبع مشخص، «یک زنجیره داده و یک چارچوب ارزیابی شواهدمحور» می‌سازد و نشان می‌دهد کدام ادعاها با این شواهد قابل اثبات و کدام‌ها غیرقابل اثبات‌اند. به‌طور خاص، نتیجه منفی مسیر

جدول ۳-۱: مقایسه این پروژه با کارهای پیشین از نظر قابلیت‌های مورد نیاز تعریف پروژه

کار	تمام دوطرفه	وزن متن‌باز	آموزش‌دهنده رسمی	پشتیبانی فارسی	بازه حافظه
Mini-Omni2	فرمان‌محور	دارد	ندارد	ندارد	مناسب
LLaMA-Omni2	ندارد	دارد	ندارد	ندارد	مناسب
Freeze-Omni	دارد	دارد	جزئی	ندارد	مناسب
Qwen2.5-Omni	دارد	دارد	ندارد	ندارد	نامناسب
Moshi	ذاتی	دارد	دارد	ندارد	نامناسب
PersonaPlex	ذاتی	دارد	جزئی	ندارد	نامناسب
این پروژه، مسیر آبشاری	کنترل بیرونی	دارد	بی‌نیاز	دارد	مناسب
این پروژه، مسیر مستقیم	ذاتی	دارد	دارد	ناموفق	نامناسب

مستقیم، که در بخش ۵-۹ گزارش شده است، یک یافته قابل استناد برای پژوهشگران بعدی است: کاهش زیان تحت تحمیل معلم، در تطبیق کم‌پارامتر یک مدل گفتاربه‌گفتار به زبانی جدید، معیار کافی برای انتخاب چک‌پوینت نیست.

فصل ۴

روش پیشنهادی و پیاده‌سازی

این فصل، ساختار سامانه و روش ساخت داده و طراحی آزمایش‌ها را شرح می‌دهد. ترتیب مطالب چنین است: نخست تلاش اولیه و درسی که از آن گرفته شد؛ سپس زنجیره ساخت مجموعه داده؛ آنگاه معماری سامانه آبشاری تحویل‌شده و ماژول تشخیص وقفه و بستر انتقال تمام‌دوطرفه؛ سپس طراحی آزمایش‌های مسیر مستقیم؛ و در پایان روش کاری شواهدمحوری که چارچوب همه ارزیابی‌های فصل بعد است.

۴-۱ تلاش اولیه و بازنگری در معماری

نخستین پیاده‌سازی پروژه بر پایه معماری LLaMA-Omni2 بنا شد: یک کدگذار گفتاری منجمد Whisper، یک لایه تصویرگر آموزش‌پذیر، یک مدل زبانی Qwen2.5-0.5B [۵۹] با آداپتر LoRA، و سرهای جداگانه برای بازشناسی و تولید نشانه‌های گفتاری. این مصنوع آموزش دید و زیان آن کاهش یافت.

یک ممیزی درونی کد پیش از هرگونه گزارش نتیجه، سه اشکال بنیادی را آشکار کرد که ثبت آن‌ها برای صداقت روشمند این نوشتار ضروری است:

- مدل زبانی در تابع پیش‌رو مشارکت نداشت؛ بنابراین آنچه آموزش می‌دید یک شبکه نگاشت صوتی بود و نه یک مدل زبانی گفت‌وگومحور.
- هدف بازشناسی از درهم‌سازی‌های تصادفی‌شده در هر فرایند استفاده می‌کرد و در نتیجه برچسب‌های آموزشی میان اجراها ناپایدار بودند.
- هدف تولید گفتار، «بازسازی همان اظهار ورودی» بود و نه تولید یک پاسخ گفت‌وگویی؛ و برای شنیدن خروجی، موتور گفتاری بیرونی مسیر مصنوع آموخته‌شده را دور می‌زد.

نتیجه‌گیری این ممیزی صریح بود: آن مصنوع یک مدل گفتاربه‌گفتار نبود و نمی‌توانست به‌عنوان چنین چیزی گزارش شود. این تجربه دو تصمیم تعیین‌کننده را رقم زد. نخست، سرویس‌دهی سامانه به‌طور کامل به یک زنجیره آبشاری با مؤلفه‌های واقعی و قابل آزمون منتقل شد. دوم، برای مسیر مستقیم تنها مدلی پذیرفته شد که «آموزش‌دهنده رسمی» داشته باشد، تا هدف آموزشی و زنجیره داده به‌جای بازنویسی محلی، از سوی سازندگان مدل تعیین شود. این دو تصمیم، شکل نهایی پروژه را ساختند.

۴-۲ ساخت مجموعه داده مکالمه فارسی

۴-۲-۱ منبع و راهبرد

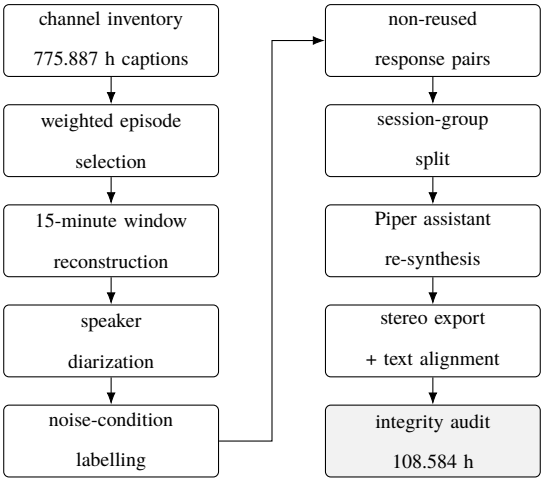
از آنجا که پیکره عمومی فارسی با برچسب وقفه در دسترس نبود (بخش ۳-۳)، مجموعه داده این پروژه از یک آرشیو داخلی محتوای گفتاری فارسی مشتق شد. این آرشیو شامل برنامه‌های گفت‌وگویی بلند از چهار کانال با سبک‌های متفاوت است. استفاده پژوهشی داخلی از این منابع با تأیید استاد راهنما ثبت شده است؛ این تأیید مجوز بازنشر صوت یا زیرنویس خام نیست و هیچ داده محدودشده‌ای در مخزن کد قرار نگرفته است.

نکته روشمندی که در میانه کار اصلاح شد ارزش ثبت دارد. در طرح نخست، برچسب متنی هر بازه با اجرای مجدد سرویس بازشناسی گفتار تولید می‌شد. اما سرویس بازشناسی مورد استفاده، خودش پیش‌تر روی زیرنویس‌های همین کانال‌ها تنظیم شده بود. بنابراین استفاده از آن به‌عنوان «معلم» یک «حلقه دوری» می‌ساخت و خطاهای سامانه‌ای خودش را به‌عنوان برچسب مرجع تثبیت می‌کرد. پس از شناسایی این مشکل، برچسب متنی به زیرنویس‌های اصلی منبع تغییر یافت و سرویس بازشناسی تنها در نقش مؤلفه زمان اجرا و ابزار سنجش باقی ماند.

۴-۲-۲ مراحل زنجیره

شکل ۴-۱ مراحل زنجیره ساخت داده را نشان می‌دهد.

موجودی و انتخاب. موجودی قابل اندازه‌گیری آرشیو برابر 775.887 ساعت زیرنویس در 1,442 برنامه بلند بود. یک انتخاب وزن‌دار و «قطعی» روی این موجودی اجرا شد که هدف آن ایجاد تعادل میان کانال‌ها و پرهیز از تسلط یک سبک گفتاری بود. خروجی این مرحله 309 برنامه و 1,129 پنجره با مجموع 219.946 ساعت نامزد است.



شکل ۴-۱: مراحل زنجیره ساخت مجموعه داده مکالمه فارسی. هر مرحله یک فرمان مستقل با خروجی ممیزی‌پذیر است.

بازسازی پنجره. برنامه‌های منبع به‌صورت قطعه‌های کوچک ذخیره شده بودند. برای آن‌که ساختار گفت‌وگو حفظ شود، قطعه‌ها به پنجره‌های پیوسته 15 دقیقه‌ای بازسازی شدند. این طول به‌قدری بلند است که چند نوبت کامل گفت‌وگو را در بر بگیرد.

تفکیک گوینده. هر پنجره به سرویس تفکیک گوینده داده شد که مرزهای زمانی و شناسه گوینده هر بازه گفتار و همچنین بازه‌های هم‌پوشانی را برمی‌گرداند. مجموع بازه‌های چندگویندگی طبقه‌بندی‌شده به‌صورت خودکار 207.154 ساعت است.

برچسب‌گذاری شرایط نویز. برای هر بازه، یک برچسب شرایط نویز بر پایه تخمین نسبت سیگنال به نویز افزوده شد تا در تحلیل‌های بعدی بتوان اثر شرایط آکوستیکی را جدا کرد.

چرا هم‌ترازی اجباری MFA به کار نرفت. پیشنهاده برای نشان‌گذاری نوبت‌ها و هم‌پوشانی‌ها Montreal Forced Aligner [۶۰] را پیشنهاد می‌کند. هم‌ترازی اجباری، متن معلوم را درون صوت «یک گوینده» جای‌گذاری می‌کند، اما نمی‌گوید کدام گوینده چه زمانی سخن می‌گوید یا دو صدا کجا روی هم افتاده‌اند؛ برای همین، مرز نوبت‌ها و بازه‌های هم‌پوشانی از تفکیک گوینده آمد و متن هر نوبت از زمان‌بندی زیرنویس. جایی که زمان‌بندی واژه‌به‌واژه لازم بود، یعنی گفتار دستیار در نسخه هفتم مسیر مستقیم (بخش ۴-۵-۳)، به هم‌تراز آماری نیازی نبود: آن گفتار را خود Piper ساخته بود و زمان هر واج از هم‌ترازی آوابه‌نمونه همان گفتارساز در یک بازسازی هم‌سان برداشته شد.

۴-۲-۳ استخراج جفت پاسخ و برچسب تعامل

از بازه‌های تفکیک‌شده، جفت‌های «گفتار کاربر و پاسخ گوینده بعدی» استخراج می‌شود. نخست بازه‌های متوالی یک گوینده که فاصله آن‌ها از نیم‌ثانیه کمتر است در هم ادغام می‌شوند تا یک نوبت کامل به دست آید. سپس برای هر دو نوبت متوالی از دو گوینده متفاوت، یک جفت ساخته می‌شود.

قید مهم این مرحله «عدم بازاستفاده» است: هر بازه از صوت منبع تنها در یک جفت ظاهر می‌شود. این قید از آن جهت لازم است که بازاستفاده، شمار ساعت گزارش‌شده را به‌طور مصنوعی بالا می‌برد و در آموزش نیز به‌صورت تکرار داده عمل می‌کند.

برای هر جفت، یک برچسب تعامل خودکار نیز محاسبه می‌شود. اگر نوبت دوم پیش از پایان نوبت اول آغاز شود، هم‌پوشانی وجود دارد. در این حالت، اگر نوبت دوم کوتاه باشد و پیش از پایان نوبت اول تمام شود، برچسب «بازخورد کلامی» و در غیر این صورت برچسب «وقفه» داده می‌شود. اگر نسبت‌دهی هم‌پوشانی به گوینده مشخص نباشد، برچسب «هم‌پوشانی بی‌نسبت» ثبت می‌گردد.

خروجی این مرحله 6,754 جفت با 123.796 ساعت صوت منبع است. همچنین 770 نامزد محافظه‌کارانه رخداد تعاملی (717 مورد وقفه‌مانند و 53 مورد بازخوردمانند) از مرزهای گوینده بازیابی شد.

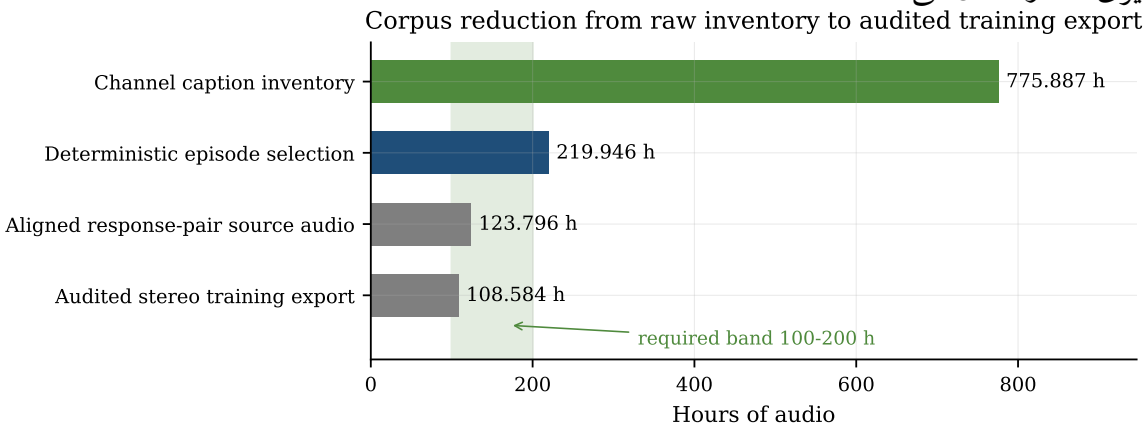
این برچسب‌ها به‌طور کامل «خودکار»اند. بازبینی شنیداری چهل‌ردیفی داده و بازبینی بیست‌وچهارردیفی رخدادهای تعاملی، تحت یک سند انصراف زمانی مستند، اجرا نشد. بنابراین در سراسر این نوشتار هیچ ردیفی به‌عنوان «تأییدشده توسط انسان» گزارش نمی‌شود و شمار برچسب‌های تأییدشده انسانی صفر است.

۴-۲-۴ تفکیک گروهی و بازسازی صدای پاسخ

تفکیک آموزش، اعتبارسنجی و آزمون بر پایه «شناسه نشست منبع» و با درهم‌سازی قطعی انجام شد (بخش ۲-۸-۴). نتیجه، 6,419 جفت آموزش، 131 جفت اعتبارسنجی و 204 جفت آزمون است و ممیزی خودکار، نشت گروهی صفر را تأیید می‌کند.

برای مسیر مستقیم، کانال «دستیار» نباید صدای گویندگان متعدد منبع را داشته باشد، زیرا مدل باید یک صدای هدف پایدار بیاموزد. به همین دلیل، متن نوبت پاسخ با موتور گفتاری فارسی و یک مدل صوتی «قطعی» و ثابت بازسازی شد. این همان رسم متعارف در آموزش مدل‌های گفتاربه‌گفتار است. خروجی نهایی، یک پرونده صوتی استریو برای هر جفت است که در آن کانال صفر گفتار دستیار و کانال یک گفتار کاربر است، همراه با یک پرونده هم‌ترازی متنی مجاور.

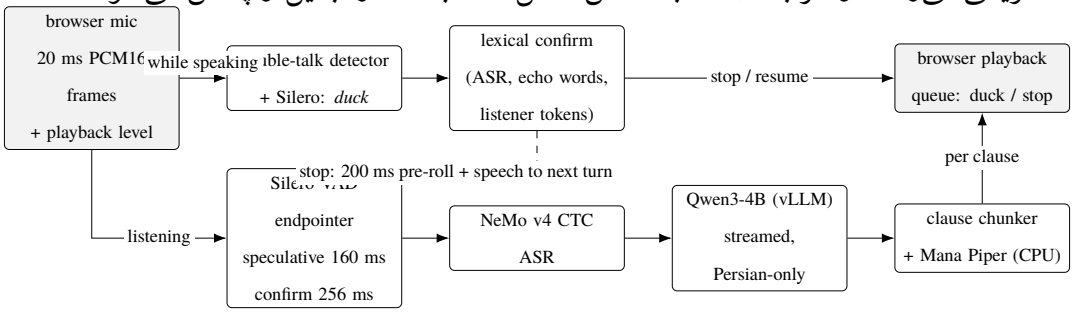
مجموع صوت استریوی خروجی 108.584 ساعت اندازه‌گیری‌شده است که درون بازه 100 تا 200 ساعت مورد نظر نیازمندی ن۴ قرار می‌گیرد. شکل ۴-۲ کاهش تدریجی حجم از موجودی خام تا خروجی ممیزی‌شده را نشان می‌دهد.



شکل ۴-۲: کاهش تدریجی مقدار صوت از موجودی زیرنویس کانال‌ها تا خروجی استریوی ممیزی‌شده آموزش. نوار روشن، بازه 100 تا 200 ساعت مورد نظر تعریف پروژه را نشان می‌دهد.

۴-۳ معماری سامانه آبشاری جریانی

سامانه تحویل‌شده یک زنجیره آبشاری جریانی است که کنترل تمام‌دوطرفه روی آن سوار شده است (شکل ۴-۳). نسخه نخست این زنجیره با دکمه «فشار برای صحبت» کار می‌کرد، کل پاسخ را پیش از پخش می‌ساخت و هر سه مرحله را پشت‌سرهم و درون یک پردازه اجرا می‌کرد؛ برآورد ما از تأخیر پایان گفتار تا نخستین صدای آن حدود 2.2 ثانیه (میانه) بود. در نسخه نهایی هر مرحله با مرحله بعد هم‌پوشانی دارد: پایان گفتار خودکار تشخیص داده می‌شود، تولید پاسخ پیش از قطعی‌شدن پایان گفتار آغاز می‌شود، توکن‌ها جریانی می‌رسند و هر بند جمله به‌محض کامل‌شدن به گفتار تبدیل و پخش می‌شود.



شکل ۴-۳: معماری جریانی سامانه تحویل‌شده. ردیف پایین زنجیره تولید پاسخ در حالت شنیدن و ردیف بالا کنترل وقفه در حالت سخن‌گفتن دستیار است. پیکان نقطه‌چین انتقال آغاز گفتار کاربر به نوبت بعد را نشان می‌دهد.

۴-۳-۱ کارخواه مرورگر و قالب قاب‌ها

کارخواه مرورگر میکروفون را پیوسته (با حذف پژواک مرورگر) می‌گیرد، آن را به 16 کیلوهرتز می‌برد و هر 20 میلی‌ثانیه یک قاب می‌فرستد: شماره ترتیب چهاربایتی، تراز ریشه میانگین مربعات صدای دستیار که در همان لحظه پخش می‌شود (اندازه‌گیری‌شده با گره تحلیل‌گر Web Audio) و 320 نمونه PCM16. کارساز بندهای صوتی پاسخ را به‌صورت پیام دودویی (شماره نوبت، شماره بند، PCM16) و رویدادهای کنترلی را به‌صورت JSON می‌فرستد. کارخواه بندها را روی یک صف پخش زمان‌بندی می‌کند، در صورت دستور، صدای پخش را کم (duck) یا منبع را قطع می‌کند و زمان‌ها را با ساعت خودش گزارش می‌دهد: از قابی که پایان آوایی گفتار در آن است تا آغاز زمان‌بندی‌شده نخستین بند ($T_{\text{first_audio}}$)، و از قاب آغاز وقفه تا کم‌کردن و قطع صدا.

۴-۳-۲ تشخیص پایان گفتار و آغاز پیش‌دستانه

هر قاب با آشکارساز فعالیت گفتار Silero (ONNX) امتیاز می‌گیرد. پس از 160 میلی‌ثانیه سکوت، نوبت «پیش‌دستانه» آغاز می‌شود: بازشناسی، تولید متن و تولید گفتار اجرا می‌شوند، اما صوت آن پشت یک دریچه نگه داشته می‌شود. اگر سکوت به 256 میلی‌ثانیه برسد، پایان گفتار قطعی می‌شود و بندهای نگه‌داشته به ترتیب آزاد می‌شوند؛ اگر کاربر پیش از آن دوباره سخن بگوید، نوبت پیش‌دستانه لغو و گفتار به ادامه همان نوبت افزوده می‌شود. خط زمان نمونه‌ها در سراسر نشست مطلق است، تا زمان پایان گفتار نوبت‌های بعدی با قاب‌های کارخواه هم‌خوان بماند (خطای بازنشانی شمارنده که در آزمون حلقه‌ای پیدا شد، با آزمون بازگشتی بسته شده است).

۴-۳-۳ بازشناسی گفتار

نوبت کاربر به سرویس محلی بازشناسی گفتار فرستاده می‌شود: مدل ترکیبی Conformer نسخه 4 با رمزگشای CTC، که مقایسه نامزدهای بازشناسی نسخه دوم (فصل ۵) آن را دقیق‌ترین نامزد درون بودجه تأخیر یافت. درهم‌سازی پرونده مدل در گزارش سلامت کارساز و هر رسید ثبت می‌شود.

نکته‌ای که در ممیزی مهم شد، «انتخاب کانال ورودی» است. پرونده‌های مجموعه داده استریواند و کانال صفر گفتار دستیار و کانال یک گفتار کاربر است. یک پنل توسعه پیشین به‌اشتباه کانال صفر را به بازشناسی داده بود، یعنی عملاً صدای بازسازی‌شده دستیار را رونویسی می‌کرد. این اشکال پیش از اجرای

هر ردیف اعتبارسنجی شناسایی و اصلاح شد و پروتکل‌ها استفاده از کانال یک «ممیزی‌شده» را الزامی می‌کنند.

۴-۳-۴ تولید پاسخ متنی جریانی

پاسخ با Qwen3-4B-Instruct-2507 [۶۱] و پرامپت قفل‌شده نسخه دوم تولید می‌شود؛ درهم‌سازی درخت مدل و پرامپت در هر رسید ثبت می‌شود. مدل با vLLM و به‌صورت جریانی سرویس می‌گیرد و دو نوبت آخر گفت‌وگو به عنوان تاریخچه به آن داده می‌شود. قید «فقط خط فارسی» دیگر پس از تولید و با تلاش دوباره اعمال نمی‌شود، بلکه هنگام رمزگشایی و با خروجی ساخت‌یافته مبتنی بر عبارت منظم اجرا می‌شود: مدل اصلاً نمی‌تواند نویسه لاتین تولید کند. در آزمون حلقه‌ای روی میزبان مشترک، نخستین توکن با میانه حدود 40 میلی‌ثانیه پس از پایان بازشناسی رسید.

مقایسه نامزدهای پاسخ‌گو و یک مسیر «ورودی گفتاری» که بازشناسی را حذف می‌کند (Gemma 4 E4B، بخش ۴-۵-۴) هیچ‌کدام به آستانه ازپیش‌ثبت‌شده جایگزینی نرسیدند؛ بنابراین همین پاسخ‌گو باقی ماند.

۴-۳-۵ بندبندی و تولید گفتار

متن جریانی در مرز بندها بریده می‌شود: نخستین تکه به‌محض رسیدن به 2 تا 4 واژه (در نخستین مرز یا حداکثر چهار واژه) و تکه‌های بعدی در نشانه‌های پایان بند فارسی («،»، «.»، «؟»، «!»، «؛») یا حداکثر 14 واژه. هر تکه بی‌درنگ با موتور Piper و صدای فارسی Mana روی پردازنده (ONNX Runtime با هشت رشته و تنظیمات قطعی) به گفتار تبدیل و فرستاده می‌شود؛ تولید چهار واژه نخست حدود 60 تا 100 میلی‌ثانیه طول می‌کشد. در کارساز زنده، شکست Piper خطا می‌دهد و به ترکیب فورمانتی جایگزین نمی‌رسد. مقایسه صداها (شش صدای فارسی Piper، ParsVoice-XTTS و مدل VITS آزمایشگاه؛ فصل ۵) صدای Mana را فهم‌پذیرترین نامزد یافت.

۴-۴ کنترل تمام‌دوطرفه و تشخیص وقفه

هنگامی که دستیار سخن می‌گوید، قاب‌های میکروفون به یک کنترل‌گر دومرحله‌ای داده می‌شوند. مرحله نخست سریع و برگشت‌پذیر است، مرحله دوم دقیق‌تر و کندتر.

۴-۴-۱ مرحله نخست: کم‌کردن صدا

هر قاب باید دو شرط داشته باشد تا «صدای کاربر» شمرده شود: آشکارساز Silero آن را گفتار بداند، و از پژواک مورد انتظار صدای خود دستیار بلندتر باشد. پژواک مورد انتظار از تراز پخشی که کارخواه گزارش می‌دهد به دست می‌آید: بیشینه تراز هشت قاب اخیر (برای پوشش تأخیر مسیر پژواک) به‌اضافه یک ضریب جفت‌شدگی؛ قاب باید دست‌کم 14 دسی‌بل از آن بلندتر باشد (آشکارساز هم‌سخنی به سبک Geigel). ضریب جفت‌شدگی در آغاز هر پاسخ محافظه‌کارانه 0 دسی‌بل فرض می‌شود و هنگام سکوت کاربر به‌تدریج به مقدار واقعی نزدیک می‌شود؛ مقداردهی از نخستین قاب پخش، که پیش از رسیدن پژواک تأخیری است، در شبیه‌سازی علت اصلی کم‌شدن نابه‌جای صدا در آغاز پاسخ‌ها بود. بدون تراز مرجع، یک کف نویز غلتان به‌اضافه 12 دسی‌بل به کار می‌رود. یک قاب صدای کاربر کافی است تا صدای دستیار کم شود؛ این همان واکنش «تشخیص و تطبیق پاسخ جاری» است که پیشنهاده آن را در 150 میلی‌ثانیه می‌خواهد.

۴-۴-۲ مرحله دوم: تأیید واژگانی با حذف پژواک

پس از کم‌شدن صدا، گفتار ضبط‌شده از لحظه آغاز با همان سرویس بازشناسی رونویسی می‌شود: پس از 400 میلی‌ثانیه گفتار، سپس هر 200 میلی‌ثانیه تا زمانی که تصمیم گرفته نشده، و نیز وقتی کاربر ساکت شود (320 میلی‌ثانیه). از رونویسی هنجارشده دو دسته واژه کنار گذاشته می‌شود: واژه‌های شنونده (فهرست 35 واژه‌ای مانند «آره»، «بله»، «اوهوم»، «خب»)، واژه‌های دستوری بسته (حرف اضافه، ضمیر، اشاره، ربط) که چیزی درباره خواست نوبت نمی‌گویند، و واژه‌های پاسخی که دستیار در حال پخش آن است، که همان پژواک باقی‌مانده است؛ تطبیق پژواک یکسانی، یک ویرایش برای واژه‌های سه‌حرفی و بلندتر، و پیشوند یا پسوند سه‌حرفی و بلندتر را می‌پذیرد، زیرا واژه‌های لبه پنجره ضبط بریده می‌شوند. اگر واژه‌ای باقی بماند، وقفه پذیرفته می‌شود: پخش قطع، تولید لغو و گفتار ضبط‌شده همراه با 200 میلی‌ثانیه پیش‌بافر به آغاز نوبت بعدی کاربر تبدیل می‌شود. پاسخ قطع‌شده تنها تا جایی که کاربر شنیده بود در تاریخچه گفت‌وگو می‌ماند: کارخواه همراه با تأیید توقف اعلام می‌کند چه مقدار از پاسخ پیش از آغاز سخن کاربر پخش شده بود، و کارساز بقیه پاسخ را از تاریخچه کنار می‌گذارد و آن را با «...» پایان می‌دهد، تا پاسخ بعدی فرض نکند کاربر همه آن را شنیده است. اگر رونویسی تا سکوت کاربر یا تا 1.6 ثانیه گفتار خالی یا فقط شامل واژه‌های شنونده باشد، صدا به حالت عادی برمی‌گردد و پاسخ ادامه می‌یابد. زمان بازشناسی به زمان تصمیم افزوده می‌شود و فراخوانی آن خارج از حلقه رویداد کارساز اجرا می‌شود.

دلیل این طراحی، نتیجه اجراهای توسعه شبیه‌سازی (فصل ۵) بود: تأیید بر پایه مدت گفتار یا طبقه‌بند صوتی (ویژگی‌های بخش ۲-۱ با طبقه‌بند تقویت گرادیانی یا شبکه چندلایه پیشنهاده) نمی‌تواند بازخوردهای کلامی بلند، نویزهای بلند و باقی‌مانده پژواک را از وقفه جدا کند. طبقه‌بندهای صوتی همچنان پیاده‌سازی و در آزمون آشکارساز نسخه دوم سنجیده شده‌اند.

۴-۴-۳ سه سطح ارزیابی

تشخیص وقفه در سه سطح سنجیده می‌شود: (۱) آزمون طبقه‌بند روی رخدادهای تعاملی پادکست‌ها با برچسب‌های خودکار مستقل دومرحله‌ای Gemini؛ (۲) شبیه‌سازی موقعیت استقرار از ضبط‌های واقعی، که در آن میکروفون گفتار کاربر را همراه با پژواک باقی‌مانده دستیار، نویز زمینه و پاسخ اتاق (پاسخ‌های اتاق و نویزهای نقطه‌ای مجموعه OpenSLR [۵۷]، که نویزهای آن از MUSAN [۵۵] برگرفته شده‌اند) می‌شنود؛ (۳) آزمون حلقه‌ای با مرورگر واقعی و میکروفون جعلی. برای پرهیز از دور استدلالی، بازخوردهای کلامی شبیه‌سازی و آزمون حلقه‌ای با مدل بازشناسی دیگری (SeamlessM4T v2) برگزیده شده‌اند و نه با همان مدلی که تأیید واژگانی را انجام می‌دهد.

۴-۵ طراحی آزمایش‌های مسیر مستقیم

۴-۵-۱ هدف آموزشی و شرط پذیرش

مسیر مستقیم، تطبیق کم‌پارامتر مدل Moshika با آموزش‌دهنده رسمی آن است. داده ورودی، همان پرونده‌های استریوی بخش ۴-۲ است: کانال صفر گفتار دستیار بازسازی‌شده و کانال یک گفتار کاربر، همراه با هم‌ترازی متنی که سازوکار «تک‌گویی درونی» به آن نیاز دارد. زیان کل، ترکیب وزن‌دار زیان نشانه‌های متنی و زیان نشانه‌های صوتی هر کتاب رمز است.

تصمیم روشمند مرکزی این بخش، تعریف یک «شرط پذیرش زمان اجرا» پیش از آغاز آموزش بود. برای هر چک‌پوینت نامزد، آداپتر در سرور جویباری رسمی مدل بارگذاری می‌شود، نه در یک اسکریپت محلی، و برای هر یک از ۹ ردیف ورودی از پیش تعیین‌شده باید هم‌زمان چند شرط برقرار باشد: مدل باید متن تولید کند، باید گفتار غیرساکت تولید کند، و متن تولیدی باید از قید خط فارسی بگذرد. یک چک‌پوینت تنها در صورتی «واجد شرایط» است که هر 9 ردیف را با موفقیت بگذراند.

این شرط سخت‌گیرانه است و به‌طور عمدی چنین طراحی شده. تجربه نسخه نخست نشان داد که چک‌پوینت‌هایی با کمترین زیان اعتبارسنجی، در تولید خودرگرسیو صوت تقریباً ساکت و بدون متن می‌دهند. اگر انتخاب چک‌پوینت تنها بر زیان استوار بود، همان مصنوع بی‌فایده به‌عنوان «مدل فارسی» گزارش می‌شد.

۴-۵-۲ نسل‌های آزمایشی

آزمایش‌ها به‌صورت زنجیره‌ای از فرضیه‌های قابل ابطال طراحی شدند و در هر نسل تلاش شد «تنها یک عامل» تغییر کند. جدول ۴-۱ این طراحی را خلاصه می‌کند.

سه نسخه نخست، مسیر متعارف تنظیم فراپارامتر را می‌پیمایند. نسخه‌های چهارم و پنجم، فرضیه‌های دقیق‌تری را می‌آزمایند که از تحلیل شکست نسخه‌های پیشین برآمده‌اند: اگر مشکل، نبود بازنمایی متنی فارسی است، آموزش گزینشی تنها دو درج‌گر متنی باید کافی باشد؛ و اگر مشکل، غلبه زیان معنایی بر زیان آوایی است، کاهش ضریب کتاب رمز نخست باید آن را برطرف کند.

نسخه ششم، طراحی متفاوتی دارد و به‌عمد یک «آزمون ابطال» است. در این نسخه، مدل روی تنها 32 نمونه و با پنجره متن 12 ثانیه آموزش می‌بیند و روی «همان» 32 نمونه ارزیابی می‌شود. هدف، سنجش تعمیم نیست، بلکه پاسخ به یک پرسش دوگزینه‌ای است: آیا این آداپتر «ظرفیت» یادگیری هدف را دارد یا نه؟ اگر مدل نتواند حتی روی داده آموزشی خودش زیان را به‌قدر کافی کاهش دهد، مشکل در ظرفیت است؛ اگر بتواند اما در تولید خودرگرسیو شکست بخورد، مشکل در اریبی مواجهه است (بخش ۲-۴-۲). نسخه v6.2 همچنین «حذف تصادفی زمان‌بندی‌شده ورودی متنی» را اضافه می‌کند: سهم نشانه‌های متنی مرجع که در آموزش پنهان می‌شوند به‌تدریج از 0.25 به 0.75 افزایش می‌یابد تا مدل بیاموزد بر پیش‌بینی خودش تکیه کند.

۴-۵-۳ نسخه هفتم: آزمون علت ریشه‌ای در توکن‌ساز

ممیزی پایانی پروژه نشان داد که شش نسل پیشین عاملی ساختاری را نیازموده بودند. مدل Moshi در هر قاب 12.5 هرتزی حداکثر یک نشانه متنی تولید می‌کند و متن «تک‌گویی درونی» باید کمی جلوتر از صوت حرکت کند. توکن‌ساز انگلیسی SentencePiece این مدل برای هر واژه فارسی به‌طور میانگین 6.6 نشانه لازم دارد و 55 درصد نشانه‌ها بازگشت به بایت‌اند (تنها 8 حرف از 33 حرف فارسی قطعه مستقل دارند)؛ در نتیجه 98.5 درصد نوبت‌های دستیار بیش از یک نشانه در هر قاب نیاز داشتند و هم‌ترازی در سطح کل نوبت، این کمبود را پنهان می‌کرد. همان گفتار، اگر واج‌های espeak-ng که Piper واقعاً تلفظ کرده به

حروف لاتین برگردانده شوند، 2.7 نشانه در هر واژه می‌خواهد و تنها 0.3 درصد نوبت‌ها از بودجه قاب فراتر می‌روند.

نسخه v7a دقیقاً دو چیز را نسبت به آزمون ظرفیت نسخه ششم تغییر می‌دهد: متن تک‌گویی درونی، لاتین‌نویسی قطعی واج‌های گفته‌شده است، و زمان هر واژه از هم‌ترازی دقیق واج‌های Piper می‌آید. همان 32 نمونه، همان پنل نُه‌ردیفی و همان شرط «هر نُه ردیف» به کار رفت؛ طبق پروتکل ازپیش‌ثبت‌شده، آموزش کامل (v7b) و گشودن آزمون مهروموم‌شده تنها در صورت گذر از این شرط مجاز بود. مدل PersonaPlex نیز بررسی شد؛ همان معماری و توکن‌ساز را دارد، فقط انگلیسی آموخته و کد آموزش آن منتشر نشده است، بنابراین علت ریشه‌ای یادشده برای آن هم برقرار است و آموزش داده نشد.

۴-۵-۴ مسیر ورودی گفتاری: Gemma 4

مسیر مستقیم دوم، مدل زبانی‌ای است که صوت را مستقیم می‌شنود و بازشناسی گفتار را حذف می‌کند. Gemma 4 E4B (نسخه کوانتیده QAT w4a16) ورودی صوتی تا 30 ثانیه را می‌پذیرد. سه بازو با سامانه تولیدی مقایسه شدند: بازشناسی و سپس Gemma متنی، Gemma با شنیدن مستقیم صوت (بدون آموزش)، و همان با آداپتر LoRA گفتاری. آداپتر با رتبه 16 روی لایه‌های توجه و پیش‌خور مدل زبانی (رمزگذار صوتی منجمد) و با دو وظیفه آموخت: رونویسی، و «خودتقطیری» به سبک DiVA، یعنی پاسخ دادن به صوت همان‌گونه که مدل به رونوشت متنی آن پاسخ می‌دهد. داده آموزش 3,817 نوبت کاربر (11.2 ساعت از 137 نشست آموزشی) بود و هیچ نشستی از پنل‌های ارزیابی در آن نبود. وزن‌های کوانتیده برای آموزش به bf16 برگردانده شدند و آداپتر روی همان پایه کوانتیده سرویس گرفت. داوری با پنل‌ها و معیار پاسخ‌گوی نسخه دوم انجام شد و قاعده تصمیم پیش از آموزش آداپتر ثبت شده بود: مسیر گفتاری تنها اگر میانگین مرتبط‌بودن آن حداکثر 0.10 کمتر از سامانه تولیدی و زمان تا نخستین توکن آن کمتر باشد، نتیجه مثبت شمرده می‌شود.

۴-۶ روش کاری شواهدمحور

بخش بزرگی از سهم روشمند این پروژه، در چگونگی «گزارش» نتایج است. تجربه تلاش اولیه (بخش ۴-۱) نشان داد که یک مصنوع می‌تواند زیان کاهنده و ظاهر موفق داشته باشد و در همان حال هیچ ادعای معناداری را پشتیبانی نکند. برای پرهیز از تکرار این وضعیت، پنج قاعده عملیاتی تعریف و در کد اعمال شد.

یک. تعریف پیشینی پروتکل. برای هر ارزیابی، یک سند پروتکل شامل شاخص دقیق ردیف‌های آزمون، آستانه‌های پذیرش، بازنگری مدل‌ها و درهم‌سازی پرونده‌ها، پیش از اجرا نوشته و در مخزن ثبت می‌شود. آستانه پذیرش پس از مشاهده نتیجه ساخته نمی‌شود.

دو. تفکیک مرحله صلاحیت از آزمون نهایی. ارزیابی معنایی دومرحله‌ای است. نخست یک مرحله صلاحیت روی شمار کوچکی از ردیف‌های اعتبارسنجی اجرا می‌شود. تنها در صورت عبور کامل از این مرحله، آزمون نهایی روی ردیف‌های آزمون «یک‌بار» باز می‌شود. این طراحی از انتخاب پس از مشاهده نتیجه جلوگیری می‌کند. داور این ارزیابی، مدل Qwen3.8-27B-FP8 با بازنگری 017b9c7af6b5689d5dd426a76e0bc077eb5ca20a، دمای صفر، ترتیب بازوی دوسوکور و دو تکرار در هر ردیف است. چون داور و نامزد از یک خانواده‌اند، نتیجه در کلاس «تقریب خودکار هم‌خانواده» می‌ماند و نیازمندی تعریف پروژه را اثبات نمی‌کند.

سه. مصنوعات یک‌بارنوشت. هر نتیجه نهایی در یک پرونده ساختارمند ثبت می‌شود که شامل مقادیر اندازه‌گیری‌شده، وضعیت هر شرط پذیرش، درهم‌سازی‌های ورودی، مشخصات سخت‌افزار و یک فهرست صریح محدودیت‌ها است. این پرونده بازنویسی نمی‌شود.

چهار. کلاس‌بندی شواهد. هر اندازه‌گیری با یک «کلاس شواهد» برچسب می‌خورد. جدول ۴-۲ این کلاس‌ها را تعریف می‌کند. قاعده بنیادی آن است که تنها کلاس رسمی می‌تواند برآورده‌شدن یک نیازمندی تعریف پروژه را اثبات کند.

پنج. تجمیع شکست‌بسته. یک مؤلفه تجمیع‌کننده، همه مصنوعات نتیجه را می‌خواند و وضعیت کلی پروژه را می‌سازد. این مؤلفه «شکست‌بسته» است: اگر مصنوع پشتیبان یک شرط وجود نداشته باشد، یا درهم‌سازی آن با ورودی مورد انتظار نخواند، یا کلاس شواهد آن پایین‌تر از حد لازم باشد، آن شرط «ناموفق» گزارش می‌شود و نه «نامعلوم». همچنین این مؤلفه صریحاً مانع از ارتقای یک تقریب به شواهد رسمی می‌شود.

پیامد این روش کاری آن است که وضعیت شواهد هر شرط، همان‌طور که در فصل ۵ گزارش می‌شود، مستقل از آمادگی گزارش برای ارائه و داوری بیان شود. نتیجه نهایی، تفکیک روشن آنچه ساخته شده از آنچه با شواهد رسمی اثبات شده است.

۴-۷ پیاده‌سازی و بازتولیدپذیری

کد پروژه در یک بسته پایتون با رابط خط فرمان یکپارچه سازمان یافته است که هر مرحله زنجیره داده، آموزش، ارزیابی و سرویس‌دهی را به‌صورت یک زیرفرمان مستقل ارائه می‌کند. پیاده‌سازی مدل‌ها بر PyTorch [۶۲] و کتابخانه Transformers [۶۳] استوار است. دو محیط مجازی جداگانه نگه داشته می‌شود: یکی برای سامانه اصلی و یکی برای پشته مسیر مستقیم که وابستگی‌های سخت‌گیرانه‌تری دارد.

سه سازوکار، بازتولیدپذیری را پشتیبانی می‌کنند. نخست، یک پرونده قفل «مخازن بالادستی» که برای هر مدل و مخزن بیرونی، بازنگری دقیق و درهم‌سازی وزن‌ها را ثبت می‌کند. دوم، بذر تصادفی ثابت برای هر آزمایش که در مصنوع نتیجه گزارش می‌شود. سوم، مجموعه آزمون خودکار به همراه یکپارچه‌سازی پیوسته که در آن، بررسی سبک کد، بررسی نوع، ممیزی آسیب‌پذیری وابستگی‌ها، ممیزی مصنوعات ثبت‌شده و پوشش آزمون اجرا می‌شود.

فرمان‌های بازتولید هر مرحله در پیوست آ‌ـ۴ فهرست شده‌اند.

جدول ۴-۱: طراحی هفت نسل آزمایشی مسیر مستقیم و فرضیه‌ای که هر نسل آزمود

نسخه	عامل تغییریافته	فرضیه آزمون‌شده	رتبه
v1	پیکربندی پایه، پنجره 20 ثانیه، آموزش همه درج‌گرها	مدل با داده کافی، گفتار فارسی می‌آموزد	64
v2	پنجره متن به 100 ثانیه	پنجره کوتاه، آغاز پاسخ را در بافت نمی‌گنجاند	64
v3	انجماد همه درج‌گرها و رتبه بالاتر	آموزش درج‌گرها بازنمایی پایه را تخریب می‌کند	128
v4	آموزش تنها دو درج‌گر متنی	تنها فضای متنی فارسی نیاز به تطبیق دارد	128
v5	ضریب زیان کتاب رمز نخست از 100 به 10	وزن زیاد کتاب رمز معنایی، یادگیری آوایی را خفه می‌کند	128
v6.2	آزمون ظرفیت درون‌نمونه با حذف تصادفی ورودی متنی و پنجره 12 ثانیه	مدل ظرفیت یادگیری دارد و مشکل، اریبی مواجهه است	64
v7a	متن تک‌گویی درونی لاتین‌شده واجی با زمان‌بندی واژه‌ای (بخش ۴-۵-۳)	توکن‌ساز انگلیسی بودجه یک نشانه در قاب را می‌شکند	64

جدول ۴-۲: کلاس‌های شواهد و توان ادعای هر کلاس

کلاس شواهد	شرایط لازم	اثبات نیازمندی
رسمی سرتاسری	نشست زنده با رضایت کاربر، تأیید پخش از سوی کارخواه، میکروفون واقعی و سخت‌افزار واجد شرایط	مجاز
زنده غیررسمی	همان پروتکل، اما سخت‌افزار یا شرایط مطالعه واجد شرایط نیست	غیرمجاز
مؤلفه سمت سرور	زمان‌سنجی تولید یا آشکارساز، بدون اثبات رفتار شنیدنی کارخواه	غیرمجاز
تقریب مصنوعی	صوت تولیدشده یا رخداد شبیه‌سازی‌شده	تنها آزمون بازگشتی
تقریب خودکار هم‌خانواده	داوری با مدل زبانی از خانواده نامزد	غیرمجاز

فصل ۵

آزمایش‌ها و نتایج

این فصل نتایج اندازه‌گیری‌شده را ارائه می‌کند. برای هر نتیجه، سه چیز مشخص شده است: مقدار مشاهده‌شده، مخرج و شرایط اندازه‌گیری، و «مرز ادعای مجاز» بر پایه کلاس شواهد آن (جدول ۴–۲). همه اعداد این فصل از مصنوعات ثبت‌شده و درهم‌سازی‌شده پروژه خوانده شده‌اند و هیچ مقداری تخمینی نیست.

۵–۱ پوشش شروط پذیرش و وضعیت شواهد

جدول ۵–۱ وضعیت شروط پذیرش «رسمی» پروژه را، همان‌طور که تجمیع‌کننده شکست‌بسته تولید می‌کند، کنار شواهد خودکار مرحله پایانی می‌گذارد. شروط رسمی عمداً سخت‌گیرانه‌اند (برچسب انسانی، سخت‌افزار فیزیکی هدف، مطالعه انسانی کامل) و شواهد خودکار جای آن‌ها را نمی‌گیرد؛ ستون سوم نشان می‌دهد هر شرط تا کجا با شواهد خودکار پوشش داده شده است.

پنج شرط مهندسی شواهد رسمی کافی دارند. برای سه شرط آشکارساز، تأخیر و حافظه، شواهد خودکار معیارهای عددی پیشنهاده را برآورده می‌کند، اما با برچسب خودکار و روی H100؛ مدل مستقیم منفی است و مطالعه انسانی در انتظار پاسخ است.

۵–۲ مجموعه داده

جدول ۵–۲ مشخصات نهایی مجموعه داده را نشان می‌دهد.

جدول ۵-۱: شروط پذیرش رسمی پروژه و شواهد خودکار مرحله پایانی

شرط پذیرش	وضعیت رسمی	شواهد خودکار پایانی
نمونه اولیه کارکردی گفتاربه‌گفتار فارسی	کافی	سامانه جریانی، آزمون حلقه‌ای مرورگر
عبور از آزمون نهایی معنایی خودکار	کافی	—
خروجی ممیزی‌شده در بازه 100 تا 200 ساعت	کافی	—
حل‌شدن سیاست داده تحت انصراف مستند بازبینی	کافی	—
انتخاب مجوز کد منبع	کافی	—
مدل مستقیم فارسی واجد شرایط استقرار	منفی	Moshi v7a: 6/9، گفتار نافهم؛ ورودی گفتاری Gemma: منفی
آشکارساز با دقت بیش از 80 درصد روی برچسب مستقل	انسانی نیست	شبیه‌سازی 0.880/0.933؛ مرورگر 0.817/0.825
تناسب و تأخیر زنده روی سخت‌افزار 12 تا 24 گیگابایتی	سخت‌افزار هدف نیست	حافظه GiB 11.1؛ میانگین 372 و صدک نود 431 میلی‌ثانیه روی H100
تکمیل مطالعه انسانی	در انتظار	ابزار و پروتکل ثبت‌شده؛ پاسخ‌ها هنوز نرسیده

مقدار 108.584 ساعت درون بازه 100 تا 200 ساعت نیازمندی ن۴ قرار می‌گیرد و ممیزی خودکار یکپارچگی، شامل بررسی ترتیب کانال‌ها، درهم‌سازی پرونده‌ها و تفکیک گروهی، بدون شکست گذشته است.

راستی‌آزمایی مستقل برچسب‌ها. برچسب‌های مرز نوبت و هم‌پوشانی با یک شنونده خودکار مستقل (Gemini 3.8 Flash، دو پرسش با واژه‌بندی متفاوت و فقط برچسب‌های هم‌رأی) روی 300 جفت از نسخه متوازن دوم سنجیده شد؛ نمونه از 1,353 جفتی برداشته شد که صوت منبعشان پس از انتقال صوت به پشتیبان ابری هنوز روی دیسک بود (عمدتاً دو کانال از چهار کانال). در 93.8 درصد مرزهای نوبت، شنونده مستقل آغاز سخن گوینده‌ای دیگر را شنید (بازه‌های اطمینان دو لایه حدود 87 تا 97 درصد). هم‌پوشانی‌های علامت‌خورده در 75.7 درصد موارد هم‌پوشانی شنیده شدند، اما شنونده در یک‌سوم مرزهای بدون علامت

نیز هم‌پوشانی شنید؛ یعنی تفکیک گوینده هم‌پوشانی‌های کوتاه را کمتر از واقع گزارش می‌کند. زیرنویس نوبت‌ها با رونوشت دقیق شنونده 15.9 درصد خطای نویسه دارد. توافق دو پرسش 71 تا 73 درصد بود.

این نتیجه، یک خروجی ممیزی‌شده «خودکار» است. برچسب‌های تعاملی نامزد خودکارند و شمار ردیف‌های تأییدشده انسانی صفر است؛ بنابراین این مجموعه داده را نمی‌توان «برچسب‌گذاری‌شده توسط انسان» نامید؛ راستی‌آزمایی بالا هم خودکار است و روی نمونه‌ای در دسترس انجام شده است. همچنین داده منبع قابل بازنشر نیست.

۵-۳ سامانه آبشاری: پنل مکانیکی

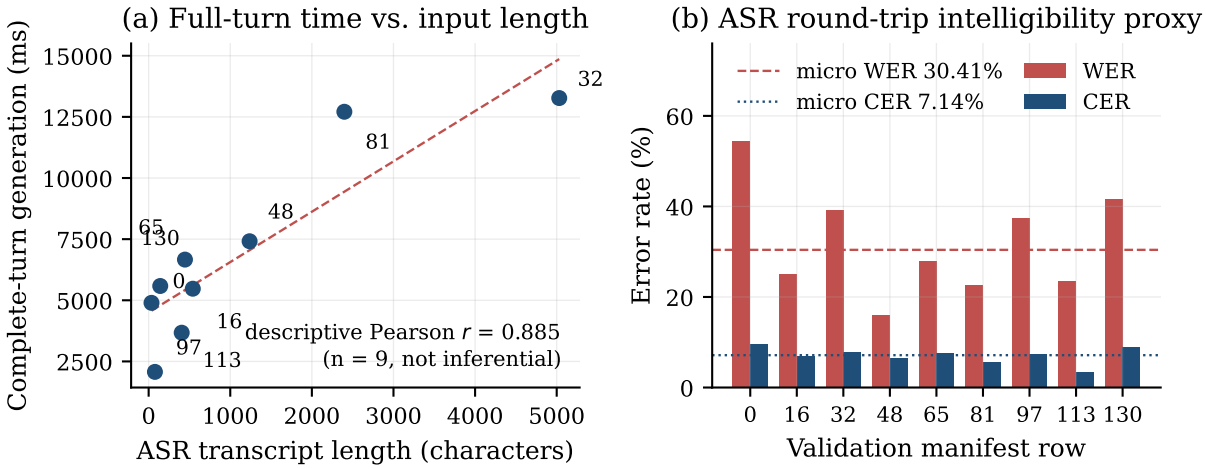
پنل اعتبارسنجی، ۹ ردیف با فاصله ثابت از فهرست‌نامه 131 ردیفی اعتبارسنجی است. شاخص این ردیف‌ها پیش از اجرا قفل شده بود. زنجیره اجراشده، سرویس واقعی بازشناسی گفتار، پاسخ‌گوی محلی Qwen2.5-0.5B-Instruct و موتور گفتاری واقعی است و کانال ورودی، کانال یک ممیزی‌شده کاربر است. این پنل مکانیک زنجیره را می‌سنجد و نه کیفیت معنایی پاسخ‌گوی Qwen3-4B سامانه تحویل‌شده. نتیجه تجمیعی این پنل در جدول ۵-۳ آمده است.

جدول ۵-۴ جزئیات هر ردیف را نشان می‌دهد. ستون زمان، مدت «تولید کامل پاسخ» است و نه تأخیر نخستین صوت.

یک تحلیل توصیفی پس‌نگر و حریم‌خصوصی‌محور نیز روی همین گزارش اجرا شد که تنها مقادیر تجمیعی و درهم‌سازی‌ها را می‌خواند و متن رونویسی یا پاسخ را نمی‌خواند و منتشر نمی‌کند. یافته‌های آن چنین است: هیچ شکست مکانیکی رخ نداد؛ میانه، صدک نودوپنجم و بیشینه طول رونویسی 445، 3977.8 و 5031 نویسه بود؛ میانه، صدک نودوپنجم و بیشینه زمان تولید کامل 5584.736، 13045.919 و 13270.249 میلی‌ثانیه بود؛ سه ردیف رونویسی بیش از 1000 نویسه داشتند و دو ردیف زمان تولید بیش از 10 ثانیه.

مهم‌ترین ریسک مهندسی مشاهده‌شده، رشد زمان تولید کامل با طول ورودی است. همبستگی پیرسون توصیفی میان طول رونویسی و زمان تولید کامل 0.885 است و بلندترین رونویسی و کندترین نوبت، هر دو ردیف 32 بودند. شکل ۵-۱ (الف) این رابطه را نشان می‌دهد.

این یک نتیجه مثبت مکانیکی و برون‌نمونه روی یک پنل گروه‌ناهمپوشان با پاسخ‌گوی Qwen2.5-0.5B است. پنل نه‌ردیفی برای اثبات تعمیم جمعیتی یا کیفیت معنایی کافی نیست و به پاسخ‌گوی Qwen3-4B سامانه تحویل‌شده تعمیم داده نمی‌شود. همبستگی گزارش‌شده توصیفی است و نه استنباطی. زمان تولید کامل روی سخت‌افزار موجود، سنجه T_{first_audio} نیست و نمی‌تواند شرط 500 میلی‌ثانیه را برآورده کند.



شکل ۵-۱: (الف) زمان تولید کامل پاسخ در برابر طول رونویسی ورودی برای ۹ ردیف پنل اعتبارسنجی، همراه با خط برازش و همبستگی پیرسون توصیفی. (ب) نرخ خطای واژه و نویسه بازبازشناسی برای همان ۹ خروجی، همراه با مقادیر تجمیع خرد.

۵-۴ تقریب خودکار فهم‌پذیری گفتار تولیدشده

برای سنجش این‌که آیا گفتار تولیدشده محتوای متن پاسخ را حفظ می‌کند، یک اندازه‌گیری بازبازشناسی روی همان ۹ خروجی زنجیره با پاسخ‌گوی Qwen2.5-0.5B اجرا شد: متن پاسخ تولیدشده مرجع است و رونویسی سرویس بازشناسی از موج صوتی خروجی، فرضیه. پروتکل این اندازه‌گیری، شامل هنجارسازی، تعریف نشانه‌ها و شروط اعتبار، پیش از اجرا ثبت شده بود و همه درهم‌سازی‌های ورودی بازتولید شدند. نتیجه در جدول ۵-۵ گزارش شده است.

شکل ۵-۱ (ب) توزیع این دو نرخ خطا را به‌صورت ردیف‌به‌ردیف نشان می‌دهد. فاصله چشمگیر میان نرخ خطای نویسه و نرخ خطای واژه، در بخش ۶-۲ تفسیر شده است.

این سنجه یک تقریب خودکار «حفظ محتوا» با یک صدای واحد و روی خروجی پاسخ‌گوی Qwen2.5-0.5B است. از آنجا که سرویس بازشناسی هم در سامانه و هم در اندازه‌گیری مشارکت دارد، و از آنجا که ۹ خروجی برای برآورد فاصله اطمینان کافی نیست، این نتیجه فهم‌پذیری انسانی، درستی تلفظ، طبیعی‌بودن یا کیفیت معنایی را اثبات نمی‌کند و به پاسخ‌گوی Qwen3-4B تعمیم داده نمی‌شود. هیچ آستانه قبولی نیز پس از مشاهده نتیجه ساخته نشد.

۵-۵ آزمون معنایی خودکار

۵-۵-۱ مرحله صلاحیت

طراحی این ارزیابی دومرحله‌ای است. مرحله نخست روی هفت ردیف اعتبارسنجی که پیش‌تر استفاده نشده بودند اجرا شد و همه شروط را گذراند: هر 42 فراخوانی داور معتبر بود، میانگین ارتباط نامزد 3.857 در برابر 1.000 خط پایه، بهبود ارتباط 2.857، میانگین انسجام 3.571 با بهبود 2.286+، نرخ برد زوجی 85.7 درصد (6/7) و نرخ ارتباط حداقل دو، 100 درصد. تنها پس از این عبور کامل، آزمون نهایی «یک‌بار» باز شد.

۵-۵-۲ آزمون نهایی

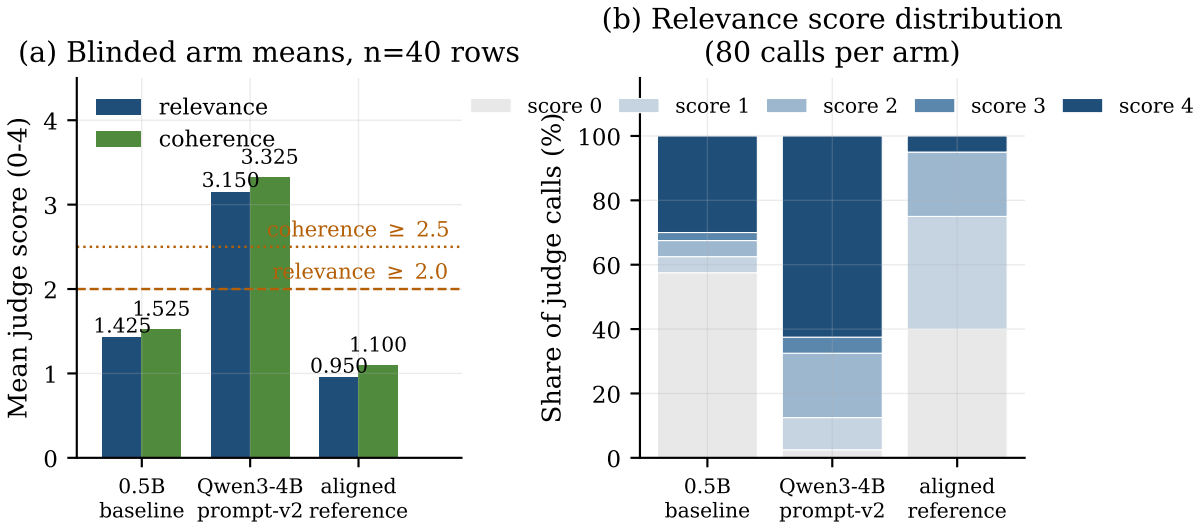
آزمون نهایی روی 40 ردیف از فهرست‌نامه 204 ردیفی آزمون و در پنج نشست منبع کنارگذاشته اجرا شد. سه بازو به‌صورت دوسوکور و با ترتیب تصادفی‌شده به داور داده شدند: خط پایه قفل‌شده Qwen2.5-0.5B، نامزد Qwen3-4B با پرامپت v2، و مرجع هم‌ترازشده خودکار نوبت گوینده بعدی. داور، مدل Qwen3.8-27B-FP8 با بازنگری 017b9c7af6b5689d5dd426a76e0bc077eb5ca20a، دمای صفر و دو تکرار در هر ردیف بود. هر بازو و هر ردیف دو فراخوانی داور برای ارتباط و انسجام دریافت کرد. جدول ۵-۶ نتیجه این آزمون را نشان می‌دهد.

جدول ۵-۷ نشان می‌دهد که هر هفت شرط خودکار ازپیش‌تعریف‌شده برآورده شده‌اند. هیچ آستانه‌ای پس از مشاهده نتیجه تغییر نکرد.

عبور از هفت شرط خودکار به معنای کیفیت ادراکی یا معیار مستقل نیست. داور و نامزد هم‌خانواده‌اند و این نتیجه در کلاس تقریب خودکار باقی می‌ماند.

شکل ۵-۲ میانگین امتیاز هر بازو و توزیع کامل امتیازها را نشان می‌دهد. نکته قابل توجه در بخش (ب)، توزیع دوقطبی خط پایه است: مدل 0.5 میلیاردپارامتری در بخشی از ردیف‌ها امتیاز کامل و در بخش بزرگ‌تری امتیاز صفر گرفته است. همچنین بازوی مرجع هم‌ترازشده خودکار، پایین‌ترین امتیاز را دارد؛ تفسیر این مشاهده در بخش ۶-۳ آمده است.

این یک نتیجه مثبت «خودکار» با داوری مدل زبانی هم‌خانواده با نامزد است. ارزیابی انسانی، معیار مستقل گفت‌وگو، سنجش واقعیت یا ایمنی، اثبات طبیعی‌بودن، تعمیم جمعیتی، تناسب سخت‌افزار هدف و تأخیر مرورگر را اثبات نمی‌کند.



شکل ۵-۲: (الف) میانگین امتیاز ارتباط و انسجام برای سه بازوی دوسوکور، همراه با آستانه‌های ازپیش‌تعریف‌شده. (ب) توزیع کامل امتیاز ارتباط در 80 فراخوانی داور برای هر بازو.

۵-۵-۳ آزمایش تطبیق پاسخ‌گو با LoRA

یک آزمایش جانبی بررسی کرد که آیا تطبیق کم‌پارامتر پاسخ‌گوی متنی روی نوبت‌های پاسخ همین مجموعه داده، کیفیت معنایی را بهبود می‌دهد. آموزش با موفقیت اجرا شد و زیان توسعه کاهش یافت: زیان نشانه‌های پاسخ مدل پایه 3.723 بود، پس از دوره نخست 2.643 و پس از دوره دوم 2.562، یعنی 31.18 درصد کاهش نسبت به مدل پایه. چک‌پوینت دوره دوم بر پایه کمترین زیان توسعه انتخاب شد.

اما ارزیابی معنایی روی چهل ردیف آزمون نشان داد که این آداپتر از خط پایه پیشی نمی‌گیرد. نتیجه به‌عنوان یک «نتیجه منفی معتبر» ثبت شد و آداپتر در سامانه نهایی به کار نرفت. تفسیر این تناقض ظاهری در بخش ۶-۳ آمده است.

۵-۶ بازگزینش اجزا روی پنل‌های تازه

ممیزی پایانی نشان داد که پنل‌های پیشین بازشناسی گفتار دیگر مستقل نیستند (نسخه‌های جدید مدل‌های بازشناسی روی همان کانال‌های یوتیوب آموزش دیده بودند)، داور پاسخ‌گو هم‌خانواده نامزدها بود و صدای گفتار هرگز با بیش از یک شنونده خودکار سنجیده نشده بود. هر سه جزء با پروتکل تازه و پیش‌ثبت‌شده دوباره مقایسه شدند.

۵-۶-۱ بازشناسی گفتار روی رونوشت‌های انسانی

مرجع این مقایسه بنچمارک عمومی PSRB است: 344 قطعه با رونوشت انسانی از منابع گوناگون (47 قطعه گوینده سالمند و 183 قطعه نویزی، تلفنی یا پرطنین) که هیچ‌یک از نامزدها روی آن آموزش ندیده‌اند. امتیازدهی با هنجارساز بدون نشانه‌گذاری انجام شد. تأخیر، زمان یک قطعه منفرد روی H100 است و بودجه تأخیر سامانه جریانی 150 میلی‌ثانیه تعیین شده بود (جدول ۵-۸).

Seamless دقیق‌ترین نامزد است اما بیش از چهار برابر بودجه تأخیر زمان می‌برد؛ در میان نامزدهای درون بودجه، NeMo نسخه 4 با رمزگشای CTC کمترین خطا را دارد و در سامانه باقی ماند. Seamless به‌عنوان «شنونده مستقل دوم» در سنجش فهم‌پذیری گفتار و گزینش بازخوردهای کلامی به کار رفت. خطای همه نامزدها روی گویندگان سالمند بیشتر است (برای نامزد مستقر 15.6 در برابر 8.6 درصد).

۵-۶-۲ پاسخ‌گو با پنل درخواست‌های سالمندان

نسخه دوم مقایسه پاسخ‌گو دو پنل دارد: 60 درخواست محاوره‌ای سالمندان در هشت دسته (سلامت و دارو، خانواده، زندگی روزمره، اطلاعات، حمایت عاطفی، ایمنی خانه، فرهنگ و مذهب، کمک فناوری) که پیش از تولید پاسخ‌ها نوشته شدند، و 60 نوبت واقعی کاربر از نشست‌هایی که در هیچ پنل یا آموزشی نبوده‌اند. قاعده جایگزینی پیش‌ثبت‌شده، افزایش دست‌کم 0.25 در میانگین مرتبط‌بودن، عدم کاهش انسجام و تناسب با سالمندان، و برد در دست‌کم 55 درصد ردیف‌ها زیر **هر دو** داور بود: Qwen3.8-27B محلی و Gemini 3.8 Flash از خانواده‌ای دیگر (جدول ۵-۹).

دو داور درباره خود سامانه مستقر اختلاف دارند: Gemini مرتبط‌بودن پاسخ‌های آن را 2.38 و داور Qwen 3.29 ارزیابی کرد، و توافق دقیق دو داور تنها 44.6 درصد بود. زیر Gemini، Qwen3.5-4B و Gemma 4 با پرامپت سالمندان با فاصله زیاد بهترند (بازه اطمینان افزایش 0.71 تا 1.23 و 0.93 تا 1.39)، اما زیر داور Qwen نه؛ بنابراین طبق قاعده هیچ جایگزینی‌ای انجام نشد. سوگیری خانوادگی به‌تنهایی این اختلاف را توضیح نمی‌دهد، چون Qwen3.5-4B هم‌خانواده سامانه مستقر و داور Qwen است. این نتیجه نشان می‌دهد سطح مطلق آزمون معنایی پیشین، که فقط با داور Qwen سنجیده شد، به داور وابسته است؛ تنها امتیاز انسانی می‌تواند این اختلاف را حل کند. Qwen3.5-4B با پرامپت سالمندان قوی‌ترین نامزد جایگزینی است.

۵-۶-۳ صدای گفتار با دو شنونده خودکار

هر شش صدای فارسی Piper با همان 60 پاسخ تولید و فهم‌پذیری آن‌ها با بازگرداندن به متن توسط دو مدل بازشناسی مستقل (NeMo و Seamless) سنجیده شد؛ DNSMOS نیز به‌عنوان نشانگر خودکار کیفیت سیگنال (و نه طبیعی‌بودن فارسی) گزارش شده است (جدول ۵-۱۰).

صدای Mana فهم‌پذیرترین است و سه صدا به‌طور معنادار از آن فهم‌پذیری کمتری دارند. ganji_adabi از نظر فهم‌پذیری هم‌تراز است و بهترین امتیاز DNSMOS را دارد؛ بنابراین این دو صدا برای سنجش طبیعی‌بودن به مطالعه شنیداری انسانی فرستاده شدند.

در نسخه سوم، ParsVoice-XTTS (تنظیم XTTS-v2 روی 2,200 ساعت گفتار فارسی، با شبیه‌سازی صدای گوینده ManaTTS از دو ضبط با مجوز CC0) نیز سنجیده شد. روی یک قطعه معمولی به اندازه Mana فهم‌پذیر است (میانه خطای نویسه قطعه 5.6 تا 6.2 درصد)، اما حدود یک قطعه از هر ده قطعه از مسیر خارج می‌شود و گفتار بی‌معنا تولید می‌کند؛ میانگین خطای دو شنونده 13.55 درصد شد که به‌طور معنادار از Mana بدتر است (بازه 0.9+ تا 19.3+ واحد درصد). نخستین قطعه صوت جریانی آن روی H100 نیز 307 میلی‌ثانیه طول می‌کشد. بنابراین طبق قاعده ازپیش‌ثبت‌شده به مطالعه شنیداری راه نیافت.

مدل VITS آزمایشگاه (star.text_to_speech) پس از فراهم‌شدن چک‌پوینت تشخیص کسره اضافه با همان پنل و قواعد سنجیده شد. در حالت سرویس فعلی، میانگین خطای دو شنونده 9.89 درصد بود که به‌طور معنادار از Mana بدتر است (بازه 1.4+ تا 8.1+ واحد درصد)، هرچند امتیاز DNSMOS آن (3.39) بالاتر بود. سپس این مدل بدون آموزش مجدد و طبق پروتکلی ازپیش‌ثبت‌شده بهینه شد: خواندن درست اعداد (جداکننده هزارگان که بخشی از عدد را حذف می‌کرد، ساعت، تاریخ، فشار خون، کسر و واحد)، رفع خطای واژه‌بندی که فعل پایانی «می‌خواهید» را حذف می‌کرد، اجرای درون‌فرایندی espeak-ng با واج‌نویسی یکسان، بازنمونه‌برداری یکسان اما ده برابر سریع‌تر، اجرای مدل روی GPU و تنظیم نویز نمونه‌برداری و سرعت گفتار روی متن‌های توسعه. نسخه بهینه روی همان 60 پاسخ به خطای 9.19 درصد، بالاترین DNSMOS در میان همه صداها (3.43) و زمان چهار واژه نخست 116 میلی‌ثانیه روی H100 (416 میلی‌ثانیه روی پردازنده، در برابر 538 میلی‌ثانیه سرویس فعلی) رسید، اما همچنان به‌طور معنادار از Mana فهم‌پذیری کمتری دارد (بازه 0.8+ تا 8.1+ واحد درصد) و طبق همان قاعده به مطالعه شنیداری راه نیافت. فاصله باقی‌مانده به مدل صوتی و جلوی متنی‌ای برمی‌گردد که با آن آموزش دیده است، نه به تنظیمات استنتاج.

۵-۷ تشخیص وقفه

۵-۷-۱ آزمون مصنوعی

روی داده مصنوعی، طبقه‌بند تقویت گرادیانی روی 32 نمونه کنارگذاشته (با 128 نمونه آموزش) به دقت 1.000، امتیاز F1 کلاس وقفه 1.000، نرخ پذیرش نادرست 0.000 و نرخ رد نادرست 0.000 رسید، در حالی که خط پایه انرژی و نرخ گذر از صفر دقت 0.375، امتیاز F1 0.545 و نرخ پذیرش نادرست 1.000 داشت. فاصله اطمینان ویلسون 95 درصد برای دقت مصنوعی 89.28 تا 100 درصد است. زمان استنتاج هر گام روی پردازنده مرکزی 7.931 میلی‌ثانیه بود که در بودجه 20 میلی‌ثانیه‌ای هر فریم جای می‌گیرد.

دقت کامل روی داده مصنوعی، یک نتیجه معنادار درباره عملکرد واقعی نیست؛ داده مصنوعی از همان مدل تولیدی ساخته شده که ویژگی‌ها را جداپذیر می‌کند. این عدد تنها به‌عنوان آزمون بازگشتی نرم‌افزاری ارزش دارد و در این نوشتار به‌عنوان شاهد کارایی آشکارساز ارائه نمی‌شود.

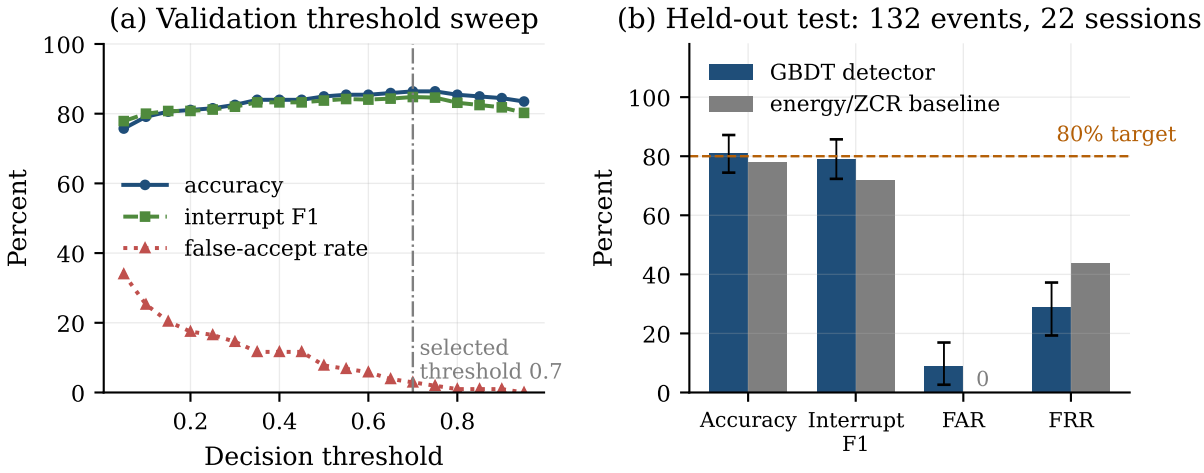
۵-۷-۲ تقریب روی داده ضبط‌شده

ارزیابی معنادار روی رخدادهای برگرفته از صوت واقعی مجموعه داده انجام شد. از 1,730 رخداد کشف‌شده، 1,048 رخداد انتخاب و بر پایه نشست به سه بخش تقسیم شد. آستانه تصمیم تنها روی 24 نشست اعتبارسنجی انتخاب شد (مقدار 0.70) و سپس یک‌بار روی 22 نشست آزمون با 132 رخداد اعمال گردید. نتیجه در جدول ۵-۱۱ آمده است.

ماتریس درهم‌ریختگی آشکارساز پیشنهادی روی مجموعه آزمون چنین است: 60 منفی درست، 6 مثبت نادرست، 19 منفی نادرست و 47 مثبت درست. فاصله اطمینان ویلسون 95 درصد در سطح رخداد برای دقت 73.53% تا 86.83%، برای نرخ پذیرش نادرست 4.23% تا 18.45% و برای نرخ رد نادرست 19.27% تا 40.64% است؛ فاصله امتیاز F1 در همین سطح، خودراه‌انداز رخدادی است (69.47% تا 86.33%). شکل ۵-۳ جست‌وجوی آستانه روی نشست‌های اعتبارسنجی و مقایسه نهایی با خط پایه را نشان می‌دهد.

آشکارساز پیشنهادی در برابر خط پایه، بهبود روشنی در امتیاز F1 کلاس وقفه و کاهش چشمگیر نرخ رد نادرست نشان می‌دهد. خط پایه انرژی نرخ پذیرش نادرست صفر دارد اما این به بهای رد 43.94 درصد از وقفه‌های واقعی به دست آمده است، که در یک سامانه تعاملی به معنای بی‌اعتنایی مکرر به کاربر است.

دقت نقطه‌ای 81.06 درصد از 80 درصد بالاتر است، اما کران پایین فاصله اطمینان بلوکی در سطح نشست 74.44 درصد است و از 80 درصد پایین‌تر می‌رود. مهم‌تر آن‌که برچسب‌های مرجع این ارزیابی، از تفکیک گوینده خودکار به دست آمده‌اند و بازبینی مستقل انسانی ندارند. بنابراین نیازمندی ن۵ با این شواهد «اثبات نشده» است.



شکل ۵-۳: (الف) جست‌وجوی آستانه تصمیم روی نشست‌های اعتبارسنجی؛ خط عمودی، آستانه انتخاب‌شده 0.70 است. (ب) مقایسه آشکارساز پیشنهادی با خط پایه انرژی روی نشست‌های آزمون؛ میله‌های خطا، فاصله اطمینان بلوکی در سطح نشست‌اند.

۵-۷-۳ شبیه‌سازی موقعیت استقرار

کنترل‌گر مستقر (بخش ۴-۴) در شبیه‌سازی‌ای سنجیده شد که میکروفون را در هنگام پخش پاسخ دستیار بازسازی می‌کند: پژواک باقی‌مانده پاسخ (18 تا 32 دسی‌بل پایین‌تر از کاربر و 20 تا 60 میلی‌ثانیه دیرتر)، نویز زمینه، پاسخ اتاق و یک رخداد واقعی در آغاز، میانه یا پایان پاسخ: وقفه (گفتار واقعی فارسی)، بازخورد کلامی واقعی، انفجار نویز واقعی، یا هیچ. شش اجرای توسعه فقط روی صوت بخش آموزشی انجام شد (جدول ۵-۱۲) و گونه برگزیده یک‌بار روی 600 سناریوی بخش آزمون اجرا شد (جدول ۵-۱۳).

دقت و F1 هر دو از 0.80 بالاترند و میانه زمان کم‌کردن صدا 120 میلی‌ثانیه است. توقف کامل بیشتر طول می‌کشد (میانه 786 میلی‌ثانیه)، چون کنترل‌گر صبر می‌کند تا واژه‌ای شنیده شود؛ در این فاصله صدای دستیار کم شده است. بزرگ‌ترین جهش در اجراهای توسعه از دو جا آمد: تأیید واژگانی (که بازخوردهای کلامی و پژواک را از وقفه جدا می‌کند) و رفع مقداردهی ضریب جفت‌شدگی آشکارساز هم‌سخنی. اجرای هفتم، پس از ارزیابی، افزودن 200 میلی‌ثانیه صوت پیش از آغاز به ورودی تأیید واژگانی را آزمود: وقفه‌های بیشتری متوقف شدند (0.98 در برابر 0.95) اما بازخورد و نویز بیشتری هم، پس طبق همان قاعده کنار گذاشته شد.

این نتیجه روی آمیزه‌های شبیه‌سازی‌شده از ضبط‌های واقعی است و نه کاربران زنده؛ پژواک به‌صورت گفتار تضعیف‌شده و تأخیری دستیار مدل شده و برچسب‌ها از قواعد استخراج و یک بازشناس به‌همراه فهرست واژه‌های شنونده آمده‌اند، نه از انسان.

۵-۸ پیوستگی انتقال تمام‌دوطرفه

آزمون بازگشتی خودکار بستر WebSocket با چهار آزمون گذشت. این آزمون‌ها تأیید می‌کنند که پیش‌بافر 3,200 نمونه‌ای پیش از وقفه با 1,600 نمونه دریافت‌شده پس از آن ترکیب می‌شود و یک ورودی 4,800 نمونه‌ای برای نوبت بعدی می‌سازد. همچنین دریافت تأیید توقف از کارخواه، تله‌متری شناسه زمان اجرا، لغو نوبت، اتصال هم‌زمان، اتصال مجدد، جداسازی وضعیت نشست‌ها، ورودی ناقص یا ساکت، بازیابی از خطای تولید و کمبود حافظه، و حالت نگه‌داری فقط‌سنجه بدون نوشتن پرونده صوتی پوشش داده شده‌اند.

ممیزی نهایی مخزن نیز 206 آزمون موفق با پوشش شاخه‌ای 65 درصد (در برابر حد لازم 60 درصد) و بررسی نوع بدون خطا روی 49 پرونده را ثبت کرده است.

این شواهد پیوستگی را در سطح انتقال سرور اثبات می‌کنند. اجرای مرورگر فیزیکی انجام نشده است و اجرای سخت‌افزار هدف نیز انجام نشده است؛ بنابراین نیازمندی ن۲ به‌صورت نرم‌افزاری برآورده و به‌صورت رسمی اثبات‌نشده باقی می‌ماند.

۵-۹ مسیر مستقیم: هفت نسل آزمایشی

۵-۹-۱ نتیجه کل

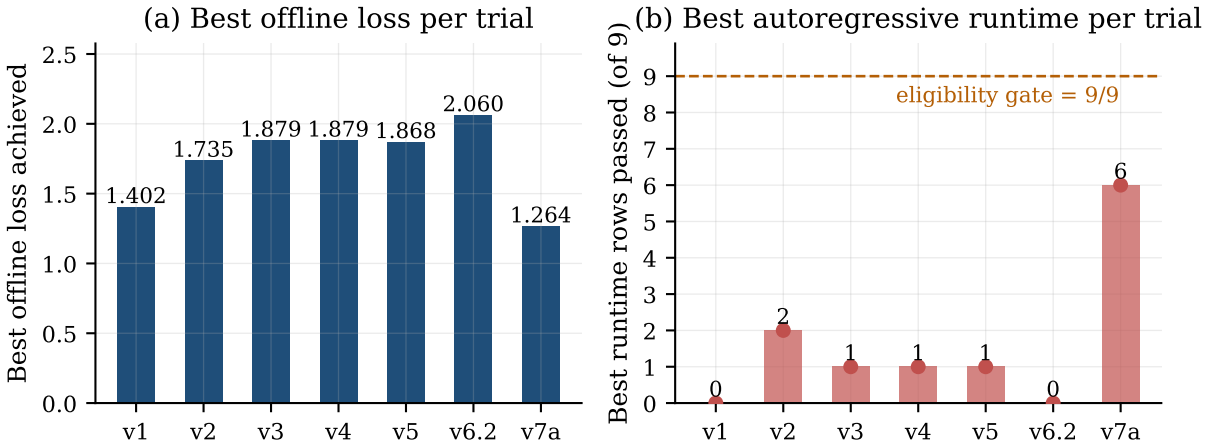
جدول ۵-۱۴ خلاصه هفت نسل آزمایشی را نشان می‌دهد. الگوی مشترک همه نسل‌ها یکسان است: زیان کاهش می‌یابد و شرط اجرای خودرگرسیو برآورده نمی‌شود.

مقادیر کمینه زیان میان نسل‌ها «مستقیماً قابل مقایسه نیستند»، زیرا پنجره متن، مجموعه اعتبارسنجی و شمار نمونه‌های ارزیابی میان نسل‌ها تفاوت دارد. برای نسخه‌های v6.2 و v7a، زیان روی همان داده آموزشی محاسبه شده و یک سنجه درون‌نمونه است. این ستون تنها برای نشان‌دادن روند کاهش زیان در هر نسل آورده شده است.

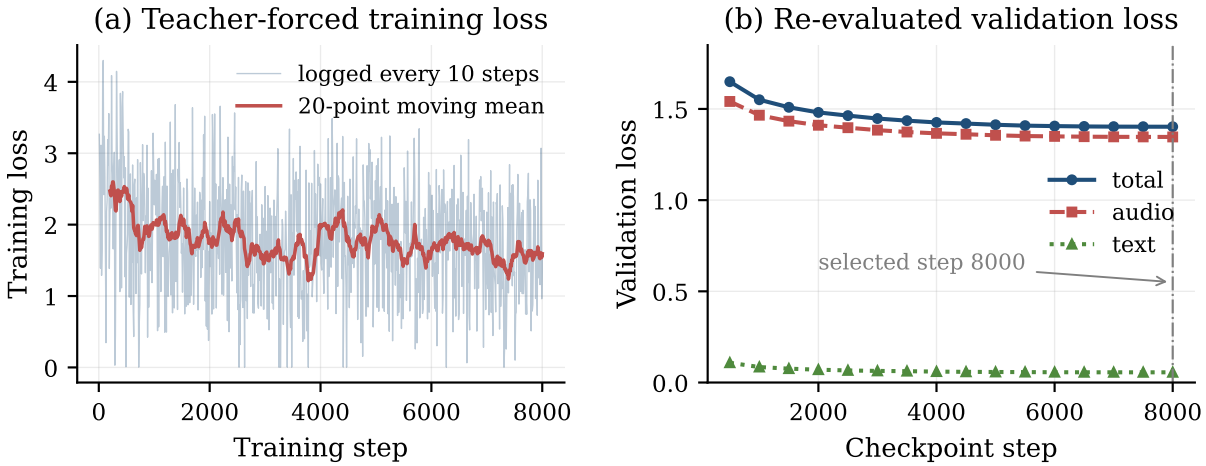
شکل ۵-۴ همین دو محور را در برابر یکدیگر می‌گذارد: کاهش زیان آفلاین در همه نسل‌ها رخ داده است، اما هیچ نسلی به شرط 9 از 9 نرسیده است.

۵-۹-۲ نسخه نخست: زیان کنارگذاشته مثبت، اجرای ناموفق

نسخه نخست تا 8000 گام و با پنجره 20 ثانیه آموزش دید. شکل ۵-۵(الف) روند زیان آموزش و بخش (ب) زیان اعتبارسنجی بازارزیابی‌شده 16 چک‌پوینت را نشان می‌دهد. زیان اعتبارسنجی به‌طور یکنوا کاهش یافت و چک‌پوینت گام 8000 با زیان 1.402444 انتخاب شد.



شکل ۵-۴: (الف) بهترین زیان آفلاین هر نسل. (ب) بیشترین شمار ردیف عبورکرده از پنل اجرای نه‌ردیفی در هر نسل، در برابر شرط پذیرش 9 از 9.



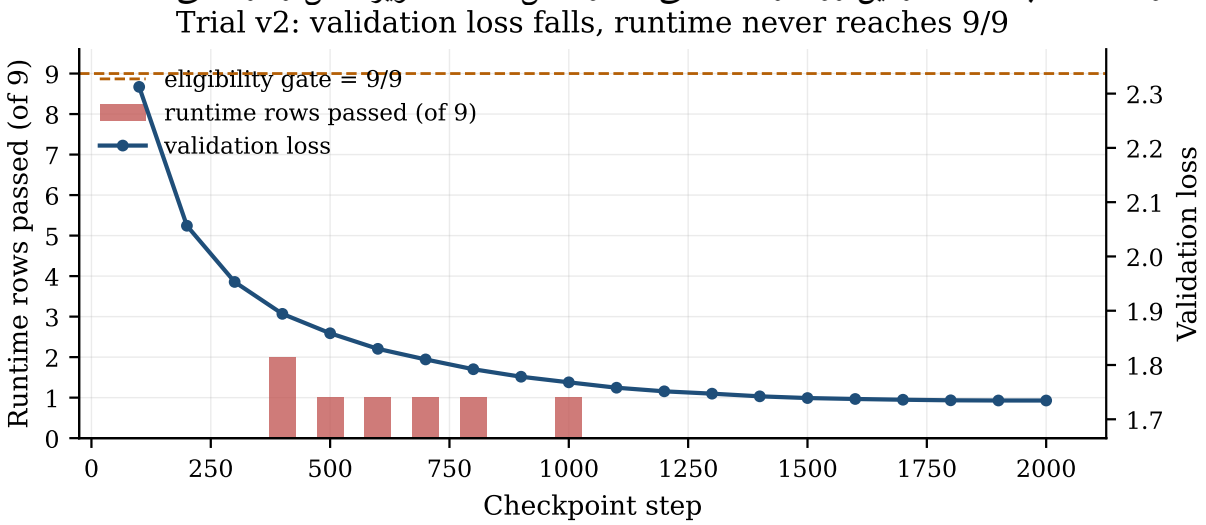
شکل ۵-۵: (الف) زیان آموزش نسخه نخست تحت تحمیل معلم، به همراه میانگین غلتان. (ب) زیان اعتبارسنجی بازارزیابی‌شده به تفکیک مؤلفه متنی و صوتی؛ خط عمودی، چک‌پوینت انتخاب‌شده است.

روی مجموعه آزمون کنارگذاشته با 204 ردیف و 331 بازه، این آداپتر زیان کل 1.7272 با فاصله اطمینان 95 درصد 1.5866 تا 1.8678 داد، در برابر 3.5670 برای مدل پایه تطبیق‌نیافته و 9.9871 برای یک گروه کنترل که در آن علامت همه ماتریس‌های B آداپتر معکوس شده بود. یعنی از دید هدف آموزشی، آداپتر هم نسبت به مدل پایه و هم نسبت به کنترل، بهبود معنادار داشت. زیان کل جمع میانگین آنتروپی متقاطع نشانه‌های متنی و صوتی است؛ به زبان سرگشتگی (نمای میانگین زیان)، سرگشتگی نشانه‌های متنی از 2.53 به 1.19 و سرگشتگی نشانه‌های صوتی از 13.98 به 4.71 کاهش یافت. این همان «کاهش سرگشتگی روی مجموعه آزمون فارسی» است که هدف دوم پیشنهاده می‌خواهد؛ بخش دوم آن هدف، «خروجی فهم‌پذیر»، برآورده نشد.

با این حال، همان آداپتر انتخاب‌شده در سرور جویباری رسمی، صوت تقریباً ساکت و هیچ متنی تولید نکرد. این تناقض، همان مشاهده‌ای است که تعریف شرط پذیرش زمان اجرا برای نسل‌های بعدی را ضروری کرد.

۵-۹-۳ نسخه دوم: روشن‌ترین نمایش شکاف

نسخه دوم با پنجره متن 100 ثانیه و 20 چک‌پوینت نامزد، روشن‌ترین نمایش الگوی مرکزی این پروژه است. جدول ۵-۱۵ چند نقطه از این روند را نشان می‌دهد و شکل ۵-۶ تصویر کامل را ارائه می‌کند.



شکل ۵-۶: نسخه دوم: زیان اعتبارسنجی روی 202 بازه در هر چک‌پوینت به‌طور یکنوا کاهش می‌یابد (خط)، در حالی که شمار ردیف‌های عبورکرده از پنل اجرای نه‌ردیفی (میله‌ها) هرگز به شرط پذیرش نمی‌رسد.

نکته تعیین‌کننده آن است که بهترین رفتار زمان اجرا در گام 400 رخ می‌دهد، یعنی جایی که زیان «بالاتر» است، و با ادامه کاهش زیان تا گام 2000 رفتار زمان اجرا «بدتر» می‌شود و به صفر می‌رسد. این یعنی زیان اعتبارسنجی در این تنظیم، حتی همبستگی مثبت با کیفیت تولید ندارد.

۵-۹-۴ نسخه‌های سوم تا پنجم: آزمون فرضیه‌های هدفمند

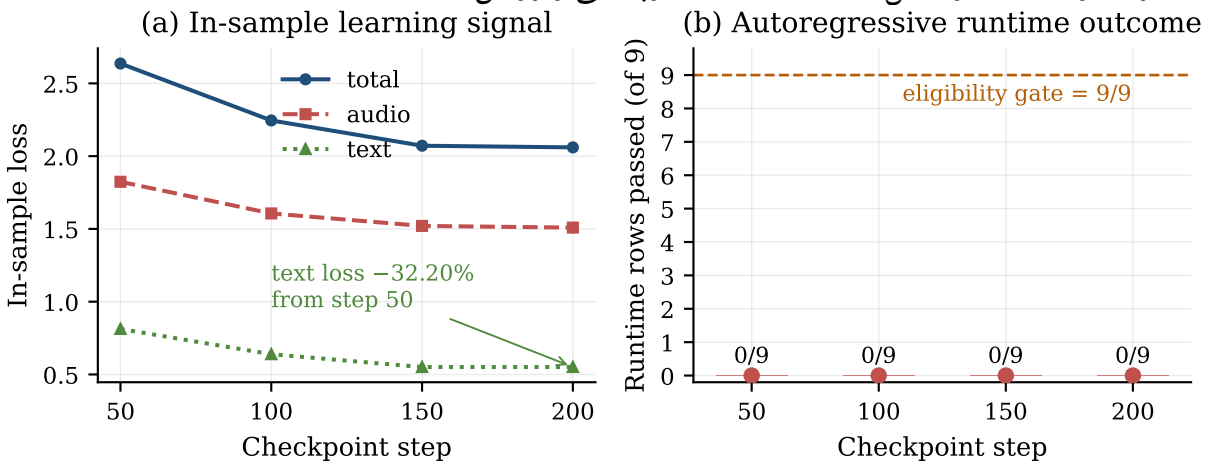
سه نسخه بعدی، فرضیه‌های مشخصی را آزمودند (جدول ۴-۱). نسخه سوم همه درج‌گرها را منجمد کرد و رتبه را به 128 افزایش داد. نسخه چهارم تنها دو درج‌گر متنی را آموزش داد و نسخه پنجم ضریب زیان کتاب رمز نخست را از 100 به 10 کاهش داد. جدول ۵-۱۶ نتیجه ردیف‌به‌ردیف دو نسخه آخر را نشان می‌دهد.

الگوی مشترک این دو جدول قابل توجه است: با کاهش زیان، شمار ردیف‌هایی که «اصلاً گفتاری» تولید می‌کنند از 9 به 4 یا 5 کاهش می‌یابد. یعنی مدل هم‌زمان که هدف آموزشی را بهتر برازش می‌کند، در تولید خودرگرسیو بیشتر به سکوت میل می‌کند. بیشینه حافظه اختصاص‌یافته نسخه چهارم 28.640 گیگابایت بود.

هر سه نسخه با صفر چک‌پوینت واجد شرایط «شکست‌بسته» شدند، هیچ آداپتری انتخاب نشد و دیوار آتش آزمون نهایی هیچ‌گاه باز نگردید.

۵-۹-۵ نسخه ششم: تفکیک ظرفیت از تولید

نسخه v6.2 یک آزمون ابطال درون‌نمونه است: آموزش و ارزیابی روی همان 32 نمونه. نتیجه، همان‌طور که در جدول ۵-۱۷ و شکل ۵-۷ آمده است، دوبخشی و روشن است.



شکل ۵-۷: نسخه v6.2: (الف) زیان درون‌نمونه به‌طور پیوسته کاهش می‌یابد و کاهش زیان متنی از گام 50 به بهترین گام بعدی 32.20 درصد است. (ب) با این حال هر چهار چک‌پوینت 0 از 9 ردیف پنل اجرا را می‌گذرانند.

بهترین زیان متنی پس از گام 50 برابر 0.550852 است که 32.20 درصد کمتر از مقدار گام 50 (0.812474) و بالاتر از معیار ازپیش‌تعریف‌شده 30 درصد است. یعنی این آداپتر «ظرفیت» برازش هدف آموزشی را دارد.

در همان حال، هر چهار چک‌پوینت 0 از 9 ردیف پنل اجرا را می‌گذرانند و در هر چک‌پوینت تنها یک ردیف از نه ردیف هم‌زمان متن و گفتار تولید می‌کند. نتیجه‌گیری دقیق چنین است:

> نسخه v6.2 هدف آموزشی محدود درون‌نمونه را آموخت، اما رفتار آموخته‌شده به تولید خودرگرسیو قابل اتکای گفتار و متن فارسی منتقل نشد.

هیچ چک‌پوینتی از هیچ‌یک از شش نسل نخست، واجد شرایط استقرار نیست و هیچ آزمون نهایی برای مسیر مستقیم باز نشد. عبارت «مدل Moshika با موفقیت برای فارسی تنظیم شد» با این شواهد «نادرست» است. نتیجه صحیح، «آزمایش منفی با سیگنال یادگیری مثبت» است.

۵-۹-۶ نسخه هفتم: برداشتن گلوگاه توکن‌ساز

نسخه v7a روی همان 32 نمونه و همان پنل نُه‌ردیفی، بزرگ‌ترین بهبود تولید خودرگرسیو در کل آزمایش‌های Moshi را نشان داد (جدول ۵-۱۸). زیان متنی درون‌نمونه با واداشت معلم از 1.124 در گام 50 به 0.0149 در گام 150 رسید و از همان گام، کارساز رسمی روی 8 ردیف از 9 ردیف گفتار شنیدنی (RMS حدود 0.07 تا 0.19) همراه با متن روان شبه‌فارسی تولید کرد.

با این حال شرط «هر نُه ردیف» برقرار نشد: سه ردیف گام 150 با خطای پیشوند 0.76 و 0.91 (کمی بالاتر از حد 0.75) و یک ردیف همیشه ساکت رد شدند. سنجه ثانویه ازپیش‌ثبت‌شده نیز منفی است: گفتار گام 200 با بازشناس مستقر میانگین خطای پیشوند 0.88 دارد و هیچ ردیفی به حد 0.75 نمی‌رسد. بنابراین طبق پروتکل، آموزش کامل v7b آغاز نشد و آزمون مهروموم‌شده گشوده نشد. نتیجه دوگانه است: گلوگاه توکن‌ساز واقعی است و برداشتن آن خروجی تقریباً ساکت را به گفتار شنیدنی همراه با متن تبدیل کرد، اما تنها مانع نیست؛ متن تولیدی با وجود زیان واداشت معلم نزدیک صفر از هدف حفظ‌شده فاصله می‌گیرد، که نشانه همان شکاف واداشت معلم و تولید آزاد (بخش ۲-۴-۲) است.

۵-۱۰ مسیر ورودی گفتاری

جدول ۵-۱۹ سه بازوی ورودی گفتاری را با سامانه تولیدی روی 60 نوبت طبیعی و 60 درخواست سالمندان (با صدای شبیه‌سازی‌شده سالمند: دو صدای مردانه Piper، سرعت 0.85 و نویز اتاق) مقایسه می‌کند.

آداپتر زیان کنارگذاشته را از 1.296 به 0.712 رساند، اما مرتبط‌بودن بهترین بازوی گفتاری 0.75 کمتر از سامانه تولیدی است (بازه اطمینان اختلاف 1.05- تا 0.46-)؛ بنابراین طبق قاعده ازپیش‌ثبت‌شده نتیجه منفی است و سامانه آبشاری باقی ماند. سه نکته از این مقایسه برمی‌آید. نخست، حذف بازشناسی حتی با همان مدل زبانی کیفیت را کم می‌کند (2.49 در برابر 1.98)؛ گلوگاه، فهم گفتار فارسی در Gemma است و نه تولید متن فارسی. دوم، خودتقطیری روی گفتار هم‌دامنه کمک می‌کند ولی بیرون از دامنه آسیب می‌زند: روی نوبت‌های واقعی، آداپتر بیشتر فاصله تا معلم متنی خود را پر کرد (1.65 به 1.97، معلم 2.03)، اما روی درخواست‌های با صدای مصنوعی بدتر شد (2.32 به 2.13). سوم، صرفه‌جویی زمانی ناچیز است، چون بازشناسی CTC تنها حدود 20 میلی‌ثانیه به زمان تا نخستین توکن می‌افزاید.

با داور دوم (Gemini)، تصویر وارونه می‌شود: سامانه تولیدی پایین‌ترین مرتبط‌بودن را می‌گیرد (1.91)، Gemma متنی با پرامپت سالمندان 3.00، و مسیر گفتاری بدون آموزش 2.18 و با آداپتر 2.52. قاعده تصمیم با داور نخست ثبت شده بود و نتیجه رسمی منفی می‌ماند، اما این اختلاف همان اختلاف دو داور درباره

پاسخ‌گوی مستقر است. در هر دو داور، حذف بازشناسی کیفیت را کم می‌کند. مدل بزرگ‌تر Gemma 4 12B نیز گفتار فارسی را بهتر نمی‌فهمد: مسیر گفتاری آن زیر هر دو داور از نسخه E4B ضعیف‌تر است (1.48 و 1.63)، در حالی که حالت متنی آن بهتر است.

۵-۱۱ تأخیر، حافظه و آزمون حلقه‌ای مرورگر

سامانه نهایی با آزمون حلقه‌ای خودکار بخش ۴.۶ پیشنهاده سنجیده شد: مرورگر Chromium بدون رابط، صفحه واقعی کارخواه را با یک میکروفون جعلی که گفته‌های ضبط‌شده فارسی 1 تا 5 ثانیه‌ای را پخش می‌کند باز می‌کند، و صوت همان مسیر کاربر واقعی را می‌پیماید. زمان‌ها با ساعت کارخواه اندازه‌گیری شدند: از قابی که پایان آوایی گفتار در آن است تا آغاز زمان‌بندی‌شده نخستین بند پاسخ. پروتکل پیش از اجرا ثبت شد و هر نوبت برنامه‌ریزی‌شده (حتی بی‌پاسخ) در مخرج است.

حافظه. نیازمندی ن۶ پردازنده گرافیکی 12 تا 24 گیگابایتی است و چنین سخت‌افزاری در دسترس نبود؛ این انحراف اعلام شده است. برای سنجش «جاشدن»، سرور مدل زبانی به سهم 0.105 از حافظه H100 محدود شد تا بخش گرافیکی کل سامانه در یک کارت 12 گیبی‌بایتی (MiB 12,288) جا شود. بیشینه اندازه‌گیری‌شده در اجرای نهایی **MiB 11,336** (GiB 11.1) بود: MiB 9,730 رزرو مدل زبانی و MiB 1,606 بازشناسی (در اجرای نخست MiB 10,994)؛ گفتارساز و آشکارساز گفتار روی پردازنده اجرا می‌شوند. سرعت محاسبه اما همان H100 است.

دو اجرا. اجرای نخست (v1) با آغاز پیش‌دستانه پس از 160 میلی‌ثانیه سکوت انجام شد. چون نخستین بند حدود 390 میلی‌ثانیه پس از پایان گفتار آماده می‌شد، یعنی بسیار دیرتر از تأیید پایان نوبت (256 میلی‌ثانیه)، آغاز زودتر کار پیش‌دستانه بدون تغییر در زمان تأیید یا بریدن نوبت، تأخیر را کم می‌کند. با پروتکلی ازپیش‌ثبت‌شده، مقدارهای 64، 96، 128 و 160 میلی‌ثانیه روی 60 گفته توسعه که در هیچ پنل آزمونی نبودند سنجیده شدند و قاعده، 96 میلی‌ثانیه را برگزید (صدک نود تأخیر شنیدنی 488 در برابر 541 میلی‌ثانیه برای مقدار پیشین). اجرای دوم (v2) همان پنل‌های آزمون را با این مقدار دوباره سنجید؛ این سنجش دوم همان پنل‌هاست و به همین عنوان گزارش می‌شود (جدول ۵-۲۰).

در اجرای نهایی هیچ نوبتی بی‌پاسخ نماند و میانگین (372) و صدک نود (431) پنل اصلی زیر 500 میلی‌ثانیه‌اند؛ خوانش سخت‌گیرانه «هر نوبت زیر 500 میلی‌ثانیه» نیز برای پنل اصلی برآورده است (بیشینه 491). با افزودن تأخیر خروجی گزارش‌شده مرورگر (حدود 42 میلی‌ثانیه)، صدک نود 473 و 98 درصد نوبت‌ها زیر 500 میلی‌ثانیه‌اند. صدک نود گفتار شبیه‌سازی‌شده سالمند 446 میلی‌ثانیه است و تنها یک نوبت از 80 از 500 میلی‌ثانیه گذشت. سهم مراحل (میانه، از آغاز پیش‌دستانه): بازشناسی 65، نخستین توکن 42

میلی‌ثانیه پس از آن، کامل‌شدن نخستین بند 85 و ساخت صوت آن 56 میلی‌ثانیه، به اضافه 96 میلی‌ثانیه سکوت پیش از آغاز پیش‌دستانه.

وقفه در مرورگر واقعی. در 60 نوبت با وقفه واقعی و 60 نوبت با بازخورد کلامی واقعی (برگزیده با بازشناس مستقل)، 47 وقفه متوقف شد و 8 بازخورد به‌اشتباه متوقف شد: دقت **0.825** و F1 **0.817** (اجرای نخست 50 وقفه و همان 8 توقف نابه‌جا: 0.850 و 0.847؛ تفاوت سه رخداد در 60 درون نوسان نمونه‌گیری است). میانه زمان کم‌کردن صدا از قاب آغاز تشخیص‌داده‌شده 44 میلی‌ثانیه (صدک نود 60) و میانه زمان توقف 507 میلی‌ثانیه بود؛ زمان از آغاز آوایی واقعی در شبیه‌سازی 120 میلی‌ثانیه بود (بخش ۵–۷–۳).

پاسخ پس از وقفه. پیشنهاده می‌خواهد وقفه در زمان‌های آغاز، میانه و پایان پاسخ شبیه‌سازی و انسجام پاسخ تازه سنجیده شود. در 30 گفت‌وگوی ازپیش‌نوشته، یک درخواست سالمندان و سپس یک پرسش تکمیلی وابسته به آن (مانند «صبر کن، من زانوم درد می‌کنه، باز هم پیاده‌روی کنم؟») با صدای ساخته‌شده کاربر پخش شد: یک بار روی پاسخ دستیار (0.8، 1.8 یا 3.0 ثانیه پس از پایان درخواست) و یک بار به‌صورت نوبت عادی پس از پایان پاسخ. از 27 وقفه‌ای که در حین پخش رسید، 24 پاسخ را متوقف کرد (آغاز و میانه 10 از 10، پایان 4 از 7). دو داور خودکار پاسخ به پرسش تکمیلی را در دو حالت هم‌تراز دانستند: مرتبط‌بودن 1.67 در برابر 1.67 نزد Gemini و 2.90 در برابر 2.80 نزد Qwen، با بهره‌گیری یکسان از بافت درخواست نخست؛ بنابراین معیار ازپیش‌ثبت‌شده (حداکثر 0.25 کاهش) برآورده شد. سطح مطلق امتیاز، سطح خود پاسخ‌گوست. در نخستین اجرای این آزمون، مکث‌های گفتارساز در میان جمله‌های کاربر باعث شد تشخیص پایان گفتار درخواست‌ها را زودهنگام ببندد؛ آن اجرا امتیازدهی نشد و جمله‌ها بدون مکث داخلی دوباره ساخته شدند (این پدیده در گفتار واقعی نیز رخ می‌دهد؛ بخش ۵–۱۲).

این آزمون حلقه‌ای خودکار روی میزبان مشترک H100 است: حافظه یک کارت 12 گیگابایتی رعایت شده اما سرعت آن نه، کاربر انسانی و مسیر فیزیکی میکروفون و بلندگو (و بنابراین پژواک صوتی) در کار نیست. این همان شرط سخت‌افزار هدف پیشنهاده نیست.

۵–۱۲ تحلیل خطا

پیشنهاده می‌خواهد حالت‌های شکست دسته‌بندی شوند. جدول ۵–۲۱ شکست‌های هر مرحله را از رسیدهای همین فصل کنار هم می‌گذارد.

۵-۱۳ مطالعه انسانی

ابزار مطالعه شنیداری کوچک، یک صفحه فارسی خودبسنده است که بدون ضبط صدا و بدون پرسیدن نام اجرا می‌شود: رضایت و گروه سنی، امتیاز طبیعی‌بودن (1 تا 5) برای 8 جمله با صدای Mana، همان 8 جمله با صدای ganji_adabi، 6 نمونه گفتار طبیعی انسانی به‌عنوان لنگر و یک پرسش کنترل توجه، و سپس سه گفت‌وگوی ضبط‌شده از سامانه زنده (پرسش و پاسخ، بازخورد کلامی در میانه پاسخ، و وقفه با پرسش تازه) با امتیاز سرعت پاسخ، واکنش به وقفه، رضایت و تمایل به استفاده. برای داوری میان دو داور خودکار پاسخ‌گو، هشت درخواست سالمندان با دو پاسخ (سامانه مستقر و Qwen3.5-4B با پرامپت سالمندان) به ترتیب تصادفی نشان داده می‌شود و شرکت‌کننده پاسخ بهتر را برمی‌گزیند. پروتکل و روش تحلیل پیش از ارسال ثبت شد.

نتایج این مطالعه هنگام نگارش این نسخه هنوز دریافت نشده است.

تا رسیدن پاسخ شرکت‌کنندگان، هیچ ادعایی درباره طبیعی‌بودن گفتار یا تجربه سالمندان مطرح نمی‌شود.

۵-۱۴ بده‌بستان تأخیر، اندازه و کیفیت

جدول ۵-۲۲ همه نامزدهای سنجیده‌شده هر جزء را با اندازه، کیفیت و تأخیر کنار هم می‌گذارد (پرسش ۳ پیشنهاده). شمار پارامترها از خود فایل‌های مدل شمرده شد.

سه الگو دیده می‌شود. نخست، در این بازه اندازه کیفیت نمی‌خرد: کوچک‌ترین بازشناس (117 میلیون پارامتر، تنظیم‌شده روی فارسی) از همه نامزدهای یک تا نُه میلیارد پارامتری عمومی دقیق‌تر است، و تنها مدل دقیق‌تر از آن، Seamless، خودش روی فارسی تنظیم شده و بیش از ده برابر کندتر است. در گفتارسازی نیز کوچک‌ترین مدل (Piper، 15.7 میلیون پارامتر) هم فهم‌پذیرترین و هم سریع‌ترین است. دوم، در پاسخ‌گو و ورودی گفتاری، دو داور درباره کیفیت اختلاف دارند و هیچ نامزد بزرگ‌تری زیر هر دو داور بهتر نیست؛ مدل ورودی گفتاری تنها مزیت تأخیر دارد (67 در برابر 86 میلی‌ثانیه)، که با بازشناسی جداگانه در حدود 60 میلی‌ثانیه جبران‌پذیر است. سوم، بزرگ‌ترین مدل، یعنی مدل سرتاسری 7.7 میلیارد پارامتری، با آموزش کم‌هزینه به گفتار فهم‌پذیر فارسی نرسید. برای فارسی بی‌درنگ با این منابع، بهترین نقطه بده‌بستان، اجزای کوچک و تخصصی‌شده برای فارسی است.

۵-۱۵ وضعیت نهایی نیازمندی‌ها

جدول ۵-۲۳ وضعیت هر هفت نیازمندی جدول ۱-۱ را در برابر شواهد به‌دست‌آمده قرار می‌دهد.

شواهد ن۲ ، ن۳ و ن۵ خودکار (آزمون حلقه‌ای مرورگر و شبیه‌سازی از ضبط‌های واقعی) و روی H100 است، نه آزمون انسانی یا سخت‌افزار هدف. ن۴ برچسب انسانی ندارد. ن۵ با ویژگی‌های صوتی تعیین‌شده در تعریف پروژه به‌تنهایی برآورده نشد؛ تأیید واژگانی با بازشناس گفتار جایگزین آن شد.

از چهار قلم خروجی مورد انتظار تعریف پروژه، سه قلم تولید و مستند شده‌اند: نمونه اولیه کارا برای مسیر آبشاری، کد منبع مستند با مجوز آزاد و مجموعه آزمون خودکار، و مجموعه داده مکالمه فارسی. برای قلم چهارم، ابزار مطالعه شنیداری و روش تحلیل آن ثبت شده است؛ یافته‌های تجربی سالمندان تنها پس از رسیدن پاسخ شرکت‌کنندگان قابل گزارش است.

جدول ۵-۲: مشخصات مجموعه داده مکالمه فارسی مشتق‌شده و ممیزی خودکار آن

شاخص	مقدار
موجودی زیرنویس کانال‌ها	775.887 ساعت
برنامه‌های بلند موجودی	1,442
برنامه‌های انتخاب‌شده	309
پنجره‌های نامزد	1,129
ساعت نامزد پس از انتخاب	219.946 ساعت
ساعت چندگویندگی طبقه‌بندی‌شده خودکار	207.154 ساعت
جفت‌های پاسخ بدون بازاستفاده	6,754
ساعت صوت منبع جفت‌ها	123.796 ساعت
گویندگان	407
نشست‌ها	162
جفت‌های خروجی استریو	6,754
ساعت استریوی خروجی	108.584 ساعت
تفکیک آموزش / اعتبارسنجی / آزمون	6,419/131/204
نشت گروهی	0
پرونده‌های گم‌شده در ممیزی	0
شکست ممیزی خودکار	0
نامزدهای خودکار رخداد تعاملی	770
از آن، وقفه‌مانند / بازخوردمانند	717/53
ردیف‌های تأییدشده توسط انسان	0

جدول ۵-۳: نتیجه پنل ثابت اعتبارسنجی سامانه آبشاری

شاخص	مقدار
ردیف‌های فهرست‌نامه اعتبارسنجی	131
واحد تفکیک	شناسه نشست منبع
نشت تفکیک	0
ردیف‌های ارزیابی‌شده ازپیش‌تعریف‌شده	9
پاسخ‌گوی متنی پنل	Qwen2.5-0.5B-Instruct
ردیف‌های عبورکرده از همه شروط	9/9
ردیف‌های با پاسخ جایگزین قاعده‌محور	0/9
ردیف‌های با تلاش دوباره زبانی	0/9
خطای سرویس بازشناسی	0
شکست بارگذاری یا تولید مدل زبانی	0/9
کمینه سهم نویسه فارسی در رونویسی	1.000
کمینه سهم نویسه فارسی در پاسخ	1.000
پاسخ‌های صوتی غیرساکت	9/9
کمینه ریشه میانگین مربعات صوت پاسخ	0.133529
ردیف‌های آزمون نهایی استفاده‌شده	0

جدول ۵-۴: اندازه‌گیری‌های هر ردیف پنل اعتبارسنجی سامانه آبشاری

ردیف فهرست‌نامه	نویسه رونویسی	مدت صوت پاسخ (ثانیه)	ریشه میانگین مربعات	زمان تولید کامل (ms)	عبور
0	35	4.644	0.184925	4895.3	بله
16	541	5.352	0.162841	5473.7	بله
32	5031	7.535	0.210650	13270.2	بله
48	1237	9.857	0.191641	7414.3	بله
65	445	9.288	0.162643	6664.3	بله
81	2398	7.465	0.133529	12709.4	بله
97	77	3.448	0.193290	2072.4	بله
113	405	5.259	0.191777	3674.2	بله
130	142	8.824	0.154569	5584.7	بله

جدول ۵-۵: نتیجه تقریب خودکار بازبازشناسی گفتار تولیدشده

شاخص	مقدار
ردیف‌های معتبر / خطای سرویس بازشناسی	9/0
واژه‌های مرجع / ویرایش‌های واژه	171/52
نرخ خطای واژه تجمیع خرد	30.41%
نرخ خطای واژه میانگین کلان	32.01%
نرخ خطای واژه، میانه / صدک ۹۵ / بیشینه	28.00%/49.40%/54.55%
نویسه‌های مرجع / ویرایش‌های نویسه	658/47
نرخ خطای نویسه تجمیع خرد	7.14%
نرخ خطای نویسه میانگین کلان	7.13%
نرخ خطای نویسه، میانه / صدک ۹۵ / بیشینه	7.50%/9.40%/9.62%
ردیف‌های با تطابق کامل واژه‌ای	0/9
ردیف‌های با تطابق کامل نویسه‌ای	0/9

جدول ۵-۶: نتیجه آزمون نهایی معنایی خودکار روی 40 ردیف گروه‌ناهمپوشان

شاخص	مقدار
ردیف‌های آزمون	40
نشست‌های منبع	5
فراخوانی معتبر داور / مورد انتظار	240/240
فراخوانی ناموفق داور	0
نرخ توافق تکرار داور	1.00
میانگین ارتباط نامزد	3.150
میانگین ارتباط خط پایه	1.425
میانگین ارتباط مرجع هم‌ترازشده	0.950
میانگین انسجام نامزد	3.325
میانگین انسجام خط پایه	1.525
بهبود ارتباط نسبت به خط پایه	+1.725
بهبود انسجام نسبت به خط پایه	+1.800
برد زوجی ارتباط	27/40 (67.5%)
ارتباط حداقل دو	35/40 (87.5%)
تلاش دوباره تولید نامزد	0
صوت نامعتبر نامزد	0

جدول ۵-۷: شروط خودکار ازپیش‌تعریف‌شده آزمون نهایی و مقادیر مشاهده‌شده

شرط	آستانه	مشاهده	وضعیت
میانگین ارتباط نامزد	⩾ 2.00	3.150	برآورده
میانگین انسجام نامزد	⩾ 2.50	3.325	برآورده
بهبود ارتباط	⩾ 0.50	1.725	برآورده
بهبود انسجام	⩾ 0	1.800	برآورده
نرخ برد زوجی ارتباط	⩾ 0.60	0.675	برآورده
نرخ ارتباط حداقل دو	⩾ 0.70	0.875	برآورده
اعتبار کامل مکانیکی	240/240	240/240	برآورده

جدول ۵-۸: مقایسه نامزدهای بازشناسی گفتار روی 344 قطعه PSRB با رونوشت انسانی

Candidate	CER	WER	CER (senior)	Median latency
NeMo v4 CTC (deployed)	9.44%	23.95%	15.63%	58 ms
NeMo v6 CTC	10.15%	24.34%	16.36%	60 ms
NeMo v4 RNNT	13.40%	26.81%	22.10%	61 ms
omniASR CTC 1B	14.04%	36.38%	14.87%	56 ms
Seamless v5 fine-tune (accuracy reference)	**6.92%**	**21.03%**	**10.38%**	671 ms
Seamless v6 (step 55000)	8.99%	23.28%	10.44%	855 ms
Qwen3-ASR 1.7B	20.47%	49.46%	24.97%	1466 ms
Gemma 4 E4B (audio input)	21.04%	42.67%	26.16%	2632 ms
Whisper large-v3	23.02%	47.31%	25.46%	1101 ms

جدول ۵-۹: پاسخ‌گوهای نامزد زیر دو داور (مقیاس 0 تا 4؛ افزایش نسبت به سامانه مستقر)

	Qwen3.8 judge		Gemini judge	
Arm	Relevance	Appr.	Relevance (gain, win)	Appr.
Qwen3-4B, prompt-v2 (deployed)	3.29	2.83	2.38	2.02
Qwen3-4B, elderly prompt	2.91	2.98	2.83 (+0.44, 47%)	2.57
Qwen3.5-4B, elderly prompt	**3.31**	**3.58**	3.36 (+0.98, 58%)	3.55
Gemma 4 E4B, elderly prompt	3.00	3.49	**3.54** (+1.16, 60%)	**3.77**

جدول ۵-۱۰: فهم‌پذیری خودکار صداهای فارسی Piper (میانگین خطای نویسه دو شنونده)

Voice	Mean CER	Δ vs Mana (95% CI)	DNSMOS OVRL	First 4 words
mana (deployed)	**5.82%**	–	3.13	84 ms
ganji_adabi	6.93%	$[-1.1, +4.9]$ pp	**3.40**	92 ms
gyro	7.30%	$[+0.1, +4.0]$ pp	3.30	61 ms
reza_ibrahim	8.39%	$[+0.6, +5.2]$ pp	3.26	102 ms
ganji	9.02%	$[-1.3, +11.2]$ pp	3.29	61 ms
amir	11.73%	$[+4.5, +7.6]$ pp	3.32	63 ms

جدول ۵-۱۱: نتیجه تقریب آشکارساز وقفه روی رخدادهای صوت ضبط‌شده با نشست‌های کنارگذاشته

سنجه	آشکارساز پیشنهادی	خط پایه انرژی	فاصله اطمینان 95% آشکارساز (بلوکی در سطح نشست)
دقت	81.06%	78.03%	74.44% – 87.18%
امتیاز F1 وقفه	78.99%	71.84%	72.34% – 85.71%
نرخ پذیرش نادرست	9.09%	0.00%	2.63% – 16.92%
نرخ رد نادرست	28.79%	43.94%	19.30% – 37.23%

جدول ۵-۱۲: اجراهای توسعه شبیه‌سازی (فقط بخش آموزشی)

Run	Change	Dev accuracy / F1
dev3	duration/MLP confirm + double-talk detector	0.687 / 0.624
dev4	lexical ASR confirm with echo rejection	0.840 / 0.765
dev5	+ coupling prior, wider echo matching, function words	0.920 / 0.862
dev6	+ one-frame duck (latency tie-break)	0.913 / 0.856
dev7	+ 200 ms confirm pre-roll (not kept)	0.900 / 0.840

جدول ۵-۱۳: نتیجه یک‌باره شبیه‌سازی روی 600 سناریوی آزمون (بازه اطمینان 95 درصد ویلسون)

Measure	Value
Accuracy (interrupt = positive)	**0.933** (0.910–0.951)
F1	**0.880**
Interruptions stopped (recall)	0.980 (0.943–0.993)
Stop rate: backchannel / noise / no event	0.087 / 0.093 / 0.067
Onset → duck, median / p90	**120** / 247 ms (66% ⩽ 150 ms)
Onset → stop, median / p90	786 / 1344 ms

جدول ۵-۱۴: خلاصه هفت نسل آزمایشی مسیر مستقیم. ستون «بهترین اجرا» بیشترین شمار ردیف عبورکرده از ۹ ردیف پنل اجرا در میان همه چک‌پوینت‌های آن نسل است.

نسخه	پنجره (ثانیه)	نامزد	کمینه زیان	بهترین اجرا	واجد شرایط
v1	20	16	1.402	0/9	نه
v2	100	20	1.735	2/9	نه
v3	100	5	1.879	1/9	نه
v4	100	5	1.879	1/9	نه
v5	100	5	1.868	1/9	نه
v6.2	12	4	2.060	0/9	نه
v7a	12	4	1.264	6/9	نه

جدول ۵-۱۵: نمونه‌ای از چک‌پوینت‌های نسخه دوم: زیان اعتبارسنجی به‌طور یکنوا کاهش می‌یابد در حالی که شمار ردیف‌های عبورکرده از پنل اجرا افزایش نمی‌یابد

گام	زیان کل	زیان متنی	زیان صوتی	عبور از پنل
100	2.312407	0.402789	1.909618	0/9
400	1.894230	0.201763	1.692467	2/9
800	1.792216	0.164635	1.627582	1/9
1000	1.768085	0.155691	1.612394	1/9
1500	1.739114	0.144936	1.594178	0/9
2000	1.734574	0.143414	1.591161	0/9

جدول ۵-۱۶: نتیجه هر چک‌پوینت نسخه‌های چهارم و پنجم روی پنل اجرای نه‌ردیفی

	نسخه چهارم			نسخه پنجم		
گام	زیان	گفتار	عبور	زیان	گفتار	عبور
100	2.082125	9/9	1/9	2.082676	9/9	0/9
200	1.948315	7/9	0/9	1.943459	7/9	0/9
300	1.899640	4/9	0/9	1.889862	6/9	0/9
400	1.881632	5/9	1/9	1.870719	5/9	1/9
500	1.879061	5/9	0/9	1.867859	4/9	1/9

جدول ۵-۱۷: نسخه v6.2: سیگنال یادگیری درون‌نمونه مثبت در برابر نتیجه اجرای خودرگرسیو منفی

گام	زیان کل	زیان متنی	زیان صوتی	عبور از پنل
50	2.636405	0.812474	1.823931	0/9
100	2.245344	0.638987	1.606357	0/9
150	2.071542	0.550852	1.520690	0/9
200	2.060297	0.551183	1.509114	0/9

جدول ۵-۱۸: شمار ردیف‌های پذیرفته پنل نُه‌ردیفی در آزمون ظرفیت درون‌نمونه

Experiment (same 32 rows)	Step 50	Step 100	Step 150	Step 200
v6 (Persian script, turn-level span, sampled text)	0/9	1/9	1/9	1/9
v6.1 (v6 weights, greedy text; controlled baseline)	0/9	0/9	1/9	3/9
v6.2 (Persian script + text-input dropout)	0/9	0/9	0/9	0/9
v7a (romanized phonemes + word timing)	0/9	0/9	**6/9**	4/9

جدول ۵-۱۹: مسیر ورودی گفتاری در برابر سامانه آبشاری (داور Qwen3.8-27B)

Arm	Rel. nat.	Rel. eld.	Rel. all	Coh.	First token
ASR → Qwen3-4B (deployed)	**2.85**	2.75	**2.80**	3.36	86 ms
ASR → Gemma 4 text	2.03	**2.95**	2.49	3.69	98 ms
Gemma 4 audio, zero-shot	1.65	2.32	1.98	3.60	**67 ms**
Gemma 4 audio + LoRA	1.97	2.13	2.05	**3.81**	200 ms*

* سربار سرویس‌دهی آداپتر ادغام‌نشده در vLLM.

جدول ۵-۲۰: تأخیر پایان گفتار تا نخستین صدای دستیار در آزمون حلقه‌ای مرورگر (میلی‌ثانیه). پنل اصلی: 61 گفته PSRB و 140 گفته پیکره؛ سالمند: همان روش با سرعت 0.85 و 3 دسی‌بل آرام‌تر؛ وقفه: نوبت‌های پایه دو پنل وقفه. ستون آخر تأخیر خروجی گزارش‌شده مرورگر را می‌افزاید.

Panel	Run	Turns	Mean	Median	p90	Max	⩽500 ms	Audible p90
Plain	v1	201	418	415	487	537	93.5%	529
	v2	201	**372**	375	**431**	**491**	**100%**	**473**
Elderly	v1	80	435	433	508	575	86.3%	550
	v2	80	**382**	371	**446**	546	98.8%	488
Barge-in	v1	120	399	388	464	509	99.2%	506
	v2	120	**366**	363	**415**	497	100%	457

جدول ۵-۲۱: حالت‌های شکست سامانه و علت سنجیده‌شده هر یک

حالت شکست	بسامد	علت سنجیده‌شده
تأخیر بیش از 500 میلی‌ثانیه	0 از 201 نوبت اصلی و 1 از 80 نوبت سالمند (اجرای نخست: 13 و 11)	در نوبت‌های کند، کندترین مرحله نسبت به میانه‌اش «کامل‌شدن نخستین بند» بود، یعنی توقف‌های تولید توکن روی پردازنده گرافیکی مشترک؛ نه بازشناسی و نه گفتارسازی
وقفه ازدست‌رفته	13 از 60 در مرورگر؛ 2 درصد در شبیه‌سازی	4 بار صدا کم نشد (هیچ قابی بلندتر از پژواک مورد انتظار نبود)؛ 9 بار کم شد اما رونوشت تأیید واژه محتوایی نداشت و پاسخ ادامه یافت
بستن زودهنگام نوبت در میان جمله	15 از 201 گفته اصلی و 7 از 80 گفته سالمند	درنگ میان جمله بلندتر از 256 میلی‌ثانیه تأیید پایان نوبت؛ سامانه با ادامه سخن کاربر پاسخ را متوقف و دو تکه را در تاریخچه نگه می‌دارد، اما نخستین پاسخ ناقص آغاز می‌شود
توقف نابه‌جا روی بازخورد کلامی	8 از 60 در مرورگر؛ 8.7 درصد در شبیه‌سازی	بازشناس واژه شنونده را واژه محتوایی شنید؛ نمونه مشاهده‌شده: «آره آره» به‌صورت «کار» (واج نخست بریده‌شده)
خطای بازشناسی	خطای نویسه 9.44 درصد؛ سالمندان 15.6	گفتار سالمندان (هم‌سو با پیشینه، بخش ۳-۵)؛ نرخ خطای واژه بسیار بیشتر از نرخ خطای نویسه به سبب گوناگونی املایی و پیوسته‌نویسی (بخش ۶-۲)
پاسخ نامرتبط یا ضعیف	داور Gemini: 2.38 از 4	دو داور خودکار درباره کیفیت پاسخ‌گو اختلاف دارند؛ تنها داوری انسانی قطعی است
گفتار ساخته‌شده نافهم	خطای نویسه 5.82 درصد (Mana)	خطاهای تلفظ باقی‌مانده گفتارساز؛ در مدل VITS آزمایشگاه، کسره اضافه و پسوندهای پس از نیم‌فاصله
گفتار نافهم مسیر مستقیم	خطای پیشوند 0.88 (v7a)	گلوگاه توکن‌ساز و شکاف واداشت معلم و تولید آزاد (بخش ۵-۹)

جدول ۵-۲۲: بده‌بستان اندازه، کیفیت و تأخیر نامزدها (کیفیت و تأخیر از همان آزمون‌های بخش‌های پیشین)

Stage	Candidate	Params	Quality	Latency
ASR	NeMo v4 CTC (deployed)	117M	CER 9.44%	58 ms
	omniASR CTC 1B	976M	CER 14.04%	56 ms
	Seamless v5 fine-tune	1.50B	**CER 6.92%**	671 ms
	Whisper large-v3	1.54B	CER 23.02%	1101 ms
	Qwen3-ASR 1.7B	2.35B	CER 20.47%	1466 ms
	Gemma 4 E4B (audio input)	8.61B[a]	CER 21.04%	2632 ms
Responder[b]	Qwen3-4B, prompt-v2 (deployed)	4.02B	2.80 / 1.91	86 ms
	Gemma 4 E4B, elderly prompt	8.61B[a]	2.49 / 3.00	98 ms
Speech input[b]	Gemma 4 E4B, audio in	8.61B[a]	1.98 / 2.18	67 ms
	+ speech LoRA	8.61B[a]	2.05 / 2.52	200 ms
TTS	Piper Mana (deployed, CPU)	15.7M	**CER 5.82%**	84 ms
	Lab VITS, optimized (H100)	36.3M	CER 9.19%	116 ms
	ParsVoice-XTTS (H100)	–	CER 13.55%	1751 ms
Direct S2S	Moshika LoRA (v7a)	7.69B	unintelligible[c]	–

[a] تعداد پارامتر ذخیره‌شده؛ نام مدل به حدود 4 میلیارد پارامتر «مؤثر» اشاره دارد. [b] مرتبط‌بودن پاسخ به همان 120 نوبت گفتاری؛ عدد نخست داور Qwen و عدد دوم داور Gemini؛ تأخیر، نخستین توکن پس از پایان صوت. [c] خطای پیشوند 0.88 نزد بازشناس مستقر.

جدول ۵-۲۳: وضعیت نهایی هفت نیازمندی تعریف پروژه و کلاس شواهد پشتیبان

شماره	وضعیت	شواهد پشتیبان
ن۱	برآورده (مسیر آبشاری جریانی)	آزمون معنایی نهایی 40 ردیفی؛ همه 401 نوبت آزمون حلقه‌ای پاسخ گرفتند
ن۲	برآورده در آزمون حلقه‌ای و شبیه‌سازی	دقت/F1 وقفه 0.82/0.83 در مرورگر و 0.88/0.93 در شبیه‌سازی
ن۳	برآورده با معیار پیشنهاده و با خوانش هرنوبت در پنل اصلی	میانگین 372 و صدک نود 431 میلی‌ثانیه؛ همه نوبت‌ها زیر 500؛ با تأخیر خروجی مرورگر صدک نود 473
ن۴	برآورده	108.584 ساعت خروجی ممیزی‌شده (برچسب خودکار)
ن۵	هدف دقت برآورده با روش دیگر	کنترل‌گر دومرحله‌ای با تأیید واژگانی؛ طبقه‌بند انرژی/زیروبمی/MFCC به‌تنهایی 0.574
ن۶	انحراف اعلام‌شده	حافظه کل سامانه GiB 11.1 اندازه‌گیری شد؛ سرعت روی H100
ن۷	در انتظار پاسخ شرکت‌کنندگان	ابزار و پروتکل ثبت‌شده؛ نتایج هنوز دریافت نشده

فصل ۶

بحث و محدودیت‌ها

این فصل نتایج فصل ۵ را تفسیر می‌کند. چهار مشاهده کلیدی به‌تفصیل بررسی می‌شوند و سپس محدودیت‌ها و ملاحظات اخلاقی و حقوقی برشمرده می‌شوند.

۶-۱ فاصله میان کاهش زیان و تولید معتبر

مهم‌ترین یافته این پروژه، الگویی است که در هر هفت نسل آزمایشی مسیر مستقیم تکرار شد: زیان تحت تحمیل معلم به‌طور یکنوا کاهش یافت و در همان حال شرط اجرای خودرگرسیو هیچ‌گاه برآورده نشد. نسخه دوم روشن‌ترین نمایش این الگو است، زیرا در آن بهترین رفتار زمان اجرا در گام 400 رخ می‌دهد، یعنی جایی که زیان اعتبارسنجی «بالاتر» است، و با کاهش بیشتر زیان تا گام 2000، رفتار زمان اجرا به صفر می‌رسد (شکل ۵-۶).

سه توضیح ممکن برای این مشاهده وجود دارد و شواهد پروژه به تفکیک آن‌ها کمک می‌کند.

توضیح یک: نبود ظرفیت یادگیری. ممکن است آداپتر کم‌رتبه ظرفیت کافی برای نمایش فارسی نداشته باشد. نسخه v6.2 به‌طور خاص برای ابطال همین فرضیه طراحی شد: آموزش و ارزیابی روی همان 32 نمونه. کاهش 32.20 درصدی زیان متنی درون‌نمونه نشان می‌دهد که آداپتر «ظرفیت» برازش هدف را دارد. بنابراین این توضیح رد می‌شود.

توضیح دو: اریبی مواجهه. توضیح سازگارتر با شواهد، همان مفهومی است که در بخش ۲-۴-۲ معرفی شد. در آموزش، مدل همیشه نشانه‌های متنی و صوتی «درست» پیشین را به‌عنوان شرط دریافت می‌کند و

پیش‌بینی یک گام جلوتر مسئله‌ای آسان است، به‌ویژه در معماری «تک‌گویی درونی» که متن هم‌ترازشده با زمان در ورودی حاضر است. اما در تولید خودرگرسیو، مدل باید هم متن و هم صوت را از صفر بسازد. اگر نشانه‌های نخست کمی از توزیع مرجع فاصله بگیرند، مدل به ناحیه‌ای می‌رود که در آموزش ندیده است و خطا به‌صورت تجمعی رشد می‌کند.

مشاهده‌ای که این توضیح را تقویت می‌کند، در جدول ۵-۱۶ دیده می‌شود: با کاهش زیان، شمار ردیف‌هایی که «اصلاً» گفتاری تولید می‌کنند از 9 به 4 یا 5 کاهش می‌یابد. یعنی مدل با برازش بهتر هدف، در تولید مستقل به سکوت میل می‌کند. این رفتار با یک مدل که تنها «به‌قدر کافی یاد نگرفته» سازگار نیست؛ با مدلی سازگار است که آموخته است در حضور متن ورودی مرجع به‌درستی پیش‌بینی کند و در غیاب آن فرو می‌ریزد.

نسخه v6.2 کوشید همین را جبران کند: حذف تصادفی زمان‌بندی‌شده ورودی متنی، سهم نشانه‌های مرجع پنهان‌شده را از 0.25 به 0.75 افزایش می‌داد تا مدل بیاموزد بر پیش‌بینی خودش تکیه کند. این مداخله، سیگنال یادگیری را حفظ کرد اما به تولید معتبر منتقل نشد. توضیح احتمالی آن است که با 32 نمونه آموزشی و 200 گام، بودجه در دسترس برای بازآموزی یک رفتار تولیدی پایدار به‌مراتب کمتر از حد لازم است.

توضیح سه: انگلیسی‌محوری مدل پایه. مدل پایه به‌شدت انگلیسی‌محور است. در نسل‌های نخست مشاهده شد که خروجی چک‌پوینت‌های میانی، گفتار «انگلیسی» است و نه فارسی. یعنی آداپتر نتوانسته توزیع زبان تولیدی را جابه‌جا کند و تنها بر جزئیات آوایی اثر گذاشته است. تلاش نسخه چهارم برای آموزش گزینشی درج‌گرهای متنی، پاسخ مستقیم به همین فرضیه بود و آن نیز کافی نبود.

نتیجه‌گیری روشمند. فارغ از این‌که کدام توضیح سهم بیشتری دارد، یک نتیجه عملی قطعی است و به نظر ما مهم‌ترین سهم علمی این نوشتار است:

> در تطبیق کم‌پارامتر یک مدل گفتاربه‌گفتار به زبانی جدید، زیان اعتبارسنجی تحت تحمیل معلم معیار کافی و حتی معیار قابل اتکایی برای انتخاب چک‌پوینت نیست. آزمون تولید خودرگرسیو در زمان اجرا باید بخشی از معیار انتخاب باشد و نه یک بررسی پس از انتخاب.

اگر پروژه معیار انتخاب را تنها بر زیان بنا کرده بود، چک‌پوینت گام 8000 نسخه نخست، با کمترین زیان اعتبارسنجی و با بهبود معنادار نسبت به مدل پایه (1.7272 در برابر 3.5670 روی داده کنارگذاشته)، به‌عنوان «مدل گفتاربه‌گفتار فارسی» گزارش می‌شد؛ در حالی که همان چک‌پوینت در سرور رسمی صوت تقریباً ساکت و هیچ متنی تولید نمی‌کرد.

۶-۲ چرا نرخ خطای واژه بسیار بیشتر از نرخ خطای نویسه است

در سنجه بازبازشناسی همان 9 خروجی پنل مکانیکی با پاسخ‌گوی Qwen2.5-0.5B، نرخ خطای نویسه 7.14 درصد و نرخ خطای واژه 30.41 درصد است؛ یعنی نرخ خطای واژه بیش از چهار برابر است. این نسبت در نگاه اول نگران‌کننده به نظر می‌رسد اما تا حد زیادی یک اثر «تعریفی» در زبان فارسی است.

سه سازوکار در این فاصله سهم دارند. نخست، **مرز واژه در فارسی**. در تعریف به‌کاررفته، نیم‌فاصله یک مرز واژه به شمار می‌آید. اگر سرویس بازشناسی یک واژه مرکب را با فاصله کامل بنویسد در حالی که مرجع آن را با نیم‌فاصله نوشته است، یک واژه به دو واژه تبدیل می‌شود و این تنها اختلاف، دو ویرایش واژه‌ای تولید می‌کند، در حالی که در سطح نویسه تنها یک نویسه تفاوت دارد. دوم، **یکسان‌نبودن صورت نوشتاری**. برای بسیاری از واژه‌های فارسی چند صورت نوشتاری پذیرفته وجود دارد. سوم، **اثر طول**. میانگین طول واژه در داده این پنل حدود چهار نویسه است؛ در چنین شرایطی هر خطای یک‌نویسه‌ای به‌طور خودکار به یک خطای کامل واژه‌ای تبدیل می‌شود.

شاهد پشتیبان این تفسیر در داده هست: در هر 9 ردیف، شمار نویسه‌های فرضیه و مرجع تقریباً یکسان است (برای نمونه 52 و 52 در ردیف نخست) در حالی که شمار واژه‌ها تفاوت دارد (11 و 12). یعنی محتوای نویسه‌ای تقریباً حفظ شده و اختلاف عمدتاً در بخش‌بندی است.

با این حال، دو محدودیت این تفسیر را باید صریح گفت. نخست، بخشی از خطا می‌تواند از تلفظ نادرست موتور گفتاری بیاید و نه از بخش‌بندی؛ تفکیک این دو سهم بدون گوش‌دادن انسانی ممکن نیست. دوم، سرویس بازشناسی هم در سامانه و هم در اندازه‌گیری مشارکت دارد؛ خطای مشترک آن‌ها می‌تواند نتیجه را به هر دو سمت جابه‌جا کند. بنابراین نرخ خطای نویسه 7.14 درصد را نمی‌توان به «گفتار تولیدی برای انسان کاملاً قابل فهم است» ترجمه کرد.

۶-۳ چرا تطبیق پاسخ‌گو زیان را کم کرد ولی کیفیت را بهتر نکرد

آزمایش بخش ۵-۵-۳ یک تناقض ظاهری دارد: تطبیق کم‌پارامتر پاسخ‌گو زیان توسعه را 31.18 درصد کاهش داد اما در ارزیابی معنایی از خط پایه پیشی نگرفت. پاسخ این تناقض در ماهیت «هدف» آموزشی نهفته است.

هدف آموزشی این آداپتر، بازتولید «نوبت گوینده بعدی» در داده مکالمه بود. اما نوبت گوینده بعدی در یک برنامه گفت‌وگوی طبیعی، پاسخ یک دستیار به یک پرسش نیست. آن نوبت می‌تواند یک تأیید کوتاه، یک تغییر موضوع، یک شوخی، یک پرسش متقابل یا ادامه روایت خود گوینده باشد. مدل با آموزش روی

این هدف، «سبک» نوبت‌گیری طبیعی را بهتر می‌آموزد و زیان کاهش می‌یابد، اما دستورپیروی و پاسخ‌دهی مرتبط را نمی‌آموزد و ممکن است آن را حتی تخریب کند.

شاهد مستقیم و تعیین‌کننده این تفسیر در آزمون نهایی معنایی است: بازوی «مرجع هم‌ترازشده خودکار نوبت گوینده بعدی» کمترین امتیاز ارتباط را گرفت، 0.950، که حتی از خط پایه 0.5 میلیاردپارامتری (1.425) نیز پایین‌تر است (شکل ۵-۲). یعنی داور خودکار، همان هدفی را که آداپتر کوشیده بود تقلید کند، به‌عنوان پاسخ نامرتبط ارزیابی کرده است.

نتیجه عملی این مشاهده برای پژوهش‌های بعدی روشن است: نوبت‌های هم‌ترازشده خودکار از مکالمه طبیعی، مواد «ارزشمندی» برای یادگیری زمان‌بندی گفتار، نوبت‌گیری و پدیده‌های تعاملی‌اند، اما بدون یک مرحله گزینش و بازنویسی، هدف «ضعیفی» برای آموزش پاسخ‌دهی دستورپیرو هستند. همین نکته احتمالاً بخشی از شکست مسیر مستقیم را نیز توضیح می‌دهد، زیرا مدل مستقیم روی همان جفت‌ها آموزش دیده است.

۶-۴ تعارض ساختاری میان نیازمندی‌ها

تحلیل جدول ۳-۱ یک تعارض ساختاری در تعریف پروژه را آشکار می‌کند که ارزش ثبت دارد. نیازمندی ن۲ قابلیت تمام‌دوطرفه را می‌خواهد و نیازمندی ن۳ تأخیر حداکثر 500 میلی‌ثانیه، در حالی که نیازمندی ن۶ اجرا روی پردازنده گرافیکی با 12 تا 24 گیگابایت حافظه را الزام می‌کند.

مدل‌هایی که قابلیت تمام‌دوطرفه «ذاتی» دارند، یعنی جریان کاربر و جریان خود را هم‌زمان مدل می‌کنند، در زمان انجام این پروژه در بازه حافظه هدف جای نمی‌گرفتند. مدل پایه مسیر مستقیم این پروژه در آموزش تا 28.640 گیگابایت حافظه مصرف کرد. در سوی دیگر، معماری آبشاری نخستین در بازه حافظه هدف جای می‌گرفت اما چون کل پاسخ پیش از پخش ساخته می‌شد، تأخیر آن (میانه 5584.7 میلی‌ثانیه برای تولید کامل پاسخ، جدول ۵-۴) از هدف بسیار دور بود.

پروژه این تعارض را با جریانی‌کردن سامانه آبشاری حل کرد: تشخیص پیش‌دستانه پایان گفتار، تولید جریانی توکن، بندبندی و گفتارسازی هر بند به‌محض کامل‌شدن. نتیجه، میانگین 372 و صدک نود 431 میلی‌ثانیه در آزمون حلقه‌ای مرورگر با بخش گرافیکی GiB 11.1 بود؛ تمام‌دوطرفه‌بودن نیز به‌جای مدل ذاتی، با کنترل‌گر دومرحله‌ای بیرونی به دست آمد. هزینه این راه‌حل، از دست رفتن قابلیت‌های «ذاتی» مدل‌های تمام‌دوطرفه مانند پیش‌بینی پیوسته نوبت و بازخورد کلامی خود دستیار است.

۶-۵ ارزش و مرز نتیجه معنایی خودکار

نتیجه آزمون نهایی معنایی، مثبت و از هر هفت شرط ازپیش‌تعریف‌شده عبور کرده است. طراحی این آزمون چند نقطه قوت روشمند دارد: مرحله صلاحیت جدا از آزمون نهایی، شاخص ردیف‌ها و آستانه‌های قفل‌شده پیش از اجرا، دوسوکورسازی و تصادفی‌سازی ترتیب بازوها، کدگشایی قطعی داور، و اعتبار کامل هر 240 فراخوانی با نرخ توافق تکرار 1.00.

با این حال، سه محدودیت آن را از یک نتیجه انسانی جدا می‌کند. نخست، **هم‌خانواده‌بودن داور و نامزد.** داور و نامزد از یک خانواده مدل‌اند؛ پیشینه ارزیابی خودکار نشان داده است که داورها به خروجی مدل‌های هم‌خانواده تمایل نشان می‌دهند [۳۷]. دوم، **کالیبره‌نبودن سنجه‌نامه.** سنجه‌نامه امتیازدهی با امتیاز انسانی فارسی‌زبان کالیبره نشده است؛ بنابراین نمی‌دانیم امتیاز 3.150 از 4 به چه سطحی از رضایت کاربر واقعی متناظر است. سوم، **محدوده معنایی.** این آزمون تنها ارتباط و انسجام را می‌سنجد و درباره درستی واقعی محتوا، ایمنی پاسخ یا طبیعی‌بودن گفتار چیزی نمی‌گوید.

با این مرزها، تفسیر درست چنین است: زنجیره آبشاری، پاسخ‌هایی تولید می‌کند که یک داور خودکار آن‌ها را به‌طور نظام‌مند و با فاصله زیاد (+1.725 در ارتباط) مرتبط‌تر از خط پایه ارزیابی می‌کند. این یک شاهد مهندسی معتبر برای کارکرد سامانه است و نه یک ادعای کیفیت ادراکی.

۶-۶ محدودیت‌ها

محدودیت‌های این پروژه به‌صورت صریح و فهرست‌شده چنین است.

۱. **سخت‌افزار هدف.** ارزیابی روی پردازنده گرافیکی فیزیکی 12 تا 24 گیگابایتی انجام نشد. حافظه کل سامانه با محدودکردن سرور مدل زبانی سنجیده شد (GiB 11.1)، اما سرعت محاسبه همان H100 است؛ تأخیر روی یک کارت مصرفی احتمالاً بیشتر خواهد بود.

۲. **آزمون حلقه‌ای خودکار.** تأخیر و وقفه با مرورگر بدون رابط و میکروفون جعلی سنجیده شد، نه با کاربر انسانی، میکروفون و بلندگوی فیزیکی و پژواک واقعی؛ پژواک در شبیه‌سازی به‌صورت گفتار تضعیف‌شده و تأخیری مدل شد. بیشینه تأخیر (537 میلی‌ثانیه) و صدک نود گفتار شبیه‌سازی‌شده سالمند (508) از 500 بیشترند.

۳. **مطالعه انسانی.** تنها یک مطالعه شنیداری کوچک (5 تا 10 شرکت‌کننده، دور از هم، بر پایه ضبط) طراحی شد و نتایج آن هنگام نگارش این نسخه دریافت نشده بود. تعامل زنده سالمندان سنجیده نشد.

۴. **برچسب‌ها و داوری خودکار.** برچسب‌های وقفه از قواعد استخراج و Gemini و فهرست واژه‌های شنونده آمده‌اند، کیفیت پاسخ با داور LLM و گفتار با بازشناس خودکار سنجیده شده است؛ هیچ‌یک برچسب انسانی نیست. دو داور پاسخ‌گو با یکدیگر تنها 44.6 درصد توافق دقیق دارند.

۵. **روش تشخیص وقفه.** تعریف پروژه تشخیص وقفه با ویژگی‌های انرژی، زیروبمی و MFCC را می‌خواهد؛ طبقه‌بند مبتنی بر این ویژگی‌ها به‌تنهایی روی رخدادهای واقعی تنها 0.574 دقت گرفت و کنترل‌گر مستقر به بازشناس گفتار تکیه دارد، که تأخیر توقف کامل را به حدود نیم ثانیه می‌رساند.

۶. **بازبینی شنیداری داده.** هیچ ردیفی از مجموعه داده «تأییدشده توسط انسان» نیست.

۷. **مسیر مستقیم.** هیچ نسل آزمایشی Moshika و هیچ آداپتر ورودی گفتاری Gemma واجد شرایط استقرار نشد.

۸. **تعمیم.** مجموعه داده از چهار کانال گفت‌وگویی مشتق شده و صدای کاربر سالمند در آزمون‌ها شبیه‌سازی (صدای ماشینی آهسته) است، نه ضبط سالمندان.

۹. **بازتولید کامل.** تنسورهای آداپترهای نسخه‌های دوم تا پنجم حذف شده‌اند و تنها درهم‌سازی‌ها و نتایج آن‌ها باقی است.

۶-۷ ملاحظات اخلاقی، حریم خصوصی و حقوقی

۶-۷-۱ خاستگاه و حقوق داده

مجموعه داده از یک آرشیو داخلی محتوای گفتاری فارسی مشتق شده است. استفاده پژوهشی داخلی از این منابع با تأیید استاد راهنما ثبت شده است. این تأیید «مجوز بازنشر» نیست: صوت خام، زیرنویس خام و مشتقات آن‌ها در مخزن کد قرار نگرفته‌اند و در بسته تحویل پروژه نیز منتشر نمی‌شوند. عبارت «داده عمومی در دسترس، مجوز آموزش یا بازنشر آزاد دارد» نادرست است و در این نوشتار به کار نرفته است.

۶-۷-۲ حریم خصوصی در مطالعه انسانی

سامانه سه حالت نگه‌داری داده دارد: نگه‌داری پرونده صوتی، نگه‌داری تنها بردار ویژگی کاهش‌یافته، و نگه‌داری تنها سنجه‌ها. حالت پیش‌فرض پیشنهادی برای مطالعه انسانی، حالت فقطویژگی است تا گفتار قابل بازسازی شرکت‌کننده ذخیره نشود. آزمون خودکار نیز بررسی می‌کند که در حالت فقطسنجه هیچ پرونده صوتی نوشته نمی‌شود.

در ارزیابی‌های خودکار نیز اصل کمینه‌سازی داده رعایت شده است: مصنوعات نتیجه، متن رونویسی، متن پاسخ و توضیح داور را به‌صورت متن آشکار ذخیره نمی‌کنند و تنها درهم‌سازی و مقادیر تجمیعی نگه می‌دارند. تحلیل توصیفی پس‌نگر بخش ۵-۳ نیز به‌طور صریح بدون خواندن متن آشکار اجرا شد.

۶-۷-۳ مجوز و مرزهای آن

کد منبع و مستندات متعلق به این پروژه با مجوز Apache-2.0 منتشر می‌شوند. این مجوز «شامل» موارد زیر نیست و شرایط مستقل هر یک همچنان حاکم است: اجزای نرم‌افزاری شخص ثالث، وزن‌های مدل‌های زبانی و صوتی، مجموعه داده منبع و مشتقات آن، آداپترهای آموزش‌دیده، رسانه محدودشده و زیرنویس‌ها، و مواد شرکت‌کنندگان مطالعه انسانی. به‌طور خاص، موتور گفتاری مورد استفاده مجوز متفاوتی دارد و تعهدات آن جداگانه باقی می‌ماند.

۶-۷-۴ کاربرد و سوءکاربرد

سامانه‌ای که گفتار فارسی طبیعی تولید می‌کند، قابلیت سوءکاربرد دارد. در شکل کنونی، دو عامل این خطر را محدود می‌کند: صدای خروجی، یک صدای هم‌آمایش‌شده واحد و شناخته‌شده است و شبیه‌سازی صدای افراد پیاده نشده است؛ و پاسخ‌گوی متنی با یک پرامپت قفل‌شده کار می‌کند. با این حال، پروژه هیچ سنجش ایمنی محتوا انجام نداده است و مدل پاسخ‌گو می‌تواند محتوای نادرست تولید کند؛ استفاده از این نمونه اولیه در هر زمینه‌ای که پاسخ نادرست پیامد جدی دارد، بدون یک لایه سنجش ایمنی مجاز نیست.

۸-۶ عبارت‌هایی که این نوشتار از آن‌ها پرهیز کرده است

برای شفافیت، هشت عبارت زیر با شواهد این پروژه **قابل ادعا نیستند**. هر عبارت در گیومه نقل شده است تا روشن باشد که این‌ها ادعاهای این نوشتار نیستند، بلکه فهرست صریح چیزهایی‌اند که **گفته نشده‌اند** و نباید از این پروژه نتیجه گرفته شوند:

- «مدل Moshika با موفقیت برای فارسی تنظیم شد.»
- «تأخیر سامانه کمتر از 500 میلی‌ثانیه است.»
- «دقت رسمی تشخیص وقفه بیش از 80 درصد است.»
- «خروجی گفتاری برای انسان طبیعی و کاملاً قابل فهم است.»
- «سامانه برای استفاده سالمندان مناسب است.»
- «پنل نه‌ردیفی، تعمیم سامانه به گفتار فارسی را اثبات می‌کند.»
- «داده منبع مجوز بازنشر یا آموزش آزاد دارد.»
- «مجموعه داده توسط انسان برچسب‌گذاری و تأیید شده است.»

فصل ۷

نتیجه‌گیری و کارهای آینده

۷-۱ جمع‌بندی

هدف این پروژه، طراحی، پیاده‌سازی و ارزیابی یک نمونه اولیه گفتاربه‌گفتار تمام‌دوطرفه برای زبان فارسی بود. دو مسیر به‌طور موازی پیش برده شد: تطبیق یک مدل سرتاسری گفتاربه‌گفتار، و یک سامانه آبشاری ماژولار با کنترل تمام‌دوطرفه. نتیجه نامتقارن بود.

سامانه آبشاری جریانی به نمونه‌ای کارکردی رسید که با میکروفون باز کار می‌کند: پایان گفتار را خودکار و پیش‌دستانه تشخیص می‌دهد، پاسخ را جریانی و بندبه‌بند تولید و پخش می‌کند، و در هنگام پخش به وقفه کاربر واکنش نشان می‌دهد. در آزمون حلقه‌ای با مرورگر واقعی، میانگین تأخیر پایان گفتار تا نخستین صدای دستیار 372 و صدک نود آن 431 میلی‌ثانیه بود و هیچ‌یک از 201 نوبت بی‌پاسخ نماند یا از 500 میلی‌ثانیه نگذشت؛ بخش گرافیکی کل سامانه GiB 11.1 حافظه گرفت. آزمون معنایی نهایی 40 ردیفی پاسخ‌گوی Qwen3-4B از هر هفت شرط خودکار گذشت (مرتبط‌بودن 3.150 در برابر 1.425 خط پایه).

تشخیص وقفه با یک کنترل‌گر دومرحله‌ای به هدف دقت رسید: یک قاب گفتار بلندتر از پژواک مورد انتظار صدای دستیار را کم می‌کند و سپس بازشناس گفتار، پس از کنارگذاشتن واژه‌های شنونده، واژه‌های دستوری و پژواک خود دستیار، تصمیم توقف یا ادامه را می‌گیرد. در شبیه‌سازی موقعیت استقرار از ضبط‌های واقعی، دقت 0.933 و F1 0.880 با میانه 120 میلی‌ثانیه تا کم‌کردن صدا، و در مرورگر واقعی دقت 0.825 و F1 0.817 به دست آمد. طبقه‌بند صوتی انرژی/زیروبمی/MFCC به‌تنهایی روی رخدادهای واقعی پادکست به 0.574 محدود ماند؛ این نتیجه منفی دلیل طراحی واژگانی است.

اجزا روی پنل‌های تازه و با پروتکل پیش‌ثبت‌شده دوباره برگزیده شدند: بازشناس NeMo دقیق‌ترین نامزد درون بودجه تأخیر روی رونوشت انسانی بود، صدای Mana فهم‌پذیرترین صدا نزد دو شنونده خودکار (در برابر دیگر صداهای Piper، ParsVoice-XTTS و مدل VITS آزمایشگاه، حتی پس از بهینه‌سازی استنتاج آن)، و هیچ پاسخ‌گوی جایگزینی به آستانه جایگزینی نرسید.

مسیر مستقیم به مدل قابل استقرار نرسید، اما علت اصلی آن یافته شد: توکن‌ساز انگلیسی Moshi برای هر واژه فارسی 6.6 نشانه می‌خواهد و 98.5 درصد نوبت‌ها از بودجه یک نشانه در قاب فراتر می‌روند. برداشتن این گلوگاه با لاتین‌نویسی واجی بهترین نتیجه تولید را دو برابر کرد (6/9 در برابر 3/9) و خروجی ساکت را به گفتار شنیدنی تبدیل کرد، اما گفتار هنوز فهم‌پذیر نبود. مدل ورودی گفتاری Gemma 4، حتی با آداپتر خودتقطیری، از سامانه آبشاری ضعیف‌تر بود.

مجموعه داده 6,754 جفت «گفتار کاربر و پاسخ» با 108.584 ساعت صوت ممیزی‌شده و نشت گروهی صفر است. برچسب‌های آن خودکارند و برچسب انسانی ندارند.

۷-۲ پاسخ به پرسش پژوهش

پرسش عملی این پروژه دو بخش داشت. بخش نخست: با بودجه یک پروژه کارشناسی، تا چه اندازه می‌توان یک سامانه گفتاربه‌گفتار فارسی تمام‌دوطرفه ساخت؟ پاسخ این است که یک سامانه آبشاری جریانی با کنترل وقفه، معیارهای عددی پیشنهاده برای تأخیر (میانگین و صدک نود زیر 500 میلی‌ثانیه) و تشخیص وقفه (بالای 80 درصد) را در آزمون‌های خودکار برآورده می‌کند و در حافظه یک کارت 12 گیگابایتی جا می‌شود؛ اما یک مدل سرتاسری فارسی، با معماری‌ها و توکن‌سازهای موجود و در این بودجه، قابل دستیابی نبود.

بخش دوم: چه چیزی را می‌توان با شواهد قابل ممیزی اثبات کرد؟ پاسخ در جدول ۵-۲۳ آمده است. ن۱ و ن۴ برآورده‌اند؛ ن۲، ن۳ و ن۵ با شواهد خودکار (آزمون حلقه‌ای مرورگر و شبیه‌سازی) برآورده‌اند، ن۳ با معیار پیشنهاده و برای پنل اصلی حتی با خوانش هرنوبت، و ن۵ با روشی غیر از ویژگی‌های صوتی تعیین‌شده؛ ن۶ یک انحراف اعلام‌شده است (حافظه سنجیده شد، سرعت روی سخت‌افزار هدف نه)؛ و ن۷ به پاسخ شرکت‌کنندگان مطالعه شنیداری وابسته است. سهم روشمند نوشتار در همین تفکیک است: برای هر سنجه، مرز ادعای مجاز مشخص شده و نتایج منفی همان‌قدر گزارش شده‌اند که نتایج مثبت.

۳-۷ پاسخ به پرسش‌های پژوهش پیشنهاده

پرسش ۱: تطبیق کم‌هزینه یک مدل گفتاربه‌گفتار موجود. تطبیق کم‌پارامتر Moshika با آداپتر LoRA روی یک H100 هدف آموزشی را بهبود داد: روی آزمون کنارگذاشته، سرگشتگی نشانه‌های متنی از 2.53 به 1.19 و نشانه‌های صوتی از 13.98 به 4.71 رسید. اما در هیچ‌یک از هفت نسل، گفتار فارسی فهم‌پذیر تولید نشد. علت اصلی در توکن‌ساز است: توکن‌ساز انگلیسی برای هر واژه فارسی 6.6 نشانه می‌خواهد، در حالی که مدل در هر قاب 12.5 هرتزی حداکثر یک نشانه متنی می‌سازد. لاتین‌نویسی واجی این بار را به 0.67 نشانه در قاب رساند و بهترین اجرا را دو برابر کرد (6/9)، اما کافی نبود. پاسخ: با «کمترین هزینه آموزش مجدد» نه؛ تطبیق این معماری به فارسی دست‌کم یک نمایش متنی سازگار با فارسی و آموزشی فراتر از یک آداپتر کوچک می‌خواهد.

پرسش ۲: تغییرات معماری لازم برای تمام‌دوطرفه زیر 500 میلی‌ثانیه. در مسیر آبشاری این تغییرات لازم و کافی بودند: (۱) تشخیص پیش‌دستانه پایان گفتار که کار را پیش از قطعی‌شدن پایان آغاز می‌کند و صوت را تا تأیید نگه می‌دارد؛ (۲) تولید جریانی توکن با قید «فقط خط فارسی» در زمان رمزگشایی؛ (۳) بندبندی که نخستین تکه را با دو تا چهار واژه می‌سازد و هر بند را بی‌درنگ به گفتار برمی‌گرداند؛ (۴) یک صف پخش در کارخواه و یک دروازه نگه‌داشت صوت در کارساز که با هم نقش «بافر دوگانه» را دارند؛ و (۵) کنترل وقفه دومرحله‌ای: کم‌کردن صدا در یک قاب و تأیید واژگانی با کنارگذاشتن واژه‌های شنونده و پژواک، به‌همراه نگه‌داشتن فقط بخش شنیده‌شده پاسخ قطع‌شده در تاریخچه. با این طراحی، میانگین تأخیر 372 و صدک نود 431 میلی‌ثانیه شد و پاسخ پس از وقفه به اندازه پاسخ نوبت عادی مرتبط ماند (بخش ۵-۱۱). در مسیر مستقیم، تغییر لازم پیش از هر تغییر معماری، توکن‌ساز است.

پرسش ۳: بده‌بستان تأخیر، اندازه و کیفیت. در این پروژه اندازه، کیفیت نخرید (جدول ۵-۲۲): کوچک‌ترین بازشناس تنظیم‌شده روی فارسی (117 میلیون پارامتر) دقیق‌تر از همه مدل‌های یک تا نُه میلیارد پارامتری عمومی بود و تنها مدل دقیق‌تر از آن، که خود روی فارسی تنظیم شده بود، بیش از ده برابر کندتر بود؛ کوچک‌ترین گفتارساز (15.7 میلیون پارامتر) هم فهم‌پذیرترین و هم سریع‌ترین بود؛ و بزرگ‌ترین مدل، یعنی مدل سرتاسری 7.7 میلیارد پارامتری، به گفتار فهم‌پذیر نرسید. بهترین نقطه بده‌بستان برای فارسی بی‌درنگ، اجزای کوچک و تخصصی‌شده برای فارسی است.

پرسش ۴: درک سالمندان. ابزار و پروتکل مطالعه شنیداری آماده و ازپیش‌ثبت‌شده است، اما پاسخ شرکت‌کنندگان هنوز نرسیده است؛ تا آن زمان این نوشتار درباره درک سالمندان ادعایی ندارد.

۷-۴ کارهای آینده

۷-۴-۱ تکمیل شواهد

۱. **سخت‌افزار هدف و مسیر فیزیکی.** اجرای همان پروتکل حلقه‌ای روی یک کارت 12 تا 24 گیگابایتی، و یک آزمون با میکروفون و بلندگوی فیزیکی که پژواک واقعی و حذف پژواک مرورگر را در بر بگیرد.

۲. **مطالعه انسانی.** گردآوری پاسخ 5 تا 10 شرکت‌کننده (دست‌کم دو نفر بالای 60 سال) با ابزار ثبت‌شده؛ و در گام بعد، یک جلسه کوتاه تعامل زنده با سالمندان.

۳. **برچسب انسانی.** بازبینی شنیداری نمونه‌ای از رخدادهای وقفه و جفت‌های مجموعه داده توسط دو بازبین مستقل، تا برچسب‌های خودکار Gemini و قواعد استخراج اعتبارسنجی شوند.

۴. **داوری انسانی پاسخ‌گو.** دو داور خودکار درباره پاسخ‌گوها اختلاف زیادی دارند (Gemini پاسخ‌گوهای با پرامپت سالمندان را حدود یک امتیاز بهتر می‌داند و داور Qwen نه)؛ یک داوری انسانی کوچک روی همین پنل می‌تواند تعیین کند که Qwen3.5-4B با پرامپت سالمندان، قوی‌ترین نامزد، جایگزین شود یا نه.

۷-۴-۲ بهبود سامانه

۱. **تأیید واژگانی دقیق‌تر.** واج نخست بازخوردهای کوتاه گاهی بریده می‌شود («آره» به «کار»). افزودن 200 میلی‌ثانیه صوت پیش از آغاز به ورودی بازشناس آزموده شد و رد شد: وقفه‌های بیشتری متوقف شدند (0.98 در برابر 0.95) اما بازخوردها و نویزهای بیشتری هم، و دقت کم شد (بخش ۵-۷-۳). جداکردن واژه شنونده از واژه محتوایی در آغاز بریده‌شده به داده برچسب‌دار و مدلی آموخته نیاز دارد.

۲. **تشخیص پایان گفتار برای سالمندان.** درنگ‌های بلند گفتار آهسته گاهی پیش از پایان جمله نوبت را می‌بندد (87 نوبت سرور برای 80 نوبت برنامه‌ریزی‌شده). سامانه این را با ادامه‌دادن کاربر و توقف پاسخ جبران می‌کند، اما یک مدل پایان‌نوبت معنایی یا درنگ تطبیقی می‌تواند بهتر باشد.

۳. **بازشناس دقیق‌تر در همان بودجه.** Seamless خطای نویسه کمتری داشت اما بیش از چهار برابر بودجه تأخیر؛ تقطیر آن در یک مدل CTC یا اجرای جریانی آن می‌تواند دقت را بدون هزینه تأخیر بالا ببرد.

۷-۴-۳ مسیر مستقیم

یافته توکن‌ساز مسیر روشنی پیش می‌گذارد: مدل مستقیم فارسی به توکن‌سازی نیاز دارد که در بودجه یک نشانه در قاب جا شود (واج‌محور یا با واژگان فارسی) و به راهکاری برای شکاف واداشت معلم و تولید آزاد، مانند حذف تصادفی زمان‌بندی‌شده ورودی در مقیاس بزرگ‌تر یا آموزش با خروجی خود مدل. رویکرد مدل منجمد Freeze-Omni [۲] و تثبیت تولید گفتار فارسی با داده تک‌گوینده فراوان مانند ManaTTS [۳] پیش از آموزش گفت‌وگو نیز مسیرهای امیدبخشی‌اند. برای مدل ورودی گفتاری، آموزش روی گفتار متنوع‌تر (و نه فقط پادکست) لازم است، چون خودتقطیری روی یک دامنه، بیرون از آن دامنه آسیب زد.

۷-۵ سخن آخر

این پروژه نشان داد که یک دستیار گفتاری فارسی تمام‌دوطرفه با میکروفون باز، تأخیر زیر نیم ثانیه و تشخیص وقفه قابل اتکا، در بودجه یک پروژه کارشناسی و با اجزای متن‌باز قابل ساخت است؛ و نشان داد که مدل سرتاسری گفتاربه‌گفتار فارسی به چیزی بیش از تطبیق کم‌پارامتر نیاز دارد، از جمله توکن‌سازی متناسب با زبان. نتیجه منفی مسیر مستقیم، همراه با علت سنجیده‌شده آن، ارزشی کمتر از نتیجه مثبت مسیر آبشاری ندارد: کاهش زیان آفلاین می‌تواند گمراه‌کننده باشد و آزمون تولید در زمان اجرا باید بخشی از معیار انتخاب باشد.

Bibliography

[1] A. Défossez, L. Mazaré, M. Orsini, A. Royer, P. Pérez, H. Jégou, E. Grave, and N. Zeghidour. Moshi: A speech-text foundation model for real-time dialogue. Technical report, Kyutai, 2024. arXiv:2410.00037.

[2] X. Wang, Y. Li, C. Fu, Y. Zhang, Y. Shen, L. Xie, K. Li, X. Sun, and L. Ma. Freeze-Omni: A smart and low latency speech-to-speech dialogue model with frozen LLM. In *Proceedings of the 42nd International Conference on Machine Learning*, volume 267 of *Proceedings of Machine Learning Research*, pages 63345–63354. PMLR, 2025.

[3] M. F. Qharabagh, Z. Dehghanian, and H. R. Rabiee. ManaTTS Persian: A recipe for creating TTS datasets for lower-resource languages. In *Proceedings of the 2025 Conference of the Nations of the Americas Chapter of the Association for Computational Linguistics: Human Language Technologies (Volume 1: Long Papers)*, pages 9177–9206, Albuquerque, New Mexico, 2025. Association for Computational Linguistics.

[4] J. Xu, Z. Guo, J. He, H. Hu, T. He, S. Bai, K. Chen, J. Wang, Y. Fan, K. Dang, B. Zhang, X. Wang, Y. Chu, and J. Lin. Qwen2.5-Omni technical report. *arXiv preprint arXiv:2503.20215*, 2025.

[5] Z. Xie and C. Wu. Mini-Omni2: Towards open-source GPT-4o with vision, speech and duplex capabilities. *arXiv preprint arXiv:2410.11190*, 2024.

[6] Q. Fang, Y. Zhou, S. Guo, S. Zhang, and Y. Feng. LLaMA-Omni 2: LLM-based real-time spoken chatbot with autoregressive streaming speech synthesis. In *Proceedings of the 63rd Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers)*, pages 18617–18629, Vienna, Austria, 2025. Association for Computational Linguistics.

[7] Kyutai Labs. Moshi-finetune: LoRA fine-tuning for Moshi. https://github.com/kyutai-labs/moshi-finetune, 2024.

[8] J. Sohn, N. S. Kim, and W. Sung. A statistical model-based voice activity detection. *IEEE Signal Processing Letters*, 6(1):1–3, 1999.

[9] A. de Cheveigné and H. Kawahara. YIN, a fundamental frequency estimator for speech and music. *The Journal of the Acoustical Society of America*, 111(4):1917–1930, 2002.

[10] S. B. Davis and P. Mermelstein. Comparison of parametric representations for monosyllabic word recognition in continuously spoken sentences. *IEEE Transactions on Acoustics, Speech, and Signal Processing*, 28(4):357–366, 1980.

[11] A. Graves, S. Fernández, F. Gomez, and J. Schmidhuber. Connectionist temporal classification: Labelling unsegmented sequence data with recurrent neural networks. In *Proceedings of the 23rd International Conference on Machine Learning*, pages 369–376, 2006.

[12] A. Graves. Sequence transduction with recurrent neural networks. In *ICML Workshop on Representation Learning*, 2012. arXiv:1211.3711.

[13] A. Gulati, J. Qin, C.-C. Chiu, N. Parmar, Y. Zhang, J. Yu, W. Han, S. Wang, Z. Zhang, Y. Wu, and R. Pang. Conformer: Convolution-augmented transformer for speech recognition. In *Proceedings of Interspeech*, pages 5036–5040, 2020.

[14] A. Vaswani, N. Shazeer, N. Parmar, J. Uszkoreit, L. Jones, A. N. Gomez, Ł. Kaiser, and I. Polosukhin. Attention is all you need. In *Advances in Neural Information Processing Systems*, volume 30, pages 5998–6008, 2017.

[15] O. Kuchaiev, J. Li, H. Nguyen, O. Hrinchuk, R. Leary, B. Ginsburg, S. Kriman, S. Beliaev, V. Lavrukhin, J. Cook, and Others. NeMo: A toolkit for building AI applications using neural modules, 2019. arXiv:1909.09577.

[16] A. Radford, J. W. Kim, T. Xu, G. Brockman, C. McLeavey, and I. Sutskever. Robust speech recognition via large-scale weak supervision. In *Proceedings of the 40th International Conference on Machine Learning*, pages 28492–28518, 2023.

[17] J. Kim, J. Kong, and J. Son. Conditional variational autoencoder with adversarial learning for end-to-end text-to-speech. In *Proceedings of the 38th International Conference on Machine Learning*, pages 5530–5540, 2021.

[18] Rhasspy Project. Piper: A fast, local neural text-to-speech system. https://github.com/rhasspy/piper, 2023.

[19] L. Ouyang, J. Wu, X. Jiang, D. Almeida, C. Wainwright, P. Mishkin, C. Zhang, S. Agarwal, K. Slama, A. Ray, and Others. Training language models to follow instructions with human feedback. In *Advances in Neural Information Processing Systems*, volume 35, pages 27730–27744, 2022.

[20] M. Ranzato, S. Chopra, M. Auli, and W. Zaremba. Sequence level training with recurrent neural networks. In *Proceedings of the 4th International Conference on Learning Representations*, 2016.

[21] S. Bengio, O. Vinyals, N. Jaitly, and N. Shazeer. Scheduled sampling for sequence prediction with recurrent neural networks. In *Advances in Neural Information Processing Systems*, volume 28, pages 1171–1179, 2015.

[22] N. Houlsby, A. Giurgiu, S. Jastrzebski, B. Morrone, Q. De Laroussilhe, A. Gesmundo, M. Attariyan, and S. Gelly. Parameter-efficient transfer learning for NLP. In *Proceedings of the 36th International Conference on Machine Learning*, pages 2790–2799, 2019.

[23] X. L. Li and P. Liang. Prefix-tuning: Optimizing continuous prompts for generation. In *Proceedings of the 59th Annual Meeting of the Association for Computational Linguistics*, pages 4582–4597, 2021.

[24] E. J. Hu, Y. Shen, P. Wallis, Z. Allen-Zhu, Y. Li, S. Wang, L. Wang, and W. Chen. LoRA: Low-rank adaptation of large language models. In *Proceedings of the 10th International Conference on Learning Representations*, 2022.

[25] N. Zeghidour, A. Luebs, A. Omran, J. Skoglund, and M. Tagliasacchi. SoundStream: An end-to-end neural audio codec. *IEEE/ACM Transactions on Audio, Speech, and Language Processing*, 30:495–507, 2021.

[26] A. Défossez, J. Copet, G. Synnaeve, and Y. Adi. High fidelity neural audio compression. *Transactions on Machine Learning Research*, 2023.

[27] Z. Borsos, R. Marinier, D. Vincent, E. Kharitonov, O. Pietquin, M. Sharifi, D. Roblek, O. Teboul, D. Grangier, M. Tagliasacchi, and N. Zeghidour. AudioLM: A language modeling approach to audio generation. *IEEE/ACM Transactions on Audio, Speech, and Language Processing*, 31:2523–2533, 2023.

[28] C. Wang, S. Chen, Y. Wu, Z. Zhang, L. Zhou, S. Liu, Z. Chen, Y. Liu, H. Wang, J. Li, L. He, S. Zhao, and F. Wei. Neural codec language models are zero-shot text to speech synthesizers. *arXiv preprint arXiv:2301.02111*, 2023.

[29] D. Lee, C. Kim, S. Kim, M. Cho, and W.-S. Han. Autoregressive image generation using residual quantization. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, pages 11523–11532, 2022.

[30] H. Sacks, E. A. Schegloff, and G. Jefferson. A simplest systematics for the organization of turn-taking for conversation. *Language*, 50(4):696–735, 1974.

[31] G. Skantze. Turn-taking in conversational systems and human-robot interaction: A review. *Computer Speech & Language*, 67:101178, 2021.

[32] J. H. Friedman. Greedy function approximation: A gradient boosting machine. *Annals of Statistics*, 29(5):1189–1232, 2001.

[33] F. Pedregosa, G. Varoquaux, A. Gramfort, V. Michel, B. Thirion, O. Grisel, M. Blondel, P. Prettenhofer, R. Weiss, V. Dubourg, J. Vanderplas, A. Passos, D. Cournapeau, M. Brucher, M. Perrot, and É. Duchesnay. Scikit-learn: Machine learning in Python. *Journal of Machine Learning Research*, 12:2825–2830, 2011.

[34] V. I. Levenshtein. Binary codes capable of correcting deletions, insertions, and reversals. *Soviet Physics Doklady*, 10(8):707–710, 1966.

[35] E. B. Wilson. Probable inference, the law of succession, and statistical inference. *Journal of the American Statistical Association*, 22(158):209–212, 1927.

[36] B. Efron and R. J. Tibshirani. *An Introduction to the Bootstrap*. Chapman & Hall/CRC, 1994.

[37] L. Zheng, W.-L. Chiang, Y. Sheng, S. Zhuang, Z. Wu, Y. Zhuang, Z. Lin, Z. Li, D. Li, E. P. Xing, H. Zhang, J. E. Gonzalez, and I. Stoica. Judging LLM-as-a-judge with MT-Bench and chatbot arena. In *Advances in Neural Information Processing Systems*, volume 36, pages 46595–46623, 2023.

[38] D. Zhang, S. Li, X. Zhang, J. Zhan, P. Wang, Y. Zhou, and X. Qiu. SpeechGPT: Empowering large language models with intrinsic cross-modal conversational abilities. In *Findings of the Association for Computational Linguistics: EMNLP 2023*, pages 15757–15773, 2023.

[39] Q. Fang, S. Guo, Y. Zhou, Z. Ma, S. Zhang, and Y. Feng. LLaMA-Omni: Seamless speech interaction with large language models. In *Proceedings of the 13th International Conference on Learning Representations*, 2025.

[40] Z. Du, Y. Wang, Q. Chen, X. Shi, X. Lv, T. Zhao, Z. Gao, Y. Yang, C. Gao, H. Wang, F. Yu, H. Liu, Z. Sheng, Y. Gu, C. Deng, W. Wang, S. Zhang, Z. Yan, and J. Zhou. CosyVoice 2: Scalable streaming speech synthesis with large language models. *arXiv preprint arXiv:2412.10117*, 2024.

[41] A. Zeng, Z. Du, M. Liu, K. Wang, S. Jiang, L. Zhao, Y. Dong, and J. Tang. GLM-4-Voice: Towards intelligent and human-like end-to-end spoken chatbot. *arXiv preprint arXiv:2412.02612*, 2024.

[42] T. A. Nguyen, E. Kharitonov, J. Copet, Y. Adi, W.-N. Hsu, A. Elkahky, P. Tomasello, R. Algayres, B. Sagot, A. Mohamed, and E. Dupoux. Generative spoken dialogue language modeling. *Transactions of the Association for Computational Linguistics*, 11:250–266, 2023.

[43] R. Roy, J. Raiman, S.-g. Lee, T.-D. Ene, R. Kirby, S. Kim, J. Kim, and B. Catanzaro. PersonaPlex: Voice and role control for full duplex conversational speech models, 2026. arXiv:2602.06053.

[44] R. Ardila, M. Branson, K. Davis, M. Kohler, J. Meyer, M. Henretty, R. Morais, L. Saunders, F. Tyers, and G. Weber. Common voice: A massively-multilingual speech corpus. In *Proceedings of the 12th Language Resources and Evaluation Conference*, pages 4218–4222, 2020.

[45] M. J. Ranjbar Kalahroodi, H. Faili, and A. Shakery. ParsVoice: A large-scale multi-speaker Persian speech corpus for text-to-speech synthesis, 2025. arXiv:2510.10774.

[46] A. N. Mohammadi. Corpus of conversational Persian transcripts. Linguistic Data Consortium, LDC2019T11, 2019.

[47] X. Chen, Y. Wu, Z. Wang, S. Liu, and J. Li. Developing real-time streaming transformer transducer for speech recognition on large-scale dataset. In *Proceedings of the IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP)*, 2021. arXiv:2010.11395.

[48] V. Noroozi, S. Majumdar, A. Kumar, J. Balam, and B. Ginsburg. Stateful conformer with cache-based inference for streaming automatic speech recognition, 2023. arXiv:2312.17279.

[49] G. Xiao, Y. Tian, B. Chen, S. Han, and M. Lewis. Efficient streaming language models with attention sinks. In *International Conference on Learning Representations (ICLR)*, 2024. arXiv:2309.17453.

[50] R. Vipperla, S. Renals, and J. Frankel. Ageing voices: The effect of changes in voice parameters on ASR performance. *EURASIP Journal on Audio, Speech, and Music Processing*, 2010:525783, 2010.

[51] A. Pradhan, A. Lazar, and L. Findlater. Use of intelligent voice assistants by older adults with low technology use. *ACM Transactions on Computer-Human Interaction*, 27(4):31:1–31:27, 2020.

[52] J. Kowalski, A. Jaskulska, K. Skorupska, K. Abramczuk, C. Biele, W. Kopeć, and K. Marasek. Older adults and voice interaction: A pilot study with Google Home. In *Extended Abstracts of the 2019 CHI Conference on Human Factors in Computing Systems*, pages LBW0187:1–LBW0187:6, 2019.

[53] H. Bredin, R. Yin, J. M. Coria, G. Gelly, P. Korshunov, M. Lavechin, D. Fustes, H. Titeux, W. Bouaziz, and M.-P. Gill. Pyannote.audio: Neural building blocks for speaker diarization. In

Proceedings of the IEEE International Conference on Acoustics, Speech and Signal Processing, pages 7124–7128, 2020.

[54] T. J. Park, N. R. Koluguri, J. Balam, and B. Ginsburg. Multi-scale speaker diarization with dynamic scale weighting. In *Proceedings of Interspeech*, pages 5080–5084, 2022.

[55] D. Snyder, G. Chen, and D. Povey. MUSAN: A music, speech, and noise corpus, 2015. arXiv:1510.08484.

[56] J. Thiemann, N. Ito, and E. Vincent. The diverse environments multi-channel acoustic noise database (DEMAND): A database of multichannel environmental noise recordings. *Proceedings of Meetings on Acoustics*, 19:035081, 2013.

[57] T. Ko, V. Peddinti, D. Povey, M. L. Seltzer, and S. Khudanpur. A study on data augmentation of reverberant speech for robust speech recognition. In *Proceedings of the IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP)*, pages 5220–5224, 2017.

[58] International Telecommunication Union. Methods for subjective determination of transmission quality. *ITU-T Recommendation P.800*, 1996.

[59] A. Yang, B. Yang, B. Zhang, B. Hui, B. Zheng, B. Yu, C. Li, D. Liu, F. Huang, H. Wei, H. Lin, J. Yang, J. Tu, J. Zhang, J. Yang, J. Zhou, J. Lin, K. Dang, and Others. Qwen2.5 technical report. *arXiv preprint arXiv:2412.15115*, 2025.

[60] M. McAuliffe, M. Socolof, S. Mihuc, M. Wagner, and M. Sonderegger. Montreal forced aligner: Trainable text-speech alignment using Kaldi. In *Proceedings of Interspeech 2017*, pages 498–502, 2017.

[61] A. Yang, A. Li, B. Yang, B. Zhang, B. Hui, B. Zheng, B. Yu, C. Gao, C. Huang, C. Lv, and Others. Qwen3 technical report. *arXiv preprint arXiv:2505.09388*, 2025.

[62] A. Paszke, S. Gross, F. Massa, A. Lerer, J. Bradbury, G. Chanan, T. Killeen, Z. Lin, N. Gimelshein, L. Antiga, and Others. PyTorch: An imperative style, high-performance deep learning library. In *Advances in Neural Information Processing Systems*, volume 32, pages 8024–8035, 2019.

[63] T. Wolf, L. Debut, V. Sanh, J. Chaumond, C. Delangue, A. Moi, P. Cistac, T. Rault, R. Louf, M. Funtowicz, and Others. Transformers: State-of-the-art natural language processing. In *Proceedings of the 2020 Conference on Empirical Methods in Natural Language Processing: System Demonstrations*, pages 38–45, 2020.

واژه‌نامه

الف

آبشاری ... cascade
آزمون بازگشتی ... regression test
آستانه ... threshold
آشکارساز ... detector
آغاز آوایی ... acoustic onset
اپیزود ... episode
ارتباط ... relevance
اریبی مواجهه ... exposure bias
اعتبارسنجی ... validation
افق تصمیم ... decision horizon
انتهای گفتار ... end of speech
انرژی ... energy
انسجام ... coherence
انصراف مستند ... waiver
آداپتر ... adapter
ایمنی ... safety

ب

بازبینی حقوق ... rights review
بازتولیدپذیری ... reproducibility
بازخورد کلامی ... backchannel
بازشناسی گفتار ... speech recognition
بذر تصادفی ... seed
بسامد پایه ... fundamental frequency
بسامد نمونه‌برداری ... sample rate

پ

پخش ... playback
پرامپت ... prompt
پروتکل ... protocol
پنجره متن ... context window
پنل ... panel
پیش‌بافر ... pre-roll
پیکره ... corpus

ت

تأخیر ... latency
تبدیل متن به گفتار ... text-to-speech
تجزیه‌گر نشانه ... tokenizer
تحمیل معلم ... teacher forcing
ترانسفورمر ... transformer
تشخیص فعالیت گفتاری ... voice activity detection
تطبیق ... adaptation
تفکیک گوینده ... diarization
تقریب جانشین ... proxy
تقویت گرادیانی ... gradient boosting
تمام‌دوطرفه ... full-duplex

نوبت‌گیری ..... turn-taking

تنظیم دقیق ..... fine-tuning

ج

جفت پاسخ ..... response pair

جویباری ..... streaming

چ

چک‌پوینت ..... checkpoint

چندکاناله ..... multi-channel

چندگویندگی ..... multi-speaker

ح

حذف تصادفی ..... dropout

حریم خصوصی ..... privacy

حقیقت مبنا ..... ground truth

خ

خاستگاه ..... provenance

خط پایه ..... baseline

خودراه‌انداز ..... bootstrap

خودرگرسیو ..... autoregressive

خودکار ..... automatic

د

درون‌نمونه ..... in-sample

دقت ..... accuracy

دوسویه ..... bidirectional

دوسوکور ..... double-blind

ر

رمزینه صوتی ..... audio codec

ز

زیان ..... loss

زیرنویس ..... caption

زیروبمی ..... pitch

س

سرگشتگی ..... perplexity

سرور ..... server

ش

شرط پذیرش ..... gate

شکست‌بسته ..... fail-closed

شواهد ..... evidence

ض

ضرایب کپستروم بسامد مل ... mel-frequency cepstral coefficients

ضریب زیان ..... loss weight

ط

طبقه‌بند ..... classifier

طبیعی‌بودن ..... naturalness

ع

عامل ..... agent

ف

فراپارامتر ..... hyperparameter
فریم ..... frame
فهرست‌نامه ..... manifest
فهم‌پذیری ..... intelligibility

ق

قطعی ..... deterministic
قفل‌شده ..... locked
منجمد ..... frozen

ک

کتاب رمز ..... codebook
کدگشایی ..... decoding
کم‌پارامتر ..... parameter-efficient
کم‌رتبه ..... low-rank
کنارگذاشته ..... held-out
کوانتیزه‌سازی ..... quantization

گ

گروه‌ناهم‌پوشان ..... group-disjoint
گفتاربه‌گفتار ..... speech-to-speech
گوینده ..... speaker

م

مجموعه داده ..... dataset
مدل ..... model
میکروفون ..... microphone

ن

نتیجه منفی ..... negative result
نرخ ..... rate
نشت گروهی ..... group leakage
نشست ..... session
نمونه اولیه ..... prototype
نویز ..... noise
نیم‌دوطرفه ..... half-duplex

و

واک‌دار ..... voiced
وزن‌ها ..... weights
وقفه ..... interruption
وقفه ..... barge-in
ویژگی ..... feature

هـ

هم‌آمایش ..... synthesis
هم‌پوشانی ..... overlap
هم‌ترازی ..... alignment
هنجارسازی ..... normalization

ی

یادگیری ..... learning

پیوست آ

جزئیات پیاده‌سازی و بازتولید

این پیوست جزئیاتی را گرد آورده است که برای بازتولید نتایج لازم‌اند اما در متن اصلی جای نمی‌گرفتند: ساختار مخزن، فراپارامترهای دقیق آزمایش‌ها، فرمان‌های بازتولید و نقشه مصنوعات شواهد.

آ‌ـ۱ ساختار مخزن

جدول آ‌ـ۱ ساختار سطح نخست مخزن کد را نشان می‌دهد.

آ‌ـ۲ فراپارامترهای آزمایش‌های مسیر مستقیم

جدول آ‌ـ۲ فراپارامترهای دقیق هفت نسل آزمایشی را نشان می‌دهد. همه اجراها از بهینه‌ساز AdamW و نقطه‌گذاری گرادیان استفاده کردند.

نسخه‌های v4 و v5 تنها در ضریب زیان کتاب رمز نخست تفاوت دارند: 100 در برابر 10. نسخه v6.2 علاوه بر فراپارامترهای بالا، حذف تصادفی زمان‌بندی‌شده ورودی متنی از 0.25 به 0.75 و ضریب زیان صوتی 0.1 داشت و روی همان 32 نمونه آموزش و ارزیابی شد. نسخه v7a روی همان 32 نمونه، با متن تک‌گویی درونی به‌صورت لاتین‌نویسی واجی و زمان‌بندی واژه‌ای آموزش دید.

آ‌ـ۳ فراپارامترهای آشکارساز و پاسخ‌گو

جدول آ‌ـ۳ پیکربندی ماژول تشخیص وقفه و آداپتر پاسخ‌گوی متنی را گرد آورده است.

جدول آ‌ـ۱: ساختار سطح نخست مخزن کد پروژه

مسیر	محتوا
`src/thesis_s2s/runtime/`	زنجیره آبشاری، سرور تمام‌دوطرفه، تبدیل متن به گفتار، ثبت نشست
`src/thesis_s2s/bargein/`	استخراج ویژگی، آشکارساز، کنترل‌گر پخش، ارزیابی روی داده ضبط‌شده
`src/thesis_s2s/data/`	زنجیره ساخت مجموعه داده، تفکیک گوینده، استخراج جفت، خروجی و ممیزی
`src/thesis_s2s/eval/`	سنجه‌ها، آزمون‌های مقایسه‌ای و تجمیع‌کننده شکست‌بسته شواهد
`src/thesis_s2s/model/`	مصنوع آزمایشی اولیه، تنها برای مرجع تاریخی
`configs/`	پیکربندی داده، آشکارساز، سنجه‌ها و هفت نسل آزمایشی مسیر مستقیم
`scripts/`	پیش‌بررسی، آموزش، بازارزیابی، انتخاب چک‌پوینت و ارزیابی‌های قفل‌شده
`docs/`	پروتکل‌های ازپیش‌تعریف‌شده، سند انصراف بازبینی و تصمیم‌های ثبت‌شده
`results/`	مصنوعات نتیجه یک‌بارنوشت
`tests/`	مجموعه آزمون خودکار
`third_party/`	پرونده قفل مخازن و مدل‌های بالادستی

آ‌ـ۴ فرمان‌های بازتولید

فرمان‌های زیر مراحل اصلی را بازتولید می‌کنند. متغیر `PYTHONPATH` باید به شاخه `src` اشاره کند؛ زیرفرمان هر مرحله در جدول آ‌ـ۴ فهرست شده است.

ارزیابی‌های قفل‌شده به‌صورت اسکریپت مستقل در شاخه `scripts` اجرا می‌شوند؛ جدول آ‌ـ۵ آن‌ها را فهرست می‌کند.

این اسکریپت‌ها روی مصنوعات یک‌بارنوشت کار می‌کنند و نباید برای بازگشایی یک آزمون نهایی یا بازنگری یک انتخاب نهایی‌شده به کار روند. شکل‌های این نوشتار با `scripts/make_thesis_figures.py` از همین مصنوعات تولید شده‌اند.

جدول آ‌ـ۲: فراپارامترهای هفت نسل آزمایشی تطبیق کم‌پارامتر مسیر مستقیم

نسخه	گام بیشینه	پنجره (ثانیه)	رتبه	بذر	بیشینه حافظه (GB)	درج‌گرهای آموزش‌دیده
v1	8000	20	64	20260823	22.920	کلید بالادستی
v2	2000	100	64	20260827	–	کلید بالادستی
v3	500	100	128	20260827	26.504	هیچ
v4	500	100	128	20260827	28.640	دو درج‌گر متنی
v5	500	100	128	20260827	28.640	دو درج‌گر متنی
v6.2	200	12	64	20260901	16.577	سه تنسور متنی
v7a	200	12	64	20260901	22.660	سه تنسور متنی

آ‌ـ۵ نقشه مصنوعات شواهد

جدول آ‌ـ۶ برای هر ادعای این نوشتار، مصنوع مرجع آن را مشخص می‌کند.

آ‌ـ۶ محیط اجرا

جدول آ‌ـ۷ مؤلفه‌های اصلی محیط اجرا و شناسه مدل‌های به‌کاررفته را نشان می‌دهد.

بازنگری دقیق و درهم‌سازی وزن هر مدل در پرونده قفل مخازن بالادستی ثبت شده است و در مصنوع هر نتیجه نیز تکرار می‌شود، تا ادعای «مدل استفاده‌شده دقیقاً همین بود» قابل ممیزی باشد.

آ‌ـ۷ ساخت این نوشتار

این نوشتار با XeLaTeX و افزونه XePersian حروف‌چینی شده است. برای بازتولید آن، اجرای `./build.sh` در شاخه نوشتار کافی است؛ این اسکریپت زنجیره حروف‌چینی و کتاب‌نامه را در یک بستر جداشده اجرا می‌کند و بنابراین به نصب محلی TeX نیازی نیست.

دو نکته فنی که در جریان آماده‌سازی این نوشتار اصلاح شد و ممکن است برای کاربران بعدی همین قالب سودمند باشد: نخست، نام گزینه محلی‌سازی افزونه XePersian در نسخه‌های تازه تغییر کرده است

و گزینه پیشین دیگر پذیرفته نمی‌شود؛ دوم، وصله جدول‌های راست‌به‌چپ افزونه bidi با نسخه جاری بسته array سازگار نیست و باید نسخه تاریخ‌دار آن درخواست شود. هر دو اصلاح در `styles/common.tex` با توضیح ثبت شده‌اند.

نکته سوم به حروف‌چینی اعداد مربوط است. در متن راست‌به‌چپ، الگوریتم دوسویه یک عدد اعشاری را در محل جداکننده به دو بخش می‌شکند و ترتیب آن دو بخش را برعکس می‌کند؛ در نتیجه مقدار 3.150 به‌صورت «3/150» نمایش داده می‌شود. به همین دلیل، در این نوشتار همه کمیت‌های اندازه‌گیری‌شده در یک محیط چپ‌به‌راست صریح قرار گرفته‌اند، در حالی که شماره‌گذاری ساختاری، یعنی شماره فصل‌ها، بخش‌ها، صفحه‌ها، جدول‌ها و شکل‌ها، با ارقام فارسی خودکار باقی مانده است.

جدول آ‌ـ۳: پیکربندی ماژول تشخیص وقفه و آداپتر پاسخ‌گوی متنی

پارامتر	مقدار
ماژول تشخیص وقفه	
بسامد نمونه‌برداری	16000 هرتز
طول فریم	20 میلی‌ثانیه
طول پنجره متن	400 میلی‌ثانیه
شمار ضرایب MFCC	13 به همراه دلتا
بازه جست‌وجوی بسامد پایه	60 تا 400 هرتز
شمار درخت‌ها	200
عمق بیشینه درخت	4
نرخ یادگیری	0.08
کمینه نمونه در برگ	8
افق تصمیم پس از آغاز آوایی	120 میلی‌ثانیه
آستانه تصمیم انتخاب‌شده	0.70
زمان استنتاج هر گام روی پردازنده مرکزی	7.931 میلی‌ثانیه
آداپتر پاسخ‌گوی متنی	
رتبه و ضریب مقیاس	16 و 32
حذف تصادفی	0.05
دوره‌های آموزش	2
بذر تصادفی	20260906
ردیف‌های واجد شرایط آموزش	2576 از 6419
ردیف‌های واجد شرایط توسعه	12 از 131
زیان نشانه‌های پاسخ مدل پایه	3.723
زیان دوره نخست و دوم	2.643 و 2.562
کاهش نسبت به مدل پایه	31.18%

جدول آ‌ـ۴: فرمان‌های بازتولید مراحل اصلی پروژه

مرحله	زیرفرمان
طرح انتخاب پیکره	`plan-conversation-corpus`
بازسازی پنجره‌ها	`prepare-conversation-episodes`
ممیزی پنجره‌های آماده	`audit-prepared-episodes`
تفکیک گوینده	`diarize-conversation-episodes`
ممیزی تفکیک گوینده	`audit-diarized-episodes`
برچسب شرایط نویز	`annotate-conversation-noise`
برآورد بازده پیکره	`estimate-conversation-yield`
ساخت جفت‌های پاسخ	`build-conversations`
ممیزی جفت‌ها	`audit-conversations`
خروجی استریوی آموزش	`export-moshi-data`
ممیزی خروجی	`audit-moshi-data`
اجرای سامانه	`serve`
وضعیت تجمیعی شواهد	`evidence-status`
پیش‌بررسی سخت‌افزار	`gpu-preflight`

جدول آ‌ـ۵: اسکریپت‌های ارزیابی قفل‌شده

ارزیابی	اسکریپت
پنل مکانیکی سامانه آبشاری	`validation.py evaluate_cascade_`
سنجه بازبازشناسی	`evaluate_cascade_ intelligibility.py`
آزمون معنایی دومرحله‌ای	`evaluate_qwen4b_ responder_v2.py`
تقریب آشکارساز وقفه	`evaluate_recorded_ bargein_proxy.py`
تولید شکل‌های این نوشتار	`make_thesis_figures.py`

جدول آ‌ـ۶: نقشه ادعاها و مصنوعات مرجع. همه مسیرها نسبت به شاخه `results` هستند.

ادعا	مصنوع مرجع
وضعیت تجمیعی و شروط پذیرش	`eval/EVIDENCE_STATUS.json`
خلاصه قابل خواندن	`eval/SUMMARY.md`
پنل مکانیکی سامانه آبشاری	`eval/cascade_real_service_validation_panel.json`
تحلیل توصیفی پس‌نگر	`eval/cascade_validation_descriptive_analysis.json`
تقریب فهم‌پذیری	`eval/cascade_intelligibility_proxy.json`
مرحله صلاحیت معنایی	`eval/qwen4b_responder_v2_development_proxy.json`
آزمون نهایی معنایی	`eval/qwen4b_responder_v2_final_test_proxy.json`
تطبیق پاسخ‌گو	`responder_lora_v1.json training/`
تقریب آشکارساز وقفه	`eval/interrupt_recorded_proxy.json`
آزمون مصنوعی آشکارساز	`eval/interrupt_bench.json`
ممیزی مجموعه داده	`conversation_audit.json`
گزارش خروجی آموزش	`moshi_export_report.json`
انتخاب چک‌پوینت نسخه نخست	`selection.json moshi_checkpoint_`
زیان کنارگذاشته نسخه نخست	`model_eval.json moshi_heldout_`
انتخاب و اجرای نسخه دوم	`moshi_v2_checkpoint_selection.json`
نتیجه نسخه v6.2	`moshi_v6_text_dropout_reevaluation.json`
اجرای نسخه v6.2	`moshi_v6_text_dropout_runtime.json`
تأخیر سمت سرور	`eval/latency_bench.json`
مطالعه انسانی	`eval/human_study.json`
ممیزی نهایی مخزن	`release/final_audit.json`

جدول آ‌ـ۷: مؤلفه‌های اصلی محیط اجرا و مدل‌های به‌کاررفته

مؤلفه	شناسه
پاسخ‌گوی متنی سامانه نهایی	Qwen3-4B-Instruct-2507 cdbee75f17c01a7cc42f958dc650907174af0554
پاسخ‌گوی پنل مکانیکی 9/9 و بازبازشناسی	Qwen2.5-0.5B-Instruct 7ae557604adf67be50417f59c2c2f167def9a775
خط پایه پاسخ‌گو در آزمون معنایی	Qwen2.5-0.5B-Instruct
مدل پایه مسیر مستقیم	Moshika، هفت میلیارد پارامتر
رمزینه صوتی مسیر مستقیم	Mimi
بازشناسی گفتار	مدل ترکیبی RNNT-CTC خانواده Conformer
تبدیل متن به گفتار	Piper با مدل صوتی فارسی
داور آزمون معنایی	Qwen3.8-27B-FP8 017b9c7af6b5689d5dd426a76e0bc077eb5ca20a
سخت‌افزار آموزش و ارزیابی	NVIDIA H100 NVL، 93.09 گیگابایت

Abstract

This project designs, implements and evaluates a prototype Persian speech-to-speech system that operates in full-duplex mode: the user microphone stays open while the assistant speaks, and the system reacts to interruptions. Two tracks were pursued: low-rank adaptation of the end-to-end Moshika model to Persian, and a streaming cascade of NeMo speech recognition, the Qwen3-4B-Instruct-2507 responder and Piper speech synthesis. A conversational corpus of 6,754 user/response pairs (108.584 hours, session-disjoint splits) was derived from an archive of Persian spoken content.

The final cascade detects the end of speech automatically and speculatively, streams the reply clause by clause, and handles interruptions in two stages: it ducks the assistant after one frame of speech louder than the expected residual echo, then confirms lexically with the speech recognizer after discarding listener tokens and the assistant's own echoed words. In automated real-browser loopback, end-of-speech to first assistant audio had a mean of 372 ms and a 90th percentile of 431 ms, with every turn under 500 ms and the GPU side of the stack using 11.1 GiB. Interruption handling reached accuracy 0.933 and F1 0.880, with a median of 120 ms to the duck, in a deployment simulation built from real recordings, and accuracy 0.825 (F1 0.817) in the browser; an energy/F0/MFCC classifier alone reached only 0.574 on real podcast events. The responder passed all seven predeclared automatic gates of a 40-row final test (relevance 3.150 versus 1.425). All components were re-selected on fresh panels, including speech recognition on human transcripts and synthesis with two automatic listeners.

The direct track produced no deployable model. Moshi's English tokenizer needs 6.6 tokens per Persian word and exceeds its one-token-per-frame budget; phoneme romanization doubled the best runtime result but the speech was still not intelligible, and a speech-input Gemma 4 model also underperformed the cascade. Latency and interruption evidence is automated and on an H100 (the memory of a 12 GB card was respected, its compute speed was not), labels are automatic, and the human listening study is awaiting participants' responses.

Keywords: Speech-to-speech, full-duplex dialogue, barge-in detection, Persian language, large language models, streaming cascade, tokenization, parameter-efficient adaptation



Sharif University of Technology

Department of Computer Engineering

B.Sc. Thesis

A Speech-to-Speech Large Language Model for Persian

By:

Mehran Bakhtiari

Supervisor:

Dr. Hossein Sameti

October 2026